

UNIVERSITÀ DEGLI STUDI DI MILANO–BICOCCA
SCUOLA DI ECONOMIA E STATISTICA

CORSO DI LAUREA IN
SCIENZE STATISTICHE ED ECONOMICHE



ALGORITMI MM PER MODELLI
BRADLEY–TERRY GENERALIZZATI

RELATORE: Prof. Tommaso Rigon

TESI DI LAUREA DI:
Badolato Francesco
MATRICOLA N. 909302

ANNO ACCADEMICO 2025/2026

Indice

1	Fondamenti Statistici	1
1.1	Richiami di Probabilità e Inferenza Statistica	1
1.1.1	Distribuzione Binomiale	1
1.1.2	Stimatori	2
1.1.3	Verosimiglianza, Stima di Massima Verosimiglianza e Proprietà . . .	4
1.1.4	Funzione di Score e Informazione di Fisher	6
1.1.5	Test di Ipotesi	8
1.2	Modelli Lineari Generalizzati	11
1.2.1	Introduzione ai Modelli Lineari	11
1.2.2	Famiglia di Distribuzioni a Dispersione Esponenziale	12
1.2.3	Verosimiglianza e Proprietà delle Esponenziali	12
1.2.4	Struttura Generale dei GLM	14
1.3	Ottimizzazione dei GLM e l'Algoritmo IRLS	16
1.3.1	Il Problema di Ottimizzazione nei GLM	16
1.3.2	Informazione Osservata e Attesa di Fisher	18
1.3.3	Metodo di Newton-Raphson e Algoritmo IRLS	20
2	Modelli di Analisi dei Campioni a Coppie	25
2.1	Confronto di Proporzioni	25
2.1.1	Differenze e Intervalli di Confidenza	26
2.1.2	Test per l'Omogeneità Marginale	27
2.2	Modelli Logistici per Confronti	29
2.2.1	Modello Marginale e Stime di Massima Verosimiglianza	29
2.2.2	Modello Soggetto-Specifico e Stime di Massima Verosimiglianza . .	31
2.2.3	Casi Particolari di Modelli Multivariati	35
2.2.4	Modelli Marginali per Matrici di Contingenza Quadrate	36

2.2.5	Modelli Ordinali per Matrici di Contingenza	38
2.3	Simmetria, Quasi-Simmetria e Quasi-Indipendenza	39
2.3.1	Simmetria	39
2.3.2	Quasi-Simmetria	42
2.3.3	Quasi-Indipendenza	44
2.4	Misure di Concordanza	45
2.4.1	Concordanza	45
2.4.2	Kappa	46
2.5	Modelli Bradley-Terry	47
2.5.1	Specificazione del Modello	48
2.5.2	Modelli Bradley-Terry e Modelli Quasi-Simmetrici	49
2.5.3	Alcuni Esempi	50
3	Algoritmi MM per Generalizzazioni di Modelli Bradley-Terry	55
3.1	Generalizzazioni di Modelli Bradley-Terry	56
3.1.1	Modelli per Pareggi	56
3.1.2	Modelli per Vantaggio in Casa	57
3.1.3	Modelli per Confronti Multipli	58
3.1.4	Esistenza delle Stime	59
3.2	Algoritmi MM e Stime di Massima Verosimiglianza	61
3.2.1	Gli Algoritmi MM in Generale	61
3.2.2	Gli Algoritmi MM per Ottimizzare la Verosimiglianza	62
3.2.3	Vantaggi e Limiti degli Algoritmi MM	67
3.3	Convergenza al Massimo	68
3.3.1	Teorema di Lyapunov e Convergenza al Punto Stazionario	68
3.3.2	Compattezza Superiore	70
3.3.3	Concavit� della Log-Verosimiglianza	72
3.4	Esempi Applicativi	75
3.4.1	Esempio 1 - Classifica della Serie A	75
3.4.2	Esempio 2 - Classifica Storica della Premier League	81
3.4.3	Conclusioni	83
A	Appendice	85
A.1	Uguaglianza fra Varianza dello Score e Informazione di Fisher	85

A.2	Distorsione dei Parametri del Modello Logit	86
A.3	Approssimazione Numerica degli Errori Standard	88
Bibliografia		91

Ringraziamenti

Desidero innanzitutto ringraziare i miei genitori, mia sorella Fernanda e i miei fratelli Umberto e Giuseppe per il sostegno e la vicinanza in questi anni. Senza il loro supporto non avrei potuto raggiungere questo traguardo. Un pensiero speciale va ai miei nonni, ai quali sto ancora cercando di spiegare l'argomento di questa tesi.

Ringrazio il professor Rigon, di cui ho apprezzato la serietà, la disponibilità e la chiara passione, nonché lo statistico David Hunter, e tutti i ricercatori ed accademici che hanno contribuito al tema e che mi hanno permesso di approfondire e comprendere meglio un argomento così interessante.

Un sincero ringraziamento va inoltre ai miei amici e compagni di percorso, senza i quali non sarei ciò che sono. In particolare ringrazio Giacomo, per tutti noto come “Fortinati”, Andrea, Antonio, Alex e tutti coloro con i quali ho condiviso tanto i momenti più leggeri quanto quelli più duri. Se, come disse Darwin, “le amicizie di un uomo sono una delle migliori misure del suo valore”, sono la persona più fortunata e valorosa del mondo.

Dichiarazione sull'uso di strumenti di intelligenza artificiale

Il/La sottoscritto/a Badolato Francesco, matricola 909302, dichiara quanto segue in merito all'utilizzo di strumenti di intelligenza artificiale generativa (modelli linguistici di grandi dimensioni quali ChatGPT, Claude, Gemini, etc.) nella preparazione e nella stesura della presente tesi.

☐ Non ho fatto uso di alcuno strumento di intelligenza artificiale generativa.

■ Ho fatto uso di tali strumenti, nei termini specificati di seguito.

Strumenti utilizzati: *ChatGPT (GPT-5.5, GPT-5.6), Claude (Opus 4.8, Fable 5, Sonnet 5).*

Ambiti di utilizzo:

■ Revisione linguistica e correzione di errori ortografici o sintattici.

☐ Traduzione di testo da me redatto.

■ Chiarimenti su concetti teorici e supporto allo studio della letteratura.

■ Ricerca e reperimento di riferimenti bibliografici.

■ Scrittura, correzione o debugging di codice.

☐ Elaborazione o analisi dei dati.

☐ Altro: *specificare.*

Misura dell'utilizzo: *Misura dell'utilizzo: L'utilizzo dell'IA per chiarimenti teorici ha riguardato principalmente la verifica dell'interpretazione e della comprensione di determinati argomenti, nonché la creazione di esempi pratici volti a facilitare la comprensione. Detto ciò, lo strumento non è stato adoperato nello studio della letteratura. Ritengo infatti che, per quanto talvolta possa risultare frustrante, sia necessario comprenderla individualmente e in profondità, perché altrimenti non vi sarebbe, a mio avviso, alcun reale apprendimento o contributo personale al tema. Per quanto riguarda l'ambito informatico e la programmazione, l'IA non è stata in alcun modo utilizzata per la scrittura dell'implementazione del modello in R, se non per una correzione finale a postumi della convergenza corretta del modello, legata all'efficienza del modello. È stata invece impiegata nella creazione di alcuni oggetti matematici e grafici presenti nell'elaborato, come matrici e rappresentazioni grafiche, e per un generico supporto nel conoscere meglio la struttura $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$. Concludo questa dichiarazione sottolineando che gli strumenti di IA sono stati utilizzati senza sostituire il pensiero critico umano e sempre sotto la mia supervisione. Il*

loro impiego ha avuto esclusivamente lo scopo di migliorare la fruibilità e la solidità dell'elaborato, senza in alcun modo sostituire le mie personali riflessioni, i miei ragionamenti, le mie interpretazioni e le mie conclusioni legate al tema. Infatti mi ritengo orgoglioso del risultato finale e fiero che sia frutto del mio lavoro, sia negli aspetti migliori sia nelle sue criticità.

Dichiaro che la struttura del lavoro, le scelte metodologiche, le analisi e l'interpretazione dei risultati sono opera personale, e sono consapevole di essere l'unico/a responsabile di ogni contenuto della presente tesi, comprese eventuali imprecisioni, dimostrazioni errate o riferimenti bibliografici inesistenti prodotti da tali strumenti.

Introduzione

“The only thing to which two players could agree is that a third one is over-rated.”

Arpad Elo

Il problema del ranking di un insieme di “player”, siano essi individui, algoritmi o metodologie, emerge in numerosi contesti applicativi, in cui l’obiettivo è ordinare gli elementi in base ad abilità latenti, ed è un problema ampiamente studiato nella letteratura statistica. Stimare la probabilità di successo a partire da esiti binari o qualitativi, come vittoria o sconfitta, richiede strutture probabilistiche capaci di tradurre confronti diretti in misure di probabilità e graduatorie coerenti. Il modello di [Bradley & Terry \(1952a\)](#), proposto dai due matematici che gli danno il nome nel 1952, risolve proprio queste problematiche e trova applicazioni nel tennis, negli scacchi, nella classificazione di algoritmi, nei sistemi competitivi dei videogiochi, nella raccomandazione di prodotti su piattaforme di e-commerce, nel confronto dell’efficacia di trattamenti medici su pazienti ed innumerevoli altri ambiti.

Nel presente elaborato si analizza la struttura del modello e si propone una applicazione di una sua generalizzazione che include i pareggi, nota come modello di [Davidson \(1970\)](#). Successivamente si propone una classe di metodi per l’ottimizzazione numerica, chiamata Algoritmi MM, che verrà adoperata nell’ottimizzazione dei modelli menzionati. L’elaborato è organizzato come segue. Il Capitolo 1 richiama fondamenti di inferenza statistica necessari per il contesto analizzato. Il Capitolo 2 introduce i metodi per l’analisi di dati appaiati e matrici di contingenza e la specificazione del modello Bradley-Terry. Nel Capitolo 3 vengono presentate le principali generalizzazioni del modello Bradley-Terry, fra le quali il modello per pareggi. Successivamente si introdurranno gli algoritmi MM, le loro caratteristiche principali e si proporrà una applicazione di essi nel contesto calcistico.

Capitolo 1

Fondamenti Statistici

1.1 Richiami di Probabilità e Inferenza Statistica

1.1.1 Distribuzione Binomiale

L'analisi di dati qualitativi, come risultati binari, richiede l'uso di distribuzioni probabilistiche costruite con lo scopo di studiare proprio questi casi. In particolare, si presenta la distribuzione binomiale, che siede alla base di tutti i modelli successivamente affrontati. La binomiale fu introdotta per la prima volta dal matematico elvetico Jacob Bernoulli nella sua opera *Ars Conjectandi* (pubblicata post mortem dal nipote). Essa, come praticamente tutti i primi casi di analisi probabilistica, viene inizialmente sviluppata per avere un vantaggio nel gioco d'azzardo, ed in particolare cerca di individuare la probabilità che un numero di eventi restituisca una certa quantità di risultati favorevoli. L'opera stessa di Bernoulli contiene numerosi esempi riguardanti carte da gioco, possibilità di vittoria contro il banco e metodi su come pesare posta in gioco e rischio, ed ha portato alla scoperta di numerosissimi fenomeni matematici tra i quali i numeri di Bernoulli, alcuni risultati di serie infinite e una prima formulazione della Legge dei Grandi Numeri.

Si formalizza ora la distribuzione binomiale. Siano $y_1, y_2, \dots, y_n$ osservazioni per n estrazioni identiche e indipendenti tali per cui la probabilità di successo e fallimento siano rispettivamente $P(Y_i = 1) = \pi$, $P(Y_i = 0) = 1 - \pi$, costanti $\forall i = 1, \dots, n$. Chiamando Y la variabile aleatoria che denota il numero di successi, dunque $Y = \sum_{i=1}^n Y_i$, si definisce la funzione di probabilità dei possibili risultati di Y come

$$P(Y = k) = \binom{n}{k} \pi^k (1 - \pi)^{n-k}, \quad k = 0, 1, 2, \dots, n, \quad (1.1)$$

dove $\binom{n}{k}$ è il coefficiente binomiale. Alcuni risultati notevoli della distribuzione sono il valore atteso, $\mu = \mathbb{E}(Y) = n\pi$ e la varianza $\sigma^2 = \text{Var}(Y) = n\pi(1 - \pi)$ (Agresti, 2013, p. 5).

1.1.2 Stimatori

Normalmente, nei casi reali, non si conoscono a priori i parametri (che da ora si definiranno con θ) della generica distribuzione del campione che si sta analizzando. È quindi naturale che si adoperi la statistica inferenziale, quel ramo che studia caratteristiche e metodologie della stima dei parametri partendo da rilevazioni campionarie. A tale scopo, si introdurranno il concetto di stimatore, alcune sue proprietà ed il principale metodo per ottenerli, la massima verosimiglianza. Per una trattazione più estensiva degli argomenti affrontati si rimanda a Pace & Salvan (2001).

Uno stimatore è una legge applicata ad un campione ed usata per ottenere una stima di un parametro θ caratterizzante la distribuzione originale dei dati. L'insieme contenente i valori assumibili da θ viene indicato col nome di spazio parametrico (indicato con Θ). Un primo esempio di stimatori sono gli stimatori naturali, ovvero applicare la stessa legge adoperata per ottenere il parametro della popolazione intera sul campione ottenuto. Ecco per esempio gli stimatori naturali della media e della varianza su un campione casuale osservato $x_1 \dots x_n$ estratti da una legge con funzione di densità f , $X \sim f(x; \theta)$, e con $x \in I$, $I \subseteq \mathbb{R}$:

$$\begin{aligned}\mu &= \mathbb{E}(X), & \hat{\mu} = \bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i, \\ \sigma^2 &= \text{Var}(X), & \hat{\sigma}^2 = \bar{S}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.\end{aligned}$$

Questi stimatori, malgrado siano i più intuibili, non sono per forza i migliori. Per esempio, si dimostrerà che lo stimatore naturale della varianza è distorto, cioè che restituisce un risultato errato in media, correggibile qualora dividiamo per $n - 1$ anziché n . Si introducono dunque due proprietà fondamentali per studiare gli stimatori, ovvero la non distorsione (o correttezza) e l'efficienza di uno stimatore.

La correttezza richiede che lo stimatore sia in media uguale al vero parametro stimato. Ciò quindi richiede che, dato un determinato stimatore t_n di θ ed un campione di grandezza n :

$$\mathbb{E}(t_n - \theta) = 0 \quad \text{o alternativamente} \quad \mathbb{E}(t_n) = \theta.$$

Più in generale si definisce la quantità $\mathbb{E}(t_n - \theta)$ il “BIAS”. Nell’esempio sopra fornito, si richiede che $\mathbb{E}(\bar{X}) = \mu$ e che $\mathbb{E}(\bar{S}^2) = \sigma^2$. Malgrado questa proprietà sembri semplice da verificare, come menzionato prima si può dimostrare che la stima $\bar{S}^2$ della varianza campionaria non è in media uguale alla varianza della distribuzione originale. Esiste una condizione più semplice da verificare per gli stimatori, ovvero la non distorsione asintotica. Lo stimatore t_n si definirà non distorto asintoticamente quando:

$$\lim_{n \rightarrow +\infty} \text{Bias}(t_n) = 0.$$

Si può notare che lo stimatore $\bar{S}^2$ è asintoticamente non distorto, infatti la correzione del BIAS tende ad annullarsi per $n \rightarrow +\infty$. L’efficienza riguarda invece la varianza dello stimatore, e ne misura la stabilità della stima. Se si ricorre alla classica analogia del tiro al bersaglio, la correttezza corrisponde all’accuratezza (quanto i colpi sono centrati sul bersaglio) mentre l’efficienza corrisponde alla precisione (quanto i colpi risultano raggruppati tra loro). Uno stimatore corretto ma poco efficiente colpisce il bersaglio in media, ma le singole stime possono cadere molto lontane dal valore vero del parametro. Più precisamente, dati due stimatori non distorti t_1 e t_2 del parametro θ , si dice che t_1 è più efficiente di t_2 se, dato un valore fissato di θ , si ha:

$$\text{Var}(t_1) < \text{Var}(t_2) \quad \Longleftrightarrow \quad e(t_1, t_2) = \frac{\text{Var}(t_2)}{\text{Var}(t_1)} > 1.$$

Dunque tra due stimatori non distorti, è preferibile quello che presenta una minore dispersione attorno al valore atteso. Naturalmente si vorrà ottenere lo stimatore più efficiente per più del singolo valore di θ . L’efficienza di uno stimatore t_1 rispetto a tutto lo spazio parametrico viene infatti definita come:

$$\text{Var}(t_1) \leq \text{Var}(t_2), \quad \forall \theta \in \Theta,$$

con la disuguaglianza che diventa stretta per almeno un valore appartenente a Θ . Unendo distorsione e varianza si ottiene il “MEAN SQUARED ERROR (MSE)”, errore quadratico medio, definito come:

$$\text{MSE}(t_n) = \mathbb{E}((t_n - \theta)^2),$$

che può essere decomposto in $\text{MSE}(t_n) = \text{Var}(t_n) + \text{Bias}(t_n)^2$. Il MSE fornisce quindi una misura complessiva della qualità di uno stimatore, combinando accuratezza e precisione. Detto ciò, uno stimatore costante potrebbe accidentalmente fornire una stima vicina al vero valore di un parametro, ottenendo una distorsione molto bassa e una varianza nulla, ma ottenendo una stima scorretta per qualsiasi altro valore di θ . Si definisce allora efficienza assoluta di uno stimatore $\tilde{t}_n$ non distorto se, dato un altro stimatore t_n non distorto, si ha che:

$$\text{Var}(\tilde{t}_n) \leq \text{Var}(t_n), \quad \forall \theta \in \Theta.$$

Questo stimatore non distorto, se minimizza la varianza tra tutti i possibili stimatori non distorti si definisce UMVUE (Uniformly Minimum Variance Unbiased Estimator), cioè stimatore non distorto a varianza uniformemente minima. Esso è lo stimatore che, tra tutti quelli non distorti, ha la minima varianza per ogni valore del parametro $\theta \in \Theta$. Un'ultima proprietà degli stimatori è la consistenza. Questa proprietà garantisce che per un campione abbastanza grande, la distribuzione dello stimatore si “concentra” sul vero valore di θ . Formalmente:

$$\lim_{n \rightarrow +\infty} \mathbb{P}(|t_n - \theta| < \epsilon) = 1, \quad \forall \epsilon > 0,$$

che equivale a dire che lo stimatore tende in probabilità al vero parametro (relazione denotata con $t_n \xrightarrow{p} \theta$). Ciò significa essenzialmente che, per un campione abbastanza grande, parametro e stimatore tendono ad avvicinarsi sempre di più, con una differenza fra le distribuzioni inferiore ad un qualsiasi valore positivo di ϵ scelto.

1.1.3 Verosimiglianza, Stima di Massima Verosimiglianza e Proprietà

Uno dei possibili metodi per ottenere uno stimatore di un parametro, e sicuramente quello con maggiori applicazioni nel campo statistico, è il metodo di massima verosimiglianza. L'idea di base consiste nell'osservare un campione di un qualsiasi fenomeno e calcolare quale valore del parametro renda tali dati più plausibili (verosimili).

Definizione 1.1. (Funzione di verosimiglianza) *Siano $X_1, \dots, X_n$ un campione di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.), con*

$$X_i \stackrel{i.i.d.}{\sim} f(x; \theta), \quad \theta \in \Theta, \quad x \in I \subseteq \mathbb{R},$$

dove $f(\cdot; \theta)$ è la funzione di densità (o di probabilità) e Θ lo spazio parametrico. Fissate le osservazioni $x_1, \dots, x_n$, si dice funzione di verosimiglianza la funzione del parametro θ

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

Il parametro θ potrà essere sia un valore singolo sia un vettore di parametri (che verrà indicato come $\boldsymbol{\theta}$). Al contrario delle funzioni di densità, che mostrano la probabilità di estrarre un risultato dalla distribuzione dato il valore di θ , la verosimiglianza considera le estrazioni come costanti e tratta il parametro come incognita. Grazie all'indipendenza del campione si può fattorizzare la verosimiglianza rispetto alle marginali. Siccome ottenendo il valore di θ con verosimiglianza maggiore dato il campione equivale a trovare la stima dei parametri che ha più probabilità di restituire il campione considerato, questo metodo di stima del parametro si chiama per l'appunto "Massima Verosimiglianza". Esso possiede proprietà desiderabili, fra le quali l'invarianza, ovvero il fatto che, applicando trasformazioni biunivoche τ della stima θ di massima verosimiglianza, il migliore stimatore della quantità trasformata sarà la trasformazione di $\hat{\theta}$. Formalmente:

$$\text{se } \hat{\theta} = \arg \max L(\theta), \text{ allora } \hat{\tau} = \arg \max L(\tau(\theta)) = \tau(\hat{\theta}).$$

Inoltre, sotto condizioni di regolarità, vale che la stima di massima verosimiglianza su un campione di grandezza n , definita $\hat{\theta}_n$, è consistente per il vero parametro θ e che la stima ha una distribuzione asintoticamente Normale (questo concetto verrà approfondito successivamente). Per queste ragioni, la ricerca del massimo della funzione di Verosimiglianza è una delle problematiche più importanti affrontate nella statistica inferenziale. Poiché applicando una funzione monotona crescente, l'argomento che restituisce il massimo resta invariato, si definisce la funzione di log-verosimiglianza:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Questa trasformazione aiuta nella semplificazione dei calcoli, soprattutto quando ci si riferisce a distribuzioni appartenenti alla famiglia esponenziale, che si vedranno successivamente nella sezione 1.2.2. Si ricorda che i valori x_i sono da considerare costanti, e non è necessario specificarli nella funzione.

1.1.4 Funzione di Score e Informazione di Fisher

Continuando con lo studio del massimo della funzione di verosimiglianza, si definisce la funzione di score come:

$$u(\theta) = \nabla \ell(\theta) = \frac{\partial \log L(\theta)}{\partial \theta} = \left(\frac{\partial \ell}{\partial \theta_1}, \frac{\partial \ell}{\partial \theta_2}, \dots, \frac{\partial \ell}{\partial \theta_p} \right)^T \in \mathbb{R}^{1 \times p}$$

che in condizioni regolari possiede valore atteso pari al vettore nullo. Le condizioni regolari di stima richiedono che lo spazio parametrico di $\theta = (\theta_1, \dots, \theta_p)^T$ sia un intervallo aperto in $\mathbb{R}^p$, che la funzione $f(x)$ sia almeno di classe C^1 e che il supporto, ovvero i valori che la variabile casuale X può assumere, sia indipendente dai parametri, il che ci garantisce alcune proprietà importanti come la scambiabilità fra integrazione rispetto alla variabile x e derivazione rispetto a θ della funzione. Il fatto che il valore atteso della funzione di score sia nullo, cioè che $\mathbb{E}(u(\theta)) = 0$, indica che, in media, la derivata della log-verosimiglianza non presenta una direzione preferenziale di crescita o decrescita nel vero parametro θ , cioè che reiterando molte volte il medesimo esperimento, la media degli score valutati nel vero valore del parametro tende a zero.

Per studiare le proprietà dello stimatore di massima verosimiglianza, però, non è sufficiente analizzare il punto di massimo della funzione, ma è necessario comprenderne anche la curvatura locale. Questo perché quanto più la funzione è curva intorno al massimo, tanto più è informativo uno spostamento del parametro. Se la curva fosse poco pendente, ciò implicherebbe che i valori "vicini" di θ hanno verosimiglianza quasi uguale a quella ottenuta del massimo. Al contrario, se percorrendo di poco la funzione il valore di verosimiglianza cresce relativamente tanto, allora stimare il parametro θ con un valore vicino porterebbe a grandi differenze in verosimiglianza. A tal fine si introduce la derivata seconda della log-verosimiglianza, $h(\theta) = \frac{d^2}{d\theta^2} \ell(\theta)$, che misura la concavità della funzione. In particolare, si definisce l'Informazione di Fisher come il valore atteso dell'opposto della derivata seconda:

$$I(\theta) = -\mathbb{E} \left(\frac{\partial^2 \ell}{\partial \theta \partial \theta^T} \right) = -\mathbb{E} \begin{pmatrix} \frac{\partial^2 \ell}{\partial \theta_1^2} & \cdots & \frac{\partial^2 \ell}{\partial \theta_1 \partial \theta_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 \ell}{\partial \theta_p \partial \theta_1} & \cdots & \frac{\partial^2 \ell}{\partial \theta_p^2} \end{pmatrix} \in \mathbb{R}^{p \times p},$$

dove $\boldsymbol{\theta}^T$ definisce il trasposto del vettore dei parametri, dove l'elemento $I_{i,j}$ sarà pari a $-\mathbb{E}\left(\frac{\partial^2 \ell}{\partial \theta_i \partial \theta_j}\right)$. Questa quantità permette di ottenere un "riassunto" della curvatura della funzione. Maggiore il valore dell'Informazione Attesa di Fisher, maggiore sarà l'informazione portata dal campione rispetto al valore di $\boldsymbol{\theta}$. Si può inoltre dimostrare (A.1), tramite passaggi algebrici che, in condizioni di regolarità, l'informazione attesa di Fisher è pari alla Varianza della funzione di Score.




Figura 1.1: Curvatura della log-verosimiglianza al variare dell'Informazione di Fisher: una curva più concava (Alta informazione) implica che uno spostamento δ dal punto di massimo $\hat{\theta}$ produce una perdita in verosimiglianza Δ_1 maggiore rispetto al caso di bassa informazione (Δ_2).

Questa intuizione è fondamentale per le stime di Massima Verosimiglianza. Infatti si può anche dimostrare che l'Informazione attesa di Fisher è legata al “LOWER BOUND” dell'efficienza degli stimatori, tramite la Disuguaglianza di Cramér-Rao.

Teorema 1.1 (Disuguaglianza di Cramér-Rao). *Sia $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} f(x; \boldsymbol{\theta})$ un campione estratto da una legge con funzione di densità f e vettore di parametri $\boldsymbol{\theta}$, e si supponga di essere in un caso regolare di stima. Allora ogni stimatore t_n non distorto di $\boldsymbol{\theta}$ soddisfa la disequazione*

$$\text{Var}(t_n) \geq \frac{1}{I_n(\boldsymbol{\theta})},$$

dove $I_n(\boldsymbol{\theta}) = n I_1(\boldsymbol{\theta})$ è l'informazione di Fisher attesa dell'intero campione.

Si definisce $I_1(\boldsymbol{\theta})$ come il contributo della singola unità all'informazione attesa di Fisher. Quando le osservazioni sono indipendenti e identicamente distribuite allora si ha che

$I_n(\boldsymbol{\theta}) = nI_1(\boldsymbol{\theta})$. Tramite questo teorema si possono introdurre gli stimatori efficienti, cioè stimatori non distorti e con varianza minima, dunque che soddisfano la disequazione con l'uguaglianza. Come già menzionato prima, questi stimatori, se esistono, si definiscono UMVUE, ed è dimostrabile che essi sono unici.

1.1.5 Test di Ipotesi

Come già menzionato prima, se $n \rightarrow \infty$, e sotto opportune condizioni di regolarità, lo stimatore di massima verosimiglianza è asintoticamente normale, ovvero:

$$\sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I_1(\boldsymbol{\theta})}\right).$$

In particolare, per n sufficientemente grande:

$$\hat{\boldsymbol{\theta}} \approx \mathcal{N}\left(\boldsymbol{\theta}, \frac{1}{I_n(\boldsymbol{\theta})}\right). \quad (1.2)$$

La dimostrazione di questo risultato si basa su una combinazione della legge dei grandi numeri, del teorema del limite centrale e di un'espansione di Taylor della funzione di Score, che permette di riscrivere la differenza fra $\hat{\boldsymbol{\theta}}$ e $\boldsymbol{\theta}$ come una distribuzione normale con media zero. Conoscere la distribuzione campionaria dello stimatore ci permette di costruire test formali per ipotesi sul parametro. Creare un test significa individuare, nello spazio campionario, l'insieme dei campioni che, se l'ipotesi nulla H_0 fosse vera, risulterebbero sufficientemente improbabili da rendere l'ipotesi improbabile. Per esempio, volendo testare se la media sia uguale a 0 ($H_0: \theta = \theta_0 = 0$) e viene osservata una stima $\hat{\boldsymbol{\theta}}$ molto elevata, ciò che il test misura non è la probabilità che H_0 sia vera, ma la probabilità di osservare, assumendo H_0 vera, un campione che produca una stima pari o più estrema di quella osservata. Se questa probabilità (definita p -value) è inferiore al livello di significatività prefissato (solitamente 0,05), viene rifiutata l'ipotesi. Bisogna stare attenti a non fraintendere però che rifiutare un'ipotesi non significa che l'ipotesi di per sé sia falsa, ma che i dati osservati risultano scarsamente compatibili con essa. Più in generale, i test statistici considerati in questo caso riguardano il parametro $\boldsymbol{\theta}$ e sono del tipo $H_0: \boldsymbol{\theta} = \boldsymbol{\theta}_0$ contro $H_1: \boldsymbol{\theta} \neq \boldsymbol{\theta}_0$, dove $\boldsymbol{\theta}_0$ è il valore ipotizzato del parametro. Per poter calcolare la distanza fra il campione e l'ipotesi, si necessita che la distribuzione del test dipenda da dati e dall'ipotesi nulla. Fra i molti test realizzabili, si presentano

tre test classici per verificare ipotesi, che fra l'altro risultano asintoticamente equivalenti sotto l'ipotesi nulla.

Test di Wald. Il test di Wald è il primo, e sfrutta il fatto che il quadrato di una variabile con distribuzione normale standard segue una distribuzione χ^2 . Questo test agisce dunque direttamente sullo spazio parametrico. Esso risulta pari a:

$$W_e = (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0)^T \mathbf{I}_n(\hat{\boldsymbol{\theta}})(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{d} \chi_q^2.$$

Il test di Wald ha però un difetto (o meglio, un problema strutturale), ed è legato alle trasformazioni non lineari applicate a $\boldsymbol{\theta}$. Questo test infatti è instabile rispetto alle trasformazioni tramite funzioni non lineari. Questo avviene perché adoperando il metodo Delta per ottenere una stima della varianza campionaria rispetto alla trasformazione (in questo caso, $g(\boldsymbol{\theta})$) tramite una serie di Taylor, si ottiene che:

$$W_e = (g(\hat{\boldsymbol{\theta}}) - g(\boldsymbol{\theta}_0))^T \left[\mathbf{J}_g(\hat{\boldsymbol{\theta}}) [\mathbf{I}_n(\hat{\boldsymbol{\theta}})]^{-1} \mathbf{J}_g(\hat{\boldsymbol{\theta}})^T \right]^{-1} (g(\hat{\boldsymbol{\theta}}) - g(\boldsymbol{\theta}_0)) \xrightarrow{d} \chi_q^2,$$

dove se la trasformazione applicata possiede uno sviluppo di Taylor di ordine maggiore al primo, si ottiene una distorsione del test, tant'è che è possibile ottenere degli intervalli di confidenza non simmetrici rispetto al valore trasformato $g(\hat{\boldsymbol{\theta}})$.

Test di Score-Rao. Il test di Score, detto anche test di Rao, utilizza invece la funzione di score valutata nel punto $\boldsymbol{\theta}_0$, agendo quindi sui valori della derivata della funzione.

$$W_u = \mathbf{u}(\boldsymbol{\theta}_0)^T [\mathbf{I}_n(\boldsymbol{\theta}_0)]^{-1} \mathbf{u}(\boldsymbol{\theta}_0) \xrightarrow{d} \chi_q^2.$$

Il vantaggio del test è che si agisce direttamente sulla curvatura della funzione. Se si ha una pendenza molto elevata, banalmente questo suggerisce che “percorrendo” di poco la funzione si ottiene un valore significativamente molto diverso, e ciò implica che non ci si trova nel punto di ottimo, dove la derivata sarebbe vicina a 0, portandoci a respingere l'ipotesi nulla. Questo test è, al contrario di Wald, invariante rispetto alle trasformazioni.

Test del Rapporto di Verosimiglianza (LRT). Il test di Rapporto di Verosimiglianza (LRT), anche noto come test di Wilks, confronta la log-verosimiglianza nella stima di

massima verosimiglianza e nella stima vincolata dalle ipotesi:

$$W = 2[\ell(\hat{\theta}) - \ell(\theta_0)] \xrightarrow{d} \chi_q^2.$$

Il test essenzialmente misura la "distanza" in log-Verosimiglianza tra modello ristretto e modello "ricco", cioè senza restrizioni sui parametri. Se la differenza fosse reputata dal test statisticamente significativa, ciò implicherebbe che la verosimiglianza nel punto $\hat{\theta}$ è significativamente più elevata della verosimiglianza in θ_0 , il che suggerisce che $\hat{\theta}$ è lontano dall'accettare l'ipotesi nulla. Malgrado ognuno di questi test presenta comportamenti diversi in campioni finiti, il LRT risulta generalmente il più adoperato in campioni finiti, questo anche perché è invariante rispetto a trasformazioni $g(\theta)$, siccome agisce direttamente sulla verosimiglianza. I tre test condividono la stessa distribuzione limite χ_q^2 sotto l'ipotesi nulla H_0 , e si può dimostrare che sono asintoticamente equivalenti. Detto questo, nei campioni finiti, soprattutto quelli di dimensione ridotta, possono produrre conclusioni diverse. In generale, si ha che $W = W_u = W_e$ coincidono anche senza la richiesta asintotica all'interno di modelli Normali.




Figura 1.2: Test di Wald, Score e Rapporto di Verosimiglianza. Il grafico mostra come i tre test vanno a considerare quantità diverse per ottenere la significatività dei parametri: distanza in θ (Wald), pendenza della funzione in θ_0 (Score), distanza in verosimiglianza (LRT).

1.2 Modelli Lineari Generalizzati

1.2.1 Introduzione ai Modelli Lineari

I modelli lineari generalizzati (GLM) sono un'evoluzione dei modelli di regressione lineare. Nella regressione lineare, l'obiettivo è modellare il valore atteso della variabile risposta Y come combinazione lineare nei parametri β e della matrice di covariate X di dimensione $n \times k$ e di rango pieno:

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I),$$

dove le stime di β vengono ottenute minimizzando la somma dei quadrati dei residui (OLS, ovvero Ordinary Least Square). È anche importante da sottolineare come, a livello numerico, questa soluzione risulta stabile poiché risulta un sistema lineare, rendendola la scelta migliore non solo dal punto di vista statistico ma anche pratico. Questo approccio ha però, fra le tante, due limitazioni particolarmente importanti in questo caso: la prima è che impone che la variabile risposta sia continua, dunque richiede assunzioni restrittive qualora si volesse modellare, ad esempio, delle risposte binarie. La seconda è che si necessitano anche delle assunzioni di omoschedasticità, normalità e non correlazione fra gli errori. La violazione di queste assunzioni ha conseguenze diverse a seconda di quale venga meno: gli stimatori OLS rimangono non distorti, mentre viene meno la distribuzione esatta dei test e la validità dell'inferenza non asintotica. Detto ciò non risulta estremamente compromettente. Invece la presenza di eteroschedasticità o correlazione fra gli errori compromette l'efficienza di OLS e la correttezza degli errori standard. Detto ciò, esistono metodi per generalizzare il modello lineare, che riescono quantomeno a mitigare queste problematiche (se non a risolverle del tutto). Un possibile rimedio al primo limite è l'uso di trasformazioni non lineari per trasformare le variabili risposta all'interno del modello. Questo ci permette anche di osservare relazioni non polinomiali. Formalmente questo concetto si indicherà come $g(Y) = X\beta + \epsilon$. Le trasformazioni hanno però delle problematiche strutturali. In primis, rendono l'interpretazione dei coefficienti più complessa, perché il modello spiegherà la trasformazione della risposta e non la risposta stessa. In secondo luogo, la disuguaglianza di Jensen ci dice che, data una funzione f convessa su un intervallo contenente il supporto di Y , e supponendo che $\mathbb{E}[Y]$ e $\mathbb{E}[f(Y)]$ esistano e siano entrambi finiti:

$$f(\mathbb{E}(Y)) \leq \mathbb{E}(f(Y)), \tag{1.3}$$

dove la disuguaglianza va invertita qualora la funzione fosse concava. Essa implica che una misura della trasformazione monotona convessa (concava) sarà sempre maggiore (minore) della trasformazione della misura (nel caso delle trasformazioni non lineari, la media). Questo rende le previsioni su Y distorte per costruzione. I GLM presentano una soluzione a questo problema più elegante e pratica. Prima di introdurli però bisogna comprendere il concetto di Famiglia di Dispersione Esponenziale.

1.2.2 Famiglia di Distribuzioni a Dispersione Esponenziale

Una funzione di densità appartiene alla famiglia di dispersione esponenziale se può essere riscritta nella forma:

$$p(y_i, \theta_i, \phi) = \exp \left(\frac{\theta_i y_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi) \right),$$

dove $y_i \in \mathcal{Y} \in \mathbb{R}$, $\theta_i \in \Theta \in \mathbb{R}$. $\mathcal{Y}$ è il supporto delle y_i , cioè i valori che può assumere la variabile aleatoria, mentre Θ è lo spazio parametrico. Si definisce θ il parametro naturale della distribuzione e ϕ il parametro di dispersione. Queste distribuzioni soddisfano sempre le condizioni regolari di stima come, fra le altre, che il supporto $\mathcal{Y}$ non deve dipendere in nessun modo da θ o ϕ . Per quanto riguarda le funzioni, senza perdita di generalità, si può riscrivere $a(\phi)$ come pesi w_i finiti e positivi. Inoltre si richiede che la funzione $b(\theta)$ dipenda solo dal parametro θ e che essa sia di classe C^∞ . Infine la funzione $c(y_i, \phi)$ non deve dipendere dal parametro naturale. Quest'ultima, quando si vanno a effettuare i calcoli in log-verosimiglianza, è trattabile come una costante, e non risulterà particolarmente utile nelle analisi presentate. Infatti anche grazie a questo è dimostrabile che la distribuzione Binomiale e la distribuzione Bernoulliana (che rappresenta una estrazione singola, infatti la Binomiale è interpretabile come una somma di n estrazioni singole Bernoulliane con probabilità uguali) possiedono lo stesso ottimo.

1.2.3 Verosimiglianza e Proprietà delle Esponenziali

La log-Verosimiglianza di questa famiglia di distribuzioni sarà pari a:

$$\ell(\theta_i; \phi \mid y_i) = \frac{\theta_i y_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi)$$

Si possono dunque ottenere anche le funzioni di score e di informazione attesa di Fisher. Derivando per il valore i -esimo del vettore risposte con rispettivo parametro θ_i , si ottiene

$$u_i(\theta_i; \phi \mid y_i) = \frac{\partial \ell_i}{\partial \theta_i} = \frac{y_i - b'(\theta_i)}{a(\phi)},$$

$$H_{i,i}(\theta_i; \phi \mid y_i) = \mathbb{E} \left(\frac{\partial^2 \ell_i}{\partial \theta_i^2} \right) = -\frac{b''(\theta_i)}{a(\phi)}.$$

Queste quantità sono estremamente utili a ottenere informazioni sulle funzioni della distribuzione perché, ricordando le proprietà menzionate prima di Score e Informazione di Fisher in condizioni di regolarità (anche note come "Identità di Bartlett"), possiamo ottenere una formula generale della media e della varianza di questa famiglia di distribuzioni. Infatti:

$$\begin{aligned} \mathbb{E} \left(\frac{y_i - b'(\theta_i)}{a(\phi)} \right) &= 0 \quad \Rightarrow \quad \mathbb{E}(y_i) = b'(\theta_i), \\ \text{Var} \left(\frac{y_i - b'(\theta_i)}{a(\phi)} \right) &= \frac{b''(\theta_i)}{a(\phi)} \quad \Rightarrow \quad \text{Var}(y_i) = a(\phi) b''(\theta_i). \end{aligned}$$

Inoltre, siccome è noto che la varianza è definita positiva e la funzione $a(\phi)$ è riscrivibile come pesi positivi noti moltiplicati per una costante, la derivata seconda $b''(\theta)$ sarà sicuramente positiva.

Parametrizzazione Naturale e Parametrizzazione Media Una delle proprietà più importanti delle distribuzioni a dispersione esponenziale è sicuramente la possibilità di riscrivere la distribuzione in funzione del parametro naturale o della media. Infatti si può costruire una funzione biettiva (e dunque invertibile). Data la funzione media $\mu(\theta) : \Theta \rightarrow \mathcal{M}$ con $\mathcal{M} \in \mathbb{R}$:

$$\mu(\theta_i) = \mu_i = \mathbb{E}(y_i) = b'(\theta_i),$$

dove $\mathcal{M}$ è lo spazio parametrico della media. Essenzialmente si utilizza una mappatura $1 : 1$, ottenendo di fatto una parametrizzazione della distribuzione rispetto alla media, e non più rispetto al parametro naturale. Questo ci permette anche di riscrivere la varianza come funzione del parametro di dispersione o della media, infatti si ha che:

$$\text{Var}(Y_i) = a_i(\phi) b''(\theta(\mu_i)) = a_i(\phi) v(\mu_i),$$

dove si definisce $v(\mu_i)$ la funzione varianza. Invertendo $\mu(\cdot)$ possiamo ottenere una funzione che $\forall \mu_i \in \mathcal{M}$ restituisce il parametro naturale θ corrispondente:

$$\theta(\mu_i) = b'^{-1}(\mu_i).$$

Si definisce questo passaggio la parametrizzazione naturale. Questo discorso tornerà utile successivamente, quando verranno introdotti i GLM ed in particolare il legame canonico. Si propone ora un esempio di parametrizzazione naturale applicato alla Binomiale, dove si può riscrivere la distribuzione vista in 1.1, supponendo di avere $S \sim \text{Binom}(m, \pi)$, e di voler modellare la proporzione di successi dell'evento aleatorio $Y = S/m$. Si ottiene che la $P(s = k)$ sarà pari alla $P(y = k/m)$. Riscriviamo dunque la distribuzione vista come segue:

$$f(y; \pi) = \binom{m}{my} \pi^{my} (1 - \pi)^{m-my} = \exp \left\{ my \log \frac{\pi}{1 - \pi} + m \log(1 - \pi) + \log \binom{m}{my} \right\}.$$

Si può osservare come questa quantità sia riscrivibile nella forma:

$$f(y; \pi) = \exp \left\{ \frac{y\theta - \log(1 + e^{(\theta)})}{a(\phi)} + c(y, \phi) \right\}. \quad (1.4)$$

Questa riscrittura permette di vedere chiaramente come la distribuzione Binomiale faccia parte della famiglia delle distribuzioni a dispersione esponenziali. In particolare il parametro naturale θ sarà pari a $\log(\frac{\pi}{1-\pi})$.

1.2.4 Struttura Generale dei GLM

Adesso che sono state definite le basi teoriche necessarie per affrontare l'argomento, si descrivono i GLM. Essi sono stati introdotti per la prima volta in [Nelder & Wedderburn \(1972\)](#), lavoro che riuscì a generalizzare alcune regressioni già note come la logistica, la Poisson e la normale sotto un'unica famiglia (infatti alcuni di questi modelli erano stati ideati anche decine di anni prima di questa unificazione). Un modello GLM, per essere tale, deve contenere 3 elementi fondamentali:

- La Componente Casuale, costituita dalla risposta, infatti si ha che il vettore delle risposte Y di n componenti ha una funzione di dispersione esponenziale; inoltre si trattano le singole Y_i come indipendenti. Cioè che $Y_i \stackrel{ind}{\sim} ED(\mu_i, a(\phi)v(\mu_i))$, dove ED sta per Distribuzione Esponenziale.

- Il Predittore Lineare, ovvero il prodotto fra un vettore di parametri β , di dimensioni p , e una matrice disegno X , di dimensioni $n \times p$. Formalmente: $\eta = X\beta$. Naturalmente si otterranno n predittori lineari, uno per ogni distribuzione caratterizzante le n risposte.
- La Funzione Legame (Link Function), una funzione invertibile e differenziabile, che collega le medie delle distribuzioni ai predittori lineari. Formalmente:

$$g(\mu) = \eta = X\beta.$$

Di conseguenza la media sarà data dall'applicazione di $g^{-1}(\eta)$.

La scelta della funzione legame risulta di particolare importanza, in quanto determinate funzioni si adattano a modellare situazioni specifiche, restituendo risultati preferibili in determinati casi. Il criterio principale per individuare la funzione differenziabile e invertibile è che abbia dominio e codominio congruenti con la funzione di partenza (non ha senso modellare il parametro di una Binomiale con una funzione a valori su tutto l'insieme $\mathbb{R}$). Per esempio, per la funzione Binomiale si può scegliere una qualsiasi legge che abbia come dominio l'insieme $[0, 1]$ e come codominio $\mathbb{R}$ o, equivalentemente, la sua inversa $g^{-1}: \mathbb{R} \rightarrow [0, 1]$ deve restituire un valore di probabilità a partire da un qualsiasi predittore lineare reale. Esempi di tali inverse sono la funzione cumulativa della Normale ("Modello Probit", $g^{-1}(\eta) = \Phi(\eta)$) o quella di una Cauchy ($g^{-1}(\eta) = \frac{1}{2} + \frac{1}{\pi} \arctan(\eta)$). Detto ciò, esiste un tipo di Link Function che risulta più conveniente e pratico quando si parla di GLM, ovvero il Link Canonico.

Definizione 1.2 (Legame Canonico). *Si definisce la funzione legame "Canonica" quando essa corrisponde alla funzione di parametrizzazione naturale, quindi quel legame per cui:*

$$\eta = g(\mu) = \theta(\mu).$$

Questo tipo di link function permette, come osservato più avanti, di ottenere risultati in verosimiglianza più semplici degli altri casi, perché si riesce a modellare il parametro naturale in funzione delle covariate. Come esempio, ancora, si può prendere la Binomiale, della quale abbiamo ottenuto la scrittura in forma di distribuzione esponenziale all'equazione 1.4. In questo caso, si è detto che la funzione di parametrizzazione naturale sarà $\theta = \log\left(\frac{\pi}{1-\pi}\right)$, e infatti questa funzione, chiamata logit, è il legame canonico per le distribu-

zioni Binomiali e Bernoulliane, che sono uguali in termini di risultati dell'ottimizzazione, infatti fra le due cambierà solamente la presenza della funzione $c(y, \phi)$, che ai fini di ottimizzazione è essenzialmente una costante irrisoria. Ulteriori esempi di legami canonici sono la funzione identità per la normale (nel qual caso i GLM coincidono perfettamente con le stime in regressione lineare) e la funzione reciproco per la Gamma.




Figura 1.3: Confronto tra modello lineare e GLM binomiale, su dati simulati estratti da una legge con funzione di probabilità Binomiale. Come già menzionato, la struttura dei GLM permette di modellare la probabilità più precisamente e sul supporto corretto, mentre il modello lineare modella probabilità negative o superiori ad uno.

1.3 Ottimizzazione dei GLM e l'Algoritmo IRLS

1.3.1 Il Problema di Ottimizzazione nei GLM

Così come nei modelli lineari, anche nei GLM le stime dei coefficienti di regressione β vengono ottenute tramite Massima Verosimiglianza. In questo caso infatti essa sarà scrivibile, per la i -esima osservazione del campione di y , come:

$$L(\beta; \phi \mid y_1 \dots y_n) = \prod_{i=1}^n \exp \left(\frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right),$$

e dove la funzione di log-Verosimiglianza sarà:

$$\ell(\beta; \phi \mid y_1 \dots y_n) = \sum_{i=1}^n \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi).$$

Si noti che, sebbene la verosimiglianza sia scritta in termini di θ_i , l'oggetto di inferenza è il vettore β , legato al parametro grazie alla relazione $\theta = \theta(\mu) = \theta(g^{-1}(X\beta))$, cioè funzione di parametrizzazione naturale sul vettore media, ottenuta a sua volta tramite inversa del legame applicato al predittore lineare. Questo è in parte la motivazione principale per cui l'uso della famiglia esponenziale è consigliabile nel contesto dei GLM, poiché grazie all'indipendenza delle Y_i la log-Verosimiglianza si decompone in somma di contributi individuali, dove ciascuno dipende dalla sola osservazione y_i e dal proprio parametro naturale θ_i . Questo permette, come si osserverà di seguito, di riscrivere l'algoritmo di stima dei parametri β tramite lo score nei GLM per risposte con distribuzioni esponenziale come una successione di problemi di minimi quadrati pesati. Sempre in riferimento alla verosimiglianza della famiglia di distribuzione esponenziali, la funzione di score sarà pari a:

$$u(\beta; \phi) = \frac{\partial}{\partial \beta} \left[\sum_{i=1}^n \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right].$$

Naturalmente per risolvere questa derivazione è necessario conoscere se $\beta \perp \phi$, perché questo ci permetterà di trattare $a_i(\phi)$ come una costante. È dimostrabile che β e ϕ siano ortogonali nel senso di [Cox & Reid \(1987\)](#), ovvero che la matrice di informazione di Fisher risulti block-diagonale. Nell'equazione dunque la funzione $a_i(\phi)$ verrà indicata come $\frac{w_i}{\phi}$. Dato questo, è possibile risolvere l'equazione applicando la derivazione ai singoli componenti del numeratore. La funzione costante $c(y_i, \phi)$, che non dipende in nessun modo da θ , si annulla. Successivamente, per la regola della catena, sappiamo che si può riscrivere la derivata come $\frac{\partial}{\partial \beta} b(\theta_i) = b'(\theta_i) \frac{\partial \theta_i}{\partial \beta}$. Sapendo inoltre che, nelle famiglie esponenziali, $b'(\theta_i) = \mu_i$, allora si ottiene, ipotizzando di stare derivando per il j -esimo coefficiente β_j , $j = 1 \dots p$:

$$u(\beta_j; \phi) = \frac{1}{\phi} \sum_{i=1}^n w_i \left[(y_i - \mu_i) \frac{\partial \theta_i}{\partial \beta_j} \right].$$

La quantità ϕ è trattabile come costante, ed ignorabile per il problema di massimizzazione, che sarà ottenuto ponendo lo score pari a 0. La risoluzione dell'equazione dipenderà ovviamente da $\frac{\partial \theta_i}{\partial \beta_j}$. Senza perdita di generalità, la funzione $\theta(\cdot)$ corrisponde alla funzione di parametrizzazione naturale applicata su μ_i , e che risulta dunque possibile ottenere la media da una generica funzione legame applicata al predittore lineare $g^{-1}(\eta_i) = g^{-1}(x_i \beta)$.

Dunque, si riscrive la derivata di θ come:

$$\frac{\partial \theta_i}{\partial \beta_j} = \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_j} \frac{\partial \eta_j}{\partial \beta_j}.$$

In situazioni generali, questo porta lo score (e quindi il problema di ottimizzazione) ad essere pari a:

$$u(\beta_j) = \frac{1}{\phi} \sum_{i=1}^n w_i \frac{(y_i - \mu_i)}{v(\mu_i)} \frac{x_{ij}}{g'(\mu_i)},$$

dove in particolare questa quantità non è generalmente risolvibile in forma chiusa. Essenzialmente, il passaggio dove viene introdotto il predittore lineare per poi trasformarlo in parametro naturale rende troppo complessa la risoluzione tramite metodi elementari. È inoltre possibile riscrivere in forma matriciale lo score, in particolare come $D^T V^{-1}(y - \mu) = 0$, dove in particolare D è una matrice diagonale di dimensione $n \times n$ contenente elementi $d_{ij} = \frac{1}{g'(\mu_i)} x_{ij}$, mentre invece la matrice V è una matrice quadrata diagonale di dimensione n che contiene il rapporto fra la funzione varianza e i pesi noti positivi $v_{i,i} = v(\mu_i)/w_i$. Qualora però venga adoperato il legame canonico, la derivata sarà pari a $\frac{\partial \theta_i}{\partial \beta_j} = x_{ij}$ (infatti quando $g(\mu_i) = \theta_i$, si ha che $v(\mu_i)g'(\mu_i) = 1$). Ciò rende il calcolo dell'ottimo più semplice, infatti la soluzione è pari a:

$$\sum_{i=1}^n w_i (y_i - \mu_i) x_{ij} = 0, \quad (1.5)$$

che in diversi casi, come la normale che possiede come link canonico la funzione di identità, è risolvibile algebricamente.

1.3.2 Informazione Osservata e Attesa di Fisher

Per studiare le proprietà dello stimatore di massima verosimiglianza nei modelli GLM, così come nei modelli lineari, non è sufficiente analizzare la funzione di score, ma bisogna comprendere anche la curvatura locale della log-verosimiglianza circa il punto di ottimo. Come introdotto nella Sezione 1.1.4, questa curvatura è catturata dall'Informazione di Fisher, e la sua struttura nei GLM risulta particolarmente interessante. Si definisce dunque la "matrice di Informazione Osservata" J , di dimensioni $p \times p$, il cui elemento j_{jk} sarà la derivata dello score, alla quale viene cambiato il segno (per semplicità di calcolo e facilità interpretativa), ovvero:

$$j_{jk} = -\frac{\partial}{\partial \beta_k} u(\beta_j), \quad j, k = 1, \dots, p.$$

Si definisce "osservata" perché dipende dal campione, ed è stocastica. Derivando la funzione di score già ottenuta nella sezione precedente, e ricordando che $a_i(\phi) = \phi/w_i$, e che la media sarà l'unica quantità dipendente dai parametri β , si ottiene che l'elemento generico (j, k) sarà pari a:

$$j_{jk} = \sum_{i=1}^n \frac{1}{a_i(\phi)} \left[\frac{\partial \mu_i}{\partial \beta_k} \frac{\partial \theta_i}{\partial \beta_j} - (y_i - \mu_i) \frac{\partial^2 \theta_i}{\partial \beta_j \partial \beta_k} \right], \quad j, k = 1, \dots, p.$$

L'espressione contiene un termine legato agli scarti $(y_i - \mu_i)$. Per liberarci di questa dipendenza campionaria e ottenere una quantità deterministica, si definisce la Matrice di Informazione di Fisher Attesa come il valore atteso della derivata seconda della log-verosimiglianza:

$$I = \mathbb{E}(J), \quad \text{con elementi} \quad i_{jk} = \mathbb{E}(j_{jk}) \quad j, k = 1, \dots, p.$$

Ma siccome $\mathbb{E}(Y_i) = \mu_i$ per costruzione, e dunque il termine contenente $(y_i - \mu_i)$ si annulla in valore atteso, semplificando notevolmente la matrice J . Sfruttando i risultati ottenuti nella derivazione della funzione di score si può ottenere l'elemento generico (j, k) della matrice I :

$$i_{jk} = \sum_{i=1}^n \omega_i \frac{x_{ij} x_{ik}}{\phi v(\mu_i) g'(\mu_i)^2} = \sum_{i=1}^n \frac{x_{ij} x_{ik}}{\text{Var}(Y_i) g'(\mu_i)^2}, \quad j, k = 1, \dots, p.$$

Questa formula ammette una rappresentazione matriciale compatta, infatti definendo tutto ciò che non è covariata come un peso generale w_i , si può ottenere che

$$I = X^T W X,$$

dove la matrice W è una matrice diagonale di valori $w_i = 1/[\text{Var}(Y_i)g'(\mu_i)^2]$. Si noti inoltre come questa forma è del tutto uguale a una regressione pesata, informazione che tornerà utile successivamente. Infine, come nello score, l'utilizzo del legame canonico porta a semplificazioni anche nella struttura della matrice I . Infatti, è molto semplice vedere che la derivata seconda si annulla quando predittore lineare e parametro naturale coincidono:

$$\frac{\partial^2 \theta_i}{\partial \beta_j \partial \beta_k} = 0.$$

Dunque nel caso del legame canonico l'informazione osservata e l'informazione attesa coincidono, cioè $I = J$. Interessante osservare come poiché la matrice X ha rango pieno e $g'(\mu) \neq 0$, I risulta definita positiva, il che garantisce che la log-verosimiglianza sia strettamente concava e che dunque qualora esista un punto stazionario esso coincida sempre con il massimo assoluto.

Distribuzione asintotica dello stimatore di massima verosimiglianza. Lo stimatore di massima verosimiglianza $\hat{\beta}$ si distribuisce asintoticamente, sotto condizioni di regolarità e per n sufficientemente grande, come una distribuzione Normale p -dimensionale, similmente a quanto già introdotto nella Sezione 1.1.5. Formalmente:

$$\hat{\beta} \sim N_p(\beta, (X^T W X)^{-1}),$$

dove la matrice di covarianza è l'inversa della matrice di informazione attesa di Fisher. Nella pratica, poiché W dipende dagli ignoti β e ϕ , si sostituiscono con le rispettive stime $\hat{\beta}$ e $\hat{\phi}$, ottenendo la matrice di varianza stimata. Gli errori standard associati alle singole componenti di $\hat{\beta}$ saranno quindi

$$\widehat{\text{se}}(\hat{\beta}_j) = \sqrt{\left[(X^T \hat{W} X)^{-1}\right]_{jj}}, \quad j = 1, \dots, p.$$

Queste quantità sono quelle tipicamente restituite dai software statistici come R, e costituiscono la base per la costruzione di intervalli di confidenza e per i test di ipotesi.

1.3.3 Metodo di Newton-Raphson e Algoritmo IRLS

Come evidenziato nella sezione precedente, le equazioni di likelihood nei GLM,

$$D^T V^{-1}(y - \mu) = 0,$$

non ammettono in generale una soluzione in forma chiusa. Nei casi più comuni è necessario ricorrere a metodi iterativi. L'algoritmo IRLS, proposto originariamente da [Nelder & Wedderburn \(1972\)](#), è una variante del classico metodo di Newton-Raphson, del quale si presentano alcune caratteristiche importanti. L'idea alla base del metodo è di approssimare la log-verosimiglianza $\ell(\beta)$ con una parabola, ovvero tramite uno sviluppo di Taylor

al secondo ordine centrato nel valore della t -esima iterata, che indichiamo con $\beta^{(t)}$:

$$\ell(\beta) \approx \ell(\beta^{(t)}) + \ell^*(\beta^{(t)})(\beta - \beta^{(t)}) - \frac{1}{2}(\beta - \beta^{(t)})^T J^{(t)}(\beta - \beta^{(t)}),$$

dove $\ell^*(\beta^{(t)})$ è il gradiente, quindi lo score valutato in $\beta^{(t)}$ e $J^{(t)}$ è la matrice di informazione osservata in $\beta^{(t)}$. Massimizzando questa approssimazione parabolica rispetto a β , si ottiene che:

$$\ell^*(\beta^{(t)}) - J^{(t)}(\beta - \beta^{(t)}) = 0, \quad (1.6)$$

poiché la parte a sinistra dell'equazione viene posta uguale a 0 e $\ell(\beta^{(t)})$ è una costante. Da qui si ricava la regola di aggiornamento dell'algoritmo infatti, ponendo β come $\beta^{(t+1)}$, si ottiene che:

$$\beta^{(t+1)} = \beta^{(t)} + (J^{(t)})^{-1} \ell^*(\beta^{(t)}), \quad t = 1, 2, \dots$$

A livello intuitivo, il metodo cerca di partire da un punto di inizio $\beta^{(0)}$ ed approssimare la verosimiglianza con una parabola, ottenendo così un nuovo ottimo adoperato successivamente come punto di partenza nella successiva iterazione, costruendo una serie di parabole che convergono al valore reale di β . È possibile dimostrare che, per una funzione $f(\cdot) \in C^2$ con zero di funzione $f(\bar{x}) = 0$ e derivata prima non nulla in $\bar{x}$, esiste un intorno $I_{\bar{x}} =]\bar{x} - \delta, \bar{x} + \delta[$. Per qualsiasi punto di partenza x_0 appartenente a tale intorno, la successione x_k generata dal metodo di Newton-Raphson converge allo zero di funzione, cioè $x_k \rightarrow \bar{x}$. L'algoritmo si arresta quando la differenza in norma fra l'aggiornamento e il valore attuale scende al di sotto di una soglia fissata ϵ , ovvero quando $\|\beta^{(t+1)} - \beta^{(t)}\|_p < \epsilon$. Si può dimostrare inoltre che la velocità di convergenza dell'algoritmo è quadratica e proporzionale alla derivata terza della funzione, infatti si avrà che :

$$\|\beta^{(t+2)} - \beta^{(t+1)}\|_p \propto \frac{\partial^3}{\partial^3 \beta}(\ell(\beta))(\|\beta^{(t+1)} - \beta^{(t)}\|_p)^2.$$

Per una trattazione più completa del metodo di Newton-Raphson si rimanda a [Quarteroni et al. \(2014\)](#). Il metodo di Newton-Raphson ha però un punto debole strutturale quando adoperato nei GLM: essendo la matrice $J^{(t)}$ stocastica, poiché dipendente dalle osservazioni, non è garantito che sia invertibile ad ogni iterazione, rendendo l'algoritmo degenerare e capace di restituire risultati non validi o insensati. Una soluzione semplice ed efficace consiste nel sostituire la matrice di informazione osservata $J^{(t)}$ con la matrice di informazione di Fisher attesa $I^{(t)}$. Questa variante prende il nome di Fisher Scoring, e

fornisce le seguenti equazioni di aggiornamento:

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + (I^{(t)})^{-1} \ell^*(\boldsymbol{\beta}^{(t)}), \quad t = 1, 2, \dots$$

Sfruttando ora le espressioni matriciali già ricavate, è possibile riscrivere lo score e l'informazione di Fisher come:

$$\ell^*(\boldsymbol{\beta}^{(t)}) = X^T W^{(t)} \mathbf{u}^{(t)}, \quad I^{(t)} = X^T W^{(t)} X,$$

dove $\mathbf{u}^{(t)} = (u_1^{(t)}, \dots, u_n^{(t)})^T$ è il vettore con componenti $u_i^{(t)} = (y_i - \mu_i^{(t)})g'(\mu_i^{(t)})$. Sostituendo nell'equazione di Fisher scoring si ottiene

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + (X^T W^{(t)} X)^{-1} X^T W^{(t)} \mathbf{u}^{(t)}.$$

Moltiplicando entrambi i membri per $(X^T W^{(t)} X)$ e raccogliendo a destra la matrice $X^T W^{(t)}$, si arriva alla formulazione definitiva dell'algoritmo IRLS:

$$\boldsymbol{\beta}^{(t+1)} = (X^T W^{(t)} X)^{-1} X^T W^{(t)} \mathbf{z}^{(t)}, \quad t = 1, 2, \dots,$$

dove $\mathbf{z}^{(t)} = (z_1^{(t)}, \dots, z_n^{(t)})^T$ è il vettore delle pseudorisposte $\mathbf{z}^t$, con componenti

$$z_i^{(t)} = x_i^T \boldsymbol{\beta}^{(t)} + u_i^{(t)} = x_i^T \boldsymbol{\beta}^{(t)} + (y_i - \mu_i^{(t)})g'(\mu_i^{(t)}), \quad i = 1, \dots, n.$$

Ogni iterazione dell'algoritmo IRLS corrisponde quindi alla risoluzione di un problema di minimi quadrati pesati, infatti:

$$\boldsymbol{\beta}^{(t+1)} = \arg \min_{\boldsymbol{\beta}} \left[(\mathbf{z}^{(t)} - X\boldsymbol{\beta}^{(t)})^T W^{(t)} (\mathbf{z}^{(t)} - X\boldsymbol{\beta}^{(t)}) \right].$$

Essenzialmente, ad ogni passo si risolve un sistema lineare pesato, dove sia i pesi $W^{(t)}$ sia le pseudorisposte $\mathbf{z}^{(t)}$ vengono aggiornati in funzione delle stime correnti. Le pseudorisposte $z_i^{(t)}$ hanno un'ulteriore interpretazione interessante. Esse si possono vedere infatti come approssimazione lineare della risposta trasformata tramite la funzione legame:

$$g(y_i) \approx g(\mu_i^{(t)}) + (y_i - \mu_i^{(t)})g'(\mu_i^{(t)}) = \eta_i^{(t)} + (y_i - \mu_i^{(t)})g'(\mu_i^{(t)}) = z_i^{(t)}.$$

In altre parole, le pseudorisposte sono le linearizzazioni di $g(y_i)$ attorno al predittore lineare corrente $\eta_i^{(t)}$, ottenute tramite sviluppo di Taylor al primo ordine. Un'ultima osservazione da sottolineare è che le equazioni di aggiornamento dell'IRLS non dipendono dal parametro di dispersione ϕ , perché quest'ultimo si cancella nelle moltiplicazioni matriciali, grazie al fatto di essere ortogonale rispetto ai β , come già menzionato precedentemente. Questo significa che l'algoritmo è applicabile anche quando ϕ non è noto in precedenza e che la stima di $\hat{\beta}$ può essere ottenuta indipendentemente da quella di $\hat{\phi}$. Il fatto che la matrice I sia definita positiva garantisce che la log-verosimiglianza sia strettamente concava sotto legame canonico, quindi che, qualora esista, il punto stazionario sia l'unico massimo globale. L'esistenza del massimo richiede condizioni sui dati, e l'argomento verrà affrontato soprattutto nel Capitolo 3.




Figura 1.4: Convergenza dell'Algoritmo IRLS ad una variabile. La funzione obiettivo viene approssimata tramite una parabola ad ogni iterazione.

Esempio (IRLS per la regressione logistica). Come caso particolare, si considera il modello di regressione logistica binaria, dove $Y_i \sim \text{Bin}(n_i, \pi_i)$ e la funzione legame è quella logistica $g(\mu_i) = \log(\pi_i/(1 - \pi_i))$ (questo esempio è stato preso da [Agresti \(2013, Sez. 5.5.4\)](#)). La stima di massima verosimiglianza di β si ottiene tramite l'algoritmo IRLS.

In questo caso, le equazioni di aggiornamento scalare assumono la forma:

$$\pi_i^{(t)} = \frac{\exp\left(\sum_{j=1}^p \beta_j^{(t)} x_{ij}\right)}{1 + \exp\left(\sum_{j=1}^p \beta_j^{(t)} x_{ij}\right)},$$

da cui si ricavano i pesi $W^{(t)}$ pari ad una matrice diagonale con elementi $W_{i,i}$ pari a $[n_i \pi_i^{(t)} (1 - \pi_i^{(t)})]$. Le pseudorisposte saranno invece:

$$z_i^{(t)} = \log \frac{\pi_i^{(t)}}{1 - \pi_i^{(t)}} + \frac{y_i - n_i \pi_i^{(t)}}{n_i \pi_i^{(t)} (1 - \pi_i^{(t)})}.$$

Ad ogni iterazione t la stima aggiornata è quindi:

$$\hat{\beta}^{(t+1)} = (X^T W^{(t)} X)^{-1} X^T W^{(t)} \mathbf{z}^{(t)},$$

e l'algoritmo itera fino a convergenza, restituendo lo stimatore di massima verosimiglianza $\hat{\beta}$. Come ulteriore risultato, si può ottenere che la matrice di informazione di Fisher valutata in $\hat{\beta}$ sarà pari a,

$$\hat{I} = X^T \hat{W} X, \quad \hat{W} = \text{Diag}[n_i \hat{\pi}_i (1 - \hat{\pi}_i)].$$

Grazie a ciò si ottiene che $\widehat{\text{Var}}(\hat{\beta}) = \hat{I}^{-1}$, che è dunque un prodotto naturale dell'algoritmo stesso.

Capitolo 2

Modelli di Analisi dei Campioni a Coppie

Nel presente capitolo si introducono i principali strumenti per l'analisi di dati categoriali (soprattutto su binari) ottenuti da osservazioni accoppiate e le rispettive proprietà. Sebbene modelli Bradley-Terry introdotti in questa parte e trattati più a fondo nel Capitolo 3 siano un'estensione solamente di alcuni di questi modelli, condividono con ognuno di essi l'uso della medesima struttura logistica, una simile stima per massima verosimiglianza e le basi teoriche per comprendere più a fondo il tema. Infatti alcune proprietà come simmetria e concordanza introdotte in questo capitolo sono parte del contesto utile per comprendere la modellazione delle preferenze e dei ranking mediante confronti binari. Nelle seguenti sezioni, si seguirà la notazione di [Agresti \(2013\)](#), a cui va riconosciuto il merito e al quale si rimanda per ulteriori chiarimenti sugli argomenti presentati.

2.1 Confronto di Proporzioni

Il primo metodo, il più rudimentale di quelli proposti, sarà l'analisi di matrici di contingenza per campioni accoppiati con risposta binaria, grazie alle differenze nelle distribuzioni marginali delle classi. Questo genere di risultati occorrono comunemente all'interno di studi longitudinali, cioè nei quali si osservano gli stessi soggetti lungo un lasso di tempo, o di studi "CASE-CONTROL", cioè all'interno dei quali si accoppiano un soggetto che presenta la caratteristica sotto esame (chiamato "CASE") con un soggetto che non la presenta (chiamato "CONTROL"). Ad esempio si potrebbe accoppiare un soggetto malato di Alzheimer con uno sano. Questo rende più semplice comprendere l'effetto delle covariate di interesse sulle distribuzioni congiunte e marginali del campione (per esempio, l'effetto di una particolare dieta, il risultato di un certo trattamento etc.). Storicamente parlando, la creazione di coppie o più in generale di gruppi di soggetti con caratteristiche omogenee

al loro interno, adatte per il confronto, è dovuta alla necessità di riduzione della variabilità residua, problema di particolare interesse negli studi di trattamenti medici e agricoli. Uno dei primi esempi di applicazione di raggruppamento può essere il confronto fra efficienze di colture per un determinato terreno, presentato in Fisher (1935), dove questa idea viene in particolare discussa nei capitoli IV e V. Fisher espone come la divisione in porzioni di terreno con caratteristiche del suolo simili all'interno ed eterogenee fra di esse permette di spiegare parte della variabilità residua. Questo consente di isolare l'effetto dell'efficienza del trattamento o della coltura in questione, ed ottenere risultati indipendenti, per quanto possibile, dalle caratteristiche di poco interesse della popolazione (in questo caso ad esempio la fertilità dei lotti di terreno, le differenze in consistenza, la presenza di insetti etc).

2.1.1 Differenze e Intervalli di Confidenza

Si consideri un campione di n coppie di unità statistiche. Per una coppia generica, si definisce $\pi_{ab} = \mathbb{P}(Y_1 = a, Y_2 = b)$, con $a, b \in \{0, 1\}$, la probabilità congiunta che la prima risposta assuma valore a e la seconda assuma valore b . Naturalmente queste quantità saranno tali per cui $\sum_a \sum_b \pi_{ab} = 1$. Si definisca n_{ab} come il numero di coppie con risposte $Y_1 = a, Y_2 = b$. I conteggi n_{ab} verranno trattati come un'estrazione da una legge con distribuzione multinomiale $Mult(n, \boldsymbol{\pi})$, dove il vettore $\boldsymbol{\pi}$ contiene le probabilità π_{ab} . Si definisca infine p_{ab} come la proporzione n_{ab}/n e p_{a+} come proporzione del campione con risultato di $Y_1 = a$ indipendentemente dal risultato della seconda risposta, e p_{+a} la proporzione dove $Y_2 = a$ indipendentemente dalla prima. Queste proporzioni sono definite "marginali" perché considerano la distribuzione della prima o seconda unità delle coppie. Esse, opportunamente declinate ai 4 casi ottenibili con 2 risposte binarie, descrivono completamente la distribuzione congiunta di (Y_1, Y_2) e si possono organizzare nella seguente tabella di contingenza 2.1. Per comodità e semplicità di interpretazione, si utilizzeranno i pedici 1 e 2, per rappresentare i possibili risultati, anziché a e b .

Quando i due valori marginali π_{+1} e π_{1+} sono uguali, nei casi binari, le distribuzioni marginali coincidono. Questa proprietà è chiamata "omogeneità marginale", ed è facile vedere come questo implichi anche che $\pi_{12} = \pi_{21}$, perché $\pi_{11} + \pi_{12} = \pi_{1+}$ e $\pi_{11} + \pi_{21} = \pi_{+1}$. Se si ha marginalità omogenea nei casi binari, la matrice 2×2 è simmetrica (proprietà non vera per matrici di dimensioni $I \times I$, $I > 2$, come si approfondirà nella sezione 2.3). Il confronto di distribuzione marginale si basa su $\delta = \pi_{+1} - \pi_{1+}$, ovvero la differenza fra

Tabella 2.1: Tabella delle probabilità congiunte per una coppia.

		Y_2		Totale
		1	2	
Y_1	1	π_{11}	π_{12}	π_{1+}
	2	π_{21}	π_{22}	π_{2+}
Totale		π_{+1}	π_{+2}	1

le proporzioni marginali teoriche, e sulla sua realizzazione campionaria:

$$d = p_{+1} - p_{1+} = p_{2+} - p_{+2},$$

dove la seconda uguaglianza si mostra ricordando che $1 - p_{+1} = p_{+2}$. Si può dimostrare che, ricordando il vincolo $\pi_{22} = 1 - \pi_{11} - \pi_{12} - \pi_{21}$, la varianza di d è pari a:

$$\text{Var}(\sqrt{n}d) = \pi_{1+}(1 - \pi_{1+}) + \pi_{+1}(1 - \pi_{+1}) - 2(\pi_{11}\pi_{22} - \pi_{12}\pi_{21}). \quad (2.1)$$

Per campioni sufficientemente grandi, in quanto differenza fra due proporzioni che seguono distribuzioni binomiali, d tende a distribuirsi come una normale. Conoscere la distribuzione della quantità ci permette anche di ottenere un intervallo di confidenza e di testare ipotesi.

2.1.2 Test per l'Omogeneità Marginale

Si procede con la costruzione di un test per verificare l'omogeneità marginale, $H_0 : \pi_{1+} = \pi_{+1}$, che coincide con $H_0 : \delta = 0$. Sotto l'ipotesi nulla, si ha che le probabilità congiunte π_{12} e π_{21} sono uguali, ottenendo una stima della varianza pari a $\hat{\sigma}^2(d) = (p_{12} + p_{21})/n = (n_{12} + n_{21})/n^2$. Questo ci restituisce la seguente statistica test:

$$z_0 = \frac{n_{21} - n_{12}}{\sqrt{(n_{21} + n_{12})}}.$$

Questo test, se elevato al quadrato, si distribuisce come una χ_1^2 , e coincide con il test di [McNemar \(1947\)](#). Bisogna osservare che questo test dipende solamente dal numero di coppie che hanno subito un cambio della variabile risposta, e che quindi basta conoscere le quantità sull'anti-diagonale della matrice di contingenza per ottenere la significatività del test per l'omogeneità marginale. Detto ciò, le quantità concordanti n_{11}, n_{22} sono

necessarie a comprendere quanto grande è questa omogeneità. Se il numero di coppie con risultato uguale supera di molto quelle con risposte diverse, qualora si accettasse l'ipotesi di eterogeneità, essa sarebbe molto ridotta in termini relativi (il che non significa che non sia statisticamente significativa). Inoltre tutte le osservazioni contribuiscono alla varianza delle proporzioni, perché essa tiene conto della somma di tutte le possibili n coppie, non solo di quelle discordi.

La problematicità legata alla richiesta di un n sufficientemente grande ha portato anche allo sviluppo di un test valido per campioni di dimensione ridotta. Infatti l'ipotesi nulla coincide con la richiesta che $\pi_{12} = \pi_{21}$. Questo significa allora che, dato $n^* = n_{12} + n_{21}$, sotto l'ipotesi H_0 , n_{12} è distribuito come una $\text{Binom}(n^*, 1/2)$. Si può dunque ottenere un test calcolato usando la distribuzione binomiale:

$$z = \frac{n_{21} - \frac{1}{2}n^*}{\sqrt{n^* \left(\frac{1}{2}\right) \left(\frac{1}{2}\right)}},$$

e questo test ovviamente coinciderà con quello normale qualora n^* fosse sufficientemente elevato.

Un ulteriore aspetto sul quale vale la pena soffermarsi è come l'ipotesi di dipendenza migliori la precisione delle stime. Il fatto di ipotizzare una dipendenza fra le coppie (che nei casi reali è praticamente sempre positiva, cioè che $\pi_{11}\pi_{22} > \pi_{12}\pi_{21}$) rispetto alla risposta, come ad esempio nelle scelte politiche di soggetti anche a distanza di tempo, ci permette di ottenere risultati più efficienti in termini di inferenza. Infatti, l'ultima componente della varianza 2.1, che è negativa, sarebbe nulla in condizioni di indipendenza delle distribuzioni marginali. Ciò porterebbe, in casi di dipendenza positiva, ad avere intervalli di confidenza più ampi del dovuto, e naturalmente una maggiore incertezza che sarebbe fittizia. Anche nei casi di dipendenza negativa, per quanto rari, si andrebbe a sottostimare l'incertezza della stima, e maggiore la dipendenza, più grande l'errore portato dall'ipotizzare incorrelazione. Questo è in parte il perché si adopera l'accoppiamento delle unità, e più in generale il BLOCKING menzionato prima.

Una parentesi su Cochran-Mantel-Haenszel. Un'ulteriore visualizzazione del problema può avvenire tramite l'uso di n tabelle di dimensione 2×2 , ciascuna rappresentante una coppia con la propria combinazione di esiti binari. Si può ottenere dunque un test per l'indipendenza condizionata di questa nuova matrice tridimensionale di dimensione

$2 \times 2 \times n$, il Cochran-Mantel-Haenszel (o CMH) Test, che risulta numericamente uguale al McNemar. Il CMH è uno strumento particolarmente utile quando si presentano casi con variabile risposta a più classi, ed è un ulteriore metodo per affrontare il problema di confronti in un campione di osservazioni raggruppate. Ci si riferisce allo studio delle singole coppie divise in n sotto-matrici come soggetto-specifiche (“SUBJECT-SPECIFIC”), mentre se ci si riferisce allo studio del campione nel suo totale come marginale (Agresti, 2013). Generalmente parlando, i metodi che si affronteranno successivamente (in particolare con riguardo ai modelli) sono analizzabili in entrambe le metodologie, e si userà la terminologia sopra descritta per riferirsi alle rispettive situazioni. Detto ciò, la trattazione estensiva della metodologia CMH e delle sue proprietà risulta di relativo interesse per gli obiettivi di questo testo, e per una trattazione più estesa si rimanda al capitolo 6 di Agresti (2013).

2.2 Modelli Logistici per Confronti

Come introdotto nella sezione 1.2, il modello logistico descrive il valore atteso della risposta binaria tramite la funzione logit, che in quanto legame canonico della famiglia binomiale gode di proprietà già viste, ed ammette un’interpretazione semplice in termini di odds ratio. Proprio per queste caratteristiche risulta uno strumento naturale per analizzare le matrici di contingenza per risposte binarie. Si ricorda però che è teoricamente possibile adoperare un qualsiasi legame anche non canonico per queste analisi (perdendo però parte dei risultati presentati). I primi modelli che si affronteranno saranno i più generali, ma si introdurranno anche varianti più specifiche adatte a situazioni più complesse.

2.2.1 Modello Marginale e Stime di Massima Verosimiglianza

Definendo Y_{i1} e Y_{i2} le risposte per la i -esima osservazione, si può procedere provando a modellare la probabilità di successo della singola osservazione, ovvero $\mathbb{P}(Y_{it} = 1)$, oppure la media di questi valori, denotata con $\mathbb{P}(Y_t = 1)$. Ci si riferisce al secondo modello con l’aggettivo marginale, e formalmente risulta essere pari a:

$$\text{logit}[\mathbb{P}(Y_t = 1)] = \alpha + \beta x_t. \quad (2.2)$$

L’interpretazione del parametro β indica quanto il predittore lineare viene modificato al variare di t , ed è legato al parametro della media tramite il log-odds, cioè se $\text{odds}(Y_1 =$

$1) = c$, allora $\text{odds}(Y_2 = 1) = ce^\beta$. Il modello è anche saturo (2 valori per 2 parametri). La verosimiglianza esatta del campione è quella di un'unica multinomiale sulle quattro celle della tabella 2×2 ($n_{11}, n_{10}, n_{01}, n_{00}$), e non il prodotto di due binomiali indipendenti su Y_1 e Y_2 . Poiché il modello marginale (2.2) è saturo, il suo punto di massimo coincide esattamente con quello della verosimiglianza ottenuta assumendo indipendenza corretta. Le stime di α e β sono dunque valide, mentre gli errori standard ricavati da $\ell(\beta, \alpha)$ non lo sono.

$$\text{logit}(\mathbb{P}(Y_t = 1)) = \alpha + \beta x_t \quad \beta = \text{logit}(\mathbb{P}(Y_2 = 1)) - \text{logit}(\mathbb{P}(Y_1 = 1)). \quad (2.3)$$

Detto ciò, i veri valori dei π_t non sono noti a priori. Si utilizzano dunque le loro stime di massima verosimiglianza, che si ottengono massimizzando la log-verosimiglianza. È noto che la formula generale della verosimiglianza per due binomiali indipendenti sarà uguale al prodotto delle singole verosimiglianze, quindi in logaritmo sarà pari alla somma delle singole log-verosimiglianze:

$$\ell(\beta, \alpha) = n_{1+} \log(\pi_{1+}) + (n - n_{1+}) \log(1 - \pi_{1+}) + n_{+1} \log(\pi_{+1}) + (n - n_{+1}) \log(1 - \pi_{+1}),$$

dove π_{1+} sarà la probabilità di successo per Y_1 , cioè $\mathbb{P}(Y_1 = 1)$, e π_{+1} sarà quella di Y_2 , cioè $\mathbb{P}(Y_2 = 1)$. Sostituendo le probabilità invertendo la relazione 2.3, ovvero $\mathbb{P}(Y_t = 1) = \exp(\alpha + \beta x_t) / [1 + \exp(\alpha + \beta x_t)]$, si ottiene che la verosimiglianza sarà pari a:

$$\ell(\beta, \alpha) = n_{1+}(\alpha) + n_{+1}(\alpha + \beta) - n \log(1 + \exp(\alpha)) - n \log(1 + \exp(\alpha + \beta)).$$

Derivando la verosimiglianza per i due parametri, si otterrà il sistema:

$$\begin{cases} \frac{\partial \ell}{\partial \beta} = n_{+1} - n \left[\frac{\exp(\alpha + \beta)}{1 + \exp(\alpha + \beta)} \right] = 0, \\ \frac{\partial \ell}{\partial \alpha} = n_{1+} + n_{+1} - n \left[\frac{\exp(\alpha)}{1 + \exp(\alpha)} \right] - n \left[\frac{\exp(\alpha + \beta)}{1 + \exp(\alpha + \beta)} \right] = 0. \end{cases}$$

Risolvendo entrambe le equazioni del sistema sostituendo le rispettive probabilità, si ottiene che

$$\hat{\pi}_{+1} = \hat{p}_{+1}, \quad \hat{\pi}_{1+} = \hat{p}_{1+}.$$

Utilizzando dunque le proporzioni empiriche invece delle probabilità teoriche, si ottiene che:

$$\hat{\beta} = \text{logit}(p_{+1}) - \text{logit}(p_{1+}) = \log \left(\frac{p_{+1}p_{2+}}{p_{1+}p_{+2}} \right).$$

Questo modello, essendo riassuntivo e modellizzando la media, non sfrutta la possibile informazione nella singola coppia. Per tenere conto di questa ulteriore informazione si può adoperare il secondo modello, quello soggetto-specifico.

2.2.2 Modello Soggetto-Specifico e Stime di Massima Verosimiglianza

Il modello soggetto-specifico, al contrario di quello marginale, permette di modellare le probabilità di successo e fallimento per ogni singola coppia. Per fare ciò si stima il coefficiente α per ogni accoppiamento, dunque il modello risulta essere:

$$\text{logit}[\mathbb{P}(Y_{it} = 1)] = \alpha_i + \beta x_t, \quad (2.4)$$

dove ogni coppia ha quindi la propria intercetta. In questo secondo modello, il parametro β è universale, cioè l'effetto della presenza o assenza della covariata ha un effetto costante nel modello, ma quanto essa impatta la singola coppia dipende dal parametro α_i . Infatti, maggiore il valore assoluto di α_i , minore è l'impatto relativo di β sul predittore lineare. Se frequentemente gli α_i sono molto elevati, e quindi la $\mathbb{P}(Y_{i1} = 1)$ risultasse relativamente alta, allora, ipotizzando un valore di β modesto, la $\mathbb{P}(Y_{i2} = 1)$ non sarà molto diversa. Si riesce a tenere dunque in considerazione una correlazione universale fra le osservazioni, malgrado ogni coppia e ogni risultato interno alla coppia (dunque di ogni Y_{it}) vengano trattati come indipendenti. È inoltre evidente che, grazie alla non linearità del valore atteso, che ci permette di dire che la media di funzioni non costanti è diversa rispetto alla funzione calcolata nella media, si ottiene che:

$$\mathbb{E} \left(\frac{e^{\alpha_i + \beta x_t}}{1 + e^{\alpha_i + \beta x_t}} \right) \neq \frac{e^{\alpha + \beta x_t}}{1 + e^{\alpha + \beta x_t}},$$

dove la seconda è il calcolo dei coefficienti rispetto al valore atteso delle probabilità, ovvero il risultato del modello marginale. Dato l'elevato numero di parametri α_i da stimare, risulta particolarmente difficile ottimizzare la funzione. Per ovviare al problema si può rendere essenzialmente irrisoria la loro stima ai fini della verosimiglianza profilo rispetto a β , utilizzando la loro statistica sufficiente, come si vedrà a breve. La funzione di

probabilità congiunta del campione, assumendo indipendenza delle risposte Y_{it} , sarà pari a:

$$\prod_{i=1}^n \left[\frac{\exp(\alpha_i)}{1 + \exp(\alpha_i)} \right]^{y_{i1}} \left[\frac{1}{1 + \exp(\alpha_i)} \right]^{1-y_{i1}} \left[\frac{\exp(\alpha_i + \beta)}{1 + \exp(\alpha_i + \beta)} \right]^{y_{i2}} \left[\frac{1}{1 + \exp(\alpha_i + \beta)} \right]^{1-y_{i2}}.$$

Questa quantità risulta essere proporzionale ad:

$$\exp \left[\sum_{i=1}^n \alpha_i (y_{i1} + y_{i2}) + \beta \left(\sum_{i=1}^n y_{i2} \right) \right].$$

Per eliminare i parametri “NUISANCE” (ovvero di disturbo) α_i , che sono problematici e rendono distorta la stima dei β (la motivazione di questo va oltre gli scopi principali dell’elaborato, e per una trattazione più estensiva si rimanda all’appendice A.2) si può usare la loro statistica sufficiente, il numero totale di successi osservati, $S_i = y_{i1} + y_{i2}$. L’intuizione sul perché di questo fenomeno risulta particolarmente elegante. Se le coppie hanno un totale pari a 0, ciò implica che la coppia è congruente in termini di risposta e che $P(Y_{i1} = Y_{i2} = 0) = 1$, ed il parametro β è completamente assente. Qualora $S_i = 2$, si ottengono sempre entrambi i parametri e si potrà ottenere due costanti che modellano perfettamente le probabilità, ma non si hanno gradi di libertà residui. Si può verificare tutto ciò anche nella verosimiglianza, dove in casi di risposte concordanti si semplifica tutto nell’equazione e la verosimiglianza della coppia diventa pari a 1, il che significa che il contributo della coppia è nullo. L’unico caso in cui entra in gioco la quantità β è qualora $S_i = 1$, cioè solo nei casi di un cambio di risposta nella coppia. Quindi si può calcolare la probabilità condizionata a questo evento, ovvero $P(Y_{i1} = y_{i1}, Y_{i2} = y_{i2} | S_i = 1)$. Questa quantità sarà pari a:

$$\begin{aligned} & \frac{P(Y_{i1} = y_{i1}, Y_{i2} = y_{i2})}{P(Y_{i1} = 1, Y_{i2} = 0) + P(Y_{i1} = 0, Y_{i2} = 1)} = \\ & = \frac{\left[\frac{\exp(\alpha_i)}{1 + \exp(\alpha_i)} \right]^{y_{i1}} \left[\frac{1}{1 + \exp(\alpha_i)} \right]^{1-y_{i1}} \left[\frac{\exp(\alpha_i + \beta)}{1 + \exp(\alpha_i + \beta)} \right]^{y_{i2}} \left[\frac{1}{1 + \exp(\alpha_i + \beta)} \right]^{1-y_{i2}}}{\frac{\exp(\alpha_i)}{1 + \exp(\alpha_i)} \frac{1}{1 + \exp(\alpha_i + \beta)} + \frac{\exp(\alpha_i + \beta)}{1 + \exp(\alpha_i + \beta)} \frac{1}{1 + \exp(\alpha_i)}}. \end{aligned}$$

Semplificando numeratore e denominatore, si può ottenere che l'equazione risulta pari a:

$$\begin{cases} \exp(\beta)/[1 + \exp(\beta)], & \text{se } y_{i1} = 0, y_{i2} = 1, \\ 1/[1 + \exp(\beta)], & \text{se } y_{i1} = 1, y_{i2} = 0. \end{cases} \quad (2.5)$$

Il numero di coppie dove $S_i = 1$, ovvero delle coppie in cui le risposte sono differenti in $t \in \{1, 2\}$, saranno pari a $n^* = n_{12} + n_{21}$. Sapendo però che n_{21} segue una distribuzione $\text{Binom}(n^*, \exp(\beta)/[1 + \exp(\beta)])$, dove dunque n_{12} sono gli insuccessi con probabilità $1/[1 + \exp(\beta)]$, si nota come l'unico parametro caratterizzante risulta essere β . Si osserva dunque che, similmente al test di McNemar per l'omogeneità marginale, anche in questo caso conoscere le coppie concordanti non influisce sulla stima effettiva di β . La distribuzione di probabilità congiunta risulta essere dunque:

$$\prod_{S_i=1} \left[\frac{1}{1 + \exp(\beta)} \right]^{n_{12}} \left[\frac{\exp(\beta)}{1 + \exp(\beta)} \right]^{n_{21}} = \frac{[\exp(\beta)]^{n_{21}}}{[1 + \exp(\beta)]^{n^*}}.$$

Si procede ad ottenere il risultato della stima di massima verosimiglianza per il parametro β e il suo errore standard.

$$\frac{\partial \ell}{\partial \beta} = \frac{[\exp(\beta)][n_{21} \exp^{n_{21}-1}][1 + \exp(\beta)]^{n^*} - n^*[1 + \exp(\beta)]^{n^*-1}[\exp(\beta)][\exp(\beta)^{n_{21}}]}{[1 + \exp(\beta)]^{2n^*}}.$$

Raccogliendo il coefficiente $[1 + \exp(\beta)]^{n^*-1}$, semplificando ed eliminando le costanti e il denominatore, sempre diversi da 0, si ottiene che:

$$\frac{\partial \ell}{\partial \beta} = n_{21} - n_{12} \exp(\beta) = 0.$$

Grazie a questo è possibile ottenere la stima e dimostrare matematicamente che dipende solamente dalle coppie discordanti, ovvero:

$$\hat{\beta} = \log \left(\frac{n_{21}}{n_{12}} \right). \quad (2.6)$$

L'informazione attesa di Fisher risulta invece essere pari a:

$$I = -\mathbb{E} \left(\frac{\partial}{\partial \beta} \frac{[n_{21} + n_{12}] \exp(\beta)}{1 + \exp(\beta)} \right).$$

Sostituendo $\exp(\beta)$ con la stima di massima verosimiglianza, si ottiene che:

$$\hat{I} = (n_{21} + n_{12}) \left(\frac{n_{21}/n_{12}}{[1 + n_{21}/n_{12}]^2} \right),$$

mentre la stima di massima verosimiglianza dell'errore standard asintotico sarà pari alla radice dell'inversa dell'informazione di Fisher (ed il perché di questo è stato affrontato in 2.1.2):

$$\hat{SE} = \frac{1}{\sqrt{\hat{I}}} = \sqrt{\frac{1}{n_{12}} + \frac{1}{n_{21}}}. \quad (2.7)$$




Figura 2.1: Confronto fra modello soggetto-specifico e marginale in Probabilità (a sinistra) e in scala Logit (a destra) rispetto a dati simulati. Si noti come nel secondo grafico le rette del modello soggetto-specifico sono parallele, perché l'effetto del parametro β resta costante fra le osservazioni, malgrado ciò può non essere chiaro dalla prima figura. Infatti, nel primo grafico, si può notare che più elevato il valore assoluto del parametro α_i , minore l'impatto percepito del parametro β . Il motivo di ciò è esposto nella Sezione 2.2.2

Gli studi Caso-Controllo e i Modelli Condizionali Come già definito prima, gli studi Caso-Controllo permettono alle coppie di non riferirsi alla medesima unità statistica, ma anzi permettono di unire osservazioni con una risposta diversa, per osservare il possibile effetto di una covariata x rispetto alla variabile che si ritiene essere dipendente (per esempio, accoppiare pazienti affetti da una malattia cardio-vascolare con pazienti sani ed osservarne la relazione rispetto ai livelli di attività fisica). In questo modo, si ottiene

il modello definito condizionale, matematicamente identico a quanto visto nella sezione 2.2.2:

$$\text{logit}[\mathbb{P}(Y_{it} = 1)] = \alpha_i + \beta x_{it}.$$

In questo caso, malgrado non si abbiano informazioni sulla distribuzione della variabile indipendente, si riesce comunque ad ottenere una stima della relazione fra risposta e covariata. Anche in questo caso, per le coppie concordanti, la variabile dipendente sarà uguale $y_{i1} = y_{i2}$, e dunque non utili ai fini della stima di β . Anche in questo caso quindi sono solo le coppie discordi che ci permettono di riconoscere la presenza di un'eterogeneità significativa (che non significa per forza con un valore elevato), e quindi di un effetto della covariata circa la risposta.

2.2.3 Casi Particolari di Modelli Multivariati

Una generalizzazione dei modelli appena affrontati saranno i modelli logistici soggetto-specifici con multipli regressori. Quando si hanno p covariate, il modello diventa:

$$\text{logit}[P(Y_i = 1)] = \alpha_i + \beta_1 x_{1it} + \beta_2 x_{2it} + \cdots + \beta_p x_{pit}, \quad (2.8)$$

dove x_{pit} sarà il valore della variabile p nella i -esima coppia per la t -esima osservazione. Lo studio di questi modelli risulta naturalmente più complicato di quelli appena visti. Tipicamente però si è interessati all'effetto di una singola variabile sul predittore lineare, cioè al singolo β_j . Si ponga di avere un caso in cui i due vettori $\mathbf{x}_{i1}$ e $\mathbf{x}_{i2}$ differiscono solamente per il j -esimo valore. Inoltre, anche in questo caso, si vuole eliminare la stima degli α_i tramite la loro statistica sufficiente. Il risultato in massima verosimiglianza è molto simile al caso affrontato precedentemente, ed è ottenuto tramite una generalizzazione di quanto visto in 2.5, ovvero:

$$P(Y_{i1} = 0, Y_{i2} = 1 | S_i = 1) = \exp(\mathbf{x}_{i2}^T \boldsymbol{\beta}) / [\exp(\mathbf{x}_{i1}^T \boldsymbol{\beta}) + \exp(\mathbf{x}_{i2}^T \boldsymbol{\beta})],$$

$$P(Y_{i1} = 1, Y_{i2} = 0 | S_i = 1) = \exp(\mathbf{x}_{i1}^T \boldsymbol{\beta}) / [\exp(\mathbf{x}_{i1}^T \boldsymbol{\beta}) + \exp(\mathbf{x}_{i2}^T \boldsymbol{\beta})].$$

Dividendo a numeratore e denominatore per $\exp(\mathbf{x}_{i1}^T \boldsymbol{\beta})$, si riottengono praticamente le medesime stime di massima verosimiglianza viste in 2.5, infatti:

$$\begin{cases} \exp(\beta_j)/[1 + \exp(\beta_j)], & \text{se } y_{i1} = 0, y_{i2} = 1, \\ 1/[1 + \exp(\beta_j)], & \text{se } y_{i1} = 1, y_{i2} = 0, \end{cases} \quad (2.9)$$

dove $\mathbf{x}^* = \mathbf{x}_{i2} - \mathbf{x}_{i1} = \mathbf{e}_j$, ovvero il j -esimo vettore della base canonica, che ci consente di semplificare tutte le variabili non rilevanti e ad isolare l'effetto della j -esima componente sulla variabile risposta. Per esempio, in uno studio Caso-Controllo si può costruire la variabile fantoccio $y^* = y_{i2} - y_{i1}$, che sarà sempre uguale a 1 per costruzione, siccome i casi hanno la presenza della risposta e i controlli no. Allora la variabile indipendente sarà sempre pari a $\mathbf{x}^* = 0$ nei casi concordanti (cioè dove non è cambiata la covariata) e pari a $\{-1, 1\}$ nei casi discordanti, permettendoci di ottenere le corrette stime di β_j in maniera relativamente semplice, malgrado la presenza di molteplici parametri ed un modello più complesso.

L'ultimo modello che viene considerato è quello proposto da [Chamberlain \(1980\)](#) per la stima di ML per coppie appaiate. Infatti nei modelli soggetto-specifici visti finora, il parametro α_i si riferisce alla singola coppia (o più generalmente all'insieme). Esempi di insiemi possono essere molteplici misurazioni sul soggetto i , oppure un cluster di soggetti, come bambini di un nucleo familiare. In questi casi però la stima riesce a quantificare solo l'effetto interno al gruppo. La verosimiglianza soggetto-specifica non riesce dunque a stimare un effetto fra gruppi, cioè relativo a una variabile esplicativa che è costante in t per ogni gruppo ma diversa fra gruppi. Tale variabile si cancella direttamente nella verosimiglianza, perché se $x_{ji1} = x_{ji2}$ per ogni i , il contributo della variabile scompare. Questo problema si può risolvere, ma la soluzione risulta troppo articolata ai fini del presente lavoro, e si rimanda a [Agresti \(2013\)](#) per una trattazione più estesa dell'argomento.

2.2.4 Modelli Marginali per Matrici di Contingenza Quadrate

Naturalmente i modelli affrontati per matrici di contingenza di dimensione 2×2 , e dunque con risposte binarie, possono estendersi a modelli con $I > 2$, ovvero con generiche risposte nominali. Questo genere di modelli verrà affrontato in maniera meno estensiva rispetto a quelli appena visti, ma vale la pena osservarli perché sono la loro naturale estensione. In questi casi la matrice di contingenza sarà di dimensione $I \times I$ e la quantità n_{ab} mostra

il numero di coppie dove $Y_{i1} = a$ e $Y_{i2} = b$, con $a, b \in \{1, 2, \dots, I\}$. Il primo genere di modelli presentati è il modello contenente la baseline:

$$\log \left[\frac{\mathbb{P}(Y_t = j)}{\mathbb{P}(Y_t = I)} \right] = \alpha_j + \beta_j x_t. \quad (2.10)$$

In questo genere di modello la I -esima categoria funge da baseline, ovvero da riferimento rispetto al quale sono espressi tutti i coefficienti. Ogni α_j è il log-odds della categoria j -esima rispetto alla baseline. Questa estensione permette essenzialmente di trattare ogni coppia di classi j, I come una propria tabella di dimensioni 2×2 , ottenendo di fatto il modello marginale 2.2. Per costruzione si fissa $\alpha_I = 0$, cosicché gli odds della baseline rispetto a sé stessa valgono $\exp(\alpha_I) = 1$ e costituiscono il termine di paragone. Se ad esempio $\alpha_j = 0.5$, allora $\pi_j/\pi_I = \exp(0.5)$. Ogni confronto è dunque in riferimento alla baseline, pur restando possibile recuperare quello diretto fra due categorie qualsiasi j e k come $\alpha_j - \alpha_k$. Questo modello è inoltre saturo, perché vengono calcolati $2(I - 1)$ parametri per i $2(I - 1)$ valori delle marginali da ottenere. La stima dei parametri di questo modello risulta ottenibile solamente in forma numerica tramite la massimizzazione della verosimiglianza. Anche nei modelli a risposte multiple si possono adoperare test di ipotesi per verificare l'omogeneità marginale, equivalente ad accettare l'ipotesi nulla $H_0 : \beta_j = 0$, $j = 1, \dots, I - 1$. Per testare questa ipotesi si presentano 3 test differenti, tutti quanti con $I - 1$ gradi di libertà:

- Il primo, proposto da [Madansky \(1963\)](#), ottiene la direzione di crescita maggiore e permette all'algoritmo di trovare un punto di massimo lungo i vincoli dell'ipotesi nulla. Una volta ottenute $\hat{\mu}_{ab}$ tramite ottimizzazione della funzione di Score (sotto opportuni vincoli), che sono stime dei conteggi n_{ab} , si adopera un test di massima verosimiglianza per testare l'ipotesi. Se l'ottimo del modello non vincolato non è significativamente più elevato dell'ottimo vincolato, il modello accetta l'ipotesi di omogeneità marginale.
- Il secondo è di [Stuart \(1955\)](#), che ha proposto un test di Wald che sfrutta la normalità asintotica della differenza di due normali, dove la varianza è calcolata sotto l'ipotesi di omogeneità marginale:

$$W = n\hat{d}^T \hat{V}_0^{-1} \hat{d}.$$

- L'ultimo test presentato si basa sul lavoro di Bhapkar (1966), che riprende la struttura del del secondo test. In questo caso però la stima della matrice di varianza viene calcolata con $\hat{\mathbf{V}}^{-1}$, che adopera le proporzioni osservate p_{kl} , $k, l = 1, \dots, I - 1$. Chiamando $\hat{\mathbf{d}}^T$ il vettore contenente le $I - 1$ differenze fra proporzioni osservate $\hat{d}_k = p_{+k} - p_{k+}$, e sapendo che sotto ipotesi nulla $\mathbb{E}(\hat{d}_k) = 0$, si ottiene che:

$$W = n\hat{\mathbf{d}}^T\hat{\mathbf{V}}^{-1}\hat{\mathbf{d}}.$$

2.2.5 Modelli Ordinali per Matrici di Contingenza

Le variabili categoriali non si dividono soltanto in nominali e binarie: esiste una terza classe, quella delle variabili ordinali, in cui le categorie possiedono un ordine. Ignorare questa struttura equivale a perdere un'informazione chiave delle risposte, ed è dunque importante vedere come trattare questi casi. Per risposte ordinali con I categorie, il modello per coppie appaiate diventa:

$$\text{logit}[\mathbb{P}(Y_t \leq j)] = \alpha_j + \beta x_t, \quad t = 1, 2, \quad j = 1, \dots, I - 1, \quad (2.11)$$

dove $x_1 = 0$ e $x_2 = 1$ indicano il primo e il secondo soggetto o periodo di rilevazione. I parametri α_j sono le intercette dette “cumulative”, e monotone crescenti per costruzione. Infatti se si avesse una certa $\mathbb{P}(Y_t \leq j)$, allora $\mathbb{P}(Y_t \leq j + 1)$ sarà almeno pari se non maggiore. Il parametro β è invece universale per tutte le soglie e cattura una sorta di effetto globale della covariata. L'interpretazione di β è leggermente diversa dal solito, infatti gli odds che $Y_2 \leq j$ risultano pari a e^β volte gli odds che $Y_1 \leq j$. La difficoltà principale di questo modello risiede nella stima. A differenza dei modelli binari visti precedentemente infatti non è possibile ottenere una soluzione in forma chiusa per l'ottimizzazione della verosimiglianza:

$$\ell(\boldsymbol{\alpha}, \beta) = \sum_{a=1}^I \sum_{b=1}^I n_{ab} \log \pi_{ab}.$$

Ciò avviene perché Y_1 e Y_2 sono dipendenti e non fattorizzabili. Poiché le π_{ab} non hanno soluzione in forma chiusa, la stima richiede l'uso degli ormai noti algoritmi iterativi numerici, come varianti dell'algoritmo di Newton-Raphson. Il modello 2.11 descrive $2(I - 1)$ probabilità marginali tramite I parametri (le $I - 1$ intercette più β), ottenendo dunque $I - 2$ gradi di libertà per il test di bontà di adattamento del modello alle marginali osser-

vate. Per una trattazione più completa della stima e dei test associati a questo modello, che risultano troppo lontani dagli obiettivi di questa tesi, si rimanda al capitolo 12 di [Agresti \(2013\)](#).

2.3 Simmetria, Quasi-Simmetria e Quasi-Indipendenza

L'analisi delle matrici di contingenza, e in particolare delle loro probabilità congiunte, può essere condotta anche senza l'uso del modello logistico, nel quale una variabile viene designata come risposta e le altre come esplicative. Si presenta infatti il modello log-lineare, che va a modellare le probabilità congiunte partendo dalle interazioni fra le variabili. In questo caso infatti non si distingue una risposta da un predittore, ma sono i termini di associazione a catturare la dipendenza fra le variabili. Questo meccanismo è utile per analizzare, tramite opportune ipotesi sui parametri del modello, la matrice di contingenza rispetto alle proprietà di simmetria e indipendenza. Esse ci danno informazioni importanti nei contesti di soggetti accoppiati perché strettamente legate alle asimmetrie dei dati e dei risultati e indipendenti dalle caratteristiche delle variabili indipendenti.

2.3.1 Simmetria

La prima proprietà che si analizzerà è la più semplice, la simmetria. Essa è soddisfatta se, per una qualsiasi matrice di dimensioni $I \times I$, vale che:

$$\pi_{ab} = \pi_{ba}, \quad \forall a, b \in \{1, 2, \dots, I\}$$

Si può interpretare questa proprietà come un'assenza di preferenza delle categorie da parte del modello. Sotto simmetria si avrà sempre omogeneità marginale, perché i risultati di riga e colonna devono coincidere per costruzione della proprietà. Ma, se nelle matrici di contingenza di dimensione 2×2 queste due proprietà coincidono, perché i conteggi interni non hanno più libertà una volta fissati i totali marginali e i valori sulla colonna, nelle matrici di dimensione $I > 2$ si può avere omogeneità marginale anche senza simmetria. A tal fine, si introdurrà successivamente una proprietà meno stringente sulle ipotesi per matrici di dimensioni maggiori a 2×2 . Il fenomeno della simmetria può essere analizzato modellando le frequenze attese μ_{ab} tramite un modello log-lineare, ed in generale tutte le proprietà osservate possono essere viste come ipotesi rispetto a determinate restrizioni sui

modelli log-lineari. In questo caso, il modello simmetrico sarà specificato come:

$$\log(\mu_{ab}) = \lambda + \lambda_a + \lambda_b + \lambda_{ab}.$$

Questo modello risulta essere pari ad un GLM che adopera il link canonico della distribuzione di Poisson. Risulta importante, prima di procedere, comprendere i parametri in gioco. La quantità λ corrisponde all'intercetta del modello ed è il valore di base dal quale partono tutte le probabilità congiunte. λ_a e λ_b rappresentano rispettivamente gli effetti riga e colonna. Nel modello log-lineare generale questi due effetti sono distinti, poiché le distribuzioni marginali di righe e colonne possono differire. Tuttavia, sotto l'ipotesi di simmetria, questi due effetti coincidono e pertanto i rispettivi parametri sono equivalenti. Formalmente:

$$\lambda_a^{(R)} = \lambda_a^{(C)}.$$

In altre parole, una stessa categoria del risultato produce lo stesso effetto sia quando compare come riga sia quando compare come colonna. Questo riflette il fatto che il modello non privilegia alcuna direzione nella classificazione. Il modo in cui agiscono queste quantità è modificando moltiplicativamente il valore di base e^λ in base al livello medio di frequenze della riga. Se le proporzioni della riga k sono sistematicamente più elevate del resto del modello, questo effetto è espresso dal rispettivo coefficiente, ed il valore per la riga diventerà pari a $e^{(\lambda+\lambda_k)}$. Infine la quantità λ_{ab} coincide con la relazione che le due risposte hanno. Questo parametro è la chiave della simmetria, perché se $\lambda_{ab} = \lambda_{ba}$ ciò significa che non importa l'ordine di riga e colonne, e che la singola probabilità dipende solo da queste informazioni, non dal confronto singolo. Inoltre, per le caratteristiche menzionate prima, si ottiene che in simmetria $\log(\mu_{ab}) = \log(\mu_{ba})$. Le stime di massima verosimiglianza vengono ottenute tramite ottimizzazione grazie alla Lagrangiana. La log-verosimiglianza del modello risulta essere pari a:

$$\ell(\boldsymbol{\pi}) = \log(n!) - \sum_{a=1}^I \sum_{b=1}^I \log(n_{ab}!) + \sum_{a=1}^I \sum_{b=1}^I n_{ab} \log(\pi_{ab}).$$

In questo caso vengono modellate le probabilità $\boldsymbol{\pi}$ tramite la multinomiale anziché i valori $\boldsymbol{\mu}$, e questo usando la distribuzione Poisson. Questo è stato per una questione di continuità rispetto alla sezione prima. In ogni caso le stime di questi valori, qualsiasi sia il metodo scelto, risultano numericamente identiche, cambiano solo di una costante, infatti

$\mu_{ab} = n\pi_{ab}$, dunque se $\pi_{ab} = \pi_{ba}$ equivale a $\mu_{ab} = \mu_{ba}$. Dunque al netto di costanti si ha che la verosimiglianza risulta pari a, sotto ipotesi di simmetria:

$$= \sum_{a=1}^I n_{aa} \log(\pi_{aa}) + \sum_{a < b} \left[n_{ab} \log \pi_{ab} + n_{ba} \log(\pi_{ba}) \right] = \log(\pi_{aa}) + \sum_{a=1}^I \sum_{a < b} (n_{ab} + n_{ba}) \log(\pi_{ab}).$$

Adesso si procede ottimizzando la verosimiglianza vincolata rispetto alla somma delle probabilità $\sum_{a=1}^I \pi_{aa} + 2 \sum_{a=1}^I \sum_{b=a+1}^I \pi_{ab} = 1$. Derivando e sostituendo nel vincolo, si ottiene che:

$$\begin{cases} \frac{\partial \ell}{\partial \pi_{aa}} = \frac{n_{aa}}{\pi_{aa}} - \lambda = 0 \Rightarrow \pi_{aa} = \frac{n_{aa}}{\lambda}, \\ \frac{\partial \ell}{\partial \pi_{ab}} = \frac{n_{ab} + n_{ba}}{\pi_{ab}} - 2\lambda = 0 \Rightarrow \pi_{ab} = \frac{n_{ab} + n_{ba}}{2\lambda}, \\ \frac{\partial \ell}{\partial \lambda} = \sum_{a=1}^I \frac{n_{aa}}{\lambda} + \sum_{b \neq a} \frac{n_{ab} + n_{ba}}{2\lambda} = 1 \Rightarrow \frac{n}{\lambda} = 1 \Rightarrow \lambda = n. \end{cases}$$

Si ottengono dunque le stime ML, che sono pari a:

$$\hat{\pi}_{ab} = \frac{n_{ab} + n_{ba}}{2n} \Rightarrow \hat{\mu}_{ab} = \frac{n_{ab} + n_{ba}}{2}.$$

Risulta quindi evidente che le quantità sulle diagonali sono stime di massima verosimiglianza. Siccome si ha una matrice di valori, restano $I(I-1)/2$ gradi di libertà liberi. Per testare l'ipotesi di simmetria si può utilizzare un test χ^2 , che coincide alla somma dei residui standardizzati del GLM logistico, e risulta pari al test di McNemar se $I = 2$ affrontato in 2.1.2:

$$X^2 = \sum_{a < b} \frac{(n_{ab} - n_{ba})^2}{n_{ab} + n_{ba}} \sim \chi^2_{\frac{I(I-1)}{2}}.$$

Questo test è stato proposto da Bowker (1948), e misura la discordanza fra celle opposte. Interessante notare come i residui definiti non sembrano essere i classici residui di Pearson. Si può dimostrare però che le due quantità coincidono; infatti il chi-quadrato di Pearson per il modello di simmetria è:

$$X_P^2 = \sum_{a=1}^I \sum_{b=1}^I \frac{(n_{ab} - \hat{\mu}_{ab})^2}{\hat{\mu}_{ab}}.$$

Sostituendo $\hat{\mu}_{ab} = (n_{ab} + n_{ba})/2$ si ottiene che:

$$\frac{(n_{ab} - \hat{\mu}_{ab})^2}{\hat{\mu}_{ab}} = \frac{(n_{ab} - n_{ba})^2}{2(n_{ab} + n_{ba})}.$$

Ma osservando che le celle simmetriche contribuiscono per stessa quantità, risulta che:

$$X_P^2 = \sum_{a < b} \frac{(n_{ab} - n_{ba})^2}{n_{ab} + n_{ba}} \sim \chi^2_{\frac{I(I-1)}{2}},$$

e risulta essere un'estensione del test di McNemar.

2.3.2 Quasi-Simmetria

Per matrici di dimensioni $I \times I$ la condizione di simmetria risulta, come menzionato prima, difficile da soddisfare. Esiste perciò una proprietà più semplice, che prevede una struttura di eterogeneità marginale, ovvero la quasi-simmetria. Il modello log-lineare si definisce come:

$$\log \mu_{ab} = \lambda + \lambda_a^X + \lambda_b^Y + \lambda_{ab}.$$

Si indica con l'esponente X l'effetto delle righe e con Y l'effetto della colonna. Questo modello richiede comunque che $\lambda_{ab} = \lambda_{ba}$. A livello logico dunque, il modello ammette che l'effetto della risposta possa cambiare da riga a colonna, ma che la proprietà sia indipendente dall'effetto dell'incontro fra due classi a, b . La loro interazione resterà infatti costante, cioè la probabilità π_{ab} dell'evento di ottenere $Y_1 = a, Y_2 = b$ e la probabilità specchiata π_{ba} non dipenderanno dall'ordine di incontro delle risposte, ma solo dagli effetti generali di riga e colonna. Il modello simmetrico è un caso particolare del quasi-simmetrico, dove $\lambda_k^X = \lambda_k^Y, \forall k = 1, \dots, I$. Ulteriore specificazione del modello sarebbe la presenza di indipendenza, cioè che la relazione fra la coppia non sia solo costante ma nulla, cioè $\lambda_{ab} = 0$. È possibile interpretare il modello di quasi simmetria tramite l'uso dei modelli con baseline 2.10, dove essenzialmente gli effetti delle colonne sono assenti e gli effetti delle righe coincidono con i coefficienti $\lambda_a^X = \beta_j$.

Le stime di massima verosimiglianza, utilizzando la distribuzione di Poisson per semplicità di calcolo, pur sapendo essere equivalenti a livello numerico alle stime multinomiali

al netto di una costante moltiplicativa, sono pari a:

$$\ell(\boldsymbol{\mu}) = \sum_{a=1}^I \sum_{b=1}^I [n_{ab} \log \mu_{ab} - \mu_{ab}],$$

si può osservare che derivando resta solamente la differenza in sommatoria fra n_{ab} e μ_{ab} .

Per esempio, derivando per λ_a^X si ottiene che:

$$\frac{\partial \ell}{\partial \lambda_a^X} = \sum_{b=1}^I n_{ab} - \sum_{b=1}^I \mu_{ab} = 0 \implies \hat{\mu}_{a+} = n_{a+}.$$

Le stime finali risultano essere:

$$\begin{aligned} \hat{\mu}_{a+} &= n_{a+}, & a &= 1, \dots, I, \\ \hat{\mu}_{+b} &= n_{+b}, & b &= 1, \dots, I, \\ \hat{\mu}_{ab} + \hat{\mu}_{ba} &= n_{ab} + n_{ba}, & a &\leq b. \end{aligned}$$

Tenere in considerazione tutti gli effetti della matrice rende la stima della probabilità congiunta π_{ab} dipendente dalle somme marginali della matrice, e di conseguenza da un elevato numero di parametri (in particolare infatti, [Agresti \(2013\)](#) mostra che solamente le stime sulla diagonale sono ottenibili in forma chiusa). Generalmente, le soluzioni di massima verosimiglianza vengono ottenute tramite metodi iterativi come Newton-Raphson, in maniera simile a quanto mostrato in [1.3.3](#).

Si è visto dunque che generalmente la proprietà di simmetria implica la presenza di quasi-simmetria e omogeneità marginale, ma si può dimostrare che vale anche il contrario, cioè se valgono entrambe le proprietà allora si ha simmetria. La dimostrazione è relativamente semplice, ed adopera la rappresentazione moltiplicativa $\pi_{ab} = \exp(\lambda_a^X + \lambda_b^Y + \lambda_{ab})$. La costante moltiplicativa λ permette di ottenere $\mu_{ab} = e^\lambda \pi_{ab}$. In condizioni di quasi-simmetria, riscrivendo $\pi_{ab} = \alpha_a \beta_a \gamma_{ab}$, $\gamma_{ab} = \gamma_{ba} > 0$, è possibile definire questa quantità come:

$$\pi_{ab} = \rho_a \delta_{ab},$$

dove $\rho_a = \alpha_a / \beta_a$ e $\delta_{ab} = \beta_a \beta_b \gamma_{ab}$. Se c'è omogeneità marginale, allora vale sicuramente che:

$$\pi_{j+} = \rho_j \sum_{b=1}^I \delta_{jb} = \sum_{a=1}^I \rho_a \delta_{aj} = \pi_{+j}.$$

Dunque ogni ρ_j è una media pesata della a -esima riga. Portando a denominatore dalla seconda equazione $\sum_{b=1}^I \delta_{jb}$, si ottengono i pesi $\{\delta_{aj} / \sum_{b=1}^I \delta_{jb}, a = 1, \dots, I\}$. Ora, siccome le quantità in gioco sono esponenziali, sono tutte quante strettamente maggiori di zero. Dato ciò, i pesi risultano per forza strettamente positivi. Date tutte queste considerazioni, i valori $\{\rho_a\}$ devono essere uguali. Se ciò non fosse vero esisterebbe un ρ_j minore di tutti gli altri. Questo significa che ci devono essere dei pesi nulli, perché sennò la media pesata sarà sicuramente maggiore del minimo. Ma questo è in contraddizione con quanto definito prima, dunque si è provato che i $\{\rho_a\}$ sono tutti uguali. Questo implica anche che $\pi_{ab} = \rho_a \delta_{ab} = \rho_b \delta_{ab} = \rho_b \delta_{ba} = \pi_{ba}$, e quindi vale la simmetria. Questo dimostra che se si ha quasi-simmetria, provare l'omogeneità marginale implica dimostrare la presenza di simmetria. Si può testare questa ipotesi tramite Loglikelihood-Ratio Test (LRT), visto che il modello simmetrico è letteralmente il quasi-simmetrico dove vengono vincolati $I - 1$ parametri, qualora l'ipotesi nulla sia l'omogeneità. Si ottiene dunque il seguente test:

$$W(S|QS) = W(S) - W(QS) \stackrel{H_0}{\sim} \chi_{I-1}^2.$$

2.3.3 Quasi-Indipendenza

Come definito prima, l'indipendenza è quella condizione che permette di ottenere le probabilità della matrice conoscendo solamente gli effetti riga-colonna. In altre parole, note le marginali, si ottengono anche le probabilità condizionate, appunto perché non c'è correlazione fra combinazioni di risposte, dunque $\pi_{ij} = \pi_{i+} \pi_{+j}$. Nella realtà però spesso accade che si ha una concordanza maggiore del previsto fra le coppie o i gruppi osservati, il che si manifesta in diagonalità con frequenze più alte di quelle previste. Dunque, anche in questo caso, si cerca una proprietà meno restrittiva per modellare i risultati. Si definisce un modello log-lineare di quasi-indipendenza quando si assume che le celle fuori dalla diagonale soddisfino l'indipendenza, mentre le celle diagonali possano deviare liberamente. Formalmente, questo si esprime col modello:

$$\log \mu_{ab} = \lambda + \lambda_a^X + \lambda_b^Y + \delta_a I(a = b).$$

Dove $I(\cdot)$ è la funzione indicatrice. Questo permette alle celle diagonali di avere un parametro libero in più per compensare la loro sovrarappresentanza nel campione. Le soluzioni della verosimiglianza, ottenibili in maniera simile al modello di quasi-simmetria,

ci portano a risultati simili ai precedenti:

$$\hat{\mu}_{a+} = n_{a+}, \quad \hat{\mu}_{+a} = n_{+a}, \quad \hat{\mu}_{aa} = n_{aa}, \quad a = 1, \dots, I.$$

Anche in questo caso le stime individuali delle probabilità congiunte risultano troppo complesse, e pertanto vengono ottenute adoperando metodi iterativi come Newton-Raphson.

2.4 Misure di Concordanza

In studi contenenti pareri umani, è importante riuscire a misurare il livello di concordanza (interpretabile come correlazione positiva) fra i soggetti che esprimono suddetto parere. Riuscire a trovare una misura matematica in un contesto di opinioni soggettive è alla base di campi come il confronto fra prodotti alimentari o (soprattutto in passato) la diagnosi di malattie rare. Nella seguente sezione si presentano alcune quantità per misurare la concordanza fra i soggetti.

2.4.1 Concordanza

Due soggetti concordano quando assegnano la stessa etichetta o risultato, sia esso binario o nominale, alla i -esima rilevazione. Dunque, la probabilità di concordanza risulta essere pari alla sommatoria dei valori sulla diagonale, cioè $\sum_a \pi_{aa}$. Se due soggetti sono completamente d'accordo su qualsiasi rilevazione, la probabilità di concordanza sarà 1. Una prima analisi “NAIVE” confronta le frequenze osservate n_{ab} con quelle teoriche sotto ipotesi di indipendenza $n_{a+}n_{+b}/n$. L'idea è che se non ci fosse nessuna associazione o differenza strutturale nelle scelte, questo modello coinciderebbe perfettamente con i dati osservati. Nella realtà questo modello tende ad adattarsi male qualora un minimo di correlazione esista nelle scelte. Per risolvere il problema è possibile adoperare un modello di quasi-indipendenza ed osservare il parametro δ_j . Maggiore il valore, più forte sarà l'associazione positiva e la concordanza fra i soggetti. Per misurare, date 2 coppie, gli odds dei due soggetti di essere d'accordo sul classificare la prima osservazione come a e la seconda come b saranno, in un modello di quasi-indipendenza:

$$\gamma_{ab} = \frac{\pi_{aa}\pi_{bb}}{\pi_{ab}\pi_{ba}} = \frac{\exp [(\lambda + \lambda_a^X + \lambda_a^Y + \delta_a) + (\lambda + \lambda_b^X + \lambda_b^Y + \delta_b)]}{\exp [(\lambda + \lambda_a^X + \lambda_b^Y) + (\lambda + \lambda_b^X + \lambda_a^Y)]} = \exp(\delta_a + \delta_b).$$

Detto ciò, l'usare solamente due parametri limita le capacità modellative del modello. Questo naturalmente non è un problema intrinseco, ma in alcuni contesti può portare alla conseguente mancanza di adattamento del modello di quasi indipendenza, in particolare in contesti di confronto di opinioni, nelle quali necessitiamo di più parametri. In questi casi si può utilizzare un modello di quasi-simmetria, che permette di avere parametri di associazione per ogni coppia.

2.4.2 Kappa

Un secondo modo per analizzare la concordanza fra due soggetti nel campione è l'indice Kappa di Cohen ([Cohen, 1960](#)). Sostanzialmente questo indice compara le probabilità osservate $\sum_a \pi_{aa}$ con quelle teoriche assumendo indipendenza (cioè il prodotto delle marginali). Formalmente:

$$\kappa = \frac{\sum_a \pi_{aa} - \sum_a \pi_{a+} \pi_{+a}}{1 - \sum_a \pi_{a+} \pi_{+a}}.$$

Il denominatore porta a normalizzare questa quantità, poiché massima concordanza implica che $\sum_a \pi_{aa} = 1$. Malgrado il range di valori sia $[-1, 1]$, nella realtà è molto difficile osservare un valore ampiamente negativo, legato ad una elevata discordanza. Siccome si può dimostrare che l'indice Kappa ha una distribuzione asintoticamente normale ([Fleiss et al., 1969](#)), si possono effettuare dei test legati non solo alla significatività dell'indice, ma anche alla forza dell'associazione.

Il κ ha però una problematica legata alla tipologia di dati, e cioè che tratta le risposte come variabili nominali equamente pesate. Però qualora le categorie di risposta fossero ordinali, o più generalmente pesate in maniera non equa, una discordanza di più classi sarà pesata ugualmente a un errore di una sola. Ponendo di avere un esempio nei quali si vuole misurare la discordanza fra le opinioni di due dottori, non avrebbe senso “punire” la discordanza fra due dottori che diagnosticano stadi avanzati di cancro ma non uguali ad un paziente tanto quanto una discordanza totale. Per questo motivo è stato proposto l'indice κ -pesato, una misura che penalizza gli errori più lontani in base alla differenza $a - b$ (esistono diversi modi per ottenere i pesi, che non si discuteranno in questa tesi). Formalmente, si ottiene che

$$\kappa_w = \frac{\sum_a \sum_b w_{ab} \pi_{ab} - \sum_a \sum_b w_{ab} \pi_{a+} \pi_{+b}}{1 - \sum_a \sum_b w_{ab} \pi_{a+} \pi_{+b}}.$$

Naturalmente, come ogni misura riassuntiva di una struttura complessa sottostante, bisogna stare attenti alla perdita di informazione che essa comporta. Non bisogna giudicare puramente dal risultato, ma valutarlo nel contesto.

2.5 Modelli Bradley-Terry

Fino ad adesso si sono affrontati modelli per la valutazione e modellazione di risultati da campioni raggruppati, spesso ma non solo a coppie. In tutti i contesti esaminati, l'obiettivo era descrivere la struttura di dipendenza fra due risposte (e delle loro distribuzioni) o misurare il grado di concordanza (e discordanza) fra due soggetti. Esiste però una classe di problemi in cui l'interesse non risiede nella struttura della coppia in sé, ma nella capacità di ordinare o classificare un insieme di oggetti sulla base di confronti a coppie, come menzionato nell'introduzione. In questo caso, da esiti binari come “successo” o “fallimento” l'obiettivo è di riuscire a stimare una classifica generale che ordini i soggetti valutati. Proprio per queste ragioni, nell'ambito dell'analisi dei confronti a coppie, gli autori di [Bradley & Terry \(1952a\)](#) hanno elaborato un modello per il ranking basato su risultati binari. Storicamente parlando, l'idea di quantificare probabilità in base a un sistema di pesi tali per cui:

$$\mathbb{P}(i \succ j) = \frac{\gamma_i}{\gamma_i + \gamma_j},$$

fu per la prima volta presentato in [Zermelo \(1929\)](#), e riscoperto indipendentemente da Bradley e Terry. I due ricercatori hanno ideato un metodo per quantificare questi pesi γ , e malgrado [Guttman \(1946\)](#) avesse proposto un metodo alternativo legato ai minimi quadrati, nel loro noto lavoro del 1952 viene notato come effettivamente il rapporto fra probabilità osservate diventasse lineare in logaritmo, dunque che convertire i pesi in questa scala avrebbe senso. Bradley e Terry osservarono anche che il logaritmo del rapporto tra le probabilità di vittoria dei due soggetti risulta lineare nelle quantità $\log\left(\frac{\mathbb{P}(i \succ j)}{\mathbb{P}(j \succ i)}\right) = \log(\gamma_i) - \log(\gamma_j) = \beta_i - \beta_j$, suggerendo di modellare le probabilità similmente alla parametrizzazione naturale del modello Binomiale. Gli autori ottennero quindi la funzione di verosimiglianza assumendo che il numero di vittorie osservate in ciascun confronto seguisse una distribuzione binomiale, idea che è tutt'ora prassi. Questo metodo infine fu pensato con l'idea di poter testare ipotesi sulle quantità in maniera più semplice dei metodi precedenti, in particolare con test di verosimiglianza riguardanti l'assenza di differenze tra le abilità dei soggetti. Nella seguente sezione si introdurrà il modello Brad-

ley-Terry e si presenterà un esempio di applicazione, mentre nel Capitolo 3 esso verrà generalizzato e analizzato più approfonditamente.

2.5.1 Specificazione del Modello

Sia Π_{ab} la probabilità che a sia preferito a b . Si supponga che $\Pi_{ab} + \Pi_{ba} = 1$ per ogni coppia, e dunque che non esista pareggio. Il modello Bradley-Terry è:

$$\log \left(\frac{\Pi_{ab}}{\Pi_{ba}} \right) = \beta_a - \beta_b. \quad (2.12)$$

Alternativamente, il modello si può esprimere in termini delle singole probabilità, infatti $\Pi_{ab} = \exp(\beta_a) / [\exp(\beta_a) + \exp(\beta_b)]$. Si può osservare come il modello Bradley-Terry assomigli ai modelli marginali (2.2) e soggetto-specifici (2.4), e questa similitudine è giustificata dal fatto che sono l'uno l'estensione dell'altro. Infatti, il modello specifico è stato costruito apposta per modellare probabilità nelle coppie discordanti dato un campione di risposte accoppiate, cioè quando $S_i = 1$, mentre il Bradley-Terry ha per costruzione sempre e solo risultati discordi, dunque entrambi lavorano sulle stesse quantità. Oltretutto, le stime dei parametri coincidono, come si vede nell'equazione 2.6. Infatti, ipotizzando di avere un modello Bradley-Terry rispetto a campioni appaiati con risposte binarie, e sapendo che uno dei due parametri è posto pari a 0, si ottengono le medesime quantità. Naturalmente per questo genere di dati non ha neanche senso scomodare un modello pensato per situazioni più complesse. Inoltre il modello di Bradley-Terry risulta anche un caso particolare del modello affrontato nella Sezione 2.2.3. Riprendendo infatti la forma delle probabilità condizionate, basterà costruire la variabile differenza $x^* = x_{i2} - x_{i1}$ in modo tale che, dato un confronto fra le classi a e b , essa abbia valore +1 in posizione a , -1 in posizione b e 0 altrove, ottenendo che $x^{*T} \beta = \beta_a - \beta_b$, ovvero esattamente il predittore lineare del modello 2.12.

Il modello Bradley-Terry, per essere identificabile, e cioè tale per cui ogni possibile formulazione del modello sia identificata da un unico vettore di parametri β , creando una sorta di relazione biunivoca fra vettori parametri e modelli possibili, richiede di utilizzare una delle I categorie prese in considerazione come baseline, ad esempio $\beta_I = 0$. Infatti si può dimostrare che il modello è invariante aggiungendo una costante a tutti i parametri β_i (uno dei motivi per cui questa struttura è apprezzata negli scacchi, poiché le probabilità di




Figura 2.2: Visualizzazione della Probabilità che il soggetto a batte il soggetto b , modellato tramite la differenza fra i parametri β_a e β_b

vittoria non dipendono dalla forza dei giocatori ma dalla differenza di punteggio). Siccome si modellano $I(I-1)/2$ probabilità del confronto fra coppie, i gradi di libertà residui del modello sono $(I-1)(I-2)/2$. Questa quantità servirà quando si vorrà testare la significatività dei parametri β tramite un likelihood-ratio test. Definendo $a < b$, sia N_{ab} il numero di valutazioni o match della coppia, e sia n_{ab} il numero di volte in cui a è stato preferito a b , e dunque $n_{ba} = N_{ab} - n_{ab}$. Se i confronti avvengono in condizioni di indipendenza, è valido ipotizzare che $n_{ab} \sim \text{Binom}(N_{ab}, \Pi_{ab})$. Il modello Bradley-Terry in generale non è risolvibile in forma chiusa per un numero di parametri maggiore a 3, perché dà vita a sistemi complessi con grado elevato non risolvibili con radici semplici, e come al solito si adoperano metodi numerici come quelli iterativi menzionati in 1.3.3.

2.5.2 Modelli Bradley-Terry e Modelli Quasi-Simmetrici

Un'interessante connessione lega i modelli log-lineari di quasi-simmetria al modello di Bradley & Terry (1952a) per il confronto a coppie. Come mostrato da Fienberg & Larntz (1976), il modello di Bradley-Terry coincide con un particolare modello di quasi-simmetria visto nella sezione 2.3.2, infatti sotto opportune ipotesi, vale:

$$\log \frac{\mu_{ab}}{\mu_{ba}} = (\lambda_a^X - \lambda_a^Y) - (\lambda_b^X - \lambda_b^Y) = \beta_a - \beta_b,$$

dove si è definito $\beta_a = \lambda_a^X - \lambda_a^Y$. Le stime $\{\hat{\lambda}_a^X\}$ e $\{\hat{\lambda}_a^Y\}$ ottenute sotto quasi-simmetria forniscono direttamente $\{\hat{\beta}_a\}$. Per il modello di Bradley-Terry è possibile interpretare il rapporto in logaritmo $\log \frac{\mu_{ab}}{\mu_{ba}}$ come netto degli effetti riga-colonna. Inoltre se il modello marginale visto nella Sezione 2.2.1 modella le distribuzioni marginali della matrice di contingenza, ed il suo test naturale è quello per l'omogeneità marginale di McNemar, il modello di Bradley-Terry modella invece le celle interne della matrice al netto degli effetti marginali, siccome coincide con un modello quasi-simmetrico. Questa distinzione permette di ottenere una conseguenza interessante, grazie a quanto dimostrato nella Sezione 2.3.2, ovvero che la presenza congiunta di quasi-simmetria e omogeneità marginale implichi la simmetria. Verificare l'ipotesi nulla $H_0 : \beta_1 = \dots = \beta_m$, cioè che nessun soggetto è necessariamente più forte di altri, equivale infatti ad ottenere che $\pi_{ab} = \pi_{ba}$ per ogni coppia, e dunque a testare la simmetria della matrice dei confronti.

Il modello di Bradley-Terry si estende infine al caso in cui l'esito del confronto non sia binario (vince/perde) ma ordinale, come accade ad esempio nelle scale di valutazione a più livelli (dove ad esempio per una scala di preferenza fra due vini si potrebbero avere le categorie “molto meglio”, “leggermente meglio”, “uguale”, “leggermente peggio”, “molto peggio”). Sia Y_{ab} la risposta ordinale a I categorie per un confronto tra a e b . Allora, adoperando una struttura logit cumulativa, il modello diventa:

$$\text{logit}[\mathbb{P}(Y_{ab} \leq j)] = \alpha_j + (\beta_a - \beta_b), \quad j = 1, \dots, I - 1.$$

Poiché $\mathbb{P}(Y_{ab} \leq j) = \mathbb{P}(Y_{ba} > I - j) = 1 - \mathbb{P}(Y_{ba} \leq I - j)$, si ottiene immediatamente che $\text{logit}[\mathbb{P}(Y_{ab} \leq j)] = -\text{logit}[\mathbb{P}(Y_{ba} \leq I - j)]$, il che impone il vincolo di simmetria sulle intercette $\alpha_j = -\alpha_{I-j}$. In questo caso l'interpretazione dei β è leggermente diversa dal solito, poiché in questo caso $e^{\beta_a - \beta_b}$ è pari all'odds ratio a favore di scegliere la categoria a rispetto alla b per ogni soglia j .

2.5.3 Alcuni Esempi

Citazioni nelle Riviste Statistiche L'esercizio 11.17 di Agresti (2013) fornisce un esempio applicativo di modello Bradley-Terry generale. In questo esempio, si vuole ottenere una classifica del prestigio, misurato grazie a quante volte la rivista viene citata. È possibile interpretare che la rivista A vince contro la rivista B quando la prima viene citata dalla seconda. Il numero di citazioni è contenuto nella seguente tabella:

Tabella 2.2: Dati per l'Esercizio 11.17 sulle Citazioni fra Riviste.

<i>Rivista Citante</i>	<i>Rivista Citata</i>			
	<i>Biometrika</i>	<i>Commun. Stat.</i>	<i>JASA</i>	<i>JRSS-B</i>
<i>Biometrika</i>	714	33	320	284
<i>Commun. Stat.</i>	730	425	813	276
<i>JASA</i>	498	68	1072	325
<i>JRSS-B</i>	221	17	142	188

Per semplicità, ci si riferirà alla rivista BIOMETRIKA come (A), COMMUNICATIONS IN STATISTICS come (B), JOURNAL OF THE AMERICAN STATISTICAL ASSOCIATION come (C) e JOURNAL OF THE ROYAL STATISTICAL SOCIETY SERIES B come (D). Come menzionato in 2.5.1, ipotizzando indipendenza fra le singole citazioni, si possono vedere queste quantità come estrazioni da una funzione con legge Binomiale. Ipotizzando che la probabilità di vittoria della i -esima rivista sulla j -esima Π_{ij} sia pari a

$$\Pi_{ij} = \frac{e^{\beta_i}}{e^{\beta_i} + e^{\beta_j}},$$

si ottiene la funzione di massima verosimiglianza per poter adattare il modello Bradley-Terry. Per esempio, prendendo la rivista D come baseline, dunque $\beta_d = 0$, la likelihood sarà pari a:

$$L(\boldsymbol{\beta}) = \prod_{i=a}^d \prod_{j=a}^d \left(\frac{e^{\beta_i}}{e^{\beta_i} + e^{\beta_j}} \right)^{n_{ij}},$$

dove gli estremi della produttoria indicano che vengono osservati tutti i confronti fra categorie. Naturalmente si ignorano le autocitazioni delle riviste, poiché esse non contribuiscono alle stime dei β_i . Come già discusso nella sezione 2.5.1, il modello non è risolvibile in forma chiusa, e si deve ricorrere a metodi numerici. Bisogna però stare attenti alla stabilità numerica dell'algoritmo, perché malgrado nel caso in esame si stanno moltiplicando diverse quantità, che di per sé non è problematico, il fatto che esse vengono elevate per un esponente molto elevato, implica che il risultato risulta essere molto vicino allo 0. Bisogna quindi o adoperare calcolatori capaci di elevata precisione o trasformare

le quantità in forme numericamente più stabili (ed equivalenti alla log-verosimiglianza):

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^m \sum_{j=1}^m n_{ij} (\beta_i - \log(e^{\beta_i} + e^{\beta_j})).$$

Detto ciò, bisogna menzionare che i pacchetti più moderni come in [Turner & Firth \(2012\)](#), adoperano un'ottimizzazione tramite IRLS, che risultano ovviamente più efficienti, ma in questo contesto l'ottimizzazione risulta relativamente poco problematica e praticamente uguale anche adoperando metodi più generali come [Nelder & Mead \(1965\)](#). Le stime risultano dunque essere pari a:

$$\beta_a = -0.2689541, \quad \beta_b = -3.2180266, \quad \beta_c = -0.7485238.$$

Dunque la rivista D, ovvero JRSS-B risulta essere la più citata (e in questo caso, la più prestigiosa) seguita da BIOMETRIKA e in terza posizione JASA. Paragonando le probabilità ottenute con quelle osservate, si osserva che il modello sembra adattarsi particolarmente bene ai dati (questo anche grazie all'alta mole di confronti). Infatti, confrontando le riviste A e B come esempio, si nota che:

$$\hat{\Pi}_{ab} = 0.9502196, \quad \Pi_{ab} = 0.9567497.$$

Infine siccome i gradi di libertà residui saranno pari a $(I-1)(I-2)/2$ con $I=4$, dunque si hanno 3 gradi di libertà residui rispetto a una devianza residua pari a 4.293, ed il p-value del test di bontà di adattamento χ_3^2 risulta pari a 0.237, e dunque il modello risulta soddisfacente sotto questo punto di vista.

Preferenze tra Bibite Analcoliche. Un secondo esempio che viene presentato riguarda un caso particolare nel quale il numero di parametri è pari a 3, ed il modello Bradley-Terry risulta sufficientemente semplice da essere possibile trovare una soluzione in forma chiusa. Anche questo esercizio è preso da [Agresti \(2013\)](#), ed è il numero 11.16. Nel 1990, un campione di studenti di psicologia dell'Università della Florida fu sottoposto a test di preferenza cieca a coppie su tre bevande cola: Coca-Cola (A), Pepsi (B) e Classic Coke (C). I confronti, i relativi conteggi di vittoria e i totali di confronto osservati sono riassunti nella successiva Tabella:

Tabella 2.3: Dati per l'Esercizio 11.16 sulle Preferenze fra Bevande.

Confronto	n_{ij} (vince i)	n_{ji} (vince j)	N_{ij}
A vs. B	29	20	49
A vs. C	31	19	50
B vs. C	28	19	47

Sempre per quanto detto nella 2.5.1, è noto che $n_{ij} \sim \text{Binom}(N_{ij}, \Pi_{ij})$ sono indipendenti per ipotesi. Chiamando ancora $m = 3$ il numero di classi, e per i passaggi visti nell'esempio appena proposto, chiamando $\gamma_i = \exp(\beta_i)$, la log-verosimiglianza sarà pari a:

$$\ell(\gamma) = \sum_{i=1}^m \sum_{j=1}^m \left[n_{ij} \log \gamma_i - n_{ij} \log(\gamma_i + \gamma_j) \right], \quad (2.13)$$

dove quando i pedici sono uguali la verosimiglianza ha un contributo nullo. Nel caso considerato, $m = 3$, e fissando $\gamma_C = 1$ come baseline (equivalente a $\beta_C = 0$), i parametri liberi sono γ_A e γ_B . Derivando la log-verosimiglianza (2.13) rispetto a γ_A e γ_B , si ottengono le equazioni di score. Per γ_A :

$$\frac{\partial \ell}{\partial \gamma_A} = \frac{n_{AB}}{\gamma_A} - \frac{n_{AB} + n_{BA}}{\gamma_A + \gamma_B} + \frac{n_{AC}}{\gamma_A} - \frac{n_{AC} + n_{CA}}{\gamma_A + 1} = 0,$$

e in modo analogo per γ_B :

$$\frac{\partial \ell}{\partial \gamma_B} = \frac{n_{BA}}{\gamma_B} - \frac{n_{AB} + n_{BA}}{\gamma_A + \gamma_B} + \frac{n_{BC}}{\gamma_B} - \frac{n_{BC} + n_{CB}}{\gamma_B + 1} = 0.$$

Sostituendo i dati osservati ($n_{AB} = 29$, $n_{BA} = 20$, $n_{AC} = 31$, $n_{CA} = 19$, $n_{BC} = 28$, $n_{CB} = 19$ e $N_{AB} = 49$, $N_{AC} = 50$, $N_{BC} = 47$), le equazioni diventano il sistema non lineare:

$$\begin{cases} 60 = \frac{49 \gamma_A}{\gamma_A + \gamma_B} + \frac{50 \gamma_A}{\gamma_A + 1}, \\ 48 = \frac{49 \gamma_B}{\gamma_A + \gamma_B} + \frac{47 \gamma_B}{\gamma_B + 1}. \end{cases} \quad (2.14)$$

È possibile dimostrare con alcuni passaggi algebrici che, isolando γ_B in funzione di γ_A :

$$\gamma_B = \frac{39 \gamma_A^2 - 11 \gamma_A}{10 \gamma_A + 60},$$

e sostituendo nella seconda si ottiene un'equazione polinomiale in γ_A . L'equazione ottenuta è risolvibile in forma chiusa, ma trovare le radici di questo genere di sistemi richiede l'uso della celebre formula di Ferrari, che risulta poco pratica e sconsigliata. Per semplicità si risolverà dunque il sistema tramite approccio numerico. Le radici per il polinomio in γ_A sono naturalmente quattro, ma solo una di queste radici risulterà non complessa e massimizzante della funzione, e sarà:

$$\hat{\gamma}_A = 1.78525, \quad \hat{\gamma}_B = 1.34434, \quad \hat{\gamma}_C = 1 \quad (\text{baseline}).$$

Passando alla scala logaritmica si ottengono i β :

$$\hat{\beta}_A = \ln(1.78525) \approx 0.5796, \quad \hat{\beta}_B = \ln(1.34434) \approx 0.2959, \quad \hat{\beta}_C = 0.$$

Poiché $\hat{\beta}_A > \hat{\beta}_B > \hat{\beta}_C$, il modello induce il ranking $A \succ B \succ C$, ovvero che Coca-Cola è la bevanda preferita, seguita da Pepsi e infine da Classic Coke. Questo risultato è consistente con le frequenze osservate in ciascun confronto a coppie. Di seguito si confrontano le probabilità stimate e quelle realmente osservate.

$$\hat{\Pi}_{AB} = \frac{\hat{\gamma}_A}{\hat{\gamma}_A + \hat{\gamma}_B} = \frac{1.78525}{1.78525 + 1.34434} \approx 0.570, \quad p_{AB} = 29/49 \approx 0.591,$$

$$\hat{\Pi}_{AC} = \frac{\hat{\gamma}_A}{\hat{\gamma}_A + \hat{\gamma}_C} = \frac{1.78525}{1.78525 + 1} \approx 0.640, \quad p_{AC} = 31/50 \approx 0.620,$$

$$\hat{\Pi}_{BC} = \frac{\hat{\gamma}_B}{\hat{\gamma}_B + \hat{\gamma}_C} = \frac{1.34434}{1.34434 + 1} \approx 0.573, \quad p_{BC} = 28/47 \approx 0.596.$$

Le quantità sono ragionevolmente vicine, e la differenza riflette il fatto che il modello Bradley-Terry impone coerenza sull'intero insieme di confronti, mentre la proporzione osservata si riferisce unicamente al singolo confronto. Viene essenzialmente sfruttata l'informazione di tutti i confronti, quindi confrontando le due squadre direttamente ed indirettamente, per modellare anche le probabilità del singolo scontro. Infine, avendo $\binom{3}{2} = 3$ coppie di confronto e $3 - 1 = 2$ parametri liberi (con la baseline), i gradi di libertà residui sono $(I - 1)(I - 2)/2 = 1$. Il test del rapporto di verosimiglianza (LRT) restituisce un p-value molto elevato (0.9444143), e il ranking stimato sembra essere affidabile.

Capitolo 3

Algoritmi MM per Generalizzazioni di Modelli Bradley-Terry

Nel capitolo precedente è stata introdotta la cornice teorica necessaria per comprendere il modello di Bradley–Terry. Nella sua formulazione originale, esso rappresenta uno strumento semplice ed efficace per modellare esiti derivanti da confronti a coppie. Tuttavia, molte applicazioni reali presentano caratteristiche che non possono essere adeguatamente descritte dalla specificazione base. Per questo motivo, nel corso degli anni sono state proposte molteplici estensioni del modello, volte a incorporare ulteriori parametri e a rappresentare situazioni più complesse. Tra queste rientrano, ad esempio, l'introduzione di un parametro per il vantaggio della squadra di casa, già discusso nella Sezione 2.5.1, e l'estensione del modello per tenere conto della possibilità di pareggio, come in Davidson (1970). Ciò nonostante, nei casi di generalizzazione del modello, gli autori ricorrevano a ottenere le stime di massima verosimiglianza per i parametri del modello specifico *ex novo*. L'assenza di un metodo generale per ottenere le stime dei parametri per una vasta gamma di modelli Bradley-Terry generalizzati ha portato Hunter (2004) a ideare una metodologia per ottenere stime di massima verosimiglianza tramite un metodo iterativo, e che richiede condizioni relativamente semplici da soddisfare. In particolare il lavoro di Hunter si sviluppa su una classe di algoritmi nota come “Algoritmi MM” (la cui sigla può indicare due possibili criteri di ottimizzazione, come si vedrà più avanti), che verranno analizzati di seguito. Riprendendo il lavoro di Hunter (2004), nella prima parte di questa sezione, si presentano delle generalizzazioni proposte nel corso degli anni. Nella seconda, si introducono gli algoritmi MM e il loro meccanismo di funzionamento, mentre nella terza si discuteranno le proprietà principali del modello.

3.1 Generalizzazioni di Modelli Bradley-Terry

Supponendo di avere un problema di ranking di un gruppo di m unità statistiche, e volendo determinare i parametri $\gamma_1, \dots, \gamma_m$ che rappresentano la forza di ogni squadra, si adopera il metodo della massima verosimiglianza introdotto nella Sezione ?? . Se si ipotizza che i confronti siano indipendenti, come spiegato già nella Sezione 2.5.1, la log-verosimiglianza risulta essere pari a:

$$\ell(\gamma) = \sum_{i=1}^m \sum_{j=1}^m [n_{ij} \ln \gamma_i - n_{ij} \ln(\gamma_i + \gamma_j)] \quad (3.1)$$

dove n_{ij} è il numero di volte in cui l'elemento i ha un ranking maggiore rispetto all'elemento j (nel caso binario implica che i ha vinto contro j). È semplice notare come $\ell(\gamma) = \ell(\alpha\gamma)$, e dunque generalmente il vettore dei parametri non è identificabile, come già spiegato nella Sezione 2.5.1. Detto ciò risulta semplice porre un singolo vincolo sullo spazio parametrico, e per semplicità si impone che $\sum_{i=1}^m \gamma_i = 1$, limitando lo spazio delle risposte e risolvendo la non identificabilità.

3.1.1 Modelli per Pareggi

È possibile estendere il modello per poter tenere in considerazione i pareggi, un risultato che non si può ignorare in ambiti come quello calcistico. I modelli che si affronteranno in questa Sezione introducono una relazione moltiplicativa fra il parametro di pareggio e le forze dei soggetti, ma esistono modelli che provano a costruire una relazione additiva. In ogni caso, proprio per modellare i pareggi, il modello proposto da Davidson (1970) include un certo parametro $\theta > 0$ per tenere conto di questa terza risposta. Maggiore il valore di θ , maggiore la probabilità di pareggio. In particolare i rapporti fra le probabilità sono:

$$\mathbb{P}(i \succ j) : \mathbb{P}(j \succ i) : \mathbb{P}(i \sim j) = \gamma_i : \gamma_j : \theta \sqrt{\gamma_i \gamma_j}.$$

La struttura proporzionale del termine θ implica che più le forze dei player (o squadre) sono vicine, più è probabile un pareggio. La log-verosimiglianza del modello risulta essere pari a, denotando con $\succ$ la relazione di preferenza, per cui $i \succ j$ indica che i è preferito a j :

$$\ell(\gamma, \theta) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \left[2n_{ij} \ln \frac{\gamma_i}{\gamma_i + \gamma_j + \theta \sqrt{\gamma_i \gamma_j}} + t_{ij} \ln \frac{\theta \sqrt{\gamma_i \gamma_j}}{\gamma_i + \gamma_j + \theta \sqrt{\gamma_i \gamma_j}} \right], \quad (3.2)$$

dove n_{ij} è il numero di vittorie di i su j , mentre invece t_{ij} è il numero di pareggi. Si noti inoltre come $t_{ij} = t_{ji}$. Si noti che in assenza di pareggi, la seconda parte si elide, poiché il contributo relativo ai t_{ij} risulta nullo, e si riottiene il modello classico 3.1.

Un secondo modello che si presenta è quello proposto da Rao & Kupper (1967), nel quale il parametro del pareggio è $\theta > 1$, e che entra in gioco anche nella modellazione di vittoria o sconfitta. Infatti questo modello interpreta il pareggio come parte dei risultati svantaggiosi nei confronti dell' i -esimo player, e dunque il parametro θ “lievita” la forza dell’avversario per una certa costante. Infatti, il rapporto fra le probabilità saranno:

$$P(i \succ j) : P(j \succ i) : P(i \sim j) = \frac{\gamma_i}{\gamma_i + \theta\gamma_j} : \frac{\gamma_j}{(\theta\gamma_i + \gamma_j)} : \frac{(\theta^2 - 1)\gamma_i\gamma_j}{(\gamma_i + \theta\gamma_j)(\gamma_j + \theta\gamma_i)}.$$

In questo caso, la log-verosimiglianza sarà pari a:

$$\ell(\gamma, \theta) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \left[2n_{ij} \ln \left(\frac{\gamma_i}{\gamma_i + \theta\gamma_j} \right) + t_{ij} \ln \left(\frac{(\theta^2 - 1)\gamma_i\gamma_j}{(\theta\gamma_i + \gamma_j)(\gamma_i + \theta\gamma_j)} \right) \right]. \quad (3.3)$$

Entrambi questi modelli restano validi per affrontare le problematiche legate al pareggio, ma questo elaborato si concentrerà in particolare sul modello 3.2.

3.1.2 Modelli per Vantaggio in Casa

Spesso però l’ipotesi di indipendenza dello scontro singolo da fattori esterni può risultare forte, un esempio può essere il noto vantaggio del giocatore o della squadra che gioca nel campo di casa, tant’è che ad esempio nel calcio si parla del dodicesimo uomo in campo per riferirsi al pubblico di casa. Dunque ci possono essere contesti nei quali un incontro fra due squadre porti a probabilità di vittorie diverse a seconda del contesto. L’obiettivo è modellare ogni situazione nella quale ci può essere una preferenza strutturale per una delle opzioni, come la tendenza a preferire la prima opzione fra due, le condizioni meteorologiche, oppure le caratteristiche genetiche non controllabili nella valutazione di una malattia, e questi sono solo alcuni dei numerosi esempi plausibili. Per ovviare a questo problema, è possibile costruire un modello che tenga conto di queste ulteriori variabili, proposto in Agresti (2013). Infatti si può inserire nel nostro modello un parametro costante α che ingloba tutti questi effetti esterni. Chiamando Π_{ba}^* la probabilità che a prevalga su b in casa di a (ma che potrebbe rappresentare un qualsiasi vantaggio come l’essere posizionati

per primi in un confronto, quindi a prima di b):

$$\log \left(\frac{\Pi_{ba}^*}{1 - \Pi_{ba}^*} \right) = \alpha + (\beta_a - \beta_b).$$

Se il valore di α è significativamente maggiore di zero, allora risulta valido ipotizzare effettivamente l'esistenza di questo vantaggio esterno. Definendo $e^{\beta_i} = \gamma_i$, le probabilità saranno pari a:

$$P(i \succ j) = \begin{cases} \alpha \gamma_i / (\alpha \gamma_i + \gamma_j), & \text{se } i \text{ gioca in casa,} \\ \gamma_i / (\gamma_i + \alpha \gamma_j), & \text{se } j \text{ gioca in casa.} \end{cases}$$

Similmente al modello 3.3, il parametro α amplifica la forza della squadra in casa e viceversa. La verosimiglianza risulta invece essere pari a:

$$\ell(\gamma, \alpha) = \sum_{i=1}^m \sum_{j=1}^m \left[a_{ij} \ln \frac{\alpha \gamma_i}{\alpha \gamma_i + \gamma_j} + b_{ij} \ln \frac{\gamma_j}{\alpha \gamma_i + \gamma_j} \right], \quad (3.4)$$

dove a_{ij}, b_{ij} sono rispettivamente il numero di vittorie e di sconfitte del soggetto i quando gioca in casa.

3.1.3 Modelli per Confronti Multipli

Un'ultima generalizzazione che viene presentata è legata allo sviluppo dei modelli Bradley-Terry per includere paragoni fra molteplici soggetti. Sebbene questi modelli non verranno trattati estensivamente, è utile approfondirli perché rappresentano uno sviluppo dei concetti appena presentati, e poiché gli algoritmi MM si dimostrano particolarmente utili in situazioni di questo genere. Seguendo Hunter (2004), si definisce il modello. Si supponga che vi siano m individui, etichettati da 1 a m . Per $A \subset \{1, \dots, m\}$ insieme di $k \leq m$ elementi. Sia $\mathcal{S}_k$ il gruppo delle permutazioni di k elementi. Dato A e una permutazione $\pi \in \mathcal{S}_k$, la probabilità assegnata all'ordinamento $\pi(1) \succ \dots \succ \pi(k)$ è:

$$P_A[\pi(1) \succ \dots \succ \pi(k)] = \prod_{i=1}^k \frac{\gamma_{\pi(i)}}{\gamma_{\pi(i)} + \dots + \gamma_{\pi(k)}}. \quad (3.5)$$

Risulta doveroso sottolineare che, malgrado questa generalizzazione sia presentata da Marden (1995), questo modello è stato introdotto da Plackett (1975), noto infatti come

modello di Plackett-Luce poiché alcune proprietà come la consistenza interna del modello si fondano sugli assiomi di Luce (1959). In particolare esso si basa sul principio di indipendenza dalle alternative irrilevanti, ma queste particolarità verranno discusse più avanti. Per comprendere meglio il modello, si presenta il caso più semplice, cioè quando $m = 3$. Esso fu introdotto da Pendergrass & Bradley (1960), sebbene una versione preliminare fosse già apparsa come letteratura grigia in Bradley & Terry (1952b), e nel quale la probabilità che tre individui vengano comparati e messi in ordine decrescente, è modellata nel seguente modo:

$$\mathbb{P}(i \succ j \succ k) = \frac{\gamma_i \gamma_j}{(\gamma_i + \gamma_j + \gamma_k)(\gamma_j + \gamma_k)}.$$

In questo modello specifico inoltre, chiamando n_{ijk} la frequenza osservata di casi nei quali i soggetti $i \succ j \succ k$, la verosimiglianza sarà pari a:

$$\ell(\gamma) = \sum_{i=1}^m \sum_{j=1}^m \sum_{k=1}^m n_{ijk} [\log \gamma_i + \log \gamma_j - \log(\gamma_i + \gamma_j + \gamma_k) - \log(\gamma_j + \gamma_k)]. \quad (3.6)$$

3.1.4 Esistenza delle Stime

L'esistenza dello stimatore di massima verosimiglianza per i parametri di questi modelli non è garantita in generale, e in particolare può venire meno in presenza di casi degeneri dei dati che verranno discussi nel prossimo paragrafo. Una soluzione a questo problema è offerta dall'approccio di Firth (1993), che attraverso una penalizzazione della funzione di verosimiglianza garantisce l'esistenza e l'unicità della stima. Tuttavia, una trattazione approfondita di tale metodo risulta lontana dagli obiettivi del presente lavoro. È tuttavia possibile garantire l'esistenza (e a meno del vincolo di identificabilità anche l'unicità) dello stimatore di massima verosimiglianza tramite alcune assunzioni. Per esempio, per il modello 3.1, Ford (1957) ha individuato una assunzione molto semplice che garantisce sempre l'esistenza dello stimatore di massima verosimiglianza:

Assunzione 3.1. *In ogni possibile partizione degli individui in due sotto-insiemi non vuoti, almeno un individuo del secondo insieme deve aver vinto almeno una volta contro un individuo del primo insieme.*

Si sottintende che questo deve valere anche per il secondo gruppo, dato che cambiando le etichette dei due gruppi otteniamo un'altra possibile ripartizione, nella quale almeno un individuo del primo gruppo deve vincere contro un individuo del secondo. Da un punto di vista pratico, questa assunzione garantisce due cose:

- Che non vi siano casi nei quali si abbiano due sottoinsiemi divisi senza alcuna relazione fra di essi, perché questo farebbe perdere la relatività dei parametri fra i due gruppi. Infatti, ipotizzando che i parametri $\gamma_1 \dots \gamma_s = \gamma_A$ si riferiscano ad osservazioni contenute nel gruppo A , mentre i parametri $\gamma_{s+1} \dots \gamma_m = \gamma_B$ si riferiscano ad elementi nel gruppo B , e che i due gruppi non abbiano un singolo elemento a confronto con un soggetto dell'altro gruppo, allora:

$$\ell(\gamma) = \ell(\gamma_A; \gamma_B) = \ell(\alpha\gamma_A; \lambda\gamma_B),$$

con α, λ costanti tali per cui $\alpha \sum_{i=1}^s \gamma_{Ai} + \lambda \sum_{i=s+1}^m \gamma_{Bi} = 1$. Si intuisce infatti che, siccome i due gruppi non hanno interazioni e la log-verosimiglianza risulta separabile in $\ell(\alpha\gamma_A; \lambda\gamma_B)$, anche se la somma dei parametri risulta pari a 1, lo stimatore di massima verosimiglianza è invariante rispetto a scalari e non risulta identificabile.

- Che non vi siano casi nei quali solo gli elementi di un solo gruppo vincano sempre, perché ciò porterebbe la stima di massima verosimiglianza a non esistere, poiché anche se si moltiplicassero tutti i valori del primo gruppo per una certa costante α e venisse normalizzato il vettore per soddisfare la restrizione di identificabilità, la verosimiglianza dovrebbe continuare a crescere. Infatti, aumentando i parametri associati agli elementi del gruppo A e diminuendo proporzionalmente quelli del gruppo B , tutte le probabilità di vittoria osservate si avvicinano a uno, facendo aumentare continuamente la funzione di verosimiglianza. Essenzialmente si considera una funzione crescente senza un dominio chiuso, della quale non è possibile trovare il massimo, perché situato ai limiti dello spazio parametrico. Formalmente, ipotizzando che il gruppo A abbia gli elementi sempre vincenti:

$$\ell(\gamma) = \ell(\gamma_A; \gamma_B) \leq \ell\left(\frac{\alpha\gamma_A}{c}; \frac{\gamma_B}{c}\right),$$

dove $c = \sum \alpha\gamma_A + \sum \gamma_B$.

Date queste condizioni, ed assumendo di stare lavorando in un insieme compatto come quello individuato dalle assunzioni $\{\mathbf{w} \in \mathbb{R}^m : w_i \geq 0, \sum_i w_i = 1\}$ contenente un unico vettore $\mathbf{w}$ che massimizza la funzione, dimostrando che essa è concava, si può dimostrare che esso sia unico. Questo procedimento logico è importante da precisare perché verrà ripro-

posto, con apposite estensioni delle assunzioni, anche nelle dimostrazioni di convergenza ai massimi di modelli più complessi.

3.2 Algoritmi MM e Stime di Massima Verosimiglianza

3.2.1 Gli Algoritmi MM in Generale

Ora che si è in grado di garantire l'esistenza delle stime di massima verosimiglianza, dando per vera l'assunzione 3.1, si vuole identificare un metodo stabile ed applicabile al modello in generale per ottenerle. Proprio per questo fine, è stato ideato l'algoritmo MM, il cui nome è stato per la prima volta proposto in [Lange et al. \(2000b\)](#), e si spiegherà successivamente perché mantenere questa sigla ambigua abbia un suo preciso scopo. Storicamente parlando, la struttura matematica alla base di questo genere di algoritmi è stata presentata da [Ortega & Rheinboldt \(1970\)](#) (e in alcuni lavori sempre della stessa annata dai medesimi autori), ma questi algoritmi non hanno inizialmente interessato la comunità statistica generale tanto quanto una loro applicazione specifica, ovvero gli algoritmi EM presentati in [Dempster et al. \(1977\)](#). Infatti gli algoritmi EXPECTATION-MAXIMIZATION sono un caso particolare degli MM. Nell'algoritmo MM si cerca di sostituire la funzione obiettivo con una surrogata più facile, chiamata minorante o maggiorante, a seconda del caso nel quale si cerca un massimo o un minimo, rendendo l'acronimo "MM" appropriato in entrambi i casi. Negli EM il primo passaggio consiste nell'individuare la verosimiglianza completa attesa condizionatamente ai dati osservati, ma ciò risulta essere pari a una funzione che fornisce una minorante della verosimiglianza. Malgrado gli MM non abbiano avuto la stessa diffusione, nel corso degli anni hanno visto applicazioni di successo in diversi contesti, dalla regressione quantilica ai modelli Bradley-Terry analizzati. Si procede ora a definire le funzioni minoranti e maggioranti, come proposta in [Hunter & Lange \(2004\)](#).

Definizione 3.1. Sia $\theta^{(m)}$ un valore fisso del parametro θ , e sia $g(\theta \mid \theta^{(m)})$ una funzione reale della variabile θ la cui forma dipende da $\theta^{(m)}$. Si dice che la funzione $g(\theta \mid \theta^{(m)})$ minora una funzione a valori reali $f(\theta)$ nel punto $\theta^{(m)}$ se valgono le seguenti condizioni:

$$\begin{aligned} g(\theta \mid \theta^{(m)}) &\leq f(\theta) && \text{per ogni } \theta, \\ g(\theta^{(m)} \mid \theta^{(m)}) &= f(\theta^{(m)}). \end{aligned} \tag{3.7}$$

In altre parole, la superficie $\theta \mapsto g(\theta \mid \theta^{(m)})$ si trova al di sotto della superficie $f(\theta)$ ed è tangente ad essa nel punto $\theta = \theta^{(m)}$. Si dice che la funzione $g(\theta \mid \theta^{(m)})$ *maggiora* $f(\theta)$ in $\theta^{(m)}$ se $-g(\theta \mid \theta^{(m)})$ *minora* $-f(\theta)$ in $\theta^{(m)}$.

Si ottiene dunque una funzione $g(\theta \mid \theta^{(m)})$ che è sempre minore (maggiore) della funzione obiettivo e che coincide con essa nel punto di tangenza $\theta^{(m)}$, ovvero nell'iterata corrente. Bisogna comprendere bene il fatto che la surrogata non coincide necessariamente con essa nel punto di massimo (minimo), altrimenti una singola massimizzazione sarebbe sufficiente e non vi sarebbe nulla da iterare, ma che essa dipende dal valore corrente $\theta^{(m)}$ in ogni iterazione. Una volta ottenuta la surrogata, si massimizza (minimizza), ottenendo la stima dell'ottimo $\theta^{(m+1)}$. Si rivaluta la funzione $\theta \mapsto g(\theta \mid \theta^{(m+1)})$, e si itera questo processo fino a convergenza. Naturalmente la difficoltà dell'algoritmo risiede nel trovare questa funzione minorante per poter semplificare i calcoli, e spesso si ricorre a note disequaglianze e caratteristiche delle funzioni, come la convessità o concavità. Uno dei vantaggi principali di questa metodologia è semplificare funzioni di massima verosimiglianza a più parametri in somme di funzioni mono-parametriche, il che permette un recupero di efficienza e semplicità di calcolo non indifferente. Una variante dell'algoritmo è la sua versione ciclica, dove si aggiornano i parametri con le loro stime nel corso della iterazione. Cioè, siccome nella m -esima iterazione si stimano p parametri, per stimare il j -esimo parametro è possibile utilizzare le stime aggiornate già ottenute $\theta_1^{(m+1)}, \dots, \theta_{j-1}^{(m+1)}$, rendendo il nostro algoritmo ciclico in maniera del tutto parallela a quello che accade negli Algoritmi EM ciclici. Questo aggiornamento anticipato non implica in nessun modo una preferibilità degli algoritmi ciclici, ed anzi è possibile che il dover ottenere funzioni diverse specifiche per ognuna delle p componenti renda meno efficiente l'algoritmo. Bisogna infine precisare che l'algoritmo porta sempre ad un aumento (diminuzione) della funzione obiettivo ad ogni iterata, ma in generale non è garantito che esso converga al punto di massimo assoluto, perché questo dipenderebbe dal punto di partenza.

3.2.2 Gli Algoritmi MM per Ottimizzare la Verosimiglianza

Dopo aver analizzato gli algoritmi MM in generale, si procede applicandoli alle verosimiglianze dei modelli Bradley-Terry generali affrontati nella Sezione 3.1, partendo dal modello di base 3.1. Senza perdita di generalità, si ipotizzi di identificare un generico vettore di parametri $\gamma^{(0)}$ come punto di partenza (questa scelta inciderà sull'efficienza ma non sulla convergenza o precisione del metodo). Si deve procedere ad ottenere la funzione




Figura 3.1: Esempio di Algoritmo MM, per una generica funzione $f(\theta)$. Si sottolinea una importante discrepanza fra il grafico e la Figura 1.4, poiché se nella prima la minorante deve essere sempre minore della funzione obiettivo, nella seconda ciò non è dovuto. I due metodi agiscono in maniera distinta, per quanto possano sembrare simili a primo impatto.

minorante, ed in particolare si vuole semplificare il secondo termine della verosimiglianza. Per farlo si deve trovare una funzione sempre inferiore al secondo termine $-n_{ij} \log(\gamma_i + \gamma_j)$. Questa funzione è convessa e monotona, ed è noto che il piano tangente risulta essere sempre inferiore a questa funzione. Utilizzando gli sviluppi di Taylor si ottiene che:

$$f(u) \geq f(u_0) + \nabla f(u_0)(u - u_0), \quad \forall u, u_0 > 0.$$

Siccome la funzione $f(x) = -\log(x)$ è convessa (infatti la derivata seconda risulta essere pari a $\frac{1}{x^2}$), allora questa disuguaglianza vale anche per la nostra log-verosimiglianza, per la quale si ottiene che:

$$-\log(u) \geq -\log(u_0) - \frac{u - u_0}{u_0} = 1 - \log(u_0) - \frac{u}{u_0}. \quad (3.8)$$

Definendo $u = \gamma_i + \gamma_j$ e $u_0 = \gamma_i^{(k)} + \gamma_j^{(k)}$, si costruisce la funzione minorante $Q_k(\gamma)$ di 3.1 pari a:

$$Q_k(\gamma) = \sum_{i=1}^m \sum_{j=1}^m n_{ij} \left[\log \gamma_i + 1 - \log \left(\gamma_i^{(k)} + \gamma_j^{(k)} \right) - \frac{\gamma_i + \gamma_j}{\gamma_i^{(k)} + \gamma_j^{(k)}} \right] \leq \ell(\gamma), \quad (3.9)$$

Questo risultato è stato anche ottenuto in [Lange et al. \(2000a\)](#). Si può spiegare la minorazione mostrando che:

$$Q_k(\gamma) + [\ell(\gamma^{(k)}) - Q_k(\gamma^{(k)})] \leq \ell(\gamma),$$

con uguaglianza se e solo se $\gamma = \gamma^{(k)}$ coincide con l'argomento di partenza dell'iterazione. Ottimizzando la minorante si ottiene la seguente equazione:

$$\frac{\partial Q_k(\gamma)}{\partial \gamma_i} = \sum_{j=1}^m \left[\frac{n_{ij}}{\gamma_i} - \frac{n_{ij}}{(\gamma_i^{(k)} + \gamma_j^{(k)})} - \frac{n_{ji}}{(\gamma_i^{(k)} + \gamma_j^{(k)})} \right],$$

dove si ricorda che se $i = j$ il contributo è nullo. Ponendo la derivata pari a zero e dopo semplici passaggi algebrici:

$$\gamma_i^{(k+1)} = N_i \left[\sum_{j=1}^m \frac{n_{ij} + n_{ji}}{\gamma_i^{(k)} + \gamma_j^{(k)}} \right]^{-1}, \quad (3.10)$$

dove $N_i = \sum_{j=1}^m n_{ij}$, cioè il numero totale di vittorie dell' i -esimo player, e $n_{ij} + n_{ji}$ risulta pari al numero di incontri fra la i -esima e j -esima squadra. Si noti anche come questi risultati coincidano con quanto ottenuto in [Zermelo \(1929\)](#). L'algoritmo riesce a mostrare che questo risultato è uguale al metodo classico ma ne permette la generalizzazione. Qualora $\gamma^{(k)}$ non soddisfi la condizione $\sum_{i=1}^p \gamma_i = 1$, basterà normalizzare la quantità ad ogni passaggio. La versione ciclica di questo algoritmo (simile al rapporto fra metodo di Jacobi e Gauss-Seidel per risoluzione di un sistema lineare) risulta essere pari a:

$$\gamma_i^{(k+1)} = N_i \left[\sum_{j < i} \frac{n_{ij} + n_{ji}}{\gamma_i^{(k)} + \gamma_j^{(k+1)}} + \sum_{j > i} \frac{n_{ij} + n_{ji}}{\gamma_i^{(k)} + \gamma_j^{(k)}} \right]^{-1}.$$

Sotto Assunzione [3.1](#) si hanno quindi due algoritmi che convergono e nei quali ogni iterazione aumenta la verosimiglianza, ottenendo come risultato una sequenza di vettori di parametri $\gamma^{(1)}, \gamma^{(2)} \dots$ tali per cui $\ell(\gamma^{(1)}), \ell(\gamma^{(2)}) \dots$ è sempre crescente. Dopo aver testato l'efficacia degli algoritmi MM sul caso meno complesso dei modelli Bradley-Terry, si procede ad una applicazione più ostica e complessa.

Ottimizzazione del Modello di Davidson Passiamo ora al modello 3.2 per pareggi. Bisogna ottenere la funzione minorante $Q_k(\gamma, \theta)$ della verosimiglianza:

$$\ell(\gamma, \theta) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m [2n_{ij} \log \gamma_i + t_{ij} \log (\theta \sqrt{\gamma_i \gamma_j}) - (2n_{ij} + t_{ij}) \log(\gamma_i + \gamma_j + \theta \sqrt{\gamma_i \gamma_j})] . \quad (3.11)$$

Si nota in particolare che l'ultimo termine presenta una struttura simile all'ultimo termine del modello di base. Riutilizzando la disequazione 3.8 si ottiene che:

$$Q_k(\gamma, \theta) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \left[2n_{ij} \log \gamma_i + t_{ij} \log (\theta \sqrt{\gamma_i \gamma_j}) - \frac{(2n_{ij} + t_{ij})(\gamma_i + \gamma_j + \theta \sqrt{\gamma_i \gamma_j})}{\gamma_i^{(k)} + \gamma_j^{(k)} + \theta^{(k)} \sqrt{\gamma_i^{(k)} \gamma_j^{(k)}}} \right] .$$

Malgrado però questa prima semplificazione abbia rimosso il logaritmo dalla parte problematica dell'equazione, e malgrado sia possibile semplificare ulteriormente la quantità $\log(\theta \sqrt{\gamma_i \gamma_j})$, riuscendo a dividerla nelle sue componenti singole, la presenza della media geometrica $\theta \sqrt{\gamma_i \gamma_j}$ nell'ultimo termine risulta ancora troppo problematica. Per ovviare a questo si utilizza un'altra disuguaglianza nota, cioè quella fra media geometrica e media aritmetica, che dice:

$$\sqrt[m]{\prod_{i=1}^m x_i} \leq \frac{1}{m} \sum_{i=1}^m x_i .$$

Ponendo i valori della media $x_1 = \gamma_i \sqrt{\gamma_j^{(k)} / \gamma_i^{(k)}}$ e $x_2 = \gamma_j \sqrt{\gamma_i^{(k)} / \gamma_j^{(k)}}$, e ricordandoci che il segno della log-verosimiglianza risulta negativo, si può maggiorare:

$$-\sqrt{\gamma_i \gamma_j} \geq -\frac{\gamma_i}{2} \sqrt{\frac{\gamma_j^{(k)}}{\gamma_i^{(k)}}} - \frac{\gamma_j}{2} \sqrt{\frac{\gamma_i^{(k)}}{\gamma_j^{(k)}}} .$$

Si ottiene finalmente una verosimiglianza con parametri separati che verrà indicata come $Q_k^*(\gamma, \theta)$, che sarà minorante per $Q_k(\gamma, \theta)$, e quindi per transitività sarà minorante anche della verosimiglianza. Essa sarà pari a:

$$Q_k^*(\gamma, \theta) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \left[2n_{ij} \ln \gamma_i + t_{ij} \ln(\theta \sqrt{\gamma_i \gamma_j}) - \frac{(2n_{ij} + t_{ij})(\gamma_i + \gamma_j)}{\gamma_i^{(k)} + \gamma_j^{(k)} + \theta^{(k)} \sqrt{\gamma_i^{(k)} \gamma_j^{(k)}}} \right]$$

$$- \frac{\theta(2n_{ij} + t_{ij})}{\gamma_i^{(k)} + \gamma_j^{(k)} + \theta^{(k)} \sqrt{\gamma_i^{(k)} \gamma_j^{(k)}}} \left(\frac{\gamma_i}{2} \sqrt{\frac{\gamma_j^{(k)}}{\gamma_i^{(k)}}} + \frac{\gamma_j}{2} \sqrt{\frac{\gamma_i^{(k)}}{\gamma_j^{(k)}}} \right) \Bigg].$$

Passando ora alla derivazione della funzione, è possibile ottimizzare ogni parametro separatamente. Si ottiene infatti il massimo rispetto al vettore di parametri γ , dando per costante il valore di $\theta^{(k)}$. Derivando la funzione minorante rispetto a γ_i si ottiene:

$$\begin{aligned} \frac{\partial Q_k^*(\gamma, \theta^{(k)})}{\partial \gamma_i} &= \frac{1}{2} \sum_{j=1}^m \left[\frac{2n_{ij}}{\gamma_i} + \frac{t_{ij}}{2\gamma_i} + \frac{t_{ji}}{2\gamma_i} - \frac{(2n_{ij} + t_{ij})}{\gamma_i^{(k)} + \gamma_j^{(k)} + \theta^{(k)} \sqrt{\gamma_i^{(k)} \gamma_j^{(k)}}} \right. \\ &\quad \left. - \frac{\theta^{(k)}(2n_{ij} + t_{ij}) \sqrt{\gamma_j^{(k)}}}{\gamma_i^{(k)} + \gamma_j^{(k)} + \theta^{(k)} \sqrt{\gamma_i^{(k)} \gamma_j^{(k)}}} \frac{1}{2\sqrt{\gamma_i^{(k)}}} \right] = 0, \end{aligned}$$

dove il numero di pareggi fra squadre i e j sarà uguale, cioè $t_{ij} = t_{ji}$. Tramite alcuni passaggi algebrici, e riordinando dall'altra parte dell'equazione, si vede che:

$$= \frac{1}{2} \sum_{j=1}^m \left[\frac{2n_{ij} + t_{ij}}{\gamma_i} \right] = \sum_{j=1}^m \frac{(4n_{ij} + 2t_{ij}) + \theta^{(k)}(2n_{ij} + t_{ij}) \frac{\sqrt{\gamma_j^{(k)}}}{\sqrt{\gamma_i^{(k)}}}}{2(\gamma_i^{(k)} + \gamma_j^{(k)} + \theta^{(k)} \sqrt{\gamma_i^{(k)} \gamma_j^{(k)}})}.$$

Chiamando la parte a destra dell'equazione g_{ij} , e risolvendo alcuni passaggi algebrici:

$$\gamma_i^{(k+1)} = \frac{2N_i + T_i}{\sum_{j=1}^m g_{ij}(\gamma^{(k)}, \theta^{(k)})}. \quad (3.12)$$

Ora che si è ottenuta la stima per i valori di $\gamma^{(k+1)}$, si passa alla stima del coefficiente $\theta^{(k+1)}$. Derivando infatti $Q_k^*(\gamma, \theta)$ per θ si ottiene:

$$\begin{aligned} \frac{\partial Q_k^*(\gamma^{(k+1)}, \theta)}{\partial \theta} &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \frac{t_{ij}}{\theta} - \\ &\quad \frac{2n_{ij} + t_{ij}}{\gamma_i^{(k+1)} + \gamma_j^{(k+1)} + \theta^{(k)} \sqrt{\gamma_i^{(k+1)} \gamma_j^{(k+1)}}} \left(\frac{\gamma_i^{(k+1)}}{2} \sqrt{\frac{\gamma_j^{(k+1)}}{\gamma_i^{(k+1)}}} + \frac{\gamma_j^{(k+1)}}{2} \sqrt{\frac{\gamma_i^{(k+1)}}{\gamma_j^{(k+1)}}} \right). \end{aligned}$$

Si può notare come l'ultima parte dell'equazione fra parentesi si può semplificare nel termine $\sqrt{\gamma_i^{(k+1)}\gamma_j^{(k+1)}}$, e di conseguenza ponendo la derivata pari a 0 risulta che:

$$\sum_{i=1}^m \sum_{j=1}^m \frac{t_{ij}}{\theta} = \sum_{i=1}^m \sum_{j=1}^m \frac{2n_{ij} + t_{ij}}{\gamma_i^{(k+1)} + \gamma_j^{(k+1)} + \theta^{(k)} \sqrt{\gamma_i^{(k+1)}\gamma_j^{(k+1)}}} \left(\sqrt{\gamma_i^{(k+1)}\gamma_j^{(k+1)}} \right).$$

Procedendo risolvendo le sommatorie per il valore t_{ij} , che ci restituisce il doppio del numero di pareggi nel sistema, che si indica con T , e invertendo entrambe le componenti, si ottiene che:

$$\theta^{(k+1)} = 2T \left[\sum_{i=1}^m \sum_{j=1}^m \frac{(2n_{ij} + t_{ij})(\sqrt{\gamma_i^{(k+1)}\gamma_j^{(k+1)}})}{\gamma_i^{(k+1)} + \gamma_j^{(k+1)} + \theta^{(k)} \sqrt{\gamma_i^{(k+1)}\gamma_j^{(k+1)}}} \right]^{-1}. \quad (3.13)$$

I risultati appena presentati possono essere liberamente adattati (con le apposite correzioni) al caso ciclico che converge, sotto la medesima 3.1, allo stimatore di massima verosimiglianza.

3.2.3 Vantaggi e Limiti degli Algoritmi MM

Sono già stati discussi alcuni dei vantaggi intrinseci dell'algoritmo MM, come la necessità di poche assunzioni o il poter avere un punto di partenza $\gamma^{(0)}$ arbitrario sotto adeguate condizioni. Giunti a questo punto, è naturale chiedersi se, qualora siano soddisfatte le condizioni di convergenza e stabilità di altri algoritmi come Newton-Raphson visto in 1.3.3, preferirlo all'approccio MM appena presentato. È possibile infatti costruire un parallelismo con il rapporto fra bisezione e Newton Raphson per la ricerca degli zeri di funzione: il primo è un metodo molto generale, necessita di poche condizioni, ma per questo relativamente lento nella convergenza (infatti l'errore decresce linearmente), mentre il secondo richiede più assunzioni ma produce una stima molto veloce poiché sfrutta l'informazione della derivata (infatti presenta una velocità di convergenza quadratica). L'aggiornamento MM è un'iterazione di punto fisso non lineare che ricalca la struttura dell'aggiornamento di Jacobi (o Gauss-Seidel nella versione ciclica). Con ciò non si intende in nessun modo dire che i due coincidano, ma si vuole costruire un paragone con due metodi più comuni e dei quali i principi di convergenza risultano simili. Siccome è possibile dimostrare che attorno all'ottimo si ottiene convergenza lineare, si può giustificare intuitivamente il criterio d'arresto sulle iterate. Infatti per quanto alto sia il coefficiente angolare, se ci

si trova vicino al valore ottimo, la differenza tra iterate successive convergerà sempre a 0. Naturalmente questo non significa che i due metodi coincidono perfettamente, infatti in Jacobi si ha un problema di punto fisso, mentre nel caso presentato bisogna individuare condizioni per garantire la convergenza al punto ottimo. Detto ciò, l'algoritmo di Newton-Raphson può risultare estremamente pesante a livello computazionale, infatti per ottenere l'equazione 1.6 bisogna risolvere a ogni iterazione un sistema lineare associato alla matrice Hessiana, di dimensione $p \times p$. Negli algoritmi MM la separazione dei parametri porta ad un guadagno in termini di semplicità di calcolo talmente elevato da risultare solitamente più conveniente di Newton-Raphson (come mostra anche Hunter (2004) nel suo esempio, dove N-R risulta circa 70 volte più lento, malgrado richieda un quinto delle iterazioni). Per quanto riguarda altri metodi, come i metodi quasi-Newtoniani, Fisher Scoring o addirittura l'algoritmo di Nelder e Mead, che è euristico e non utilizza gradiente (per una trattazione più approfondita di questi ultimi, si rimanda a Nocedal & Wright (2006)), i quali spesso si concentrano sull'alleggerimento computazionale o di condizioni dell'algoritmo, andando però a perdere in termini di efficienza, non risultano essere particolarmente consigliabili rispetto agli MM. Malgrado ogni metodo possieda vantaggi e svantaggi, e ovviamente bisogna trattare ogni caso individualmente, gli MM sono metodi stabili e, sotto semplici ipotesi, "BULLET-PROOF". Un secondo punto di riflessione, come spiegano Hunter & Lange (2004), può essere la stima degli errori standard. Solitamente si può utilizzare quanto visto in 1.3.2 ed invertire l'informazione attesa di Fisher per stimare la varianza. Quando però essa risulta difficile da ottenere, come nel caso degli algoritmi MM, si possono utilizzare approssimazioni numeriche della derivata seconda grazie alla funzione minorante (o maggiorante) $g(\theta \mid \theta^{(m)})$. Infatti si può dimostrare (A.3) che, grazie al teorema della funzione implicita, assumendo una certa regolarità della minorante, definendo $M(\theta) = \arg_{\theta} \max g(\theta \mid \phi)$:

$$\nabla^2 \ell(\hat{\theta}) = \nabla^2 g(\hat{\theta} \mid \hat{\theta})[I - M(\hat{\theta})].$$

3.3 Convergenza al Massimo

3.3.1 Teorema di Lyapunov e Convergenza al Punto Stazionario

Nella precedente Sezione si è ottenuto un algoritmo MM capace di ottenere stime dei parametri per molteplici generalizzazioni di algoritmi Bradley-Terry, concentrandosi in

particolare sul modello di Davidson. Malgrado l'algoritmo garantisca una crescita certa della verosimiglianza ad ogni iterazione, questo di per sé non implica che il punto stazionario ottenuto coincida con lo stimatore di massima verosimiglianza, come già affermato in 3.1.4. Infatti generalmente non c'è garanzia che l'algoritmo MM converga, e cioè non solo non è garantito che $\lim_{k \rightarrow \infty} \gamma^{(k)} = \hat{\gamma}$, con $\hat{\gamma} = \arg \max_{\gamma} \ell(\gamma)$, ma non è neanche garantito che il limite esista effettivamente. Per dimostrarne l'esistenza, si può adoperare il seguente Teorema:

Teorema 3.1. *(Teorema di Lyapunov) Supponendo che $M : \Omega \rightarrow \Omega$ sia continua e che $\ell : \Omega \rightarrow \mathbb{R}$ sia differenziabile e che, per ogni $\gamma \in \Omega$, si abbia che $\ell(M(\gamma)) \geq \ell(\gamma)$, con uguaglianza se e solo se γ è un punto stazionario di $\ell(\cdot)$ (cioè il gradiente è nullo). Allora, per un arbitrario punto di inizio $\gamma^{(0)} \in \Omega$, ogni punto limite della successione*

$$\{\gamma^{(k+1)} = M(\gamma^{(k)})\}_{k \geq 1}$$

è un punto stazionario di $\ell(\gamma)$.

Infatti il teorema garantisce che $\ell(\gamma^{(k_n)}) \leq \ell[M(\gamma^{(k_n)})] \leq \ell(\gamma^{(k_{n+1})})$. Nel caso degli algoritmi MM presentati, la funzione $M(\gamma^{(k)})$ restituisce l'argomento massimo della mino-
rante nella k -esima iterazione, ovvero $\arg \max_{\gamma^{(k)}} Q_k(\gamma^{(k)})$. Si noti che essa risulta continua come risultato di operazioni su funzioni continue. È possibile dunque garantire che l'algoritmo converga ad un punto stazionario, poiché il teorema assume che $\ell[M(\gamma)] = \ell(\gamma)$ solo in un punto stazionario. Si è dunque dimostrato che l'algoritmo converge ad un punto stazionario, e bisogna dunque dimostrare che questo coincida con il massimo assoluto della funzione. Per fare ciò basterà ottenere due condizioni sufficienti per garantire che:

- L'insieme di livello della verosimiglianza sia compatto, ovvero che:

$$\{\gamma \in \Omega : \ell(\gamma) \geq c\}, \quad \forall c \in \mathbb{R}.$$

Questa proprietà, chiamata Compattezza Superiore, riesce a garantire che l'argomento che massimizza la funzione è individuabile, ed evita casi anomali come la presenza di asintoti verticali, che renderebbero impossibile l'identificazione di punti di massimo.

- Si possa riparametrizzare la funzione di log-verosimiglianza in modo tale da avere una condizione sufficiente alla concavità, il che implica che l'eventuale punto stazio-

nario esistente sia unico e coincida con il massimo assoluto della funzione. Questo inoltre non comporta una perdita delle proprietà della funzione minorante o maggiorante e nemmeno al cambiamento delle iterazioni opportunamente parametrizzate, perché la riparametrizzazione non influisce sulle diseguaglianze. Al contrario, algoritmi come ad esempio Newton-Raphson non godono di queste proprietà di invarianza perché, adoperando l'Hessiana, vengono influenzati dalla forma locale della funzione.

Si potrà dunque garantire, grazie al Teorema 3.1 e alle condizioni appena presentate, la convergenza del nostro algoritmo al massimo assoluto della verosimiglianza indipendentemente dal punto di inizio $\gamma^{(0)}$. Nelle successive Sezioni si procederà a ricavare assunzioni sufficienti a soddisfare le condizioni e a garantire la convergenza al massimo.

3.3.2 Compattezza Superiore

Garantire la compattezza superiore dell'insieme risulta difficile, ma adoperando una assunzione molto simile a quella costruita da Ford (1957) per il modello base 3.1, si dimostra questa proprietà nel caso del modello di Davidson (1970). Infatti quanto visto in 3.1.4 non serve semplicemente a dimostrare l'esistenza della stima, ma contribuisce anche a garantire che tale stima corrisponda a un massimo. Infatti, qualora la Assunzione 3.1 sia valida, si può dimostrare il seguente Lemma:

Lemma 3.1. (*Compattezza Superiore*) Sia $\Omega = \{\gamma \in \mathbb{R}^m : \gamma_i > 0, \sum_{i=1}^m \gamma_i = 1\}$. Lo spazio dei parametri è assunto essere Ω per la log-verosimiglianza del modello Bradley-Terry di base (3.1), e $\Omega \times \{\theta \in \mathbb{R} : \theta > 0\}$ per la log-verosimiglianza del modelli di Davidson (3.2). Allora:

- (a) La log-verosimiglianza del modello 3.1 è superiormente compatta se e solo se vale l'Assunzione 3.1.
- (b) La log-verosimiglianza del modello 3.2 è superiormente compatta se vale l'Assunzione 3.1 ed è presente almeno un pareggio.

Anche per dimostrare il Lemma è possibile utilizzare un ragionamento simile a quello di Ford (1957). Si consideri un punto $\tilde{\gamma}$ sul bordo dello spazio parametrico, ovvero tale che $\tilde{\gamma}_i = 0$ per almeno un indice i . Per l'Assunzione 3.1 esiste almeno un individuo j , con $\tilde{\gamma}_j > 0$, che ha battuto almeno una volta un individuo i con $\tilde{\gamma}_i = 0$ (qualora ciò non valesse direttamente, l'assunzione garantisce comunque una catena di vittorie indirette che

collega i due gruppi). Poiché ogni addendo della (3.1) è il logaritmo di una probabilità, e dunque non positivo, si migliora la log-verosimiglianza con il solo contributo di quella vittoria $\ell(\boldsymbol{\gamma}) \leq \log \gamma_i - \log(\gamma_i + \gamma_j)$, dove il secondo termine è costante. Poiché $\gamma_i = 0$, allora il limite della log-verosimiglianza:

$$\lim_{\boldsymbol{\gamma} \rightarrow \tilde{\boldsymbol{\gamma}}} \ell(\boldsymbol{\gamma}) = -\infty, \quad \boldsymbol{\gamma} \in \Omega.$$

Questo garantisce la compattezza superiore della log-verosimiglianza per qualsiasi costante c . Dunque i può vincere sempre contro j senza compromettere l'esistenza del massimo, purché j partecipi a una catena di vittorie su altre squadre che la colleghi alla squadra i , ottenendo una sorta di “vittoria indiretta”. Detto ciò, dividendo le osservazioni in due gruppi distinti A e B in modo tale che nessun soggetto del gruppo A batta mai un soggetto del gruppo B, allora per quanto detto in 3.1.4 è sempre possibile moltiplicare i parametri legati ai soggetti appartenenti al gruppo B (e normalizzando opportunamente per soddisfare i vincoli del modello) ed aumentare il vettore $\boldsymbol{\gamma}$ verso i confini dello spazio parametrico senza diminuire mai la verosimiglianza, e rendendola in questo caso non superiormente compatta, perché l'insieme $\{\boldsymbol{\gamma} \in \Omega : \ell(\boldsymbol{\gamma}) \geq c\}$ non sarebbe chiuso. Dunque risulta sufficiente rispettare l'Assunzione 3.1 per dimostrare il primo punto del Lemma 3.1. Per dimostrare il secondo punto il ragionamento è parallelo. Infatti qualora i parametri $(\tilde{\boldsymbol{\gamma}}, \tilde{\theta})$ si trovino sul bordo dello spazio parametrico $\Omega \times (0, \infty)$, basterà dimostrare che

$$\lim_{(\boldsymbol{\gamma}, \theta) \rightarrow (\tilde{\boldsymbol{\gamma}}, \tilde{\theta})} \ell(\boldsymbol{\gamma}, \theta) = -\infty.$$

Siccome però nella verosimiglianza del modello 3.2 si può separare l'effetto del parametro θ , si può notare che indipendentemente dal valore di $\hat{\theta}$ il limite tenda a $-\infty$, e che quando θ appartiene al bordo dello spazio parametrico si ottiene il medesimo risultato. L'assunzione anche in questo caso permette di evitare casi di estrema suddivisione dei soggetti che rendano impossibile l'individuazione di un massimo. Bisogna anche precisare che, qualora nel modello di Davidson non vi sia presente alcun pareggio, come richiesto dal lemma, non si ha un problema nella pratica. Questo perché qualora il caso sotto esame non presenti pareggi, la stima del parametro θ risulta nulla e comunque non significativa per costituzione del problema, ed il modello sarà equivalente al caso visto in 3.1. Questo garantisce che, se l'Assunzione 3.1 è soddisfatta, la verosimiglianza sia superiormente compatta.

3.3.3 Concavità della Log-Verosimiglianza

Successivamente si vuole riparametrizzare il modello in modo tale da fornire una condizione sufficiente per la concavità della log-verosimiglianza. Se si riesce a dimostrare la concavità per una parametrizzazione che semplifica anche di molto la verosimiglianza, si può dimostrare la concavità anche nella parametrizzazione di partenza, perché gli argomenti dei massimi e la forma della funzione restano uguali. In particolare, la parametrizzazione sarà una mappatura 1 : 1 sull'insieme $\Omega = \{\boldsymbol{\gamma} \in \mathbb{R}^m : \gamma_i > 0, \sum_i \gamma_i = 1\}$ (ponendo di identificare l' I -esimo player come baseline, cioè che $\gamma_I = e^{\beta_I}$ con $\beta_I = 0$). Si precisa che la restrizione dello spazio parametrico è stata scelta per comodità espositiva, e che qualsiasi normalizzazione per ciascuna classe di equivalenza produce un problema equivalente (al netto di una costante irrilevante). Utilizzando la parametrizzazione suggerita da [Hunter \(2004\)](#), si definisca $\beta_i = \log \gamma_i - \log \gamma_I$ e $\phi = \log \theta$. Allora si ridefiniscono i parametri $(\boldsymbol{\gamma}, \theta)$ come:

$$\gamma_i = \frac{e^{\beta_i}}{\sum_{j=1}^m e^{\beta_j}}, \quad \theta = e^{\phi}.$$

Il modello originale 3.1 trasformato ritorna ad essere uguale alla forma vista in 2.12, con la verosimiglianza che diventa

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^m \sum_{j=1}^m [n_{ij} \beta_i - n_{ij} \log(e^{\beta_i} + e^{\beta_j})] \quad (3.14)$$

Nel modello di [Davidson \(1970\)](#) si modellano i rapporti fra i possibili risultati, infatti:

$$\gamma_i : \gamma_j : \theta \sqrt{\gamma_i \gamma_j} \propto e^{\beta_i} : e^{\beta_j} : e^{\phi} e^{(\beta_i + \beta_j)/2},$$

applicando il logaritmo al rapporto fra gli eventi, si ottiene, rapportando rispettivamente vittoria e sconfitta e successivamente vittoria e pareggio:

$$\log \frac{P(i \succ j)}{P(j \succ i)} = \beta_i - \beta_j, \quad \log \frac{P(i \succ j)}{P(i \sim j)} = \frac{\beta_i - \beta_j}{2} - \phi.$$

La verosimiglianza riparametrizzata risulterà di fatto uguale a:

$$\ell(\boldsymbol{\beta}, \phi) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \left[2n_{ij} \beta_i + t_{ij} \left(\phi + \frac{\beta_i + \beta_j}{2} \right) - (2n_{ij} + t_{ij}) \log (e^{\beta_i} + e^{\beta_j} + e^{\phi + (\beta_i + \beta_j)/2}) \right]. \quad (3.15)$$

Hunter (2004) discute principalmente il modello base con verosimiglianza 3.14, spiegando che esso può essere modellabile adoperando una regressione logistica, vista nella Sezione 1.2.3, poiché rispetta le proprietà necessarie e la verosimiglianza è equivalente. Infatti siccome le estrazioni saranno indipendenti, e la probabilità di successo del modello base coincide con quella adottata per la probabilità nel caso binomiale, la verosimiglianza risulterà essere concava. Ma questo approccio non è adattabile alle generalizzazioni proposte. Una funzione si dice concava se, dati due vettori di parametri α e λ e una costante $t \in (0, 1)$:

$$f(t\alpha + (1-t)\lambda) \geq tf(\alpha) + (1-t)f(\lambda),$$

ovvero quanto visto in 1.3. Bisogna dunque dimostrare la concavità e individuare condizioni sufficienti a provarla. Naturalmente ci sono moltissimi modi per dimostrarlo, ma in questo elaborato si adopererà il concetto di funzioni log-convesse, una proprietà molto più forte della convessità normale. Se si riesce a provare questa proprietà automaticamente la funzione risulterà convessa, e dunque concava qualora invertita di segno.

Definizione 3.2. Sia $I \subseteq \mathbb{R}$ un intervallo e $f : I \rightarrow (0, \infty)$. Si dice che f è log-concava se il $\log f$ è convessa su I , ovvero se:

$$\log f(tx_1 + (1-t)x_2) \leq t \log f(x_1) + (1-t) \log f(x_2), \quad \forall x_1, x_2 \in I, \quad \forall t \in [0, 1].$$

Una funzione si dice log-concava quando $\log(f(x))$ è convessa, o alternativamente se la inversa $1/f(x)$ è log-concava. A livello pratico, questa definizione implica che la crescita di queste funzioni è talmente pronunciata da riuscire a “contrastare” la concavizzazione del logaritmo. Infatti anche applicandolo, la relazione tra funzione della trasformazione e trasformazione della funzione resta convessa. È importante comprendere anche che questa classe di funzione è chiusa rispetto alla somma, cioè il risultato di somme di funzioni log-convesse risulta sempre log-convesso. Nelle verosimiglianze dei modelli Bradley-Terry e nelle sue generalizzazioni (si prenderà come esempio il modello base 3.15), si noti come i primi due termini sono rette, risultando dunque sia concave sia convesse, mentre il secondo termine è tale per cui (al netto di costanti ininfluenti):

$$-\log[e^{\beta_i} + e^{\beta_j} + e^{(\phi + (\beta_i + \beta_j)/2)}] \geq -\log(e^{\beta_i}) - \log(e^{\beta_j}) - \log e^{(\phi + (\beta_i + \beta_j)/2)}.$$

Questo prova la log-concavit  dell'ultima parte della verosimiglianza 3.15, infatti, in generale, la classe di funzioni log-convesse risulta chiuso alla somma. Dunque si sta invertendo di segno una funzione log-convessa, che risulta log-concava.

Si vogliono ora identificare le condizioni di uguaglianza della disequazione 1.3 per ottenere un criterio per la concavit  stretta della funzione, che proverebbe l'esistenza di un unico massimo e la convergenza dell'algoritmo. Si noti come la disuguaglianza, date le funzioni di log-verosimiglianza, risulta stretta quando $\alpha = \lambda$, dove entrambi i parametri appartengono al sottospazio parametrico vincolato $\Omega' = \{\beta \in \mathbb{R}^m : \beta_I = 0\}$. Bisogna infatti ricordare come per i modelli Bradley-Terry e le sue generalizzazioni, vettori di parametri che differiscono per una costante conducono allo stesso modello. Se questo non fosse vero, qualsiasi coppia di vettori α e λ tale per cui $\alpha_i - \lambda_i = \alpha_j - \lambda_j, \forall i, j$ quando si comparano i e j almeno una volta, cio  che i due vettori sono separati da una costante, soddisferebbe la condizione di uguaglianza. Dunque nel caso ristretto, per soddisfare l'uguaglianza si richiedono due vettori identici, che conducono allo stesso modello. Nel caso del modello Davidson (1970), per dimostrare la concavit  si richieder  che, dati due modelli con due vettori di parametri (α, ϕ_1) e (λ, ϕ_2) , i vettori di parametri coincidano affin  che l'equazione sia soddisfatta (dunque anche $\phi_1 = \phi_2$). Sembrerebbe dunque che, per qualsiasi vettore di parametri appartenenti a $\Omega' = \{\beta \in \mathbb{R}^m : \beta_I = 0\}$ ($(\beta, \phi) \in \Omega' \times \mathbb{R}$ nel modello con pareggio) le verosimiglianze siano strettamente concave. Questo per  non risulta necessariamente vero, ed infatti, si richiede comunque un'ulteriore assunzione per evitare alcuni particolari casi degeneri.

Assunzione 3.2. *In ogni possibile partizione degli individui in due sottoinsiemi non vuoti, esiste almeno un individuo del secondo insieme che viene confrontato almeno una volta con un individuo del primo insieme.*

Data questa Assunzione,   possibile ricavare il seguente Lemma:

Lemma 3.2. *Per la riparametrizzazione $(\gamma, \theta) \mapsto (\beta, \phi)$, in cui $\beta_i = \log \gamma_i - \log \gamma_I$ e $\phi = \ln \theta$, sia $\Omega' = \{\beta \in \mathbb{R}^m : \beta_I = 0\}$.*

- (a) *La versione riparametrizzata della log-verosimiglianza del modello base 3.14   strettamente concava su Ω' se e solo se vale l'Assunzione 3.2.*
- (b) *La versione riparametrizzata del modello per pareggi di Davidson 3.15   strettamente concava su $\Omega' \times \mathbb{R}$ se e solo se vale l'Assunzione 3.2 ed esiste almeno un pareggio.*

Si procede a dimostrare il Lemma e successivamente a mostrarne le conseguenze logiche. Qualora l'Assunzione 3.2 fosse violata, è possibile creare due gruppi A e B tali per cui nessun individuo del primo gruppo viene confrontato con un individuo del secondo gruppo. Ma ciò implicherebbe che uno dei due gruppi (poniamo B) non contiene il parametro β_I di baseline, e che i propri parametri non si debbano adattare a cambiamenti della baseline. Di conseguenza, aggiungere una costante a questi parametri non porta in nessun modo a cambiamenti della verosimiglianza, e dunque:

$$f(t\alpha + (1-t)\lambda) = tf(\alpha) + (1-t)f(\lambda),$$

anche per valori di $\alpha \neq \lambda$. Questo contraddice la condizione di concavità stretta della disuguaglianza 1.3. Dunque è necessario verificare l'Assunzione 3.2 per prevenire questo caso degenerare, e garantisce dunque che la verosimiglianza risulti concava, e dunque che il punto stazionario, qualora esiste, coincide con il massimo di funzione.

Inoltre l'Assunzione 3.2 è più debole della 3.1, perché richiede solamente la presenza di uno scontro, non di almeno una vittoria dei soggetti, quindi qualora l'Assunzione 3.1 assunzione risulti soddisfatta, si garantisce non solo la compattezza superiore della funzione di verosimiglianza ma anche la sua concavità stretta nello spazio parametrico ristretto, e di conseguenza la convergenza dell'Algoritmo MM al massimo indipendentemente dal punto di partenza (grazie al Teorema 3.1).

3.4 Esempi Applicativi

Nella seguente sezione si presentano alcuni esempi applicativi del modello di Davidson, in un contesto calcistico.

3.4.1 Esempio 1 - Classifica della Serie A

Si vuole ottenere una classifica delle squadre di calcio nel campionato di Serie A nella stagione 2025/2026. Questo contesto è tipico per i modelli di Davidson, data la presenza di pareggi che impedirebbe l'utilizzo di un modello Bradley-Terry classico. Bisogna però anzitutto accettare un'ipotesi, ovvero che la forza delle squadre resti costante nel corso del tempo. Questo significa che vengono considerate le versioni finali delle squadre, dunque considerando la squadra a fine stagione dopo cambiamenti di rosa durante il "Mercato Invernale" o di proprietà della squadra. Malgrado a primo impatto possa sembrare un

problema, il modello non ha scopo predittivo, dunque considerare retroattivamente la forza delle squadre come costante non risulta un'ipotesi insensata, soprattutto in contesti di classificazioni storiche delle squadre (come si vedrà nell'Esempio 3.4.2). In sintesi il modello non è dinamico nel corso del tempo. Detto ciò, esistono generalizzazioni dinamiche dei Bradley-Terry che permettono di osservare l'andamento dell'abilità di un player (in questo caso una squadra) nel corso del tempo. Si vuole infine precisare che nel contesto della singola stagione, il modello di Davidson potrebbe sembrare poco interessante, data la presenza della classifica ufficiale, una graduatoria che di fatto penalizza e premia squadre in base ai risultati, e data la completa assenza di asimmetria negli incontri fra le squadre. Fatte queste premesse, si procede con i risultati del modello in questo contesto.

Prima di commentare le stime è necessario accertarsi che l'Assunzione 3.1, ovvero la condizione di Ford, sia effettivamente soddisfatta. Infatti è da essa che dipendono, come dimostrato nella Sezione 3.3.2 e nella Sezione 3.3.3, sia la compattezza superiore sia la concavità stretta della log-verosimiglianza riparametrizzata, e dunque l'unicità del massimo a cui l'algoritmo MM converge per il Teorema 3.1. È però possibile verificare che non esiste alcuna partizione delle squadre in due gruppi in cui un elemento dei due non abbia mai vinto contro l'altro. Bisogna evidenziare come in un contesto di doppio girone all'italiana, dove tutte le squadre si affrontano due volte, risulta estremamente improbabile che esista una squadra sempre perdente o vincente che non riesca a collegarsi indirettamente alle altre. Inoltre, anche se questo fosse il caso, se una squadra perdesse o vincessse tutte le partite, non sarebbe necessario scomodare il modello di Davidson per affermare che siano rispettivamente la peggiore o la migliore del campionato.

Stime di γ e θ La Tabella 3.1 riporta il ranking risultante dalla stima del modello di Davidson, confrontando la stima ottenuta massimizzando direttamente la verosimiglianza (3.2) tramite la funzione di ottimizzazione numerica di R `nlmminb` con quella ottenuta tramite un'implementazione dell'algoritmo MM di Sezione 3.1¹, insieme agli errori standard ottenuti con il metodo discusso in Appendice A.3.

Nella Tabella 3.1, le stime di forza sono riportate direttamente sulla scala $\hat{\beta} = \log \hat{\gamma}$ anziché su quella di $\hat{\gamma}$. Detto ciò, il risultato non cambia in alcun modo, essendo sufficiente calcolare $e^{\hat{\beta}}$ per riottenere le forze $\hat{\gamma}$ (e, viceversa, $\log \hat{\gamma}$ per riottenere $\hat{\beta}$). Si è scelto

¹Entrambe le stime condividono la medesima identificazione, cioè $\beta_{\text{Verona}} = 0$, essendo Verona la squadra baseline. Questa scelta è stata fatta puramente per l'ordine alfabetico delle squadre, ed un cambio di baseline non cambia né la classifica finale né le probabilità dei risultati fra le squadre

di procedere così per ottenere dei valori in scala esponenziale, altrimenti si potrebbero osservare differenze anche grandi per squadre relativamente vicine in forza (come $\gamma_{inter} \approx 44$ e $\gamma_{napoli} \approx 21$). Tutti i risultati, compresi gli errori standard, possono essere riottenuti in entrambe le scale, ed è stata puramente una scelta interpretativa.

Squadra	$\hat{\beta}$ (Verosimiglianza)	$\hat{\beta}$ (MM)	SE($\hat{\beta}$)
Inter	3.758	3.758	0.706
Napoli	3.037	3.036	0.661
Como	2.853	2.853	0.653
Roma	2.764	2.764	0.650
Milan	2.764	2.764	0.650
Juventus	2.764	2.764	0.650
Atalanta	2.255	2.255	0.634
Bologna	1.929	1.929	0.627
Lazio	1.929	1.929	0.627
Udinese	1.607	1.607	0.624
Sassuolo	1.527	1.527	0.623
Parma	1.446	1.446	0.623
Fiorentina	1.364	1.364	0.623
Torino	1.364	1.364	0.623
Cagliari	1.282	1.282	0.623
Genoa	1.199	1.199	0.624
Lecce	0.947	0.947	0.626
Cremonese	0.772	0.772	0.629
Verona (baseline)	0.000	0.000	—
Pisa	-0.223	-0.223	0.669
Pareggio ($\hat{\theta}$)	0.865	0.865	0.107

Tabella 3.1: Stime di $\hat{\beta}_i = \log \hat{\gamma}_i$ e del parametro di pareggio $\hat{\theta}$ per la Serie A, ottenute massimizzando direttamente la verosimiglianza e tramite l'algoritmo MM, con i relativi errori standard. Per $\hat{\theta}$ si riporta il valore in scala originaria, non essendo stato logaritmizzato nella stima.

Il primo dato rilevante è quanto le due colonne di stime coincidano: la differenza massima fra i due metodi è pari a circa 2.04×10^{-4} (registrata su Pisa), mentre per θ scende a circa 6.9×10^{-6} . Come già ripetuto più volte, pur muovendosi con logiche del tutto diverse, uno per approssimazioni tramite algoritmo di Newton-Raphson, l'altro per iterazioni di punto fisso, entrambi i metodi convergono alla medesima soluzione. Il ranking indica l'Inter (indicata come squadra 1) come la squadra più forte del campionato. Infatti la probabilità dell'Inter di ottenere un risultato utile (vittoria o pareggio) sulla seconda

POS	CLUB	PTS	W	D	L	POS	CLUB	PTS	W	D	L
1	INTER	87	27	6	5	11	SASSUOLO	49	14	7	17
2	NAPOLI	76	23	7	8	12	TORINO	45	12	9	17
3	ROMA	73	23	4	11	13	PARMA	45	11	12	15
4	COMO	71	20	11	7	14	CAGLIARI	43	11	10	17
5	MILAN	70	20	10	8	15	FIorentina	42	9	15	14
6	JUVENTUS	69	19	12	7	16	GENOA	41	10	11	17
7	ATALANTA	59	15	14	9	17	LECCE	38	10	8	20
8	BOLOGNA	56	16	8	14	18	CREMONESE	34	8	10	20
9	LAZIO	54	14	12	12	19	HELLAS VERONA	21	3	12	23
10	UDINESE	50	14	8	16	20	PISA	18	2	12	24

Figura 3.2: Classifica ufficiale di Serie A. Le colonne indicano (rispettivamente da sinistra a destra) punteggio finale, vittorie, pareggi e sconfitte.

squadra più forte del campionato (il Napoli, squadra 2) è pari a:

$$\hat{\Pi}_{1>2} = \frac{e^{\hat{\beta}_1}}{e^{\hat{\beta}_1} + e^{\hat{\beta}_2} + \hat{\theta}(e^{\frac{\hat{\beta}_1 + \hat{\beta}_2}{2}})} = 0.479, \quad \hat{\Pi}_{1\sim 2} = \frac{\hat{\theta}(e^{\frac{\hat{\beta}_1 + \hat{\beta}_2}{2}})}{e^{\hat{\beta}_1} + e^{\hat{\beta}_2} + \hat{\theta}(e^{\frac{\hat{\beta}_1 + \hat{\beta}_2}{2}})} = 0.289.$$

Questo dimostra naturalmente la forza schiacciante dei vincitori dello Scudetto. Questa probabilità di risultato utile supera il 90% contro le squadre in fondo alla classifica, il che è assolutamente eccezionale. Il valore stimato di $\hat{\theta} \approx 0.865$ indica invece una decisa propensione al pareggio, coerentemente con quanto atteso in un campionato con un numero di squadre di forza diversa ma con una propensione al gioco difensivo tipico in della massima divisione italiana. Bisogna inoltre notare come Milan, Juventus e Roma (ed anche altre squadre) condividano il valore del parametro β , malgrado la loro differente posizione in Serie A. Inoltre il Como è “premiato” dal modello, che lo considera la terza squadra d’Italia. Questo è dovuto dal fatto che il campionato è un doppio girone all’italiana, e dunque tutte le squadre si affrontano lo stesso numero di volte, e giocano lo stesso numero di partite. Di conseguenza, come si può vedere all’interno della formula 3.12, la funzione g_{ij} , che dipende da quantità costanti in ogni iterazione, risulterà uguale. Dunque gli unici valori che, in questo caso eccezionalmente simmetrico ed equo, modellano i parametri risultano il numero di vittorie ed il numero di pareggi. Inoltre, dato quanto visto in 3.12, la vittoria è premiata il doppio del pareggio, mentre nella classifica ufficiale vale

tre punti, contro il singolo punto del pareggio. Dunque, una squadra come il Como, con 20 vittorie e 11 pareggi risulterà premiata di più dal nostro modello rispetto alla Roma, che ha ottenuto 23 vittorie e 4 pareggi, e che nel campionato si è posizionata sopra al Como. Inoltre, se moltiplicassimo per due il numero di vittorie e sommassimo il numero di pareggi, otteniamo gli stessi medesimi risultati per Juventus e Milan, e questo spiega il perché il modello li considera di egual forza.

Errori Standard e Significatività Nell'esempio presentato l'Hessiana della verosimiglianza è stata ottenuta numericamente, sia tramite l'opzione `hessian = TRUE` di `optim` sia tramite un'approssimazione fra differenze simmetriche dell'Hessiana. In questo caso, relativamente semplice, malgrado il risultato presente in A.3 sia corretto, risultava inefficiente e poco utile implementare in forma chiusa la derivata seconda. Si noti che l'errore standard associato al parametro di pareggio, pari a 0.107, è sensibilmente più piccolo di quelli stimati per i singoli $\hat{\beta}$ (che oscillano fra 0.62 e 0.71). Questo è dovuto al fatto che $\hat{\theta}$ è stimato su ogni incontro, mentre ciascun $\hat{\beta}$ sfrutta solo le informazioni relative ai confronti diretti e indiretti della singola squadra i . Si tenga presente che la scelta della baseline può incidere sulla varianza. Infatti, nonostante il cambio della baseline lasci invariate le probabilità e i risultati di classifica, l'incertezza fra l' i -esimo player e la baseline varia a seconda della scelta di quest'ultima.

È infine possibile utilizzare queste quantità per testare l'ipotesi di non significatività dei parametri. Questo implicherebbe che le differenze osservate fra le forze delle squadre sono date da rumore statistico. Si presenta dunque il test di Wald (già visto in 1.1.5, con ipotesi nulla $H_0 = \beta_i - \beta_j = 0$, $W \stackrel{H_0}{\sim} \chi_1^2$), e si confronta la differenza fra l'Inter e il Verona (baseline):

$$\text{Inter e Verona} \quad W = 28.34, \quad p\text{-value} = 1.02e - 07.$$

Si rifiuta l'ipotesi nulla, dunque sembra esserci una differenza statisticamente significativa fra la forza dell'Inter e del Verona. Successivamente, si è interessati di comprendere se la differenza fra una squadra a metà classifica e una delle migliori in Italia, come il Napoli, risulti statisticamente significativa:

$$\text{Napoli e Udinese} \quad W = 5.72, \quad p\text{-value} = 0.017.$$

Anche in questo caso viene rifiutata l'ipotesi nulla.

Velocità di Convergenza Così come mostrato in [Hunter \(2004\)](#), gli algoritmi MM risultano essere sensibilmente più efficienti rispetto a quelli di ottimizzazione numerica classici, come già esposto in [3.2.3](#). Si è dunque utilizzato il pacchetto `microbenchmark`, che misura precisamente il tempo in millisecondi richiesto dal calcolatore per ottenere una convergenza dell'algoritmo. Si presentano dunque i risultati nella seguente Tabella [3.2](#):

Metodo	Tempo medio	Tempo mediano	Iterazioni medie
NLMINB	923.18	934.95	85
MM	32.49	30.66	168

Tabella 3.2: Confronto fra stima diretta della verosimiglianza (`nlminb`) e algoritmo MM in millisecondi: tempi di esecuzione e numero di iterazioni medi su 30 ripetizioni. Il vettore iniziale è stato scelto casualmente fra valori di $\gamma_i \in [0.05, 20.00]$, lasciando però $\gamma_{Baseline} = 1$

La condizione di convergenza è raggiunta quando la differenza in norme fra i parametri in iterate successive è inferiore ad una certa tolleranza. È possibile dimostrare che la convergenza dell'algoritmo MM è lineare (per la dimostrazione si rimanda a [Vojnovic et al. \(2020\)](#)), ma per i fini dell'elaborato è necessario sapere solamente che l'errore rispetto alla k -esima iterata sarà sempre inferiore alla differenza fra iterate successive moltiplicata per una certa costante, dipendente dalla sparsità dei dati ed al numero di incontri fra i soggetti. Formalmente:

$$\|\mathbf{e}^{(k)}\| \leq \frac{\|\boldsymbol{\mu}^{(k+1)} - \boldsymbol{\mu}^{(k)}\|}{1 - c}.$$

Anche in contesti estremamente sparsi, cioè nei quali sono presenti pochi scontri diretti (si pensi ad un torneo Mondiale, dove le squadre vincenti disputano non più di una dozzina di partite a eliminazione diretta) è possibile adoperare un secondo metodo di convergenza, legato alla distanza in norma fra le verosimiglianze calcolate nei valori delle iterate, e anch'esso regolato dalla medesima costante ma in maniera più ridotta. Detto ciò, per motivi di esposizione e coerenza con il contesto, si è scelto di adoperare il primo metodo. Come si può vedere dalla tabella, i risultati ottenuti dall'applicazione presentata tornano con quanto visto in [Hunter \(2004\)](#). Anche in questo caso, infatti, l'algoritmo MM impiega molte più iterazioni in media a convergere all'ottimo di funzione, ma lo fa in un tempo 30 volte inferiore in media. Questo è spiegabile dal peso computazionale dato dall'inversione della matrice Hessiana, operazione costosa ed evitata proprio dall'algoritmo MM. Bisogna sottolineare che questo è il tempo necessario solo ad eseguire il codice una volta preparati i dati. Se fosse richiesto un tempo estremamente elevato per questo

(anche se solitamente non è il caso), il costo fisso della preparazione renderebbe meno evidente l'immenso guadagno dell'algoritmo MM rispetto ai metodi Newton-Raphson. Infatti malgrado i primi convergano linearmente, anziché quadraticamente come i secondi, il guadagno di semplicità computazionale è talmente sostanziale da contrastare la velocità di convergenza.

3.4.2 Esempio 2 - Classifica Storica della Premier League

Si presenta un esempio di applicazione del modello di Davidson per modellare una classifica storica della Premier League, considerando le partite del campionato negli ultimi 26 anni. È stato scelto questo esempio che rende il contesto applicativo meno limitante per il modello per due motivazioni:

- La prima è mostrare le conseguenze del non avere squadre che si affrontino in maniera perfettamente simmetrica, cioè che tutte le squadre affrontino le altre lo stesso numero di volte. Questo è naturalmente dovuto alla retrocessione o promozione nel campionato massimo inglese di alcune squadre.
- La seconda, è osservare come si comporta il modello in un periodo di tempo più elevato, un contesto nel quale le squadre naturalmente cambiano, ma dove se si vuole fare una classifica storica è necessario dover considerare le squadre in base ai loro risultati all time, costruendo un resoconto, senza osservare dinamicamente i cambiamenti “congiunturali”.

Naturalmente, la condizione di Ford è risultata soddisfatta, e con una struttura di scontri diretti molto più connessa come questa è difficile che essa non sia soddisfatta. Di fatto l'unico caso in cui possa accadere è o la presenza di una squadra che, dopo essere stata promossa per una stagione in Premier, perde o pareggia ogni singola partita (il che non è letteralmente mai successo nella storia del campionato, e che risulta difficile grazie agli ingenti bonus monetari dati alle squadre promosse per mantenere alto il livello della divisione) oppure che una squadra abbia vinto ogni singola partita, che è anche più improbabile. La seguente Tabella 3.3 mostra le stime dei parametri ottenute per le 45 squadre che negli ultimi 26 anni sono state almeno una stagione in Premier League. Anche in questo caso, il Wolverhampton F.C. (dunque con $\beta = 0$) è stato scelto come baseline per ordine alfabetico.

Squadra	$\hat{\beta}$	SE($\hat{\beta}$)	Squadra	$\hat{\beta}$	SE($\hat{\beta}$)
Chelsea	1.550	0.151	Fulham	0.015	0.155
Manchester United	1.539	0.151	Wolverhampton F.C.	0.000	- - -
Arsenal	1.483	0.151	Swansea City	-0.007	0.195
Liverpool	1.469	0.151	Portsmouth	-0.009	0.195
Manchester City	1.233	0.150	Wigan Athletic	-0.124	0.188
Tottenham Hotspur	0.836	0.147	Ipswich Town	-0.142	0.262
Everton	0.505	0.147	Blackpool	-0.223	0.419
Leeds United	0.396	0.201	Burnley	-0.268	0.181
Nottingham Forest	0.349	0.301	Reading	-0.276	0.265
Newcastle United	0.301	0.148	West Bromwich Albion	-0.282	0.167
Aston Villa	0.271	0.150	Sunderland	-0.339	0.165
Blackburn Rovers	0.249	0.171	Watford	-0.369	0.197
Leicester City	0.214	0.167	Hull City	-0.519	0.223
Brighton & Hove Albion	0.172	0.191	Norwich City	-0.551	0.199
Charlton Athletic	0.171	0.194	Coventry City	-0.553	0.436
Brentford	0.166	0.256	Sheffield United	-0.625	0.242
West Ham United	0.162	0.150	Queens Park Rangers	-0.759	0.275
Bolton Wanderers	0.143	0.171	Cardiff City	-0.764	0.324
Stoke City	0.102	0.176	Derby County	-0.910	0.282
Southampton	0.070	0.158	Bradford City	-0.980	0.460
Birmingham City	0.056	0.193	Huddersfield Town	-1.007	0.336
Crystal Palace	0.054	0.167	Luton Town	-1.012	0.461
AFC Bournemouth	0.037	0.193	Pareggio ($\hat{\theta}$)	0.732	0.018
Middlesbrough	0.026	0.177			

Tabella 3.3: Stime di $\hat{\beta}_i = \log \hat{\gamma}_i$ e del parametro di pareggio $\hat{\theta}$ per la Premier League, con i relativi errori standard, prendendo la squadra Wolverhampton Wanderers Football Club come baseline. Anche in questo caso, la differenza in norma fra stime tramite massima verosimiglianza e algoritmo MM risultano al massimo 2.2×10^{-4} , e si è dunque deciso di ometterle.

Si possono notare diverse differenze rispetto alla tabella precedente. Anzitutto, le squadre sembrano meno distanti le une dalle altre. L'ottima stagione dell'Inter è, almeno a livello storico, un valore eccezionale, parecchio al di sopra della media e difficilmente replicabile. Prendendo dati da molteplici stagioni, non vi è alcuna squadra con una dominanza così schiacciante, per un lungo periodo di tempo. Detto ciò, le migliori squadre inglesi come il Chelsea e l'Arsenal, che hanno dominato lo scenario calcistico europeo negli ultimi 30 anni, sono ai primi posti della classifica, e la loro ripetuta performance positiva rende più sicuro (e quindi meno variabile) il loro confronto con la baseline. Inoltre, si noti come le squadre in fondo alla classifica, le quali hanno avuto performance peggiori e quindi sono retrocesse più volte, si devono basare su più scontri indiretti per la stima delle loro abilità, il che le porta ad avere un errore standard maggiore alle altre. Bisogna infine considerare criticamente un aspetto più pratico che tecnico legato ai risultati. La qualità di gioco di diversi decenni fa resta senz'altro inferiore a quella presente. Le squadre erano meno ottimizzate, i metodi di allenamento sono stati ridefiniti, il pool di talenti si è allargato. Il premiare a pari merito vittorie di squadre all'inizio del trentennio potrebbe portare a un'inflazione artificiale della loro forza. Bisognerebbe vedere questa classifica come la forza relativa alla competizione negli ultimi trenta anni, e non come una forza assoluta delle squadre. Similmente questo è un problema che affligge anche contesti come gli scacchi, nei quali è fuorviante paragonare giocatori di epoche diverse, anche a parità di punteggio.

3.4.3 Conclusioni

In conclusione, il lavoro presentato ha mostrato come il modello di Davidson rappresenti uno strumento statistico valido ed efficace per la costruzione di classifiche di forza in contesti di confronti a coppie caratterizzati dalla possibilità di pareggio, situazione che il classico modello di Bradley-Terry non è in grado di gestire. Come evidenziato negli esempi applicativi delle Sezioni 3.4.1 e 3.4.2, l'applicabilità del modello non è però incondizionata: è necessario, anzitutto, verificare che il contesto analizzato soddisfi l'Assunzione 3.1, dalla quale dipendono, come discusso nella Sezione 3.3.2 e nella Sezione 3.3.3, sia la compattezza superiore sia la stretta concavità della log-verosimiglianza riparametrizzata e, di conseguenza, l'esistenza e unicità del massimo garantita dal Teorema 3.1. Quando tali condizioni sono rispettate, come accade tipicamente nei contesti sportivi qui analizzati, il modello di Davidson fornisce una classificazione coerente e interpretabile della forza rela-

tiva dei soggetti coinvolti. È bene ribadire, come già sottolineato nella Sezione 3.4.1, che lo scopo del modello resta primariamente descrittivo e di classificazione, e non predittivo: l'ipotesi di forza costante nel tempo, necessaria per l'identificazione dei parametri, non va interpretata come un'assunzione realistica, quanto piuttosto come una scelta funzionale all'obiettivo di sintetizzare, in un unico indice, le prestazioni complessive di ciascun soggetto in un determinato arco temporale.

Dal punto di vista computazionale, l'algoritmo MM risulta nel complesso sensibilmente più rapido, grazie al costo computazionale per iterazione drasticamente inferiore, reso possibile dagli aggiornamenti in forma chiusa dei parametri. Questo risultato non ha soltanto un valore pratico circoscritto al caso di studio qui presentato, ma si inserisce in un discorso più ampio riguardante l'utilità dell'algoritmo MM come strumento di stima per l'intera famiglia dei modelli di comparazione a coppie che generalizzano il Bradley-Terry. Come sottolineato dallo stesso Hunter (2004), il principio di maggiorizzazione-minimizzazione non va inteso come un singolo algoritmo pensato per un singolo modello, quanto piuttosto come una vera e propria "blueprint", ossia uno schema generale e replicabile con cui derivare, per ciascuna estensione del modello di Bradley-Terry (che introduca pareggi, come nel modello di Davidson qui trattato, un vantaggio campo, pesi temporali o strutture ancora più complesse), un algoritmo di stima che garantisca, ad ogni iterazione, un aumento monotono della verosimiglianza. Questa proprietà evita i problemi di instabilità numerica e di violazione dei vincoli di positività dei parametri che, come mostrato nella Sezione 3.4.1, possono invece emergere nell'applicazione di metodi di ottimizzazione generici come `nlinb`. In questo senso, l'algoritmo MM si configura non solo come un'alternativa più efficiente ai metodi di ottimizzazione classici per il caso specifico qui analizzato, ma come uno strumento metodologico imprescindibile per chiunque debba affrontare, in futuro, la stima di ulteriori generalizzazioni del modello di Bradley-Terry.

Appendice A

Appendice

Nella seguente appendice si dimostrano o approfondiscono alcuni aspetti che per ragioni di tempo o spazio non trovano spazio all'interno dell'elaborato. Questa appendice non verrà divisa per capitolo, per la relativa ridotta quantità di materiale che contiene.

A.1 Uguaglianza fra Varianza dello Score e Informazione di Fisher

A seguito si propone la dimostrazione di quanto detto nella Sezione 1.1.4. Poiché $u(\theta) = \frac{\partial \log L(\theta)}{\partial \theta} = \frac{L'(\theta)}{L(\theta)}$, derivando nuovamente si ottiene che:

$$\frac{\partial}{\partial \theta} \frac{L'(\theta)}{L(\theta)} = \frac{L''(\theta)L(\theta) - [L'(\theta)]^2}{[L(\theta)]^2} = \frac{L''(\theta)}{L(\theta)} - [u(\theta)]^2$$

Ottenendo il valore atteso di questa quantità, e ricordando le condizioni regolari di stima, otteniamo che la prima parte diventa:

$$\mathbb{E} \left[\frac{L''(\theta)}{L(\theta)} \right] = \int_{\mathbb{R}^n} \frac{L''(\theta; x)}{L(\theta; x)} dx = \frac{\partial^2}{\partial \theta^2} \int_{\mathbb{R}^n} \frac{L(\theta; x)}{L(\theta; x)} dx = \frac{\partial^2}{\partial \theta^2} (1) = 0,$$

e questo segue dal fatto che integrando funzioni di probabilità su tutto il supporto esse devono essere pari a 1, e che la verosimiglianza coincide con una distribuzione nella quale isoliamo i parametri. Segue che $\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log L(\theta; X) \right] = -\mathbb{E}[u(\theta)^2]$, e dunque, per definizione di informazione di Fisher,

$$I_n(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log L(\theta; X) \right] = \mathbb{E}[u(\theta)^2] - (\mathbb{E}[u(\theta)])^2 = \text{Var}(u(\theta)).$$

A.2 Distorsione dei Parametri del Modello Logit

Si procede a dimostrare come la stima che include i parametri α_i all'interno del modello soggetto specifico 2.4 porti ad una distorsione del parametro β . Malgrado una prima dimostrazione sia stata formulata nei primi anni settanta, la dimostrazione si baserà sul lavoro di Abrevaya (1997).

Si dimostrerà infatti come la stima condizionata alle coppie in cui la risposta è discordante, e dunque dove $S_i = y_{i1} + y_{i2} = 1$, che definiremo stima condizionata, sarà sempre pari al doppio della stima senza restrizioni, formalmente dunque che $2\hat{\beta}_{CSM} = \hat{\beta}_{ML}$. Questo naturalmente comporta ad una stima distorta dei parametri di interesse, ed è esattamente per questo che viene condizionata alla statistica sufficiente sulle coppie discordanti. Riprendendo i risultati esposti nell'equazione 2.5, è possibile interpretare queste come la stima logistica della probabilità che la differenza $\Delta_y = y_{i2} - y_{i1}$ sia pari a $+1$ o -1 data la differenza fra variabili indipendenti Δ_x , che si ricorda essere sempre unitaria. Dunque si ottiene che possiamo riscrivere la verosimiglianza ristretta come:

$$\ell_c(\beta) = \sum_{i \in \mathcal{S}} \left[\mathbb{1}(\Delta_y = 1) \ln \frac{\exp(\Delta_x \beta)}{1 + \exp(\Delta_x \beta)} + \mathbb{1}(\Delta_y = -1) \ln \left(1 - \frac{\exp(\Delta_x \beta)}{1 + \exp(\Delta_x \beta)} \right) \right], \quad (\text{A.1})$$

dove $\mathcal{S} = \{i \mid y_{i1} + y_{i2} = 1\}$ e $\mathbb{1}$ indica la funzione indicatrice. Inoltre è possibile riscrivere la verosimiglianza del modello originale come:

$$\ell(\beta, \{\alpha_i\}_{i=1}^n) = \sum_{i=1}^n \sum_{t=1}^2 \left[y_{it} \ln \frac{\exp(\Delta_x \beta + \alpha_i)}{1 + \exp(\Delta_x \beta + \alpha_i)} + (1 - y_{it}) \ln \left(1 - \frac{\exp(\Delta_x \beta + \alpha_i)}{1 + \exp(\Delta_x \beta + \alpha_i)} \right) \right].$$

Siccome il modello logistico è un modello GLM binomiale con base canonica, in base a quanto è stato discusso nella Sezione 1.3.1 è possibile risolvere in forma chiusa l'ottimo della funzione. Infatti, ottimizzando rispetto al parametro α_i , cioè specializzando l'equazione 1.5 al caso binomiale, si ottiene che il risultato in forma chiusa risulta pari a:

$$\sum_{t=1}^2 \left[y_{it} - \frac{\exp(x_{it}\beta + \alpha_i)}{1 + \exp(x_{it}\beta + \alpha_i)} \right] = 0.$$

Si noti come quando le risposte sono concordi, cioè qualora $S_i \in \{0, 2\}$, allora la sommatoria $\sum_{t=1}^2 \frac{\exp(x_{it}\beta + \alpha_i)}{1 + \exp(x_{it}\beta + \alpha_i)}$ debba essere pari a 0 o 2, ma questo è possibile solo quando il parametro α_i diverge rispettivamente a $-\infty, +\infty$, perché β e x_{it} sono costanti. Considerando

dunque di vincolare i risultati al caso di risposte discordanti, si ottiene che

$$\frac{\exp(x_{i1}\beta + \alpha_i)}{1 + \exp(x_{i1}\beta + \alpha_i)} + \frac{\exp(x_{i2}\beta + \alpha_i)}{1 + \exp(x_{i2}\beta + \alpha_i)} = 1,$$

$$\frac{\exp(x_{i1}\beta + \alpha_i) [1 + \exp(x_{i2}\beta + \alpha_i)] + \exp(x_{i2}\beta + \alpha_i) [1 + \exp(x_{i1}\beta + \alpha_i)]}{[1 + \exp(x_{i1}\beta + \alpha_i)] [1 + \exp(x_{i2}\beta + \alpha_i)]} = 1.$$

Si può ora osservare come, dopo aver moltiplicato entrambi i lati dell'equazione per il denominatore della prima, e dopo semplici passaggi algebrici, si ottiene che:

$$\exp(x_{i1}\beta + x_{i2}\beta + 2\alpha_i) = 1 \rightarrow \alpha_i = -\left(\frac{x_{i1} + x_{i2}}{2}\right)\beta.$$

Sostituendo la stima concentrata dell'effetto fisso $\hat{\alpha}_i = -\left(\frac{x_{i1} + x_{i2}}{2}\right)\beta$ all'interno della funzione di log-verosimiglianza originale, ed eliminando i termini per cui le risposte sono concordi (in quanto per essi $\hat{\alpha}_i \rightarrow \pm\infty$), la log-verosimiglianza risulta pari a:

$$\tilde{\ell}(\beta) = \sum_{i \in \mathcal{S}} \left[y_{i1} \ln \left(\frac{\exp\left(-\frac{\Delta x_i \beta}{2}\right)}{1 + \exp\left(-\frac{\Delta x_i \beta}{2}\right)} \right) + (1 - y_{i1}) \ln \left(1 - \frac{\exp\left(-\frac{\Delta x_i \beta}{2}\right)}{1 + \exp\left(-\frac{\Delta x_i \beta}{2}\right)} \right) + \right. \\ \left. y_{i2} \ln \left(\frac{\exp\left(\frac{\Delta x_i \beta}{2}\right)}{1 + \exp\left(\frac{\Delta x_i \beta}{2}\right)} \right) + (1 - y_{i2}) \ln \left(1 - \frac{\exp\left(\frac{\Delta x_i \beta}{2}\right)}{1 + \exp\left(\frac{\Delta x_i \beta}{2}\right)} \right) \right].$$

dove $\mathcal{S} = \{i \mid y_{i1} + y_{i2} = 1\}$ e $\Delta x_i = x_{i2} - x_{i1}$. Siccome però le quantità y_{it} e $1 - y_{it}$ coincidono all'utilizzo di una funzione indicatrice e le quantità che moltiplicano sono uguali, otteniamo dunque che è possibile riscrivere la verosimiglianza totale come:

$$\tilde{\ell}(\beta) = \sum_{i \in \mathcal{S}} 2 \left[\mathbb{1}(\Delta y = 1) \ln \left(\frac{\exp\left(\frac{\Delta x \beta}{2}\right)}{1 + \exp\left(\frac{\Delta x \beta}{2}\right)} \right) + \mathbb{1}(\Delta y = -1) \ln \left(1 - \frac{\exp\left(\frac{\Delta x \beta}{2}\right)}{1 + \exp\left(\frac{\Delta x \beta}{2}\right)} \right) \right],$$

E dunque si ottiene che, dato che la seconda parte coincide con quanto visto nell'equazione [A.1](#),

$$\ell(\beta) = 2\ell_c(\beta/2).$$

L'interpretazione logica che spiega questo cambiamento è legata al fatto che all'interno della verosimiglianza non condizionata i parametri α_i quantificano il valore medio della i -esima osservazione, infatti $\alpha_i = -\bar{x}_i\beta$, e dunque la stima è calcolata dimezzando la variazione delle x . Invece all'interno della stima condizionata si misura la variazione

totale del parametro, e dunque non si “spreca” la poca informazione che abbiamo con $T = 2$ osservazioni a calcolare α_i .

A.3 Approssimazione Numerica degli Errori Standard

Si procede a dimostrare come stimare la varianza del parametro attraverso la derivata seconda della funzione minorante, ovvero $\frac{\partial}{\partial \theta} \nabla g(M(\theta) \mid \theta)$. Qualora essa sia calcolata nell’ottimo ed invertita di segno, fornisce una stima adeguata dell’informazione di Fisher. Come già esposto, infatti, nei contesti applicativi reali degli algoritmi MM risulta ostico ottenere la derivata prima (e di conseguenza anche quella seconda) della funzione obiettivo e dunque comprendere l’incertezza dei parametri $\hat{\theta}$. La dimostrazione segue in parte le orme di [Lange \(1999\)](#).

Sia infatti $M(\theta^{(n)})$ la funzione passo, cioè quella mappa che restituisce, dato l’input $\theta^{(n)}$, il passo successivo $\theta^{(n+1)}$ della funzione minorante $g(\theta \mid \theta^{(n)})$, dunque

$$M(\theta^{(n)}) = \arg_{\theta} \max g(\theta \mid \theta^{(n)}).$$

È possibile ottenere un’approssimazione numerica di $-\partial^2 \ell / \partial \theta^2$, utilizzando l’informazione della funzione passo. Questo sarà possibile grazie al teorema della Funzione Implicita.

Teorema A.1 (Teorema della funzione implicita). *Siano $F : \mathbb{R}^p \times \mathbb{R}^q \longrightarrow \mathbb{R}^q$ e siano $(x_0, y_0) \in \mathbb{R}^p \times \mathbb{R}^q$ tali che*

$$F(x_0, y_0) = 0.$$

Supponiamo che F sia continuamente differenziabile in un intorno di (x_0, y_0) e che la matrice Jacobiana di F rispetto alla variabile y ,

$$\frac{\partial F}{\partial y}(x_0, y_0) = \left[\frac{\partial F_i}{\partial y_j}(x_0, y_0) \right], \quad i, j = 1, \dots, q,$$

sia non singolare, ossia che il suo determinante non sia nullo. Allora esistono due intorni U di x_0 e V di y_0 e un’unica funzione $\varphi : U \longrightarrow V$ tale che $\varphi(x_0) = y_0$ e $F(x, \varphi(x)) = 0$ per ogni $x \in U$. Inoltre φ è continuamente differenziabile in U e la sua matrice Jacobiana è pari a:

$$\frac{\partial \varphi}{\partial x}(x) = - \left[\frac{\partial F}{\partial y}(x, \varphi(x)) \right]^{-1} \frac{\partial F}{\partial x}(x, \varphi(x))$$

La dimostrazione di questo teorema, per quanto non eccessivamente complessa, risulta lontana dalle necessità dell'elaborato. Generalmente, l'intuizione riguarda la possibilità di creare una mappatura univoca, almeno in un intorno del punto di interesse (in questo caso, l'ottimo) fra i parametri della funzione e la possibilità di ottenere la Jacobiana della funzione $\varphi(y)$ conoscendo solamente alcune derivate parziali. Tutto questo ha un costo non banale, perché richiediamo diverse condizioni e questa inversione è valida solamente nell'intorno in cui esse sono soddisfatte, dunque localmente e non globalmente. Detto ciò questo metodo si presta al contesto degli algoritmi MM, perché si vuole individuare la derivata seconda solamente nel punto di massimo, ed è possibile soddisfare le condizioni almeno in un intorno del punto di massimo.

La funzione obiettivo da derivare nel caso delle funzioni minoranti è il gradiente della minorante $\nabla g(M(\theta) \mid \theta)$. Assumendo dunque che la funzione sia continua e differenziabile, e siccome si è dimostrato nella Sezione 3.3.3 che se è verificata la condizione 3.1 allora la funzione obiettivo è strettamente concava, anche la minorante lo sarà in un intorno del punto di massimo $\hat{\theta}$. Questo significa che tutte le condizioni del Teorema A.1 sono soddisfatte. Dunque, ridefinendo la funzione minorante $g(\theta \mid \vartheta)$, dove ϑ e θ rappresentano la stessa quantità, e vengono utilizzate solo per evidenziare a quale variabile ci si riferisce, si ottiene che, applicando il Teorema A.1, e chiamando $g(M(\theta) \mid \vartheta)$ la funzione $F(\cdot)$:

$$\frac{\partial M(\theta)}{\partial \theta} = - \left[\frac{\partial}{\partial \theta} \nabla g(M(\theta) \mid \vartheta) \right]^{-1} \frac{\partial}{\partial \vartheta} \nabla g(M(\theta) \mid \vartheta). \quad (\text{A.2})$$

Si è dunque ottenuta la derivata della funzione passo. Adesso, ricordandoci che, data una funzione di verosimiglianza obiettivo $\ell(\theta)$, sappiamo che nel contesto di algoritmi MM vale l'identità:

$$\ell(\theta) - g(\theta \mid \theta) = 0, \quad \forall \theta \in \Theta.$$

Ponendo $\theta = \hat{\theta}$ (e dunque $\vartheta = \hat{\vartheta}$) e derivando due volte l'uguaglianza rispetto al parametro θ si ottiene che:

$$\frac{\partial}{\partial \hat{\theta}} \nabla \ell(\hat{\theta}) - \frac{\partial}{\partial \hat{\theta}} \nabla g(\hat{\theta} \mid \hat{\vartheta}) = 0.$$

A questo punto, dividiamo la derivata della funzione minorante, e ricordando che θ e ϑ si riferiscono alla stessa quantità, si ottiene che:

$$\frac{\partial}{\partial \hat{\theta}} \nabla \ell(\hat{\theta}) - \frac{\partial}{\partial \hat{\theta}} \nabla g(\hat{\theta} \mid \hat{\vartheta}) - \frac{\partial}{\partial \hat{\vartheta}} \nabla g(\hat{\theta} \mid \hat{\vartheta}) = 0.$$

È possibile però isolare l'ultima parte dell'uguaglianza, e ricordando che $\hat{\theta} = M(\theta)$, ed ottenere la medesima quantità ottenuta in A.2. Il risultato risulta essere:

$$\frac{\partial}{\partial \hat{\theta}} \nabla \ell(\hat{\theta}) - \frac{\partial}{\partial \hat{\theta}} \nabla g(\hat{\theta} \mid \hat{\vartheta}) = \frac{\partial M(\hat{\theta})}{\partial \hat{\theta}} \left[\frac{\partial}{\partial \hat{\theta}} \nabla g(\hat{\theta} \mid \hat{\vartheta}) \right].$$

Isolando infine la derivata seconda della funzione di verosimiglianza $\ell(\theta)$ e semplificando si ottiene che essa coincide con la quantità:

$$\frac{\partial^2}{\partial \hat{\theta}^2} \ell(\hat{\theta}) = \frac{\partial^2}{\partial \hat{\theta}^2} g(\hat{\theta} \mid \hat{\vartheta}) \left[I - \frac{\partial M(\hat{\theta})}{\partial \hat{\theta}} \right],$$

ovvero una correzione rispetto alla derivata seconda della funzione minorante. A livello logico è spiegabile dal fatto che la funzione minorante, per costruzione, risulta più concava rispetto alla funzione obiettivo da massimizzare, di conseguenza un singolo passo su di essa risulta più informativo rispetto alla funzione obiettivo, ma questo accade come conseguenza della costruzione dell'algoritmo. Dunque si corregge questa quantità tramite la funzione passo, che riesce a correggere questa distorsione dell'algoritmo. Un'altra motivazione per cui la derivata seconda della funzione minorante richiede questa correzione è legata alla covarianza fra le quantità. Infatti la matrice $\frac{\partial^2}{\partial \hat{\theta}^2} g(\hat{\theta} \mid \hat{\vartheta})$ risulta essere diagonale, e questo ha senso, siccome il calcolo dell' i -esima componente del vettore di parametri $\theta_i^{(k+1)}$ considera le altre quantità come costanti (si veda come esempio 3.12). Questo si può vedere anche calcolando manualmente la derivata seconda del modello di Davidson e risolvendo con dei passaggi algebrici. Ma è noto che le stime singolari sono comunque indirettamente influenzate dalle stime degli altri parametri. Di conseguenza, questa correzione tramite funzione passo permette di ottenere questo effetto indiretto, che verrebbe altrimenti ignorato.

Bibliografia

- ABREVAYA, J. (1997). The equivalence of two estimators of the fixed-effects logit model. *Economics Letters* .
- AGRESTI, A. (2013). *Categorical Data Analysis*. Wiley, 3rd ed.
- AZZALINI, A. (2008). *Inferenza Statistica*. Springer Verlag.
- BHAPKAR, V. P. (1966). A note on the equivalence of two test criteria for hypotheses in categorical data. *Journal of the American Statistical Association* **61**, 228–235.
- BOWKER, A. H. (1948). A test for symmetry in contingency tables. *Journal of the American Statistical Association* **43**.
- BRADLEY, R. A. & TERRY, M. E. (1952a). Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika* **39**, 324–345.
- BRADLEY, R. A. & TERRY, M. E. (1952b). The rank analysis of incomplete block designs. II. the method for blocks of size three. appendix A. Tech. Rep. Bi-annual Report No. 4, Virginia Agricultural Experiment Station, Virginia Polytechnic Institute, Blacksburg, VA.
- CHAMBERLAIN, G. (1980). Analysis of covariance with qualitative data. *The Review of Economic Studies* **47**, 225–238.
- COHEN, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement* **20**.
- COX, D. R. & REID, N. (1987). Parameter orthogonality and approximate conditional inference. *Journal of the Royal Statistical Society. Series B (Methodological)* **49**, 1–39.

- DAVIDSON, R. R. (1970). On extending the Bradley-Terry model to accommodate ties in paired comparison experiments. *Journal of the American Statistical Association* **65**, 317–328.
- DEMPSTER, A. P., LAIRD, N. M. & RUBIN, D. B. (1977). Maximum likelihood from incomplete data via the em algorithm. *Journal of the Royal Statistical Society. Series B (Methodological)* **39**, 1–22.
- FIENBERG, S. E. & LARNTZ, K. (1976). Log linear representation for paired and multiple comparisons models. *Biometrika* **63**, 245–254.
- FIRTH, D. (1993). Bias reduction of maximum likelihood estimates. *Biometrika* **80**, 27–38.
- FISHER, R. A. (1935). *The Design of Experiments*. Oliver & Boyd.
- FLEISS, J. L., COHEN, J. & EVERITT, B. S. (1969). Large sample standard errors of kappa and weighted kappa. *Psychological Bulletin* **72**.
- FORD, L. R. (1957). Solution of a ranking problem from binary comparisons. *The American Mathematical Monthly* **64**, 28–33.
- GUTTMAN, L. (1946). An approach for quantifying paired comparisons and rank order. *The Annals of Mathematical Statistics* **17**, 144–163.
- HUNTER, D. R. (2004). MM algorithms for generalized Bradley-Terry models. *The Annals of Statistics* **32**, 384–406.
- HUNTER, D. R. & LANGE, K. (2004). A tutorial on mm algorithms. *The American Statistician* **58**, 30–37.
- LANGE, K. (1999). *Numerical Analysis for Statisticians*. Statistics and Computing. New York: Springer.
- LANGE, K., HUNTER, D. R. & YANG, I. (2000a). Optimization transfer using surrogate objective functions. *Journal of Computational and Graphical Statistics* **9**, 1–20.
- LANGE, K., HUNTER, D. R. & YANG, I. (2000b). Rejoinder. *Journal of Computational and Graphical Statistics* **9**, 35–39.

- LUCE, R. D. (1959). *Individual Choice Behavior: A Theoretical Analysis*. New York: John Wiley & Sons.
- MADANSKY, A. (1963). Tests of homogeneity for correlated samples. *Journal of the American Statistical Association* **58**, 97–119.
- MARDEN, J. I. (1995). *Analyzing and Modeling Rank Data*. London: Chapman & Hall.
- MCCULLAGH, P. & NELDER, J. A. (1989). *Generalized linear models*. Chapman e Hall.
- MCNEMAR, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika* .
- NELDER, J. A. & MEAD, R. (1965). A simplex method for function minimization. *The Computer Journal* **7**, 308–313.
- NELDER, J. A. & WEDDERBURN, R. W. M. (1972). Generalized linear models. *Journal of the Royal Statistical Society* **135**, 370–384.
- NOCEDAL, J. & WRIGHT, S. J. (2006). *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. New York: Springer, 2nd ed.
- ORTEGA, J. M. & RHEINBOLDT, W. C. (1970). Local and global convergence of generalized linear iterations. In *Numerical Solution of Nonlinear Problems*, J. M. Ortega & W. C. Rheinboldt, eds. Philadelphia: Society for Industrial and Applied Mathematics, pp. 122–143.
- PACE, L. & SALVAN, A. (2001). *Introduzione alla statistica II*. Cedam.
- PENDERGRASS, R. N. & BRADLEY, R. A. (1960). Ranking in triple comparisons. In *Contributions to Probability and Statistics: Essays in Honor of Harold Hotelling*, I. Olkin, S. G. Ghurye, W. Hoeffding, W. G. Madow & H. B. Mann, eds. Palo Alto, CA: Stanford University Press, pp. 331–351.
- PLACKETT, R. L. (1975). The analysis of permutations. *Journal of the Royal Statistical Society: Series C (Applied Statistics)* **24**, 193–202.
- QUARTERONI, A., SACCO, R., SALERI, F. & GERVASIO, P. (2014). *Matematica Numerica*. UNITEXT – La Matematica per il 3+2. Springer, 4th ed.

- R CORE TEAM (2012). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. ISBN 3-900051-07-0.
- RAO, P. V. & KUPPER, L. L. (1967). Ties in paired-comparison experiments: A generalization of the Bradley-Terry model. *Journal of the American Statistical Association* **62**, 194–204.
- RIGON, T. (2025). Generalized linear models.
- STUART, A. (1955). A test for homogeneity of the marginal distributions in a two-way classification. *Biometrika* **42**, 412–416.
- TURNER, H. & FIRTH, D. (2012). Bradley-terry models in r: The bradleyterry2 package. *Journal of Statistical Software* **48**, 1–21.
- VOJNOVIC, M., YUN, S.-Y. & ZHOU, K. (2020). Convergence rates of gradient descent and mm algorithms for bradley-terry models. In *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics*, vol. 108. PMLR.
- ZERMELO, E. (1929). Die Berechnung der Turnier-Ergebnisse als ein Maximumproblem der Wahrscheinlichkeitsrechnung. *Mathematische Zeitschrift* **29**, 436–460.