

UNIVERSITÀ DEGLI STUDI DI MILANO–BICOCCA
SCUOLA DI ECONOMIA E STATISTICA

CORSO DI LAUREA IN
SCIENZE STATISTICHE ED ECONOMICHE



METODO DI FIRTH PER LA
RIDUZIONE DELLA DISTORSIONE
DAGLI STIMATORI DI MASSIMA
VEROSIMIGLIANZA

RELATORE: Prof. Tommaso Rigon

TESI DI LAUREA DI:
Giacomo Arrigoni
MATRICOLA N. 908854

ANNO ACCADEMICO 2025/2026

Indice

Introduzione	1
1 Fondamenti di Inferenza Statistica e Modelli Lineari Generalizzati	3
1.1 Inferenza statistica	3
1.2 I modelli statistici	4
1.2.1 Modelli parametrici	4
1.3 Procedure principali dell'inferenza statistica	5
1.4 Problemi di stima	6
1.4.1 Problemi di stima puntuale	6
1.4.2 Problemi di stima intervallare	7
1.5 Problemi di verifica d'ipotesi	7
1.6 Problemi di previsione	8
1.7 Inferenza statistica basata sul concetto di verosimiglianza	9
1.7.1 La funzione di verosimiglianza	9
1.7.2 Proprietà della verosimiglianza	11
1.7.3 La stima di massima verosimiglianza	12
1.8 Statistiche sufficienti	13
1.9 Condizioni regolari di stima	15
1.10 Proprietà campionarie	16
1.10.1 Proprietà della funzione di score	16
1.10.2 Informazione osservata ed attesa	17
1.11 Teoria asintotica del primo ordine	19
1.11.1 Distribuzione dello stimatore di massima verosimiglianza	22
1.12 Funzione generatrice dei momenti e dei cumulanti	24
1.13 Introduzione alle famiglie esponenziali	26
1.13.1 Famiglie esponenziali e a dispersione esponenziale	26
1.13.2 Quantità di verosimiglianza	28
1.14 Modelli Lineari Generalizzati	30

1.14.1	Quantità di verosimiglianza per i GLM	32
1.14.2	Il metodo di Newton-Raphson e Fisher scoring	37
1.14.3	Minimi quadrati pesati iterati (IRLS)	37
2	Individuazione e Mitigazione della Distorsione del Primo Ordine nelle Stime di Massima Verosimiglianza	41
2.1	La notazione indiciale	42
2.2	Identità di Bartlett	43
2.3	Ordini di convergenza asintotica delle quantità di verosimiglianza . .	44
2.4	Strumenti di analisi	46
2.4.1	Formula di Taylor stocastica	47
2.4.2	Metodo delle sostituzioni iterative per l'inversione di Serie Asintotiche	47
2.5	Sviluppi asintotici notevoli	47
2.5.1	Errore di stima	48
2.5.2	Distorsione dello stimatore di massima verosimiglianza	50
2.6	Esistenza delle stime di massima verosimiglianza nelle famiglie esponenziali	51
2.7	Approcci alla riduzione della distorsione	54
2.7.1	Metodi correttivi	55
2.7.2	Metodi preventivi	55
2.8	Riduzione della distorsione nelle famiglie esponenziali con legame canonico	59
3	Penalizzazione di Jeffreys nei Modelli Lineari Generalizzati per dati binari	63
3.1	Specificazione dei GLM per risposte binarie	63
3.2	Esistenza delle SMV penalizzate	65
3.3	Contrazione delle SMV penalizzate	70
3.4	Estensione dei risultati ai legami non canonici	73
3.5	Equazione dello score penalizzato	74
3.5.1	Legame Canonico e Semplificazioni	77
3.6	Algoritmi numerici per la massima verosimiglianza penalizzata	80
3.6.1	Condizioni di stabilità numerica degli algoritmi	83
3.7	Metodi di ricerca in linea	84
3.8	Le condizioni di Wolfe	86

3.9	L'algoritmo di BACKTRACKING e il teorema di convergenza	88
3.10	Il ruolo dell'halving per la regressione binaria	91
3.11	Implementazione pratica	92
A	Dimostrazioni dei Teoremi	95
A.1	Dimostrazioni del Capitolo 1	95
A.2	Dimostrazioni del Capitolo 2	96
A.2.1	Relazioni EXLOG fra momenti e cumulanti	96
A.2.2	Ordini asintotici delle quantità di verosimiglianza	98
A.2.3	Inversione di serie di potenze per sostituzioni iterate	98
A.3	Dimostrazioni del Capitolo 3	99
A.3.1	Limite determinante matrice dei pesi	103
A.3.2	Equivalenza del punto fisso con la formulazione a pseudo-dati	104
A.3.3	Commento esperimento contrazione stime 3.4	106
	Bibliografia	109

Ringraziamenti

Vorrei ringraziare il Professor Tommaso Rigon per essere riuscito in questi anni a trasmettere la propria conoscenza e passione per la statistica in modo efficace, con serietà e competenza; i miei compagni di corso, tutti, ed in particolare Francesco Badolato, con cui in questi anni ho potuto confrontarmi ed approfondire le questioni più disparate, con uno sguardo sempre curioso e critico, Andrea Casati, vicino di banco e compagno di cordate nei fine settimana e Urso Antonio, che con la sua motivazione mi ha spinto sempre a dare il massimo. In ultimo, vorrei ringraziare tutte le persone che quotidianamente mi sono state vicine e che sempre mi hanno supportato. In particolare ringrazio la mia cara Maya, la mia Nonna Paolina e i miei fantastici genitori Giuliana e Luca, che con la loro premurosità mi hanno permesso di dedicare molto tempo ai miei studi.

Dichiarazione sull'uso di strumenti di intelligenza artificiale

Il sottoscritto **Giacomo Arrigoni**, matricola **908854**, dichiara quanto segue in merito all'utilizzo di strumenti di intelligenza artificiale generativa (modelli linguistici di grandi dimensioni quali ChatGPT, Claude, Gemini, etc.) nella preparazione e nella stesura della presente tesi.

☐ Non ho fatto uso di alcuno strumento di intelligenza artificiale generativa.

■ Ho fatto uso di tali strumenti, nei termini specificati di seguito.

Strumenti utilizzati: *Claude Opus 5, Claude Sonnet 5, Claude Fable 5, Gemini 3.1 Pro.*

Ambiti di utilizzo:

■ Revisione linguistica e correzione di errori ortografici o sintattici.

☐ Traduzione di testo da me redatto.

■ Chiarimenti su concetti teorici e supporto allo studio della letteratura.

■ Ricerca e reperimento di riferimenti bibliografici.

■ Scrittura, correzione o debugging di codice.

☐ Elaborazione o analisi dei dati.

☐ Altro: *specificare.*

Misura dell'utilizzo: *Nella redazione del presente lavoro i modelli di intelligenza artificiale sono stati utilizzati nella fase finale di correzione ortografica del testo, tramite l'individuazione di typo ed incoerenze notazionali. Per quanto riguarda invece l'utilizzo dell'IA per il supporto allo studio della letteratura, l'impiego ha riguardato la verifica della corretta interpretazione dei testi studiati, attraverso la creazione di domande per la verifica dell'apprendimento. L'ambito in cui l'utilizzo degli strumenti di IA è stato, personalmente, più utile, è relativo alla ricerca di testi e articoli riguardanti determinati temi di cui si avesse specifico interesse al fine della comprensione degli articoli analizzati. Nei fatti si è descritta la richiesta rispetto ad un particolare ambito e si è pertanto ottenuta la bibliografia più citata a livello accademico, andando poi ad analizzare i vari risultati a mano per verificarne la correttezza e l'utilità. Si cita come esempio l'individuazione del testo [Nocedal & Wright \(2006\)](#) per comprendere i fondamenti teorici relativi alla convergenza dei metodi iterativi utilizzati per implementare l'algoritmo descritto dall'Articolo [Kosmidis & Firth \(2021a\)](#). Per quanto riguarda il codice, non è stato reso necessario un utilizzo estensivo degli strumenti di IA, la funzione principale sviluppata nel presente lavoro segue direttamente dall'Articolo [Kosmidis & Firth \(2021a\)](#) e si è dunque sviluppata autonomamente. L'utilizzo di tali modelli ha invece riguardato la*

pulizia e sistemazione del codice. Gli esperimenti numerici e le rappresentazioni grafiche in linguaggio R sono state svolte autonomamente, l'utilizzo dell'IA ha riguardato invece i grafici elaborati in codice L^AT_EX, i quali sono stati disegnati a mano e solo successivamente tradotti in tale linguaggio di programmazione mediante tali modelli. Le analisi dei risultati ottenuti sono state svolte esclusivamente in modo autonomo. In conclusione, si vuole sottolineare fermamente come in questa tesi l'utilizzo degli strumenti di intelligenza artificiale generativa sia stato fatto con grande senso critico, senza delegare il pensiero scientifico a tali strumenti; si è cercato di effettuare un utilizzo che permettesse di ampliare le proprie fonti e mettere sotto stress le conclusioni raggiunte. Si vuole porre l'attenzione in questo senso alla potenzialità di tali strumenti nel trovare le fallacie logiche di un ragionamento, costringendo l'autore a non lasciare mai nulla al caso durante tutto il lavoro.

Dichiaro che la struttura del lavoro, le scelte metodologiche, le analisi e l'interpretazione dei risultati sono opera personale, e sono consapevole di essere l'unico responsabile di ogni contenuto della presente tesi, comprese eventuali imprecisioni, dimostrazioni errate o riferimenti bibliografici inesistenti prodotti da tali strumenti.

Introduzione

“Although this may seem a paradox, all exact science is dominated by the idea of approximation.”

B. Russell

Uno dei temi cardine della statistica è quello dell’inferenza, definibile in termini generali come: il processo mediante il quale si deducono caratteristiche di interesse relative ad una popolazione globale, a partire da un sottoinsieme parziale dei suoi elementi. Per le procedure di inferenza parametriche l’idea è di individuare tecniche per stimare le suddette caratteristiche utilizzando appropriati parametri per definire dei modelli. La presente tesi si pone l’obiettivo di analizzare le procedure di stima derivanti da uno degli approcci più consolidati in letteratura, ovvero il metodo della massima verosimiglianza. Nel primo capitolo verranno introdotti i concetti fondamentali dell’inferenza statistica, fornendo le basi necessarie alla trattazione dei capitoli successivi. Nel secondo capitolo si studierà l’origine della distorsione negli stimatori di massima verosimiglianza, e nello specifico l’analisi della distorsione del primo ordine, che produce effetti non ignorabili in campioni di dimensione ridotta. A tal proposito, saranno passati in rassegna alcuni tra i principali approcci storici sviluppati per eliminare la distorsione dalle stime, partendo dai classici approcci *correttivi* ai più moderni *preventivi*, basati sul rivoluzionario Articolo [Firth \(1993\)](#). Nel terzo e ultimo capitolo, si approfondirà il metodo preventivo per la riduzione della distorsione del primo ordine, basato sulla definizione dello *score penalizzato* tramite la distribuzione a priori di *Jeffreys*, nel contesto della regressione *binaria*. Si osserverà inoltre come il metodo alternativo proposto non garantisca esclusivamente la riduzione della distorsione, bensì diverse altre proprietà auspicabili per degli stimatori, come l’esistenza delle stime e la loro finitezza; a tal fine si seguirà l’approccio esposto nell’Articolo [Kosmidis & Firth \(2021a\)](#). In conclusione, si implementerà il metodo di stima per gli stimatori definiti tramite *score penalizzato*, mediante il linguaggio di programmazione R.

Capitolo 1

Fondamenti di Inferenza Statistica e Modelli Lineari Generalizzati

1.1 Inferenza statistica

L'umanità ha sempre avuto la necessità di estrarre informazioni quantitative da fenomeni più o meno complessi, al fine di comprenderli profondamente. Un esempio di ciò riguarda i censimenti, ovvero analisi a copertura globale di diverse caratteristiche relative ad una popolazione, il primo dei quali risale già al 3500 a.C. nell'antica Mesopotamia. Il censimento, termine che deriva dal verbo latino *cēnsēre* (che significa “valutare” o “stimare”), è caratterizzato dalla raccolta di tutte le informazioni disponibili riguardanti un fenomeno, così da estrarne statistiche di sintesi per programmare le diverse politiche di uno Stato. Nella maggior parte delle situazioni, però, si ha a disposizione esclusivamente un campione (che si indicherà con y), ovvero un insieme di dimensione finita estratto dalla popolazione statistica. Tuttavia, l'obiettivo delle indagini rimane, sempre e comunque, lo studio delle caratteristiche della popolazione nella sua interezza. È proprio in questo contesto che nasce e si sviluppa il concetto di *inferenza statistica*. Nella statistica moderna esistono diverse tecniche per effettuare tale operazione. La metodologia più diffusa riguarda *l'inferenza basata sulla verosimiglianza*, introdotta da [Fisher \(1922\)](#).

I concetti presentati nel presente capitolo derivano dallo studio e dalla rielaborazione principalmente dei seguenti testi: [Azzalini \(2008\)](#), [Pace & Salvan \(2001\)](#), [Pace & Salvan \(1996\)](#), [McCullagh & Nelder \(1989\)](#), [Casella & Berger \(2002\)](#) e [Agresti \(2013\)](#).

1.2 I modelli statistici

“All models are wrong, but some are useful.”

G. E. P. Box

Si consideri $y = (y_1, \dots, y_n)^T$, un campione di dati estratto da una popolazione. Sebbene y_i possa essere sia uno scalare che un vettore, per comodità di notazione, e senza perdita di generalità, si assumerà essere uno scalare. Si assuma inoltre che il campione sia stato generato da una variabile casuale (a cui ci si riferirà per brevità con la notazione v.c.) Y , e che si voglia fare *inferenza* sulla vera distribuzione incognita F_0 della popolazione. Spesso si può assumere che le v.c. siano fra loro indipendenti ed identicamente distribuite (i.i.d.); in tal caso si dice che y sia generato da un *campionamento casuale semplice* (ccs). Naturalmente, l'informazione disponibile sul fenomeno che ha generato il campione y è limitata ai dati di cui si dispone. Risulta dunque possibile definire un insieme di distribuzioni plausibili da cui il campione potrebbe esser stato generato. Tale insieme è identificato generalmente con la lettera $\mathcal{F}$ e porta il nome di *modello statistico*.

1.2.1 Modelli parametrici

L'insieme $\mathcal{F}$ potrebbe, in linea di principio, essere un qualsiasi insieme di funzioni di probabilità. In statistica si fa generalmente distinzione tra funzione di probabilità per le variabili casuali discrete e funzione di densità per quelle continue. In questa tesi, vista la non centralità di tale distinzione, si è deciso di adottare il termine *distribuzione di probabilità* per entrambe le situazioni. Un caso molto importante, che costituisce l'oggetto del presente lavoro, riguarda la fattispecie in cui gli elementi di $\mathcal{F}$ siano funzioni della stessa natura statistica, le quali si differenziano esclusivamente per il valore di un parametro θ che assume valori nello spazio parametrico Θ .

$$\mathcal{F} = \{p(\cdot; \theta) : \theta \in \Theta \subseteq \mathbb{R}^p\},$$

dove la funzione $p(\cdot; \theta)$ è definita su $\mathbb{R}^n$, mentre p e n sono numeri naturali.

Definizione 1.1 (Spazio parametrico). Nella teoria dell'inferenza, lo spazio parametrico, tipicamente indicato con la lettera maiuscola Θ , è l'insieme di tutti i possibili valori (scalari o vettoriali) assumibili dal parametro incognito θ che descrive un modello statistico parametrico. Ci si riferirà alla dimensionalità di Θ con la lettera p .

Risulta essenziale, in questa sede, introdurre un'ulteriore definizione relativa ad una proprietà dei modelli statistici parametrici.

Definizione 1.2 (Identificabilità). Un modello statistico si dice *identificabile* se e soltanto se vale la seguente doppia implicazione:

$$\theta' = \theta'' \iff \Pr_{\theta'}(Y \in B) = \Pr_{\theta''}(Y \in B), \quad \text{per ogni } B \in \mathcal{B},$$

dove $\mathcal{B}$ è la σ -algebra di Borel definita su $\mathcal{Y}$ e $B \in \mathcal{B}$ è un *insieme boreliano*, ovvero un sottoinsieme misurabile dello spazio $\mathcal{Y}$ in cui la variabile casuale Y assume i propri valori. Ci si riferirà ad $\mathcal{Y}$ con il termine *spazio campionario* che rappresenta l'insieme di tutti i valori assumibili dal campione compatibili con un determinato modello statistico.

In questa tesi non verranno approfonditi i concetti propri della *teoria della misura*, sebbene essi costituiscano l'impalcatura matematica fondamentale dell'intera teoria statistica. Per una trattazione rigorosa dei richiami teorici menzionati nel corso del presente lavoro, si rimanda a [Ambrosio et al. \(2011\)](#).

1.3 Procedure principali dell'inferenza statistica

All'interno del contesto dell'*inferenza statistica*, si distinguono tre principali categorie di problemi:

- *I problemi di stima*, che riguardano l'approssimazione del vero valore $\theta_0 \in \Theta$ sulla base del campione y e di un *modello statistico parametrico* $\mathcal{F}$;
- *I problemi di verifica d'ipotesi*, che si occupano di determinare se sia compatibile con i dati, sulla base di y , asserire che il vero valore del parametro appartenga a uno specifico sottoinsieme dello spazio parametrico, ossia $\theta_0 \in \Theta_0$;
- *I problemi di previsione*, che cercano di individuare una stima plausibile per la realizzazione futura non osservata dell'esperimento y^* sulla base del campione y e del modello statistico $\mathcal{F}$.

In questo lavoro si tratteranno esclusivamente gli approcci parametrici *frequentisti* per la risoluzione delle suddette problematiche, con particolare attenzione ai *problemi di stima puntuale*.

1.4 Problemi di stima

I problemi di stima sono generalmente suddivisi in due categorie fra loro legate: la stima puntuale e la stima intervallare.

1.4.1 Problemi di stima puntuale

Al fine di individuare una stima attendibile per un parametro di interesse θ è necessario definire uno *stimatore*.

Definizione 1.3 (Stimatore). Dato un campione casuale y a valori in $\mathcal{Y}$, si definisce *stimatore* del parametro θ una statistica, ovvero una funzione misurabile dei dati

$$T : \mathcal{Y} \rightarrow \Theta,$$

che non dipende dal valore incognito θ . Si noti che, essendo lo stimatore una funzione del campione casuale, è esso stesso una v.c.

Dato un campione effettivamente osservato $y = (y_1, \dots, y_n)^T$, la realizzazione numerica

$$\hat{\theta} = T(y),$$

è detta *stima puntuale* (o semplicemente *stima*) di θ .

Metodo dell'analogia Un importante approccio alla stima puntuale per il parametro di interesse è il metodo dell'*analogia*. Esso si basa sull'idea fondamentale di utilizzare la distribuzione empirica del campione come approssimazione di quella teorica della popolazione. La formalizzazione di tale tecnica è attribuita allo statistico K. Pearson nel suo lavoro [Pearson \(1894\)](#).

Sia $y_1, \dots, y_n$ un campione casuale i.i.d. proveniente da una variabile aleatoria Y con funzione di ripartizione $F(y; \theta)$. Si definisce funzione di ripartizione empirica

$$\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}(y_i \leq y),$$

dove $\mathbb{1}(\cdot)$ è la funzione indicatrice, ossia assume il valore uno se la condizione fra parentesi è rispettata e zero altrimenti. Il principio dell'analogia stabilisce che, se un parametro di interesse θ può essere espresso in funzione della distribuzione teorica, ovvero $\theta = g(F)$, allora uno stimatore naturale per θ è dato dalla medesima funzione applicata alla distribuzione empirica, ponendo semplicemente $\hat{\theta}_n = g(\hat{F}_n)$.

Il *metodo dei momenti* rappresenta un caso particolare e storicamente rilevante di questo principio. Si consideri il momento teorico di ordine k , definito come $\mu_k(\theta) = E(Y^k) = \int_{\mathcal{Y}} y^k dF(y; \theta)$, per il principio di analogia, lo stimatore del momento teorico è dato da quello campionario corrispondente ottenuto rispetto alla distribuzione empirica $\hat{F}_n$, denotato con $m_k = 1/n \sum_{i=1}^n y_i^k$.

La stima dei parametri si ottiene quindi risolvendo il sistema in cui i momenti teorici (funzioni del parametro θ) vengono eguagliati ai rispettivi momenti campionari

$$\mu_k(\theta) = m_k, \quad k = 1, 2, \dots, p.$$

1.4.2 Problemi di stima intervallare

Definizione 1.4 (Stima intervallare). Fissato un livello di probabilità $1 - \alpha$, con $\alpha \in (0, 1)$, si definisce *stima intervallare* la procedura statistica che associa ad ogni possibile realizzazione del campione y un sottoinsieme casuale dello spazio parametrico $C(Y) \subseteq \Theta$, tale per cui la probabilità che esso contenga il vero valore incognito del parametro rispetti la seguente disuguaglianza:

$$\Pr_{\theta}(\theta \in C(Y)) \geq 1 - \alpha, \quad \text{per ogni } \theta \in \Theta.$$

La realizzazione numerica $C(y)$, calcolata in corrispondenza di un determinato campione osservato y , prende il nome di *regione di confidenza* (o *intervallo di confidenza*, nel caso di parametro scalare) per θ al livello $1 - \alpha$, e si indica comunemente con l'abbreviazione $IC(1 - \alpha)$.

1.5 Problemi di verifica d'ipotesi

Per quanto riguarda la seconda categoria di problemi legati all'inferenza statistica, è necessario definire cosa si intende per verifica d'ipotesi.

Definizione 1.5 (Verifica di ipotesi). Si consideri una partizione dello spazio parametrico Θ in due sottoinsiemi *disgiunti e complementari*, Θ_0 e Θ_1 . Si definisce sistema di ipotesi la contrapposizione fra:

- *Ipotesi nulla* (H_0): $\theta \in \Theta_0$;
- *Ipotesi alternativa* (H_1): $\theta \in \Theta_1$.

La *verifica di ipotesi* (o test statistico) è una procedura decisionale che permette di stabilire se i dati campionari forniscono o meno un'evidenza sufficiente a rifiutare

l'ipotesi nulla. Si fissi una soglia di significatività α , che specifica la probabilità massima del parametro di appartenere al sottospazio Θ_1 , formalmente:

$$\begin{cases} \text{Se } y \in R & \implies \text{Si rifiuta } H_0 \text{ in favore di } H_1; \\ \text{Se } y \notin R & \implies \text{Non si rifiuta } H_0. \end{cases}$$

Dove $R \subset \mathcal{Y}$ è chiamata *regione di rifiuto* (o critica) e rappresenta l'insieme dello spazio campionario per cui si rifiuta l'ipotesi nulla.

1.6 Problemi di previsione

Mentre i problemi di stima e di verifica d'ipotesi si concentrano sull'inferenza riguardante il parametro incognito (o vettore di parametri) θ , i problemi di previsione si occupano di un paradigma differente, ovvero quello di anticipare il risultato di un esperimento non osservabile.

Sia Y^* una nuova variabile casuale (o vettore aleatorio) a valori nello spazio $\mathcal{Y}^*$, che rappresenta la legge da cui vengono generate le osservazioni future, le quali si ipotizzano dipendere dallo stesso parametro incognito θ .

Definizione 1.6 (Previsione puntuale). Si definisce *previsore puntuale* una statistica basata sul campione, $\hat{y}^* = g(y)$, che ha lo scopo di fornire una stima plausibile per la realizzazione futura della variabile casuale Y^* .

Si noti che l'analisi predittiva è caratterizzata da due fonti di incertezza, la prima riguardante il reale modello generatore dei dati (l'incertezza parametrica), e la seconda relativa all'intrinseca variabilità del fenomeno preso in esame, misurata dalla *varianza*. Per ottenere stime plausibili che tengano in considerazione le suddette fonti di incertezza si ricorre alle *previsioni intervallari*.

Definizione 1.7 (Previsione intervallare). Fissato un livello di probabilità $1 - \alpha$, con $\alpha \in (0, 1)$, si definisce procedura di *previsione intervallare* la costruzione di un sottoinsieme casuale $P(y) \subseteq \mathcal{Y}^*$, basato sul campione y , tale per cui la probabilità che l'osservazione futura y^* vi appartenga rispetti la seguente disuguaglianza:

$$\Pr_{\theta}(Y^* \in P(y)) \geq 1 - \alpha, \quad \text{per ogni } \theta \in \Theta.$$

La realizzazione numerica $P(y)$, calcolata in corrispondenza di un determinato campione osservato y , prende il nome di *regione di previsione* (o *intervallo di previsione*, nel caso scalare) al livello nominale $1 - \alpha$.

In chiusura di questa Sezione, risulta doveroso precisare una differenza tra intervalli di previsione e intervalli di confidenza (relativi alla stima del valore atteso). Semplificando, l'intervallo di previsione, dovendo prevedere l'osservazione futura y^* , deve inglobare entrambe le fonti di incertezza precedentemente citate (rispetto ai parametri e alla variabilità); l'intervallo di confidenza, invece, tiene in considerazione esclusivamente l'incertezza derivante dalla stima dei parametri del modello. Di conseguenza, a parità di livello nominale $1-\alpha$, gli intervalli di previsione risultano sistematicamente più ampi e conservativi rispetto ai corrispettivi intervalli di confidenza.

1.7 Inferenza statistica basata sul concetto di verosimiglianza

L'approccio più diffuso nel contesto moderno per affrontare i problemi di inferenza statistica fa uso di un concetto chiamato *funzione di verosimiglianza*. Le virtù dei metodi basati su questa funzione risiedono nella semplice interpretabilità e nelle garanzie teoriche delle stime che se ne derivano. Il metodo non è esente da problematiche, che riguardano principalmente la difficoltà di risoluzione delle equazioni per l'individuazione delle stime ed in alcuni casi la loro mancata esistenza (argomento approfondito nel Capitolo 2 nella Sezione 2.6).

1.7.1 La funzione di verosimiglianza

L'idea fondante della *teoria basata sulla verosimiglianza* risulta essere intuitiva: si pensi al significato di funzione di probabilità rispetto ad una generica variabile casuale; tale funzione, con θ noto, rappresenta la probabilità (o densità nel caso continuo) di osservare una determinata unità statistica y_i , sotto le ipotesi specificate nel *modello statistico parametrico* di riferimento. Su questa premessa risulta ragionevole pensare di definire una funzione che, invece di dipendere dai dati del campione y , dipenda dal parametro θ ; in questo modo nasce il concetto di *funzione di verosimiglianza*. La definizione data segue strettamente l'approccio esposto in [Azzalini \(2008\)](#).

Definizione 1.8 (Funzione di verosimiglianza). Sia $p_Y(y; \theta)$ la funzione di probabilità del campione osservato y , definita dal modello parametrico di riferimento con $\theta \in \Theta \subseteq \mathbb{R}^p$. Considerando $p_Y(y; \theta)$ come una funzione del parametro θ , risulta naturale definire la *funzione di verosimiglianza* (o semplicemente *verosimiglianza*)

$L : \Theta \rightarrow [0, +\infty)$ come:

$$L(\theta) = L(\theta; y) = c(y) p(y; \theta). \quad (1.1)$$

La quantità $c(y)$ rappresenta una funzione esclusivamente dei dati, positiva ed indipendente dal parametro θ ; si noti quindi che la funzione di verosimiglianza definisce una *classe di equivalenza* di funzioni che differiscono per il valore di $c(y)$, che non apporta informazioni circa il parametro (concetto che sarà approfondito nella Sezione 1.8). Si può pertanto osservare che due funzioni di verosimiglianza, per lo stesso parametro θ , derivanti da esperimenti o modelli differenti, conducono alle medesime conclusioni inferenziali se risultano proporzionali, come si può notare nell'esempio 1.1. I valori ottenuti mediante la verosimiglianza si interpretano come segue: alla luce del campione osservato, il parametro θ' risulta essere più *verosimile* rispetto a θ'' nel ruolo di parametro caratteristico del modello generatore dei dati se $L(\theta') > L(\theta'')$ (con $\theta', \theta'' \in \Theta$). Si noti che i valori assunti dalla verosimiglianza non definiscono una funzione di probabilità.

Si conclude introducendo il concetto di *funzione di log-verosimiglianza*; data la proprietà di non negatività della funzione di verosimiglianza risulta possibile (e quasi sempre conveniente) effettuare le procedure matematiche di inferenza sulla trasformata logaritmica di quest'ultima,

$$\ell(\theta) = \log L(\theta),$$

con la convenzione che se $L(\theta) = 0$ allora $\ell(\theta) = -\infty$.

Esempio 1.1 (Equivalenza della funzione di verosimiglianza). Si consideri un campione casuale semplice $y = (y_1, \dots, y_n)$, le cui determinazioni sono estratte da una variabile casuale di Bernoulli con parametro $\pi \in (0, 1)$. La sua funzione di probabilità può essere espressa nel seguente modo:

$$p(y; \pi) = \pi^y (1 - \pi)^{1-y}.$$

È quindi possibile ottenere la funzione di verosimiglianza, per l'assunzione di indipendenza, come:

$$L_1(\pi) = \prod_{i=1}^n p(y_i; \pi) = \prod_{i=1}^n \pi^{y_i} (1 - \pi)^{1-y_i} = \pi^{n_1} (1 - \pi)^{n-n_1},$$

dove $n_1 = \sum_{i=1}^n y_i$ rappresenta il numero totale di successi ottenuti nelle n prove indipendenti.

Si consideri ora un disegno sperimentale alternativo in cui il ricercatore non registra l'esito specifico e l'ordine di ogni singola prova, ma si limita a osservare unicamente il numero totale di successi ottenuti nel medesimo campione n_1 . In particolare, si mostra come tale esperimento sia modellabile in modo equivalente attraverso la variabile casuale *binomiale* in funzione del *medesimo parametro* $\pi \in (0, 1)$, con funzione di probabilità:

$$p(y; \pi) = \binom{n}{n_1} \pi^{n_1} (1 - \pi)^{n - n_1}.$$

La verosimiglianza associata a questa osservazione risulta quindi:

$$L_2(\pi) = \binom{n}{n_1} \pi^{n_1} (1 - \pi)^{n - n_1}.$$

Risulta ora immediato notare che i due metodi utilizzati per misurare le medesime realizzazioni sperimentali risultano del tutto equivalenti per la stima del parametro π , essendo valida la relazione di proporzionalità:

$$L_1(\pi) \propto L_2(\pi),$$

dove la costante di proporzionalità $c(n_1)$ è rappresentata dal coefficiente binomiale presente in $L_2(\pi)$. A livello logico risulta intuitivo che l'informazione riguardante l'ordine degli esiti non sia rilevante per l'inferenza sul parametro in un contesto in cui le variabili casuali originarie y_i siano indipendenti e identicamente distribuite. Si approfondirà questa intuizione nel contesto delle statistiche sufficienti nell'esempio [1.2](#).

1.7.2 Proprietà della verosimiglianza

La funzione di verosimiglianza gode di alcune proprietà e garanzie teoriche che rendono il suo utilizzo agevole ed intuitivo. Tra queste ci sono due teoremi fondamentali: il primo riguardante il comportamento della *verosimiglianza* in relazione a trasformazioni dei dati, mentre il secondo rispetto a riparametrizzazioni.

Teorema 1.1 (Invarianza della funzione di verosimiglianza). *Sia $t = g(y)$ una trasformazione biunivoca dei dati, ovvero $g(\cdot)$ è una funzione biettiva. Si può allora dimostrare che la verosimiglianza calcolata sul modello statistico $\mathcal{F}_T = \{p_T(t; \theta), \theta \in$*

$\Theta \subseteq \mathbb{R}^p\}$ è equivalente a quella prodotta dal modello $\mathcal{F}_Y$:

$$L^T(\theta; t) = c(y)L^Y(\theta; y).$$

Dimostrazione. Sia $t = g(y)$ una trasformazione biunivoca con inversa $y = g^{-1}(t)$. Per la formula del cambio di variabile dell'analisi matematica, la funzione di probabilità di $T = g(Y)$ risulta, $p_T(t; \theta) = p_Y(g^{-1}(t); \theta) |\partial/\partial t g^{-1}(t)|$, dove il simbolo del valore assoluto indica il determinante della matrice jacobiana. Sostituendo nella definizione di verosimiglianza si ottiene:

$$L^T(\theta; t) = c(t) p_T(t; \theta) = c(t) p_Y(g^{-1}(t); \theta) \left| \frac{\partial g^{-1}(t)}{\partial t} \right|.$$

Dato che lo *jacobiano* $|\partial/\partial t g^{-1}(t)|$ non dipende dal parametro θ , esso è parte della costante moltiplicativa $c(t)$, per cui il Teorema risulta dimostrato. $\square$

Teorema 1.2 (Invarianza per riparametrizzazione). *Sia $\psi = \psi(\theta)$ una trasformazione biunivoca del parametro con inversa $\theta = \theta(\psi)$. È immediato dimostrare che $L^\Psi(\psi; y)$, la verosimiglianza calcolata rispetto alla nuova parametrizzazione, è legata a quella calcolata rispetto al parametro originale $L^\Theta(\theta; y)$ nel seguente modo:*

$$L^\Psi(\psi; y) = L^\Theta(\theta(\psi); y).$$

Dimostrazione. Osserviamo che ψ e $\theta(\psi)$ individuano il medesimo modello statistico, pertanto deve valere $p_Y(y; \psi) = p_Y(y; \theta(\psi))$, da cui segue direttamente l'equazione del teorema. $\square$

È opportuno riportare che esiste un'estensione di tale teorema contenuto in [Casella & Berger \(2002, Cap. 6\)](#), che dimostra come la proprietà di invarianza sussista anche nel caso in cui la trasformazione $\psi(\theta)$ sia esclusivamente suriettiva.

1.7.3 La stima di massima verosimiglianza

Dopo avere introdotto rigorosamente il contesto statistico di riferimento, si può definire il metodo di stima puntuale che sarà alla base degli studi effettuati in questa tesi, la *stima di massima verosimiglianza*, a cui ci si riferirà con l'acronimo SMV (che sarà utilizzato anche per indicare lo *stimatore di massima verosimiglianza*, la distinzione sarà chiara dal contesto). Tale stima è per definizione il valore $\hat{\theta} \in \Theta$

che rispetta la proprietà di massimo per $L(\theta)$, cioè:

$$L(\hat{\theta}; y) \geq L(\theta; y), \quad \forall \theta \in \Theta,$$

dove si è utilizzata la notazione $L(\theta; y)$ per indicare la dipendenza della funzione dal parametro dato il campione osservato y , nel seguito del lavoro si utilizzerà questo tipo di notazione quando si vorrà portare l'attenzione sul condizionamento della *verosimiglianza* rispetto al campione. Per individuare la SMV si utilizzeranno i classici metodi dell'analisi matematica per la ricerca dei massimi di funzione. Essendo il logaritmo una funzione monotona strettamente crescente, risulta evidente che massimizzare la *log-verosimiglianza* permette di individuare le medesime stime semplificando le equazioni da risolvere (si procederà considerando quest'ultima forma). Nel concreto, si individueranno le derivate parziali prime di $\ell(\theta)$ rispetto a ciascun elemento del vettore dei parametri θ_j , per $j = 1, \dots, p$, noto anche come *vettore dello score* (o *funzione punteggio*) e lo si porrà pari a zero:

$$U(\theta) = \nabla \ell(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} = \left[\frac{\partial \ell(\theta)}{\partial \theta_1}, \quad \frac{\partial \ell(\theta)}{\partial \theta_2}, \quad \dots, \quad \frac{\partial \ell(\theta)}{\partial \theta_p} \right]^T = 0. \quad (1.2)$$

I valori dei parametri che risolvono il sistema omogeneo saranno le *stime di massima verosimiglianza*. Si noti che, spesso, il sistema testé definito non ammette soluzioni in forma chiusa; risulta quindi necessario ricorrere ad algoritmi di approssimazione numerica, il più utilizzato dei quali è *l'algoritmo di Newton-Raphson* ([Quarteroni et al., 2014](#)).

Per assicurarsi che i valori ottenuti dal sistema individuino effettivamente un massimo per $L(\cdot)$ è necessario che la matrice delle derivate seconde sia definita negativa, si rimanda alla Sezione 1.10.2 per la trattazione. Infine, come conseguenza del Teorema 1.2, se $\hat{\theta}$ è la *stima di massima verosimiglianza* per θ , allora $\hat{\psi} = \psi(\hat{\theta})$ è a sua volta la SMV per il parametro trasformato.

1.8 Statistiche sufficienti

In statistica si ricorre spesso all'espressione *statistiche sufficienti*, le quali giocano un ruolo fondamentale nel processo di sintesi dei dati nei processi di inferenza. L'intuizione è semplice, consiste nel fatto che alcune sintesi dei dati contengono tutta l'informazione utile al fine di stimare i parametri, pertanto, considerare solo




Figura 1.1: Massima verosimiglianza per un modello lineare. Dati penguins (libreria `palmerpenguins`), covariata lunghezza del becco (standardizzata).

tali statistiche rispetto ai singoli elementi del campione y non porta alcuna differenza sulle SMV, come palesato dal seguente Teorema.

Teorema 1.3 (Criterio di Neyman-Fisher). *Si definisce $T = g(y)$, con $g(\cdot)$ funzione anche non iniettiva, una statistica sufficiente per l'inferenza su θ , se e soltanto se la funzione di probabilità può essere fattorizzata nel seguente modo:*

$$p_Y(y; \theta) = h(y)k(T(y); \theta).$$

Come si nota dall'equazione, si tratta di scomporre la probabilità in una componente dipendente dal parametro ed una che dipende esclusivamente dai dati. Tramite la procedura di individuazione della SMV (1.2) si nota come, al momento della derivazione per individuare il *vettore di score*, la componente dipendente esclusivamente dai dati avrà contribuito nullo, e pertanto non influirà sulla stima del parametro θ . In questo contesto, l'esito del campione y può essere interpretato dapprima come un'estrazione sullo spazio della statistica sufficiente T secondo una legge $k(T(y); \theta)$ dipendente dal parametro, conseguentemente segue una traslazione rispetto ad una generica funzione $h(y)$ dipendente esclusivamente dai dati. Per la formula 1.1 le verosimiglianze ottenute da $T(y)$ e da y risultano equivalenti.

Esempio 1.2. Sia y un ccs estratto da una v.c. binomiale con parametro π e numerosità m_i . Si vuole mostrare come $n_1 = \sum_{i=1}^n y_i$, ossia il numero totale dei successi, sia una statistica sufficiente per l'inferenza su π . Si procede scrivendo la funzione di probabilità del campione definendo $N = \sum_{i=1}^n m_i$, e si mostrano i conseguenti passaggi:

$$p(y; \pi) = \prod_{i=1}^n \binom{m_i}{y_i} \pi^{y_i} (1 - \pi)^{m_i - y_i} = \prod_{i=1}^n \binom{m_i}{y_i} \pi^{n_1} (1 - \pi)^{N - n_1} = h(y)k(n_1; \pi).$$

Essendo questa la definizione del Teorema 1.3, n_1 risulta essere una statistica sufficiente per l'inferenza sul parametro π . Inoltre, si nota come essa offra una riduzione della complessità della funzione, per cui l'inferenza può essere effettuata senza tenere in considerazione il calcolo del coefficiente binomiale.

Definizione 1.9 (Statistica sufficiente minimale). Ci si riferisce ad una statistica sufficiente $T(y)$ con l'aggettivo *minimale* per l'inferenza su θ , se assume valori distinti esclusivamente in punti dello spazio campionario a cui corrispondono verosimiglianze non equivalenti. Deve quindi valere la seguente condizione per ogni $y, z \in \mathcal{Y}$,

$$T(y) = T(z) \iff L(\theta; y) \propto L(\theta; z), \text{ per ogni } \theta \in \Theta.$$

Esempio 1.3. Risulta immediato notare come la statistica sufficiente introdotta nell'esempio 1.2 sia anche minimale. Basta notare che se $n'_1 = n''_1$ sono uguali, allora la loro verosimiglianza è equivalente; la differenza dipende solo dal prodotto dei coefficienti binomiali che però non dipendono dal parametro π . Un esempio di statistica sufficiente non minimale, nel contesto della binomiale, è rappresentata dalle somme parziali dei successi. Infatti, in tal caso è possibile mostrare che $T(y) \neq T(z)$ ma $L(\pi; y) \propto L(\pi; z)$ pertanto non vale la doppia implicazione. Il criterio per verificare tali affermazioni invoca il *Teorema di Lehmann-Scheffé*, che per ragioni di tempo non sarà trattato. Si veda Azzalini (2008) per una sua esposizione esaustiva.

1.9 Condizioni regolari di stima

Arrivati a questo punto, risulta essenziale definire le quattro *condizioni regolari di stima* (a cui ci si riferirà anche con il termine *condizioni di regolarità*) che pongono il fondamento teorico per i teoremi enunciati e dimostrati nel prosieguo di questa tesi. Le condizioni sono:

1. *Identificabilità*; cioè che il modello statistico parametrico rispetti la definizione 1.2;
2. *Spazio parametrico*; lo spazio parametrico, indicato con la lettera Θ , deve essere un aperto di $\mathbb{R}^p$;
3. *Continuità*; si richiede che la funzione del modello $p(\cdot)$ abbia derivate parziali continue fino al terzo ordine rispetto a θ ;
4. *Indipendenza del supporto e scambiabilità*; il supporto $\mathcal{Y}$ della distribuzione non deve dipendere dal parametro incognito θ . Questa condizione garantisce la possibilità di scambiare l'operatore di integrazione (rispetto allo spazio campionario) con quello di derivazione (rispetto al parametro).

1.10 Proprietà campionarie

Per affrontare in modo esaustivo la teoria asintotica degli *stimatori di massima verosimiglianza* risulta essenziale introdurre alcune proprietà empiriche legate alla funzione di verosimiglianza.

Teorema 1.4 (Disuguaglianza di Wald). *La disuguaglianza di Wald afferma che, sotto le condizioni regolari di stima:*

$$E_{\theta_0}\{\ell(\theta_0; Y)\} \geq E_{\theta_0}\{\ell(\theta; Y)\}, \quad \theta \neq \theta_0.$$

dove θ_0 rappresenta il vero valore del parametro.

L'informazione che si ottiene da questa disuguaglianza è che il valore atteso della log-verosimiglianza raggiunge il suo massimo assoluto in corrispondenza del vero valore del parametro. Dunque, la stima di massima verosimiglianza può essere inquadrata come un caso particolare del metodo dell'analogia (1.4.1), poiché la massimizzazione avviene sulla funzione empirica $\ell(\theta; y)$, che costituisce la controparte campionaria di $E_{\theta_0}\{\ell(\theta, Y)\}$. Per la dimostrazione si veda l'Appendice A.1.

1.10.1 Proprietà della funzione di score

Assumendo valide le condizioni regolari di stima per cui il supporto della variabile casuale non dipenda dal parametro (4), il valore atteso della *funzione score* è identicamente nullo. In altre parole, l'equazione di verosimiglianza costituisce un'equazione

di stima non distorta,

$$E_{\theta}\{U(\theta)\} = 0, \quad \text{per ogni } \theta \in \Theta.$$

Dimostrazione. Come conseguenza del *secondo assioma di Kolmogorov* deve valere che $\int_{\mathcal{Y}} p(y; \theta) dy = 1$, derivando tale equazione si ottiene $(\partial/\partial\theta) \int_{\mathcal{Y}} p(y; \theta) dy = (\partial/\partial\theta)(1) = 0$. Grazie all'assunzione di regolarità, è lecito scambiare l'operatore di derivazione con quello di integrazione, ottenendo $\int_{\mathcal{Y}} (\partial/\partial\theta)p(y; \theta) dy = 0$. Moltiplicando e dividendo per la probabilità $p(y; \theta)$ (si noti che nel supporto i valori assunti dalla funzione di probabilità sono strettamente positivi), si ottiene $\int_{\mathcal{Y}} \{(\partial p(y; \theta)/\partial\theta)/p(y; \theta)\} p(y; \theta) dy = 0$. Ricordando la regola di derivazione del logaritmo e la definizione di valore atteso calcolato utilizzando la probabilità rispetto alla misura dominante (che in questo caso continuo è quella di Lebesgue indicata con dy), si ottiene:

$$E_{\theta}\{U(\theta; y)\} = \int_{\mathcal{Y}} \left\{ \frac{\partial}{\partial\theta} \ell(\theta; y) \right\} p(y; \theta) dy = 0. \quad (1.3)$$

□

L'intuizione è che il valore atteso del vettore dello score sia composto da elementi negativi e positivi che si compensano perfettamente. Sfruttando questa proprietà teorica, a livello campionario la stima di massima verosimiglianza $\hat{\theta}$, sotto condizioni di regolarità di stima (1.9), si ottiene individuando l'unico punto che annulla il vettore score per i dati osservati, seguendo quindi l'approccio per *analogia* (1.4.1).

1.10.2 Informazione osservata ed attesa

Un elemento di centrale importanza riguarda la matrice Hessiana della log-verosimiglianza cambiata di segno, nota come *informazione osservata*,

$$J(\theta) = -\nabla^2 \ell(\theta) = \begin{bmatrix} -\frac{\partial^2 \ell(\theta)}{\partial \theta_1^2} & \cdots & -\frac{\partial^2 \ell(\theta)}{\partial \theta_1 \partial \theta_p} \\ \vdots & \ddots & \vdots \\ -\frac{\partial^2 \ell(\theta)}{\partial \theta_p \partial \theta_1} & \cdots & -\frac{\partial^2 \ell(\theta)}{\partial \theta_p^2} \end{bmatrix}. \quad (1.4)$$

Per interpretare tale quantità si passa per la riscrittura della log-verosimiglianza (per θ scalare senza perdita di generalità), mediante sviluppo di Taylor centrato in

$\hat{\theta}$ con resto di Peano,

$$\ell(\theta) = \ell(\hat{\theta}) + U(\hat{\theta})(\theta - \hat{\theta}) - \frac{1}{2}J(\hat{\theta})(\theta - \hat{\theta})^2 + o\{(\theta - \hat{\theta})^2\}.$$

Poiché l'SMV annulla la funzione score (1.2), l'approssimazione si semplifica nella funzione chiamata *log-verosimiglianza normalizzata*,

$$\ell(\theta) - \ell(\hat{\theta}) = -\frac{1}{2}J(\hat{\theta})(\theta - \hat{\theta})^2 + o((\theta - \hat{\theta})^2). \quad (1.5)$$

L'equazione 1.5 permette di interpretare *l'informazione osservata* come la spinta informativa portata dai dati circa la stima. Infatti, se la funzione ha una curvatura molto accentuata (alta informazione osservata) implica che discostarsi, anche se di poco, dal parametro $\hat{\theta}$ fa crollare il valore della verosimiglianza. Al contrario, una curvatura poco accentuata (poca informazione osservata) porta ad un livello simile di verosimiglianza per valori del parametro anche molto differenti, lasciando intendere uno scarso potere informativo dei dati y . In altri termini, *quantifica la forza con cui i dati penalizzano una congettura errata sul parametro θ* .

Si noti in ultimo come l'equazione di Taylor introdotta mette in relazione l'errore sul valore del parametro con il suo effetto osservato rispetto alla funzione di log-verosimiglianza, il che è alla base di qualsiasi teorema per la convergenza asintotica.

Un'altra quantità strettamente legata all'informazione osservata è chiamata *informazione attesa*, che, sotto opportune condizioni di regolarità 1.9, è possibile definire come

$$I(\theta) = E_{\theta}\{U(\theta)(U(\theta))^T\}, \quad \text{per ogni } \theta \in \Theta,$$

che, essendo un valore atteso, non dipende dal campione osservato y . Si può inoltre dimostrare come il rapporto tra l'informazione attesa e quella osservata converga in probabilità ad 1 al divergere della numerosità campionaria n .

Teorema 1.5 (Identità dell'Informazione di Fisher). *Sia Y una variabile casuale la cui funzione di probabilità $p(y; \theta)$ soddisfa le condizioni regolari di stima. Allora vale la seguente identità,*

$$E_{\theta}\{J(\theta; y)\} = -E_{\theta}\left\{\frac{\partial^2}{\partial \theta^2}\ell(\theta; y)\right\} = E_{\theta}\left\{\left(\frac{\partial}{\partial \theta}\ell(\theta; y)\right)^2\right\} = I(\theta).$$

Dimostrazione. Si parta dall'equazione 1.3, derivando entrambi i membri di quest'ultima rispetto al parametro θ si ottiene $\int_y \partial/\partial \theta [(\partial \log p(y; \theta)/\partial \theta) p(y; \theta)] dy = 0$.

Segue che, applicando la regola di derivazione del prodotto e della derivata del logaritmo, l'equazione diventa

$$\int_{\mathcal{Y}} \left\{ \left(\frac{\partial^2}{\partial \theta^2} \log p(y; \theta) \right) p(y; \theta) + \left(\frac{\partial}{\partial \theta} \log p(y; \theta) \right)^2 p(y; \theta) \right\} dy = 0.$$

Riconoscendo la definizione di valore atteso per entrambi gli addendi ci si riconduce all'identità $E_{\theta}[\partial^2 \ell(\theta; Y)/\partial \theta^2] + E_{\theta}[(\partial \ell(\theta; Y)/\partial \theta)^2] = 0$, che, riordinando i termini e ricordando la definizione di informazione osservata (1.4), permette di dimostrare il Teorema

$$E_{\theta}\{J(\theta; Y)\} = E_{\theta} \left\{ \left(\frac{\partial}{\partial \theta} \ell(\theta; Y) \right)^2 \right\} = I(\theta).$$

□

Dal teorema appena dimostrato e dalla 1.3, è possibile fornire una definizione aggiuntiva dell'*informazione attesa* in termini di *varianza della funzione di score*, $I(\theta) = -E_{\theta}[\partial^2 \ell(\theta; Y)/\partial \theta^2] = \text{Var}_{\theta}(U(\theta; Y))$.

Le ultime proprietà riguardanti l'informazione attesa che si andranno ad enunciare riguardano l'*additività* e l'*equivarianza* rispetto a riparametrizzazioni. Sotto l'ipotesi di ccs (1.2) e ricordando la proprietà di additività della varianza per v.c. indipendenti, si ottiene:

$$I(\theta) = \sum_{h=1}^n i_h(\theta) = ni(\theta), \quad (1.6)$$

con $i(\theta)$ contributo del generico elemento campionario. Per quanto riguarda la proprietà di equivarianza rispetto a riparametrizzazioni si consideri $\psi(\theta)$, funzione monotona e derivabile, allora l'informazione attesa può essere ricavata nel seguente modo:

$$I(\psi(\theta)) = \{\psi'(\theta)\}^{-2} I(\theta),$$

ottenuta dal Teorema 1.2 e da quanto detto precedentemente circa l'informazione attesa definita come varianza dello *score*.

1.11 Teoria asintotica del primo ordine

L'inferenza basata sulla verosimiglianza gode di diverse garanzie teoriche che ne sostengono l'impiego, le quali necessitano di ipotesi "deboli", spesso rispettate nei casi applicativi reali, per essere valide.

Per introdurre rigorosamente la teoria asintotica della verosimiglianza, risulta essenziale definire i simboli probabilistici utilizzati per descrivere il comportamento delle successioni di variabili casuali al crescere della numerosità campionaria n . Le nozioni principali sono quelle di convergenza in distribuzione, in probabilità e quasi certa. La convergenza in distribuzione ($X_n \xrightarrow{d} X$) avviene se le funzioni di ripartizione $F_n(x)$ convergono alla medesima $F(x)$, ovvero $\lim_{n \rightarrow \infty} F_n(x) = F(x)$. Si dice, invece, che una successione X_n converge in probabilità a X (indicato con $X_n \xrightarrow{p} X$) se, per ogni $\epsilon > 0$ vale $\lim_{n \rightarrow \infty} \Pr(|X_n - X| > \epsilon) = 0$. Più stringente è invece la condizione per la convergenza quasi certa ($X_n \xrightarrow{a.s.} X$), definita come $\Pr(\lim_{n \rightarrow \infty} X_n = X) = 1$.

Per la gestione degli ordini di convergenza stocastici, si adottano le seguenti notazioni:

- $X_n = \mathcal{O}_p(a_n)$ indica che la successione è *stocasticamente limitata* rispetto alla sequenza deterministica a_n ; ovvero, per ogni $\epsilon > 0$, esiste una costante $M > 0$ tale per cui $\sup_n \Pr(|X_n/a_n| > M) < \epsilon$.
- $X_n = o_p(a_n)$ indica che il rapporto fra la successione stocastica e quella deterministica converge in probabilità a zero, ovvero $X_n/a_n \xrightarrow{p} 0$.

Un teorema fondamentale per mostrare la distribuzione asintotica delle quantità di verosimiglianza è fornito dalla *disuguaglianza di Cramér-Rao*.

Teorema 1.6 (Disuguaglianza di Cramér-Rao). *Sia $T(y)$ un generico stimatore in un contesto in cui valgano le condizioni regolari di stima (1.9), e si supponga per semplicità espositiva che $p = 1$. Si richiede che il valore atteso dello stimatore $E_\theta\{T(Y)\} = a(\theta)$ esista e sia derivabile, da cui si ottiene la seguente equazione,*

$$a'(\theta) = \frac{\partial}{\partial \theta} \int_{\mathcal{Y}} T(y) p(y; \theta) dy = \int_{\mathcal{Y}} T(y) \frac{\partial}{\partial \theta} p(y; \theta) dy.$$

Da cui, con qualche passaggio, si ricava

$$\text{Var}_\theta T(Y) \geq a'(\theta)^2 / I(\theta).$$

Per la dimostrazione si rimanda all'Appendice A.1 oppure al testo Azzalini (2008, Cap. 3.2.5).

Teorema 1.7 (Consistenza dello Stimatore di Massima Verosimiglianza). *Sotto le condizioni regolari di stima (1.9) e assumendo che la funzione di score e la sua*

derivata siano continue in θ , lo stimatore di massima verosimiglianza $\hat{\theta}_n$, unica soluzione per l'equazione di score, converge in probabilità al vero valore del parametro θ_0 :

$$\hat{\theta}_n \xrightarrow{p} \theta_0.$$

La dimostrazione sarà data per il caso univariato senza perdita di generalità.

Dimostrazione. Si consideri l'equazione di verosimiglianza divisa per la numerosità campionaria, $n^{-1} \sum_{i=1}^n U(\theta; y_i) = 0$, score dell' i -esima osservazione, con $i = 1, \dots, n$. Si noti che, essendo questa la media campionaria della *funzione di score*, al divergere di n per la legge debole dei grandi numeri sotto θ_0 , si ottiene:

$$\frac{1}{n} \sum_{i=1}^n U(\theta; y_i) \xrightarrow{p} E_{\theta_0}(U(\theta; Y_1)).$$

Sfruttando le condizioni regolari di stima e l'ipotesi di continuità sulle quantità di verosimiglianza si può mostrare che la funzione ottenuta sia monotona decrescente in un intorno di θ_0 , in quanto la derivata del valore atteso dello score coincide proprio con l'informazione attesa cambiata di segno $i(\theta)$ (che è sempre positiva per definizione). Pertanto, utilizzando il Teorema della permanenza del segno ([Pagani & Salsa, 2015](#)), la funzione

$$H(\theta) = \frac{\partial}{\partial \theta} E_{\theta_0}(U(\theta; y_1)),$$

mantiene segno negativo in un intorno di θ_0 .

Si consideri l'intorno di θ_0 , definito da $(\theta_0 - \epsilon, \theta_0 + \epsilon)$, in cui la funzione $H(\theta)$ è continua. Dall'ipotesi di continuità della funzione di score e dal fatto che $\hat{\theta}_n$ sia l'unica soluzione per l'equazione di verosimiglianza, se $U(\theta_0 - \epsilon; y) > 0$ e $U(\theta_0 + \epsilon; y) < 0$, deve essere che $\theta_0 - \epsilon < \hat{\theta}_n < \theta_0 + \epsilon$. Ma allora, poiché $A \Rightarrow B$ implica $\Pr(A) \leq \Pr(B)$, si ottiene la seguente disuguaglianza:

$$\Pr_{\theta_0} \left(\frac{1}{n} U(\theta_0 - \epsilon) > 0, \frac{1}{n} U(\theta_0 + \epsilon) < 0 \right) \leq \Pr_{\theta_0} (\theta_0 - \epsilon < \hat{\theta}_n < \theta_0 + \epsilon).$$

Per la quale, ricordando la disuguaglianza di Bonferroni, $\Pr(A \cap B) \geq \Pr(A) + \Pr(B) - 1$ e la convergenza in probabilità del valore atteso empirico dello score al suo momento teorico, si ottiene che la probabilità associata al lato sinistro della disuguaglianza non potrà che essere uno, di conseguenza

$$\lim_{n \rightarrow \infty} \Pr_{\theta_0}(\theta_0 - \epsilon < \hat{\theta}_n < \theta_0 + \epsilon) = 1,$$

che dimostra la convergenza dello SMV al vero valore del parametro. $\square$




Figura 1.2: Consistenza asintotica dello stimatore di massima verosimiglianza. Simulazione da un modello binomiale con legame canonico, parametri fissati $\beta = (-1, 0.8)$.

1.11.1 Distribuzione dello stimatore di massima verosimiglianza

Prima di mostrare la distribuzione asintotica del primo ordine dello SMV, bisogna analizzare brevemente la distribuzione della *funzione di score* nel caso univariato. È possibile considerare quest'ultima come una somma di n variabili casuali indipendenti ed identicamente distribuite. Si è già mostrato che il valore atteso della funzione punteggio è nullo e che la sua varianza coincide con *l'informazione attesa di Fisher*, pertanto, sotto l'ipotesi che $I(\theta) > 0$ (scalare) e che θ sia il vero valore del parametro, per il *Teorema centrale del limite* (Azzalini, 2008) si ottiene:

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial}{\partial \theta} \log p(y_i; \theta) \xrightarrow{d} N(0, i(\theta)). \quad (1.7)$$

Per la proprietà di additività dell'informazione attesa (1.6), la funzione di score del campione si distribuisce approssimativamente come una normale, $U(\theta) \sim N(0, I(\theta))$, dove si ricorda che $I(\theta)$ dipende da n . Nel contesto in cui θ fosse un vettore di parametri la convergenza sarebbe ad una normale p-variata con varianza pari alla matrice dell'informazione attesa.

Risulta ora possibile dimostrare la distribuzione asintotica dello stimatore di massima verosimiglianza. Sotto le condizioni utilizzate nella dimostrazione 1.11 è




Figura 1.3: Distribuzione asintotica dello stimatore di massima verosimiglianza per una regressione binaria simulata con legame logistico. In blu l'istogramma della distribuzione empirica, in rosso la distribuzione teorica dell'equazione 1.7 ed in nero la media degli stimatori ottenuti. A corroborare l'aspetto grafico che indica chiaramente una densità normale da parte delle osservazioni empiriche, si è calcolato il test di Shapiro-Wilk che evidenzia un p-value di 0.7054. Sono stati raccolti 1000 campioni di dimensione 100 da una Bernoulli con parametri $\beta = (-1, 0.8)$.

legittimo rappresentare la *funzione di score* mediante sviluppo di Taylor con resto di Lagrange:

$$0 = U(\hat{\theta}_n) = U(\theta) - (\hat{\theta}_n - \theta)J(\theta) + \frac{1}{2}(\hat{\theta}_n - \theta)^2 \ell_{***}(\tilde{\theta}_n),$$

dove $\tilde{\theta}_n$ è un valore del parametro tale che $|\tilde{\theta}_n - \theta| < |\hat{\theta}_n - \theta|$. L'identità può essere riscritta, dividendo per l'informazione attesa e moltiplicando per $\sqrt{n}$ come,

$$\sqrt{n}(\hat{\theta}_n - \theta) \left\{ \frac{J(\theta)}{I(\theta)} - \frac{1}{2}(\hat{\theta}_n - \theta) \frac{\ell_{***}(\tilde{\theta}_n)}{I(\theta)} \right\} = \sqrt{n} \frac{U(\theta)}{I(\theta)}.$$

Date le ipotesi fatte, la convergenza in probabilità di $\hat{\theta}_n$ al vero parametro θ implica la convergenza per $\tilde{\theta}_n$, perciò vale

$$\frac{\ell_{***}(\tilde{\theta}_n)}{I(\theta)} \xrightarrow{p} \frac{E\left(\frac{\partial^2}{\partial \theta^2} U(\theta; Y_i)\right)}{I(\theta)}.$$

Si supponga inoltre che esista una funzione $M(y; \theta)$ con cui è possibile maggiorare $|\partial^3/\partial\theta^3 \log p(Y_i; \theta)|$ e che sia integrabile con integrale finito sotto p . Allora,

$$\frac{1}{n} \left| \ell_{***}(\tilde{\theta}_n) \right| = \frac{1}{n} \left| \sum_{i=1}^n \frac{\partial^3}{\partial\theta^3} \log p(Y_i; \tilde{\theta}_n) \right| < \frac{1}{n} \sum_{i=1}^n M(Y_i; \tilde{\theta}_n),$$

risulta essere una quantità $\mathcal{O}_p(1)$. Notando che, per la legge dei grandi numeri, il rapporto $J(\theta)/I(\theta) \xrightarrow{p} 1$, si può asserire grazie all'algebra degli ordini di convergenza in probabilità e al Teorema di Slutsky, che la distribuzione asintotica di $\sqrt{n}(\hat{\theta}_n - \theta)$ coincida con quella di $\sqrt{n}U(\theta)/I(\theta)$. Il che dimostra immediatamente la *distribuzione asintotica dello stimatore di massima verosimiglianza*, $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, i(\theta)^{-1})$. Come conseguenza immediata di tale approssimazione, si ottiene lo sviluppo asintotico dell'errore di stima:

$$\hat{\theta}_n - \theta = i(\theta)^{-1} \frac{U(\theta)}{n} + o_p(n^{-1/2}), \quad (1.8)$$

risulta dunque evidente come $\hat{\theta}_n - \theta$ sia di ordine $\mathcal{O}_p(n^{-1/2})$. Da questa espansione deriva anche l'espressione della *distorsione asintotica* che è definita come il valore atteso dell'errore di stima. Poiché la distorsione di ordine $\mathcal{O}_p(n^{-1/2})$ risulta *lineare* rispetto alla funzione score, il suo contributo alla distorsione è identicamente nullo. Dunque, la distorsione asintotica emerge esclusivamente dagli sviluppi di Taylor di ordine superiore al primo (i quali sono argomento del Capitolo 2).

1.12 Funzione generatrice dei momenti e dei cumulanti

Definizione 1.10 (Funzione generatrice dei Momenti). Sia Y una variabile casuale unidimensionale con probabilità $p_Y(y)$ e siano $\mu_r = E(Y^r)$, per $r = 1, 2, \dots$, i suoi momenti. Si definisce *funzione generatrice dei momenti* (f.g.m.) e si indica con la lettera $M_Y(t)$ la funzione definita dalla seguente equazione:

$$M_Y(t) = E(e^{tY}), \quad t \in \mathbb{R}.$$

Si noti che tale espressione rappresenta la *trasformata di Laplace* della funzione di probabilità p_Y rispetto alla misura dominante ν (nel nostro caso la misura di Lebesgue per il continuo o la misura di conteggio per il discreto). Si dirà che una variabile casuale *ammette funzione generatrice dei momenti* se l'integrale che la definisce converge in un intorno aperto dell'origine; vi sono pertanto diverse variabili casuali per cui tale funzione non esiste. Risulta possibile estendere la definizione




Figura 1.4: Stima della velocità di convergenza dello stimatore di massima verosimiglianza. Si noti che $\hat{\theta} - \theta = n^{(-1/2)}z_n$, dove $z_n \xrightarrow{d} \mathcal{N}(0, i(\theta)^{-1})$, e quindi $\log(|\hat{\theta} - \theta|) = \log(|z_n|) - 1/2 \log(n)$. Empiricamente si è stimato un modello lineare avente come variabile risposta il valore assoluto del logaritmo dell'errore e come esplicativa $\log(n)$, il quale ha portato alle seguenti stime: intercetta pari a 0.402 e coefficiente angolare pari a -0.508 . Simulazione da un modello binomiale con legame canonico, parametri fissati a $\beta = (-1, 0.8)$.

ad una forma più generale chiamata *funzione caratteristica*, che rappresenta la trasformata di Fourier della misura. Essa è definita come $E(e^{itY})$. Per le proprietà dei *numeri complessi* è garantita la convergenza rispetto ad ogni variabile casuale. Tale estensione non sarà approfondita in questa tesi, si rimanda a [Pace & Salvan \(1996\)](#) per una trattazione completa. La funzione generatrice dei momenti gode di diverse proprietà, alcune molto rilevanti per le analisi successive: quando è esiste, essa è in corrispondenza biunivoca con la variabile casuale che l'ha generata, pertanto contiene tutte le informazioni disponibili su di essa. Il suo nome deriva dal fatto che è possibile effettuare uno sviluppo di Taylor centrato sull'origine ottenendo la nota relazione $M_Y(t) = 1 + \mu_1 t + \mu_2 t^2/2! + \mu_3 t^3/3! + \mu_4 t^4/4! + \dots$, per cui si ha che le derivate r-esime rispetto a t della f.g.m., valutate in $t = 0$, corrispondono al momento r-esimo della distribuzione e saranno indicate con il termine $\mu_r = \partial^r / \partial t^r M_Y(t)$. Se si considera una somma $S_n = \sum Y_i$, dove le Y_i rappresentano n copie indipendenti della variabile casuale Y , la funzione generatrice dei momenti della somma risulta

essere $M_{S_n}(t) = \prod_{i=1}^n M_{Y_i}(t)$, se si ipotizza inoltre identica distribuzione la formula si semplifica ulteriormente in $M_{S_n}(t) = M_Y(t)^n$.

Definizione 1.11 (Funzione generatrice dei Cumulanti). Sia $M_Y(t)$ ben definita in un intorno di $t_0 = 0$, la *funzione generatrice dei cumulanti* (f.g.c.) di Y è:

$$K_Y(t) = \log M_Y(t).$$

Dalla definizione appena fornita è naturale pensare che la f.g.c. goda di proprietà simili a quelle enunciate per la funzione generatrice dei momenti. Vale infatti che $K_Y(t)$ determina univocamente la distribuzione di Y e possiede un'espansione in serie di potenze, $K_Y(t) = \kappa_1 t + \kappa_2 t^2/2! + \kappa_3 t^3/3! + \kappa_4 t^4/4! + \dots$; il termine κ_r è detto cumulante di ordine r della variabile casuale Y , definito come $\kappa_r = \partial^r / \partial t^r K_Y(t)$, valutato in $t = 0$. Nel caso di una somma S_n composta da n variabili aleatorie indipendenti e identicamente distribuite come Y , la funzione generatrice dei cumulanti gode della proprietà di additività, cioè $K_{S_n}(t) = nK_Y(t)$ e quindi anche $\kappa_r(S_n) = n\kappa_r(Y) = n\kappa_r$.

1.13 Introduzione alle famiglie esponenziali

Per affrontare i capitoli successivi di questo lavoro risulta essenziale sviluppare confidenza con il concetto di *famiglie esponenziali*. In particolare, è questa la classe di distribuzioni su cui sono definiti i *modelli lineari generalizzati*, che sono alla base dei Capitoli successivi di questa tesi.

1.13.1 Famiglie esponenziali e a dispersione esponenziale

Un metodo per definire una famiglia esponenziale ad un parametro consiste nel modificare una densità di riferimento $p_0(y)$ tramite una procedura nota come *exponential tilting*. Essa consiste nello spostare la massa di probabilità della distribuzione originale in funzione del parametro θ . Si consideri la funzione di *tilting* $e^{\theta y}$, allora, la densità risultante è proporzionale a:

$$p(y; \theta) \propto e^{\theta y} p_0(y),$$

con $p(y; 0) = p_0(y)$. Per garantire che tale espressione sia una funzione di densità valida, è necessario venga normalizzata. Per individuare la costante di normalizzazione

si integra la nuova densità sottoposta a *tilting* rispetto alla misura ν , ottenendo:

$$M_0(\theta) = \int_{\mathcal{Y}} e^{\theta y} p_0(y) d\nu(y) \quad \text{con } \theta \in \Theta$$

dove $\Theta = \{\theta \in \mathbb{R} : M_0(\theta) < \infty\}$ definisce lo *spazio parametrico naturale* della famiglia, ossia l'insieme dei valori θ per cui tale integrale risulta finito. Se tale insieme è diverso dal vuoto, allora $M_0(\theta)$ rappresenta la *funzione generatrice dei momenti* (1.10) della variabile casuale avente probabilità originaria $p_0(y)$.

Si può dunque affermare che per ogni $\theta \in \Theta$ la funzione:

$$p(y; \theta) = \frac{e^{\theta y} p_0(y)}{M_0(\theta)} = \exp\{\theta y - K(\theta)\} p_0(y) \quad (1.9)$$

costituisce una funzione di probabilità. Il parametro θ è chiamato *parametro naturale*, mentre $K(\theta) = \log M_0(\theta)$ è l'esatta definizione di *funzione generatrice dei cumulanti* 1.11. Si farà riferimento alla famiglia parametrica definita da queste funzioni di probabilità come $\mathcal{F}_{\text{en}}$; inoltre si utilizzerà il termine *famiglia esponenziale regolare* per riferirsi alle situazioni in cui θ è un intervallo aperto di $\mathbb{R}^p$. Per una trattazione esaustiva si veda Pace & Salvan (1996, Cap. 5.2).

Per parlare rigorosamente dei GLM (*modelli lineari generalizzati*), si rende tuttavia necessaria l'introduzione di una classe di distribuzioni più flessibile, chiamata *modelli di dispersione esponenziale* (EDF), che gestiscono separatamente media e varianza introducendo il parametro di dispersione ϕ . L'introduzione di quest'ultimo permette di trattare distribuzioni esponenziali multivariate in modo agevole senza dover fare ipotesi troppo stringenti, come ad esempio la distribuzione Gamma e anche quella Normale. Si affermerà che una variabile y_i appartiene alla famiglia di dispersione esponenziale se la sua probabilità può essere riscritta nella *forma canonica*:

$$p(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\}, \quad (1.10)$$

dove θ_i rimane il parametro naturale e $b(\theta_i)$ è chiamato *generatore di cumulanti* differenziandosi dalla funzione generatrice dei cumulanti definita in precedenza a causa del parametro ϕ attraverso la funzione $a_i(\phi) = \phi/\omega_i$, con $\omega_i > 0$ pesi noti. Tale relazione è descritta dalla seguente uguaglianza $K_{y_i}(t) = \log E\{e^{ty_i}\} = \{b(\theta_i + ta_i(\phi)) - b(\theta_i)\}/a_i(\phi)$. Infine, la funzione $c(y_i, \phi)$ è nota e dipende esclusivamente dai dati e dalla dispersione, risultando pertanto ininfluente nel processo di inferenza sul parametro θ_i . Per una trattazione completa sui modelli a dispersione esponenziale si veda Jørgensen (1997).

Esempio 1.4. Per illustrare gli elementi appena introdotti, si consideri una variabile casuale Gamma $Y_i \sim \text{Gamma}(\alpha, \beta_i)$. La sua funzione di probabilità può essere espressa come:

$$\begin{aligned} p(y_i; \alpha, \beta_i) &= \frac{\beta_i^\alpha y_i^{\alpha-1} e^{-\beta_i y_i}}{\Gamma(\alpha)} \\ &= \exp \{ \alpha \log \beta_i - \beta_i y_i + (\alpha - 1) \log y_i - \log \Gamma(\alpha) \} \\ &= \exp \left\{ \alpha \left(\log \beta_i - \frac{\beta_i}{\alpha} y_i \right) + (\alpha - 1) \log y_i - \log \Gamma(\alpha) \right\}. \end{aligned}$$

Si osservi in questo contesto che il parametro di dispersione $\phi = 1/\alpha$ ed il parametro naturale $\theta_i = -\beta_i/\alpha$. Si può dunque riscrivere l'equazione nella forma,

$$p(y_i; \theta_i, \phi) = \exp \left\{ \frac{\theta_i y_i + \log(-\theta_i)}{\phi} - \frac{1}{\phi} \log \phi + \left(\frac{1}{\phi} - 1 \right) \log y_i - \log \Gamma \left(\frac{1}{\phi} \right) \right\},$$

per $y_i > 0$. In questo caso, si identifica la funzione cumulante $b(\theta_i) = -\log(-\theta_i)$, mentre la funzione del parametro di dispersione è $a_i(\phi) = \phi$ (e i pesi sono unitari, $\omega_i = 1$). Senza l'introduzione delle EDF il parametro α andrebbe fissato, il che sarebbe un grande limite per i GLM (1.14).

1.13.2 Quantità di verosimiglianza

Dopo aver introdotto formalmente le famiglie esponenziali, si rende necessario mostrare come ottenere i momenti di tali distribuzioni. Si consideri il contributo alla log-verosimiglianza della singola osservazione:

$$\ell(\theta_i, \phi; y_i) = \log p(y_i; \theta_i, \phi) = \frac{\theta_i y_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi).$$

La funzione di score e la sua derivata (matrice *Hessiana*), nel parametro naturale θ_i , risultano:

$$\begin{aligned} \frac{\partial}{\partial \theta_i} \ell(\theta_i, \phi; y_i) &= \frac{y_i - b'(\theta_i)}{a_i(\phi)}, \\ \frac{\partial^2}{\partial \theta_i^2} \ell(\theta_i, \phi; y_i) &= -\frac{b''(\theta_i)}{a_i(\phi)}. \end{aligned}$$

Assumendo valide le *condizioni regolari di stima* (1.9), è possibile impiegare le *identità di Bartlett* (che saranno presentate nel Capitolo 2 nella Sezione 2.2), per cui il valore atteso dello score è nullo e la sua varianza coincide con l'informazione

attesa:

$$E \left(\frac{\partial}{\partial \theta_i} \ell(\theta_i, \phi; Y_i) \right) = 0,$$

$$E \left\{ \left(\frac{\partial}{\partial \theta_i} \ell(\theta_i, \phi; Y_i) \right)^2 \right\} = \text{Var} \left(\frac{\partial}{\partial \theta_i} \ell(\theta_i, \phi; Y_i) \right) = E \left(-\frac{\partial^2}{\partial \theta_i^2} \ell(\theta_i, \phi; Y_i) \right).$$

Combinando la formula delle derivate ottenute in precedenza con le equazioni appena introdotte, si può ricavare semplicemente il momento primo e secondo centrato della variabile casuale Y_i ,

$$E(Y_i) = \mu_i = b'(\theta_i),$$

$$\text{Var}(Y_i) = b''(\theta_i) a_i(\phi).$$

Si noti che la media μ_i dipende dal parametro naturale tramite la relazione $\mu_i = b'(\theta_i)$ e poiché nelle famiglie esponenziali regolari la funzione cumulante $b(\cdot)$ è strettamente convessa (la derivata seconda coincide con la varianza di una v.c.), la sua derivata prima $b'(\cdot)$ risulta essere una funzione strettamente monotona, pertanto invertibile. Questa caratteristica garantisce l'esistenza di una relazione biunivoca tra il parametro naturale θ_i e la media μ_i , specificata come $\theta_i = (b')^{-1}(\mu_i)$, che consente quindi di *riparametrizzare la famiglia esponenziale* in termini della media. Per quanto riguarda la funzione di densità binomiale ad esempio, la possibilità di trattare il parametro naturale $\theta = \text{logit}(\pi)$, che ha supporto su $\mathbb{R}$, rispetto al classico parametro π , è centrale per l'introduzione dei Modelli Lineari Generalizzati (1.14). Sfruttando questo legame invertibile, è possibile definire la *funzione di varianza* $V(\mu_i) = b''(\theta_i) = b''((b')^{-1}(\mu_i))$, che risulta essere la riparametrizzazione in media della varianza definita precedentemente. In questa forma, la varianza della v.c. è espressa come $\text{Var}(Y_i) = a_i(\phi) b''(\theta_i) = a_i(\phi) b''(\theta(\mu_i)) = a_i(\phi) V(\mu_i)$, ovvero costituita dal prodotto di una componente unicamente dipendente dalla media (caratterizzante la distribuzione) e di una dipendente dal parametro di dispersione. Alla luce di questa riparametrizzazione, è prassi indicare i modelli a dispersione esponenziale tramite la notazione compatta $Y_i \sim \text{ED}(\mu_i, a_i(\phi) V(\mu_i))$, la dimostrazione sul perché questa forma definisca in modo univoco l'intera distribuzione esponenziale non è affrontata in questa tesi. A riguardo si rimanda all'Articolo [Morris \(1982\)](#) oppure alle note pubblicate di [Rigon \(2021\)](#).

Esempio 1.5. Riprendendo l'esempio della distribuzione Gamma introdotto in precedenza, si possono applicare i risultati appena ricavati per individuare la media

e la varianza della distribuzione. Ricordando che la funzione cumulante è $b(\theta_i) = -\log(-\theta_i)$ e il parametro di dispersione è $\phi = 1/\alpha$ con funzione $a_i(\phi) = \phi$, si calcolano i momenti della variabile casuale Y_i :

$$E(Y_i) = \mu_i = b'(\theta_i) = -\frac{1}{\theta_i} = \frac{\alpha}{\beta_i},$$

$$\text{Var}(Y_i) = a_i(\phi)b''(\theta_i) = \phi \left(\frac{1}{\theta_i^2} \right) = \frac{1}{\alpha} \frac{\alpha^2}{\beta_i^2} = \frac{\alpha}{\beta_i^2}.$$

Allo stesso tempo, esplicitando la funzione inversa che lega il parametro naturale θ_i alla media μ_i , si ottiene, $\theta_i = \theta(\mu_i) = -(1/\mu_i)$. Dunque la *funzione di varianza* per la distribuzione Gamma risulta essere quadratica rispetto alla media $V(\mu_i) = b''(\theta(\mu_i)) = \mu_i^2$, pertanto, impiegando la notazione compatta di (Morris, 1982), la famiglia esponenziale gamma può essere indicata semplicemente come $Y_i \sim \text{ED}(\mu_i, \phi\mu_i^2)$.

1.14 Modelli Lineari Generalizzati

I *modelli lineari generalizzati*, a cui si farà riferimento con l'acronimo inglese GLM (*Generalized Linear Model*), rappresentano il contesto operativo sul quale applicare le tecniche di riduzione della distorsione che verranno discusse nei prossimi capitoli. L'approccio e la notazione utilizzati in questa tesi per introdurre l'argomento sono basati sui testi Agresti (2013), McCullagh & Nelder (1989), sulle note pubbliche Rigon (2025) e sull'Articolo di Kosmidis & Firth (2021a). Per specificare un GLM bisogna assumere che la variabile risposta Y_i abbia distribuzione appartenente alla famiglia di dispersione esponenziale, che il campione y abbia componenti indipendenti e che si specifichi una *funzione legame* $G^{-1}(\cdot)$, monotona e differenziabile, che metta in relazione il valore atteso di y_i con il predittore lineare mediante la seguente relazione $G^{-1}(\mu_i) = \eta_i$ (contrariamente alla convenzione per cui la funzione legame è $g(\mu_i) = \eta_i$, si sceglie questa notazione per esigenze espositive rese chiare nel Capitolo 3). Il *predittore lineare* $\eta_i = x_i^T \beta$ è una funzione lineare dei parametri β_i , per questa ragione, i GLM appartengono alla classe dei modelli *linearizzabili*; essi costituiscono una generalizzazione dei modelli lineari, in cui si rilassino le ipotesi di normalità della v.c. Y e degli errori, inoltre si rimuove l'ipotesi di omoschedasticità. Si noti che il modello lineare classico si ottiene nel caso in cui la famiglia di dispersione esponenziale sia quella *Gaussiana*, come mostrato nell'Esempio 1.6. La scelta del *legame canonico* impone che il predittore lineare η coincida con il parametro




Figura 1.5: Grafico delle probabilità stimate rispetto a quelle osservate per un problema di regressione binario, a sinistra il modello lineare generalizzato con legame cloglog, mentre a destra il modello lineare classico. Si può agevolmente notare come la regressione lineare non sia un buon modello per rappresentare il fenomeno osservato, addirittura per alcuni valori la probabilità prevista supera l'unità, in contraddizione con ogni legge probabilistica. Il dataset è Beetles, introdotto dall'Articolo [Bliss \(1935\)](#), raccoglie la dose di veleno sottoposta a diversi gruppi di coleotteri di numerosità variabile ed il numero di insetti uccisi. In totale sono presenti 481 osservazioni.)

naturale θ , da questa scelta derivano notevoli semplificazioni che saranno evidenti nel prosieguo di questa tesi. La funzione *legame canonico* è pertanto definita come

$$G^{-1}(\mu_i) = (b')^{-1}(\mu_i) = \theta(\mu_i) = \eta_i = x_i^T \beta.$$

Per una trattazione estesa di questi modelli si veda [McCullagh & Nelder \(1989\)](#).

Esempio 1.6 (Modelli lineari). Sia y un campione di osservazioni indipendenti estratte da $Y_i \sim ED(\mu_i, \sigma^2)$ (una distribuzione normale). Riscrivendo la densità gaussiana nella forma canonica della famiglia esponenziale si ha:

$$f(y_i; \mu_i, \sigma^2) = \exp \left\{ \frac{y_i \mu_i - \mu_i^2/2}{\sigma^2} - \frac{1}{2} \left[\frac{y_i^2}{\sigma^2} + \log(2\pi\sigma^2) \right] \right\},$$

da cui si identificano immediatamente il parametro naturale $\theta_i = \mu_i$, la funzione cumulante $b(\theta_i) = \theta_i^2/2$ ed il parametro di dispersione $\phi = \sigma^2$. Di conseguenza, si ha $E(Y_i) = b'(\theta_i) = \mu_i$, ciò implica che la funzione legame canonica è l'identità, ovvero la media coincide con il parametro naturale della distribuzione, e $\text{Var}(Y_i) = b''(\theta_i)\phi = \sigma^2$. Da quest'ultima formula si ottiene l'omoschedasticità delle osservazioni e degli errori per i *modelli lineari*.

Il legame canonico impone la relazione $\mu_i = x_i^T \beta$, che implica la seguente log-verosimiglianza $\ell(\beta) \propto \sum_{i=1}^n (y_i \mu_i - \mu_i^2/2)/\sigma^2$. Derivando quest'ultima rispetto al vettore dei parametri β si individua l'equazione dello *score*:

$$U(\beta) = \frac{\partial \ell(\beta)}{\partial \beta} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - x_i^T \beta).$$

Come si può notare, l'equazione di score risulta lineare in β (1.6), e può essere scritta in forma matriciale come $U(\beta) = 1/\sigma^2 X^T (y - X\beta)$. Ponendo quest'ultima formula pari a zero (σ^2 è una quantità positiva che non influenza la stima dei parametri), si giunge al sistema delle equazioni normali $X^T X \hat{\beta} = X^T y$, la cui soluzione fornisce la nota formula per lo stimatore dei minimi quadrati ordinari (OLS):

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$




Figura 1.6: Linearità, e dunque simmetria, dello score per un modello lineare. Dati penguins (libreria `palmerpenguins`), covariata lunghezza del becco (standardizzata)

1.14.1 Quantità di verosimiglianza per i GLM

Al fine di svolgere l'inferenza sui parametri di interesse β , è necessario esprimere le quantità di verosimiglianza nel contesto dei GLM evidenziando tali parametri. Sfruttando l'assunzione di indipendenza delle osservazioni $Y_i \sim \text{ED}(\mu_i, a_i(\phi)V(\mu_i))$,

la log-verosimiglianza del campione assume la forma:

$$U(\beta, \phi) = \sum_{i=1}^n \left[\frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right],$$

dove $\theta_i = \theta(\mu_i) = \theta(G(x_i^T \beta))$. Tramite l'applicazione della regola della catena per la derivazione delle funzioni composte e della funzione inversa, si ricava la derivata parziale $\partial \theta_i / \partial \beta_r = (\partial \theta_i / \partial \mu_i)(\partial \mu_i / \partial \eta_i)(\partial \eta_i / \partial \beta_r) = x_{ir} g(\eta_i) / [V(\mu_i)]$. Sostituendo tale risultato e ricordando che $a_i(\phi) = \phi / \omega_i$, è possibile derivare le componenti del vettore *score* rispetto all' r -esimo parametro β_r :

$$U(\beta)_r = \frac{\partial \ell(\beta, \phi)}{\partial \beta_r} = \sum_{i=1}^n \frac{(y_i - \mu_i) g(\eta_i)}{\text{Var}(Y_i)} x_{ir}, \quad r = 1, \dots, p. \quad (1.11)$$

In notazione matriciale, definendo $V = \text{diag}(\text{Var}(Y_1), \dots, \text{Var}(Y_n))$ la matrice di covarianza delle osservazioni e D la matrice $n \times p$ delle derivate prime di μ rispetto a β , i cui elementi sono

$$d_{ir} = \frac{\partial \mu_i}{\partial \beta_r} = \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r} = g(\eta_i) x_{ir}, \quad i = 1, \dots, n, \quad r = 1, \dots, p.$$

Alla luce di ciò, il sistema delle equazioni di score può essere espresso come

$$U(\beta) = D^T V^{-1} (y - \mu) = 0. \quad (1.12)$$

Per quanto riguarda la matrice di *informazione osservata* J , ovvero l'hessiana della log-verosimiglianza cambiata di segno, nel contesto dei GLM diventa

$$\begin{aligned} j_{rs} &= -\frac{\partial}{\partial \beta_s} \left[\frac{\partial}{\partial \beta_r} \ell(\beta, \phi) \right] \\ &= -\frac{\partial}{\partial \beta_s} \sum_{i=1}^n \frac{1}{a_i(\phi)} (y_i - \mu_i) \frac{\partial \theta_i}{\partial \beta_r} \\ &= \sum_{i=1}^n \frac{1}{a_i(\phi)} \left[\frac{\partial \mu_i}{\partial \beta_s} \frac{\partial \theta_i}{\partial \beta_r} - (y_i - \mu_i) \frac{\partial^2 \theta_i}{\partial \beta_r \partial \beta_s} \right], \quad r, s = 1, \dots, p. \end{aligned} \quad (1.13)$$

Mentre l'informazione attesa è definita, come noto, dal valore atteso della matrice Hessiana cambiata di segno $I(\beta) = E\{J(\beta)\}$, per cui risulta immediato notare che la seconda parte dell'equazione 1.13 si annulla sotto il valore atteso, semplificando l'equazione dell'informazione di Fisher. In notazione matriciale si avrà $I(\beta) = X^T W(\beta) X$, con W matrice diagonale dei pesi avente entrate $w_i =$




Figura 1.7: Non linearità della funzione di *score* per un GLM per dati binari con legame canonico. Il dataset è Beetles.

$\{1/a_i(\phi)\}\{g(\eta_i)^2/V(\mu_i)\} = \{\omega_i/\phi\}\{g(\eta_i)^2/V(\mu_i)\}$, dove si è utilizzata la relazione $a_i(\phi) = \phi/\omega_i$.

L'adozione del legame canonico introduce rilevanti semplificazioni algebriche sia per le equazioni di *score* sia per le matrici di informazione. Poiché in questo scenario $\theta_i = \eta_i = x_i^T \beta$ vale la condizione $V(\mu_i)/g(\eta_i) = 1$, che permette di ridurre le componenti del vettore punteggio a:

$$U_r(\beta) = \frac{1}{\phi} \sum_{i=1}^n \omega_i (y_i - \mu_i) x_{ir} = 0, \quad r = 1, \dots, p.$$

Per quanto riguarda le matrici di informazione, essendo θ_i lineare nei parametri, la derivata seconda $\partial^2 \theta_i / (\partial \beta_r \partial \beta_s)$ risulta identicamente nulla. Ciò comporta che la matrice di informazione osservata $J(\beta)$ non sia più stocastica (la seconda parte dell'equazione si annulla), andando a coincidere con la matrice di informazione attesa di Fisher $J(\beta) = I(\beta)$. Sotto tale ipotesi, i generici elementi si semplificano:

$$i_{rs} = j_{rs} = \frac{1}{\phi} \sum_{i=1}^n \omega_i V(\mu_i) x_{ir} x_{is}, \quad r, s = 1, \dots, p, \quad (1.14)$$

mantenendo la scrittura in forma matriciale $I = J = X^T W X$, dove i pesi della matrice diagonale assumono la forma più trattabile $w_i = V(\mu_i)/a_i(\phi)$. Inoltre, se la matrice del disegno X è a rango pieno e il modello ha l'intercetta, l'informazione

di Fisher risulta definita positiva, garantendo stretta concavità e invertibilità della funzione di log-verosimiglianza. Il che assicura in definitiva che l'eventuale soluzione delle equazioni di stima corrisponda al massimo globale della funzione. Poiché tali equazioni risultano non lineari rispetto a β anche sotto legame canonico, la determinazione di tale massimo richiede l'impiego dei metodi numerici iterativi. In ultima istanza, la risoluzione delle equazioni di verosimiglianza rispetto al vettore β è un problema ben posto in quanto il quest'ultimo risulta essere ortogonale al parametro di dispersione ϕ , come mostrato in [Pace & Salvan \(1996, Cap. 6.4.1\)](#) o in [Agresti \(2013\)](#) (ciò giustifica le affermazioni fatte su σ^2 nell'esempio 1.6).

In analogia con i modelli di regressione lineare classici, nel contesto dei GLM è possibile definire la *matrice di proiezione* o di leva (in inglese *Hat matrix*), come

$$H_W = W(\beta)^{1/2} X (X^T W(\beta) X)^{-1} X^T W(\beta)^{1/2}. \quad (1.15)$$

La matrice simmetrica appena presentata proietta le pseudo-risposte z_i nel sottospazio di $\mathbb{R}^p$ generato dai regressori, secondo la regola di massimizzazione della funzione di log-verosimiglianza individuata con l'algoritmo IRLS (1.14.3). Come per la matrice di proiezione per i modelli lineari, H_W gode della proprietà di idempotenza ($H_W^2 = H_W$), e gli elementi sulla diagonale principale h_{ii} misurano il *leverage* dell' i -esima osservazione. Infine, i valori h_{ii} sono compresi tra 0 e 1, e la loro somma è pari al numero totale dei parametri del modello (p).

Nei modelli lineari classici il leverage è definito come $h_{ii} = x_i^T (X^T X)^{-1} x_i$, e non dipende dai parametri β del modello. Nei GLM invece, gli elementi $h_{ii} = w_i(\beta) x_i^T (X^T W(\beta) X)^{-1} x_i$ dipendono dalle stime correnti dei parametri attraverso la matrice dei pesi $W(\beta)$ (che si modifica ad ogni iterazione di IRLS), pertanto forniscono una misura di “leva locale” specifica del modello stimato, piuttosto che una misura globale e indipendente dai parametri come nel caso dei modelli lineari. Un'interpretazione può essere dare osservando la formula del singolo leverage: valori vicini a zero derivano da osservazioni i cui regressori pesati $\sqrt{w_i} x_i$ risultano quasi ortogonali alle direzioni informative, valutate nella *metrica dell'informazione*. Dunque, tali osservazioni contribuiscono poco alla matrice $X^T W(\beta) X$ e sono, in definitiva, poco determinanti per la stima di β (si veda la Sezione 1.10.2 per l'interpretazione dell'informazione di Fisher). Vale naturalmente l'opposto per valori vicini a uno. Nei modelli lineari la metrica coincide con la distanza euclidea, e il leverage cresce quindi con la distanza dell'osservazione dal baricentro; i modelli per dati binari non seguono la stessa logica, poiché la distanza euclidea è controbilanciata dai pesi $W(\beta)$, che




Figura 1.8: Sensibilità delle previsioni al parametro per il modello lineare e per il modello logistico (dati simulati, modelli senza intercetta). A sinistra, l'effetto sulla retta di regressione dell'aumento di β da 1 a 2; a destra, l'effetto analogo sulla curva logistica per β da 1 a 3: nel primo caso la sensibilità cresce con l'aumentare della covariata, nel secondo si annulla agli estremi.

annullano il leverage dei punti estremi. La Figura 1.8 fornisce un'intuizione grafica di questa differenza su dati simulati.

Il grafico illustra l'ingrediente principale del leverage, ovvero la sensibilità della previsione al parametro, $\partial\mu_i/\partial\beta = G'(\eta_i)x_i$, di cui h_{ii} costituisce la forma quadratica normalizzata nella metrica dell'informazione, $h_{ii} = V(\mu_i)^{-1}(\partial\mu_i/\partial\beta)^T(X^TWX)^{-1}(\partial\mu_i/\partial\beta)$. Nel modello lineare ($G' = x_i$) la sensibilità, e con essa il leverage, cresce con la distanza del regressore dal baricentro, ovvero le previsioni ai valori estremi sono le più sensibili a variazioni di β . Nel modello logistico, invece, il fattore $G'(\eta_i) = \pi_i(1 - \pi_i)$ si annulla agli estremi e agisce annullando il leverage dove i regressori sono più estremi, rendendo le previsioni in quelle regioni poco sensibili ad una variazione di β . Si noti infine che in entrambi i pannelli le previsioni in $x = 0$ sono uguali per ogni valore di β . Ciò accade a causa dell'assenza dell'intercetta nei modelli simulati; in un modello dotato di intercetta tale punto fisso scompare e il leverage non può annullarsi, risultato che sarà ripreso nella Sezione 3.6.1.

1.14.2 Il metodo di Newton-Raphson e Fisher scoring

Il *metodo di Newton-Raphson* è un approccio iterativo standard per la massimizzazione di funzioni (approfondito nella Sezione 1.14.3), il quale si presta ad essere impiegato per la funzione di *log-verosimiglianza*, ed è basato sulla direzione indicata dalla matrice Hessiana della funzione da ottimizzare. Si considerino le stime correnti $\beta^{(t)}$ al generico passo iterativo t , effettuando uno sviluppo in serie di Taylor arrestato al secondo ordine della funzione $\ell(\beta)$ nell'intorno di $\beta^{(t)}$, si ottiene $\ell(\beta) \approx \ell(\beta^{(t)}) + (\beta - \beta^{(t)})U^{(t)} + (\beta - \beta^{(t)})^T J^{(t)}(\beta - \beta^{(t)})/2$. Derivando tale espressione rispetto a β e ponendo la derivata pari a zero per individuarne il punto estrema di interesse, si ottiene:

$$\frac{\partial \ell(\beta)}{\partial \beta} = U^{(t)} + J^{(t)}(\beta - \beta^{(t)}) = 0.$$

Isolando β nell'equazione precedente, si ottiene la regola di aggiornamento iterativo,

$$\beta^{(t+1)} = \beta^{(t)} + \left(J^{(t)}\right)^{-1} U^{(t)}. \quad (1.16)$$

Un'alternativa ampiamente utilizzata per aggirare il calcolo diretto della matrice Hessiana è il metodo del *Fisher scoring*. Tale approccio prevede la sostituzione dell'informazione osservata con quella di Fisher, l'equazione di aggiornamento diviene pertanto:

$$\beta^{(t+1)} = \beta^{(t)} + \left(I^{(t)}\right)^{-1} U^{(t)}. \quad (1.17)$$

Si osserva in conclusione che i due metodi risultano equivalenti in caso di scelta della funzione legame canonico.

1.14.3 Minimi quadrati pesati iterati (IRLS)

La massimizzazione della log-verosimiglianza tramite *Fisher scoring* può essere utile riformulata come un problema di *minimi quadrati pesati iterati* (o IRLS). Partendo dalla formula dell'aggiornamento (1.17) ed esplicitando le quantità coinvolte si ottiene:

$$\beta^{(t+1)} = \beta^{(t)} + (X^T W^{(t)} X)^{-1} X^T W^{(t)} (y - \mu^{(t)}) \frac{\partial \eta}{\partial \mu} \quad (1.18)$$

Dove si definisce la quantità $z^{(t)}$, detta *pseudo-risposta* (o risposta linearizzata), come lo sviluppo di Taylor del primo ordine della funzione legame $G^{-1}(\cdot)$ valutata

in $\mu^{(t)}$

$$z_i^{(t)} = \eta_i^{(t)} + (y_i - \mu_i^{(t)}) \frac{\partial \eta}{\partial \mu}$$

Inserendo la quantità appena introdotta nella 1.18, il passo iterativo assume la forma

$$\beta^{(t+1)} = (X^T W^{(t)} X)^{-1} X^T W^{(t)} z^{(t)}, \quad (1.19)$$

che corrisponde alla classica risoluzione dei minimi quadrati pesati [Stock & Watson \(2005\)](#), in cui però il processo viene iterato aggiornando le quantità stocastiche fino a convergenza.

Da un punto di vista computazionale, l'inversione della matrice dell'informazione $(X^T W X)$ è sconsigliata poiché può originare instabilità numeriche, specialmente per matrici mal condizionate ([Russo, 2026](#)). Una strategia più robusta consiste nel risolvere il problema avvalendosi della scomposizione QR. Definendo le trasformazioni $\tilde{X} = W^{1/2} X$ e $\tilde{z} = W^{1/2} z^{(t)}$, il sistema da risolvere a ogni passo risulta equivalente a:

$$\tilde{X}^T \tilde{X} \beta^{(t+1)} = \tilde{X}^T \tilde{z}.$$

Applicando la fattorizzazione $\tilde{X} = QR$, in cui Q è una matrice ortonormale ($Q^T Q = I$) ed R è una matrice triangolare superiore, il sistema si semplifica in

$$R \beta^{(t+1)} = Q^T \tilde{z},$$

il che corrisponde alla risoluzione di un sistema triangolare numericamente stabile e rapido da calcolare (costo computazionale nell'ordine di n^2).

Per approfondimenti sull'individuazione della scomposizione e le sue proprietà matematiche, si rimanda a [Quarteroni et al. \(2014\)](#).




Figura 1.9: Generico passo di aggiornamento dell'algoritmo dei minimi quadrati pesati iterati (IRLS). Fonte [Agresti \(2015\)](#).

Capitolo 2

Individuazione e Mitigazione della Distorsione del Primo Ordine nelle Stime di Massima Verosimiglianza

In questo capitolo si tratteranno due importanti problemi legati agli stimatori di massima verosimiglianza: la *distorsione del primo ordine* e l'*esistenza delle stime*, con un'attenzione particolare al contesto dei GLM. La prima problematica è relativa alla distorsione asintotica del primo ordine. Nel capitolo precedente 1.11 si è sviluppato l'errore di stima dello stimatore di massima verosimiglianza, limitandosi ai termini lineari rispetto allo *score*. Per la maggior parte delle applicazioni una convergenza asintotica di ordine $o(n^{-1/2})$, come quella ottenuta, è ritenuta soddisfacente; tuttavia, vi sono molteplici casi in cui la numerosità campionaria è così esigua da rendere la distorsione di ordine $\mathcal{O}_p(n^{-1})$ non ignorabile. Per questi motivi si introduce la teoria asintotica di ordine superiore al primo, che rende necessaria l'introduzione di tecniche *ad hoc*; per la trattazione si è seguita la linea presentata in Pace & Salvan (1996, Cap. 9).

Successivamente si introdurrà la questione legata all'*esistenza delle stime di massima verosimiglianza*, per cui si seguirà l'approccio presentato in Pace & Salvan (1996, Capp. 5 e 6). Tale problematica risulta centrale nel contesto della regressione binaria, che sarà approfondita nel capitolo 3 di questa tesi.

Dopo aver introdotto entrambi i problemi, si andrà ad analizzare il lavoro di Firth (1993) che propone una tecnica di correzione *preventiva* della distorsione in grado di risolvere entrambe le questioni.

2.1 La notazione indiciale

Fino a questo punto, nel presente lavoro, si è fatto riferimento alla notazione vettoriale per riferirsi a derivate e matrici. Tale convenzione funziona per operare con oggetti bidimensionali, ma fatica a descrivere situazioni in cui la dimensione del problema è superiore. Se si pensa, ad esempio, alla derivata terza della log-verosimiglianza per un vettore di parametri θ , che comparirà negli sviluppi asintotici di ordine superiore al primo, essa è un oggetto tridimensionale (per cui le operazioni di moltiplicazione risulterebbero impossibili da rappresentare con la notazione classica.) La *notazione indiciale* si sviluppa nell'ambito della geometria differenziale, e sebbene utile in molti calcoli statistici multivariati, non ha avuto un utilizzo diffuso fino agli anni ottanta del secolo scorso, con la pubblicazione del testo [McCullagh \(1987\)](#). Il paradigma di tale notazione è di rappresentare le dimensioni delle quantità coinvolte nelle operazioni tramite il numero di indici apposti ad apice e pedice, chiamati rispettivamente *controvarianti* e *covarianti*. La distinzione fra le due tipologie di indici riflette il modo in cui le quantità si trasformano al variare della parametrizzazione adottata. Sia $\theta = (\theta^1, \dots, \theta^p)$ il vettore di parametri e $\psi = \psi(\theta)$ una sua riparametrizzazione, il differenziale si trasforma secondo la regola $d\psi^a = (\partial\psi^a/\partial\theta^r) d\theta^r$: tali quantità, in cui la trasformazione agisce nello stesso verso sul differenziale, sono dette *controvarianti* e si denotano con un indice ad apice. Al contrario, il gradiente di una funzione scalare, come la derivata della log-verosimiglianza $\ell_r = \partial\ell/\partial\theta^r$, si trasforma invece secondo la regola $\partial\ell/\partial\psi^a = (\partial\ell/\partial\theta^r)(\partial\theta^r/\partial\psi^a)$, ossia con la trasformazione *inversa* rispetto al differenziale: tali quantità sono dette *covarianti* e si denotano con un indice a pedice. La contrazione di un indice controvariante con uno covariante, come nel prodotto scalare $x^r y_r$ discusso più avanti, produce una quantità invariante rispetto alla parametrizzazione adottata; [Pace & Salvan \(1996, Cap. 9, Sez. 9.5\)](#) tratta formalmente questi oggetti sotto il nome di *tensori*, che in questa tesi non saranno approfonditi.

Si supporrà per gli esempi a seguire che l'insieme di variazione degli indici sia $1, \dots, p$. Si definiscano $x = x^i$ e $y = y^j$ vettori colonna di $\mathbb{R}^p$; la matrice originata dal prodotto xy^T è $A = [a_{ij}]$, per cui, in notazione indiciale, la moltiplicazione sarà rappresentata come $a^{ij} = x^i y^j$. Per l'operazione non si è reso necessario l'utilizzo del simbolo di trasposizione, questo perché la notazione utilizzata pone l'attenzione sulla natura degli elementi che compongono una matrice generalizzata, permettendo così di operare algebricamente come se si trattasse di semplici operazioni tra scalari. Tale paradigma è descritto dalla *convenzione della somma di Einstein*, in base alla

quale se in un prodotto di matrici generalizzate compaiono gli stessi indici per due o più volte alternati in posizione di covariante e controvariante, si *sottintende* la somma rispetto ad essi. Ad esempio, il prodotto scalare tra i due vettori definiti in precedenza sarebbe $c = x^r y_r$, dove si sottintende $c = \sum_{r=1}^p x_r y_r$. Nel prosieguo di questo lavoro si ometterà l'utilizzo esplicito del simbolo di sommatoria dove valga la convenzione di Einstein. Vale la pena notare che, secondo questa convenzione, la traccia del prodotto di due matrici generiche A (controvariante) e B (covariante) si rappresenta semplicemente come $a^{ij} b_{ji}$. Gli indici che appaiono più volte nella moltiplicazione fra matrici prendono il nome di *indici muti*, mentre quelli che non si ripetono sono chiamati *indici liberi*. Se, come accadrà nelle successive analisi sulle quantità di verosimiglianza, l'insieme di variazione è il medesimo per tutti gli indici coinvolti, l'utilizzo di una lettera al posto di un'altra risulta quindi del tutto indifferente. Qualora invece gli indici abbiano campi di variazione differenti, la convenzione prevede l'utilizzo di gruppi disgiunti di lettere dell'alfabeto latino a seconda del dominio, ad esempio: $\{a, b, c, \dots\}$, $\{i, j, k, \dots\}$, $\{r, s, t, \dots\}$. Una matrice generalizzata si definisce simmetrica se risulta invariante rispetto ad una permutazione dei suoi indici, ovvero, nel caso di una matrice bidimensionale, se $a^{ij} = a^{ji}$. Risulterà spesso utile esprimere le matrici generalizzate attraverso una notazione indiciale sintetica, ovvero nella forma $[a_{R_n}]$, dove $R_n = r_1, r_2, \dots, r_n$. La successione numerica R_n è detta *multi-indice*, in virtù dell'arbitrarietà nella scelta delle lettere discussa in precedenza, è possibile definire ulteriori successioni multi-indice per adempiere al medesimo scopo; si utilizzeranno principalmente, oltre ad R_n , S_m e T_q .

2.2 Identità di Bartlett

Assumendo la validità delle condizioni regolari di stima (Sezione 1.9), che permettono lo scambio dell'operatore di derivazione sotto il simbolo di integrale, risulta possibile ricavare le relazioni che legano tra di loro i momenti della log-verosimiglianza di diverso ordine. In particolare, tali relazioni sono chiamate *identità di Bartlett* e derivano dalla seguente riscrittura del *vettore punteggio* $\partial/\partial\theta^r \ell(\theta) = p(y; \theta)^{-1} \partial p(y; \theta) / \partial\theta^r$, da cui segue l'identità:

$$\frac{\partial}{\partial\theta^r} \int_{\mathcal{Y}} p(y; \theta) dy = \int_{\mathcal{Y}} \frac{\partial}{\partial\theta^r} p(y; \theta) dy = \int_{\mathcal{Y}} \ell_r(\theta) p(y; \theta) dy = 0.$$

Le *identità di Bartlett* nascono iterando tale equazione per le derivate successive, permettendo di ottenere le ben note relazioni

$$\begin{aligned}\kappa_r &= 0, \\ \kappa_{rs} + \kappa_{r,s} &= 0, \\ \kappa_{rst} + [3]\kappa_{rs,t} + \kappa_{r,s,t} &= 0, \\ \kappa_{rstu} + [4]\kappa_{rst,u} + [3]\kappa_{rs,tu} + [6]\kappa_{rs,t,u} + \kappa_{r,s,t,u} &= 0,\end{aligned}$$

dove i valori fra parentesi quadre indicano la molteplicità algebrica di ciascun termine, ottenuti per simmetria delle quantità coinvolte e κ rappresenta ancora il cumulante.

Esempio 2.1. Sia $Y \sim N(\mu, \sigma^2)$ avente come funzione generatrice dei momenti (1.10) $M_Y(t) = \int_Y e^{tY} dP(y) = \exp\{(2\mu t + t^2\sigma^2)/2\}$, e la corrispondente *funzione generatrice dei cumulanti*, ottenuta dall'applicazione del logaritmo a quest'ultima, (1.11) $K_Y(t) = (2\mu t + t^2\sigma^2)/2$. Derivando rispetto a t e valutando in $t = 0$ si ricavano momenti e cumulanti di Y :

$$\begin{aligned}\mu_r &= M'_Y(0) = \mu, \\ \mu_{rs} &= M''_Y(0) = \mu_2 + \sigma^2, \\ \kappa_r &= K'_Y(0) = \mu, \\ \kappa_{rs} &= K''_Y(0) = \sigma^2, \\ \kappa_{R_n} &= K_Y^{(n)}(0) = 0, \quad n > 2.\end{aligned}$$

Poiché K_Y è un polinomio di grado due, tutti i cumulanti di ordine superiore al secondo si annullano: questo è il tratto caratterizzante della distribuzione Normale, e giustifica l'interpretazione dei cumulanti di ordine $n > 2$ come misure di *scostamento* da quest'ultima.

2.3 Ordini di convergenza asintotica delle quantità di verosimiglianza

Per l'analisi degli sviluppi asintotici di ordine superiore risulta utile definire in modo compatto, grazie alla *notazione indiciale*, alcune fondamentali quantità di verosimiglianza. Si indicherà con ℓ_{R_n} la generica derivata di ordine n della log-verosimiglianza $\ell(\theta)$. L'ipotesi che varrà per tutto il prosieguo del capitolo è che θ sia il vettore

p -dimensionale dei parametri. Risulta immediato osservare che, sotto condizioni di regolarità (1.9), le matrici generalizzate delle derivate parziali n -esime risultano simmetriche, e sarà pertanto possibile riferirsi a tale matrice equivalentemente come ℓ_{rst} oppure ℓ_{str} . Per indicare i *momenti* delle derivate della log-verosimiglianza ed i relativi prodotti si utilizzerà la seguente notazione:

$$\begin{aligned}\nu_{R_n} &= \nu_{R_n}(\theta) = E(\ell_{R_n}(\theta)), \\ \nu_{R_n, S_m} &= \nu_{R_n, S_m}(\theta) = E(\ell_{R_n}(\theta)\ell_{S_m}(\theta)), \\ \nu_{R_n, S_m, T_q} &= \nu_{R_n, S_m, T_q}(\theta) = E(\ell_{R_n}(\theta)\ell_{S_m}(\theta)\ell_{T_q}(\theta)),\end{aligned}$$

Si noti che il valore atteso della funzione di *score* è nullo, pertanto $\nu_{r,s,\dots}$ corrisponde al momento misto nullo; invece, ν_{R_n} , con $n > 2$, denota il valore atteso della derivata di ordine n .

Sotto l'ipotesi di campionamento casuale semplice, la funzione di probabilità congiunta del campione si fattorizza nel prodotto delle marginali. La log-verosimiglianza è dunque interpretabile come una variabile casuale somma $S_n = \sum_{i=1}^n \ell_i(\theta)$, dove $\ell_i(\theta)$ rappresenta il contributo della singola osservazione. Essendo l'operatore di derivazione lineare rispetto alla somma, anche la derivata n -esima manterrà la struttura additiva:

$$\ell_{R_n}(\theta) = \sum_{i=1}^n \ell_{i, R_n}(\theta),$$

alla luce di questa struttura si definiscono gli ordini di grandezza delle quantità notevoli. Si denota con κ_{R_n} il valore atteso (ovvero il primo cumulante scritto in notazione indiciale) del singolo contributo $\ell_{i, R_n}(\theta)$, interpretabile come il contributo apportato dalla generica variabile Y_i , e con ν_{R_n} il valore atteso della derivata della somma $\ell_{R_n}(\theta)$, da cui si ottiene la relazione notevole $\nu_{R_n} = n\kappa_{R_n}$. Si noti che da questo momento l'utilizzo del pedice o dell'apice assume due significati diversi; nel primo caso si tratta di un oggetto *covariante* (in notazione vettoriale corrisponde all'inversa del cumulante), mentre nel secondo di un oggetto *controvariante*. Poiché i cumulanti κ_{R_n} non dipendono dalla numerosità campionaria, essi risultano di ordine $\mathcal{O}(1)$; ne segue immediatamente che le quantità ν_{R_n} risultano essere di ordine $\mathcal{O}(n)$ per ogni $m \geq 2$. Infine, alla luce della nullità del valore atteso della funzione punteggio ($\nu_r = 0$) e dalle identità di Bartlett (2.2), è possibile asserire che i momenti nulli misti $\nu_{r,s}$ e $\nu_{r,s,t}$ coincidano con i rispettivi cumulanti e che quindi abbiano anch'essi ordine asintotico $\mathcal{O}(n)$.

Fra i momenti μ^{I_r} e i cumulanti κ^{I_r} della variabile casuale sussiste la *relazione* EXLOG (A.1), che esprime ciascun momento come somma sui prodotti dei cumulanti

costruiti su tutte le possibili partizioni dell'insieme di indici I_r ; la sua derivazione, tramite la formula di Faà di Bruno, è riportata in Appendice A.2.1. Si noti che $\mathcal{O}(n)$ è il termine dominante nella somma, ovvero quando l'insieme I_r viene suddiviso nel massimo numero di parti. Ne segue che il momento r -esimo della somma S_n è di ordine $\mathcal{O}(n^r)$. Per una variabile casuale somma centrata, come lo score $S_n - E(S_n)$, l'ordine asintotico si riduce a $\mathcal{O}(n^k)$ con $k = r/2$ se r è pari e $k = (r - 1)/2$ se r è dispari: il primo cumulante di una variabile centrata è infatti nullo, e nella somma sopravvivono solo i termini con partizioni in cui ciascun sottoinsieme contiene almeno due indici. Ne segue che il momento misto h -esimo $E(\ell_{r_1} \dots \ell_{r_h})$, essendo il momento h -esimo di una variabile casuale somma a media nulla, è di ordine $\mathcal{O}(n^k)$ con k definito come sopra.

Per quanto riguarda la quantità ν_{r,S_m} , ovvero il momento misto fra la derivata prima e quella m -esima, essa coincide con la covarianza, che è un cumulante, pertanto il suo ordine di convergenza asintotico sarà $\mathcal{O}(n)$. Si definisce la variabile scarto

$$H_{R_n} = \ell_{R_n} - \nu_{R_n}, \quad (\text{con } n > 1), \quad (2.1)$$

sottraendo alla derivata n -esima della log-verosimiglianza il suo valore atteso. In questo modo si elimina la componente dominante di ordine n , ottenendo una somma di variabili a media nulla. Per indipendenza ed additività, tale somma avrà varianza proporzionale a n ; pertanto, l'ordine asintotico delle differenze coincide con quello della deviazione standard $\mathcal{O}_p(n^{1/2})$.

Gli ordini asintotici delle quantità di verosimiglianza appena introdotte, insieme a quelli dei loro momenti misti, sono raccolti nella Tabella A.1 posta in Appendice A.2.2. Si riportano gli ordini più importanti: $\ell_r = \mathcal{O}_p(n^{1/2})$ per il teorema del limite centrale, $i_{rs} = \mathcal{O}(n)$ per additività dei contributi unitari, e $H_{rs} = \ell_{rs} - \nu_{rs} = \mathcal{O}_p(n^{1/2})$ come residuo centrato.

2.4 Strumenti di analisi

I risultati asintotici sviluppati nelle Sezioni successive (2.5.1) si fondano su due strumenti tecnici. Il primo è l'estensione stocastica delle espansioni di Taylor, che consente di approssimare trasformazioni non lineari di successioni convergenti in probabilità; il secondo è il metodo delle sostituzioni iterative, che permette di invertire serie asintotiche ricorsive estraendo il termine di interesse.

2.4.1 Formula di Taylor stocastica

Si consideri una successione $\{Y_n\}$ di variabili casuali d -dimensionali tale che $Y_n = c + \mathcal{O}_p(n^{-\alpha})$ con $\alpha > 0$. Si consideri una trasformazione non lineare espressa dalla funzione $f: \mathbb{R}^d \rightarrow \mathbb{R}$, se essa ammette derivate parziali continue fino all'ordine $k+1$ almeno in un intorno di c , la trasformazione della successione può essere espressa in serie di potenze come segue:

$$f(Y_n) = f(c) + \sum_{m=1}^k \frac{1}{m!} (Y_n - c)^{I_m} f_{I_m}(c) + \mathcal{O}_p(n^{-(k+1)\alpha}). \quad (2.2)$$

Si osservi come questa scrittura sia la naturale generalizzazione del noto *metodo delta*, illustrato nel seguente esempio.

Esempio 2.2 (Metodo Delta). Si supponga di conoscere la successione delle medie campionarie $\bar{x}_n$ provenienti da una $N(\mu, \sigma^2)$; è noto dal *Teorema centrale del limite* che, per n sufficientemente grande, $\bar{x}_n = \mu + \mathcal{O}_p(n^{-1/2})$. Si supponga di essere interessati alla varianza del parametro $\tau(\mu) = 1/\mu$, ottenuto tramite lo stimatore naturale $T = 1/\bar{x}_n$. Applicando la 2.2 arrestata al primo ordine si ottiene:

$$T(\bar{x}_n) = \tau(\mu) + \tau'(\mu)(\bar{x}_n - \mu) + \mathcal{O}_p(n^{-1}) = \frac{1}{\mu} - \frac{1}{\mu^2}(\bar{x}_n - \mu) + \mathcal{O}_p(n^{-1}).$$

Applicando le proprietà della varianza, si ricava $\text{Var}\{T(\mu)\} \approx \{\tau'(\mu)\}^2 \text{Var}(\bar{x}_n) = n^{-1}(\sigma^2/\mu^4)$.

2.4.2 Metodo delle sostituzioni iterative per l'inversione di Serie Asintotiche

Per ottenere l'espressione asintotica dell'errore di stima si applica il metodo delle sostituzioni iterative di potenze allo sviluppo dello score (2.3). Il metodo, dettagliato in Appendice A.2.3, consiste nel sostituire iterativamente la relazione inversa della quantità da isolare e identificare i coefficienti per ordine di convergenza. Il risultato è lo sviluppo (2.4) che segue.

2.5 Sviluppi asintotici notevoli

Le tecniche introdotte in questo capitolo, insieme alla teoria presentata nel capitolo precedente, permettono di affrontare agevolmente lo sviluppo asintotico dello *stimatore di massima verosimiglianza* di ordine superiore al primo. Per l'analisi ci si

è basati sul testo [Pace & Salvan \(1996, Cap. 9\)](#); una notazione leggermente diversa, su cui si basa l'Articolo [Firth \(1993\)](#) è presentata in [McCullagh \(1987, Cap. 7\)](#).

2.5.1 Errore di stima

Il primo sviluppo di cui occuparsi riguarda l'errore della stima di massima verosimiglianza, definito come $(\hat{\theta} - \theta)^r$, in un intorno del vero valore del parametro θ (si utilizzerà l'indice covariante coerentemente con la notazione indiciale introdotta [2.1](#)). Sotto *condizioni di regolarità* ([1.9](#)) e grazie alla nota relazione $\hat{\theta} = \theta + \mathcal{O}_p(n^{-1/2})$ ([1.8](#)) è possibile applicare la *formula di Taylor stocastica* ([2.2](#)). Si ottiene il seguente sviluppo asintotico arrestato al terzo ordine per la funzione di *score campionaria* (si è già approfondito nel capitolo precedente come la stima di massima verosimiglianza sia un raffinato metodo della analogia [1.10](#)),

$$\begin{aligned} 0 = \ell_r(\hat{\theta}) &= \ell_r + (\hat{\theta} - \theta)^s \ell_{rs} + \frac{1}{2}(\hat{\theta} - \theta)^{st} \ell_{rst} \\ &\quad + \frac{1}{6}(\hat{\theta} - \theta)^{stu} \ell_{rstu} + \mathcal{O}_p(n^{-1}). \end{aligned} \tag{2.3}$$

Nel corso del Capitolo, per porre l'attenzione sull'ordine degli sviluppi asintotici introdotti nella Sezione [2.3](#), e renderne l'interpretazione immediata, si utilizzerà la seguente simbologia: $\overset{\bullet}{+}$ per evidenziare una differenza fra il termine precedente e quello successivo di $\mathcal{O}_p(n^{-1/2})$ e $\overset{\bullet\bullet}{+}$ per una differenza di $\mathcal{O}_p(n^{-1})$.

Grazie a quanto detto nella Sezione [2.3](#) e riportato nella tabella [A.1](#), è possibile determinare gli ordini di convergenza delle quantità coinvolte nell'equazione [2.3](#): ℓ_r e $(\hat{\theta} - \theta)^s \ell_{rs}$ sono di ordine $\mathcal{O}_p(n^{1/2})$, $(\hat{\theta} - \theta)^{st} \ell_{rst}$ è di ordine $\mathcal{O}_p(1)$, $(\hat{\theta} - \theta)^{stu} \ell_{rstu}$ è di ordine $\mathcal{O}_p(n^{-1/2})$ e, in ultimo, l'ordine del resto $(\hat{\theta} - \theta)^{stuv} \ell_{rstuv}$ risulta essere $\mathcal{O}_p(n^{-1})$. Utilizzando la *variabile scarto* definita nell'equazione [2.1](#) è possibile dividere la parte stocastica da quella deterministica; si procede in questo modo ottenendo

$$\begin{aligned} 0 &= \ell_r + (\hat{\theta} - \theta)^s (-i_{rs} + H_{rs}) + \frac{1}{2}(\hat{\theta} - \theta)^{st} (\nu_{rst} + H_{rst}) \\ &\quad + \frac{1}{6}(\hat{\theta} - \theta)^{stu} (\nu_{rstu} + H_{rstu}) + \mathcal{O}_p(n^{-1}), \end{aligned}$$

si noti che le quantità stocastiche centrate, rappresentate da H , risultano di ordine asintotico inferiore rispetto ai corrispondenti valori attesi ν . Ponendo in evidenza

l'errore di stima si ottiene

$$\begin{aligned} (\hat{\theta} - \theta)^r &= \ell^r + H_s^r (\hat{\theta} - \theta)^s + \frac{1}{2} \nu_{st}^r (\hat{\theta} - \theta)^{st} + \frac{1}{2} H_{st}^r (\hat{\theta} - \theta)^{st} \\ &\quad + \frac{1}{6} \nu_{stu}^r (\hat{\theta} - \theta)^{stu} + \mathcal{O}_p(n^{-2}), \end{aligned}$$

dove si è utilizzata la seguente notazione $\ell^r = i^{rs} \ell_s$, $H_{S_m}^r = i^{rt} H_{S_m t}$ e $\nu_{S_m}^r = i^{rt} \nu_{S_m t}$. Si noti che, per costruzione, questi termini hanno ordini di convergenza asintotici rispettivamente di $\ell^r = \mathcal{O}_p(n^{-1/2})$, $H_{S_m}^r = \mathcal{O}_p(n^{-1/2})$ e $\nu_{S_m}^r = \mathcal{O}(1)$.

L'espressione a cui si è pervenuti risulta essere della forma [A.2](#); pertanto è possibile applicare il metodo delle *sostituzioni iterative* ([2.4.2](#)) considerando i termini fino all'ordine $\mathcal{O}_p(n^{-3/2})$. Per completare quanto visto nel Paragrafo sulle sostituzioni iterative, si è deciso di presentare la derivazione completa dell'inversione della serie.

Si inizi inserendo l'approssimazione del secondo ordine $(\hat{\theta} - \theta)^s = \ell^s + H_v^s \ell^v + \frac{1}{2} \nu_{vw}^s \ell^{vw} + \mathcal{O}_p(n^{-3/2})$ all'interno dei termini lineari e quadratici dell'equazione, mentre si inserisce esclusivamente il termine ℓ^s per il termine cubico (i termini si inseriscono tenendo conto della scelta nell'ordine di approssimazione),

$$\begin{aligned} (\hat{\theta} - \theta)^r &= \ell^r + H_s^r \left(\ell^s + H_v^s \ell^v + \frac{1}{2} \nu_{vw}^s \ell^{vw} \right) \\ &\quad + \frac{1}{2} \nu_{st}^r \left(\ell^s + H_v^s \ell^v + \frac{1}{2} \nu_{vw}^s \ell^{vw} \right) \left(\ell^t + H_u^t \ell^u + \frac{1}{2} \nu_{uv}^t \ell^{uv} \right) \\ &\quad + \frac{1}{2} H_{st}^r \ell^{st} + \frac{1}{6} \nu_{stu}^r \ell^{stu} + \mathcal{O}_p(n^{-2}). \end{aligned}$$

Sviluppando i prodotti all'interno delle parentesi e trascurando i termini di ordine superiore a $\mathcal{O}_p(n^{-3/2})$, l'espressione assume la forma:

$$\begin{aligned} (\hat{\theta} - \theta)^r &= \ell^r + H_s^r \ell^s + H_s^r H_v^s \ell^v + \frac{1}{2} H_s^r \nu_{vw}^s \ell^{vw} \\ &\quad + \frac{1}{2} \nu_{st}^r \left(\ell^{st} + \ell^s H_u^t \ell^u + H_v^s \ell^v \ell^t + \frac{1}{2} \ell^s \nu_{uv}^t \ell^{uv} + \frac{1}{2} \nu_{vw}^s \ell^{vw} \ell^t \right) \\ &\quad + \frac{1}{2} H_{st}^r \ell^{st} + \frac{1}{6} \nu_{stu}^r \ell^{stu} + \mathcal{O}_p(n^{-2}). \end{aligned}$$

A questo punto, per le proprietà della notazione indiciale, è possibile riordinare l'espressione raggruppando i termini per potenze di ℓ e H . Separando esplicitamente gli ordini asintotici e raccogliendo a fattore comune i termini simili, si ottiene

l'espressione finale per l'errore di stima arrestato al secondo ordine

$$\begin{aligned}
 (\hat{\theta} - \theta)^r &= \ell^r + H_s^r \ell^s + \frac{1}{2} \nu_{st}^r \ell^{st} \\
 &\quad + H_s^r H_v^s \ell^v + \frac{1}{2} (H_{st}^r + 2\nu_{sv}^r H_t^v + H_v^r \nu_{st}^v) \ell^{st} \\
 &\quad + \frac{1}{6} (\nu_{stu}^r + 3\nu_{sv}^r \nu_{tu}^v) \ell^{stu} + \mathcal{O}_p(n^{-2}).
 \end{aligned} \tag{2.4}$$

2.5.2 Distorsione dello stimatore di massima verosimiglianza

L'espansione 2.4 rende possibile ottenere lo sviluppo asintotico per la *distorsione* dello stimatore di massima verosimiglianza $\hat{\theta}$. Applicando il valore atteso ad entrambi i membri, si ottiene:

$$E\{(\hat{\theta} - \theta)^r\} = \frac{1}{2} \nu_{st}^r E(\ell^{st}) + E(H_s^r \ell^s) + \mathcal{O}(n^{-2}). \tag{2.5}$$

L'operatore valore atteso trasforma i termini stocastici di ordine $\mathcal{O}_p(n^{-3/2})$ presenti nell'equazione 1.8 in quantità deterministiche di ordine $\mathcal{O}(n^{-2})$. Infatti, le quantità $E(\ell_r \ell_t \ell_u)$, $E(\ell_s \ell_t H_{uv})$ e $E(\ell_s H_{tu} H_{vw})$, essendo momenti centrali di terzo ordine di variabili somma a media nulla, coincidono con i relativi cumulanti, dunque risultano di ordine $\mathcal{O}(n)$ (A.1). Poiché nello sviluppo dell'errore di stima (2.4) tali termini compaiono con tre indici ad apice, per la notazione utilizzata essi risultano moltiplicati per tre fattori inversi dell'informazione attesa ciascuno di ordine $\mathcal{O}(n^{-1})$, portando così l'ordine asintotico complessivo a collassare: $\mathcal{O}(n) \cdot \mathcal{O}(n^{-3}) = \mathcal{O}(n^{-2})$.

A questo punto, dalla definizione della componente stocastica H_{st} e dalle identità di Bartlett (2.2) si può riscrivere il secondo termine dell'equazione 2.5 come

$$E(H_s^r \ell^s) = i^{rt} E(H_{ts} \ell^s) = i^{rt} i^{su} E\{(\ell_{ts} - \nu_{ts}) \ell_u\} = i^{rt} i^{su} \nu_{ts,u},$$

avendo posto $\nu_{st,u} = E(\ell_{st} \ell_u)$ e $\nu_{st} = -i_{st}$ (non stocastica e quindi costante rispetto al valore atteso). Per quanto riguarda il primo termine dell'equazione 2.5, senza considerare la costante, esso può essere riscritto come $\nu_{st}^r i^{st} = i^{rs} i^{tu} \nu_{stu}$. In ultimo si noti che per le *identità di Bartlett* (2.2) vale la seguente uguaglianza: $(\nu_{stu} + 2\nu_{st,u})/2 = -(\nu_{s,t,u} + \nu_{st,u})/2$. Sostituendo le equazioni appena ricavate e tenendo in considerazione la relazione tra momenti campionari ν e quelli relativi al singolo contributo κ (2.3), si ottiene l'espressione per la distorsione asintotica del




Figura 2.1: Distorsione dello stimatore di massima verosimiglianza per un modello binomiale con legame canonico. Coefficiente angolare retta stimata tramite OLS (Minimi Quadrati Ordinari, definiti nell'Esempio 1.6) -1.171, variabile risposta valore assoluto della distorsione e covariata $\log(n)$. Dati simulati, 10000 repliche per ciascun $n \in \{10, \dots, 100\}$. La stima ML è fallita 172 volte per n pari a 10, 25 per n pari a 15, 6 per n pari a 20 e 1 per n pari a 30 a causa di separazione nei dati.

primo ordine:

$$\begin{aligned} \frac{b^r(\theta)}{n} &= E\{(\hat{\theta} - \theta)^r\} = \frac{1}{2} i^{rs} i^{tu} (\nu_{stu} + 2\nu_{st,u}) + \mathcal{O}(n^{-2}) \\ &= -\frac{1}{n} \kappa^{r,s} \kappa^{t,u} (\kappa_{s,t,u} + \kappa_{st,u})/2 + \mathcal{O}(n^{-2}). \end{aligned} \quad (2.6)$$

Si conclude mettendo in evidenza che per definizione $b^r(\theta)$ è un termine di ordine $\mathcal{O}(1)$.

2.6 Esistenza delle stime di massima verosimiglianza nelle famiglie esponenziali

Una problematica di *inferenza basata sulla massima verosimiglianza* riguarda l'esistenza delle stime. In questa Sezione si affronterà il problema in relazione alle famiglie esponenziali utilizzando la notazione vettoriale. Per introdurre il concetto si parta dall'equazione 1.9 e si consideri la sua forma rispetto ad una riduzione per sufficienza, ottenendo una densità delle osservazioni di tipo $\mathcal{F}_{en}$ con vettore dei parametri θ p -dimensionale,

$$p_s(s; \theta) = \exp\{\theta^r s - K(\theta)\} p_0(s), \quad \theta \in \tilde{\Theta}.$$

La *log-verosimiglianza*, dunque, prende la forma $\ell(\theta; s) = \theta^r s - K(\theta^r)$, a meno di costanti additive, ed il relativo vettore *score* risulta $U(\theta; s) = s - \partial K(\theta)/\partial \theta^r = s - E_\theta(S)$. L'informazione osservata è $J(\theta) = -\partial/\partial \theta^r U(\theta; s) = \partial^2 K(\theta)/\partial \theta \partial \theta^r = \text{Var}_\theta(S)$, che non dipende dai dati s , pertanto coincide con l'*informazione attesa* $I(\theta)$. Inoltre, essendo tale matrice la varianza di una variabile casuale, ipotizzata non degenerare, sarà necessariamente definita positiva, garantendo che se la stima esiste, è anche unica. Dalla definizione della funzione di *score* risulta immediato asserire che, *se esiste*, la stima di massima verosimiglianza per le famiglie esponenziali $\mathcal{F}_{\text{en}}$ è quel valore del parametro per cui il valore atteso sotto θ della v.c. coincide esattamente con la statistica sufficiente osservata s .

Definizione 2.1 (Ricoprimento convesso chiuso del supporto). Sia $\mathcal{S} \subseteq \mathbb{R}^k$ il supporto di una variabile casuale. Si definisce *ricoprimento convesso chiuso* di $\mathcal{S}$, denotato con $\mathcal{C}(\mathcal{S})$, la chiusura dell'insieme di tutte le combinazioni convesse finite dei valori che S può assumere:

$$\mathcal{C}(\mathcal{S}) = \text{cl} \left\{ s \in \mathbb{R}^k : s = \sum_{i=1}^m \alpha_i s_i, \quad \text{con} \quad \alpha_i \geq 0, \sum_{i=1}^m \alpha_i = 1, s_i \in \mathcal{S} \right\}$$

dove $m \geq 1$ è un numero intero e $\text{cl}(\cdot)$ denota la chiusura dell'insieme.

Si consideri ora l'*applicazione valore atteso* $\mu(\theta) = E_\theta(Y)$, che definisce una funzione biunivoca $\mu(\cdot)$ con dominio l'insieme dei punti interni di $\tilde{\Theta}$ e codominio $M = \mu(\text{int } \tilde{\Theta})$.

I due concetti presentati si uniscono grazie alla proprietà di convessità, nonché di linearità del valore atteso, per cui $M \subseteq \text{int } \mathcal{C}$. Inoltre, è sufficiente che $\mathcal{F}_{\text{en}}$ sia regolare, affinché valga l'uguaglianza $M = \text{int } \mathcal{C}$.

Definizione 2.2 (Famiglia esponenziale regolare). La famiglia esponenziale si dice *regolare* se lo spazio parametrico naturale $\Theta = \{\theta : K(\theta) < \infty\}$ è un aperto.

Una condizione necessaria e sufficiente affinché valga l'uguaglianza stretta $M = \text{int } \mathcal{C}$ è chiamata *ripidità*, la cui dimostrazione è riportata in [Pace & Salvan \(1996, Th. 5.1\)](#).

Definizione 2.3 (Famiglia esponenziale ripida). Una famiglia esponenziale $\mathcal{F}_{\text{en}}$ si dice *ripida* se, per ogni successione di punti $\{\theta_m\} \subset \text{int } \tilde{\Theta}$ che converge ad un punto di frontiera di $\tilde{\Theta}$, la norma del vettore delle medie diverge,

$$\lim_{m \rightarrow \infty} \|\mu(\theta_m)\| = \infty.$$

Da cui si ottiene la seguente condizione necessaria e sufficiente:

$$\mathcal{F}_{\text{en}} \text{ ripida} \iff M = \text{int } \mathcal{C} \quad (2.7)$$

Di conseguenza, qualsiasi famiglia esponenziale *regolare* è anche necessariamente *ripida*. Le definizioni date permettono di enunciare il Teorema sull'esistenza delle *stime di massima verosimiglianza*; in particolare si noti che è stata delineata una corrispondenza biunivoca fra i punti di $\text{int } \mathcal{C}$ e i valori di $\theta \in \text{int } \tilde{\Theta}$.

Teorema 2.1 (Esistenza della stima di massima verosimiglianza). *Se la famiglia esponenziale $\mathcal{F}_{\text{en}}$ è ripida e a maggior ragione se regolare, la stima di massima verosimiglianza $\hat{\theta}$ esiste ed è soluzione dell'equazione $s - E_{\theta}(S) = 0$ se e solo se $s \in \text{int } \mathcal{C}$.*

Per la dimostrazione si rimanda a [Pace & Salvan \(1996, Th. 5.8\)](#), si fornisce un esempio di questa problematica al caso Binomiale, utile ai fini del Capitolo 3.

Esempio 2.3 (Esistenza della SMV nel modello Binomiale). Si consideri una variabile casuale Binomiale $Y \sim \text{Bin}(m, \pi)$, può essere mostrato agevolmente che tale distribuzione appartenga alla famiglia esponenziale con parametro naturale $\theta = \log(\pi/(1 - \pi)) \in \mathbb{R}$ (noto come *Logit*). Lo spazio parametrico naturale, definito da tutti i valori per cui $b(\theta) = K(\theta) = m \log(1 + \exp \theta)$ è finito, coincide con l'intera retta reale $\tilde{\Theta} = \mathbb{R}$, il che definisce la regolarità (e quindi la ripidità) della famiglia. Il supporto della statistica sufficiente è l'insieme discreto $\mathcal{S} = \{0, 1, \dots, m\}$, il cui ricoprimento convesso corrisponde all'intervallo $\mathcal{C} = [0, m]$, il cui interno chiuso è $\text{int } \mathcal{C} = (0, m)$. Il Teorema sull'esistenza garantisce che la stima di massima verosimiglianza per θ (e di riflesso per π) esista finita se e solo se la statistica sufficiente (1.8) cade in $\text{int } \mathcal{C}$, ovvero, nel caso di una singola osservazione, se essa rispetta la disuguaglianza $0 < y < m$.

Si consideri ora il caso estremo in cui si osservano solo successi ($s = m$) o solo fallimenti ($s = 0$). In tali circostanze, s giace sulla frontiera di $\mathcal{C}$ e la condizione $s \in \text{int } \mathcal{C}$ non è soddisfatta. Di conseguenza, l'equazione di verosimiglianza $s - E_{\theta}(S) = 0$ non ammette alcuna soluzione reale in $\tilde{\Theta}$, e si dirà formalmente che *la stima di massima verosimiglianza non esiste*. Questa dinamica introduce il noto problema di separazione nei modelli di regressione logistica, trattati estensivamente negli articoli [Silvapulle \(1981\)](#) e [Albert & Anderson \(1984\)](#). La problematica può essere compresa con riferimento al grafico 3.1. Si noti che la funzione $G(\eta)$, la quale associa ad ogni valore del predittore lineare la media (1.14), assume un comportamento asintotico nei




Figura 2.2: Configurazione di separazione completa nel dataset iris (Fisher, 1936). A sinistra si osserva come la specie *setosa* sia perfettamente discriminata dalla lunghezza del petalo. La retta verticale rappresenta l'iperpiano di separazione descritto dal vettore γ nell'Articolo Albert & Anderson (1984). A destra si osserva la log-verosimiglianza del modello logistico associato (covariata centrata nel punto di separazione senza intercetta), che risulta continua e monotona crescente, a conferma del comportamento divergente delle stime di massima verosimiglianza (Albert & Anderson, 1984).

confronti delle rette $\pi = 0$ e $\pi = 1$, che non incontra mai. Di conseguenza, i modelli binomiali non sono in grado di associare valori che appartengono alla frontiera di $\mathcal{C}$, nemmeno se il predittore lineare diverge. Questa situazione spiega il motivo per cui in presenza di separazione si osservano stime dei parametri tendenti all'infinito in valore assoluto; in tale contesto la verosimiglianza tende al proprio estremo superiore senza mai poterlo raggiungere. La Figura 2.2 mostra tale tendenza.

2.7 Approcci alla riduzione della distorsione

Negli anni sono state sviluppate diverse tecniche per la rimozione della distorsione del primo ordine dalle stime di massima verosimiglianza. Gli approcci proposti a tal fine vengono spesso divisi in due filoni, le tecniche *correttive*, ricondotte all'Articolo Cordeiro & McCullagh (1991) e quelle *preventive* introdotte dall'Articolo Firth (1993). Vi sarebbe anche il metodo *Jackknife*, introdotto da Quenouille (1956) e formalizzato successivamente da Tukey (1958). Tale tecnica non interviene sulle equazioni di stima e nemmeno sul calcolo della distorsione in forma esplicita, bensì calcola delle *pseudo-stime* ottenute omettendo iterativamente singole osservazioni dal campione. In questa tesi tale tecnica non sarà analizzata, si rimanda al Testo Efron (1982, Cap. 2) per una trattazione completa.

2.7.1 Metodi correttivi

Nella Sezione 2.5.2 si è individuata la distorsione di ordine $\mathcal{O}(n^{-1})$ definita nell'equazione 2.6. Risulta del tutto naturale pensare di definire una stima corretta $\hat{\theta}_{BC}$ (dove BC sta per “Bias Corrected”) ottenuta rimuovendo la distorsione dalla stima di massima verosimiglianza $\hat{\theta}$,

$$\hat{\theta}_{BC}^r = \hat{\theta}^r - \frac{b^r(\theta)}{n},$$

essendo θ ignoto bisognerà sostituire $b^r(\theta)$ con $b^r(\hat{\theta})$, il cui sviluppo risulta essere $b^r(\hat{\theta}) = b^r(\theta) + b_v^r(\theta)(\hat{\theta} - \theta)^v + \mathcal{O}(n^{-1})$. Facendo gli opportuni calcoli si ottiene che $b_v^r = \mathcal{O}(1)$; considerando che l'ordine asintotico di $E(\hat{\theta} - \theta)^v$ risulta essere $\mathcal{O}(n^{-1})$, tale termine concorre a formare il resto di ordine $\mathcal{O}(n^{-2})$. Questo risultato conferma che lo stimatore corretto $\hat{\theta}_{BC}$ abbia distorsione di ordine $\mathcal{O}(n^{-2})$.

Il metodo appena esposto non è applicabile al caso in cui vi sia mancata esistenza delle stime di massima verosimiglianza, trattate nella Sezione 2.6.

2.7.2 Metodi preventivi

Come si è accennato nell'introduzione di questo Capitolo, l'Articolo a cui viene attribuita l'idea alla base dei *metodi preventivi* è Firth (1993). Prima di introdurre la procedura vera e propria proposta dall'autore, vale la pena provare a formulare l'intuizione logica sottostante il metodo.

Si parta dall'analisi della *distorsione* (2.6), ciò che si può osservare è la sua dipendenza dalla quantità $(\nu_{stu} + 2\nu_{st,u})$. Analizzando i termini che la compongono, ipotizzando θ scalare, si può notare che ν_{stu} è il valore atteso della derivata terza della log-verosimiglianza $E(\partial^3/\partial\theta^3\ell(\theta))$, ovvero la curvatura della funzione di *score*. L'altro termine $(2\nu_{st,u})$ corrisponde alla covarianza fra lo score e la sua derivata prima, la quale, nel contesto delle famiglie esponenziali con parametrizzazione naturale è nulla. Infatti, a partire dalla 1.9, si può derivare $U(\theta) = s - K'(\theta)$ e $U'(\theta) = -K''(\theta)$, ma quest'ultimo, grazie alla linearità del valore atteso, non dipendendo da s porta al seguente risultato $\nu_{st,u} = E\{U(\theta)U'(\theta)\} = -K''(\theta)E\{U(\theta)\} = 0$. Questo significa che, nel caso delle famiglie esponenziali con legame canonico la *distorsione asintotica* si riduce al solo contributo di ν_{stu} , proporzionale a $K'''(\theta)$, il quale è legato all'*asimmetria della parametrizzazione*. Tale termine si annulla unicamente quando la funzione cumulante è quadratica, condizione verificata dai modelli gaussiani (1.6).

L'origine di questa distorsione risiede dunque nella scelta di parametrizzare il modello rispetto al parametro naturale piuttosto che alla media. Nella parametrizzazione in media infatti, lo stimatore di massima verosimiglianza $\hat{\mu} = s$ è esattamente non distorto, poiché per linearità $E(\hat{\mu}) = E(s) = \mu$. Nella parametrizzazione naturale, al contrario, $\hat{\theta} = (K')^{-1}(s)$ è una trasformazione non lineare della statistica sufficiente, e tale non linearità è all'origine della distorsione. Utilizzando la *disuguaglianza di Jensen* si ottiene che $(K')^{-1}(E(s)) \neq E((K')^{-1}(s))$, ovvero $\theta \neq E(\hat{\theta})$, dove il segno della disuguaglianza dipende dalla concavità o convessità della funzione cumulante.

L'intuizione alla base dell'Articolo [Firth \(1993\)](#) è quindi di modificare opportunamente l'equazione dello *score*, così da annullare l'effetto di distorsione introdotto dalla asimmetria della funzione legame. Rimane tuttavia il problema di individuare quale sia la quantità idonea con cui *penalizzare* l'equazione di *score*. Si parta dal fatto che il valore $\hat{\theta}$ rappresenta il punto di intersezione tra la funzione $U(\theta)$ e l'asse delle ascisse; è noto dall'espansione ottenuta nel Paragrafo [2.5.2](#) che $\hat{\theta}$ ed il vero valore θ distino in media $b^r(\theta)/n$ l'un l'altro. Pertanto, la nuova curva $U^*(\theta)$ deve essere "abbassata" di una quantità tale per cui la sua intersezione con l'asse delle ascisse si trovi in corrispondenza di $\hat{\theta} - b^r(\theta)$. Per fare ciò si utilizza la geometria elementare: basterà moltiplicare la distorsione per la rispettiva variazione ottenuta sulla funzione di score, ovvero la sua derivata, ottenendo in questo modo la formula dello *score corretto* (o penalizzato) $U^*(\theta) = U(\theta) - I(\theta)b(\theta)/n$ in notazione matriciale, la cui rappresentazione grafica nel caso univariato è riportata nella Figura [2.3](#).

Dopo aver dato l'intuizione del metodo, è doveroso fornire lo sviluppo matematico rigoroso utilizzando la notazione indiciale. Si inizia fornendo la definizione della funzione di *score corretta*: $U^*(\theta) = U(\theta) + A(\theta)$, dove A è una generica quantità che può dipendere dai dati, oltre che dal parametro, tale che il suo valore atteso sia $E(A(\theta)) = -I(\theta)b(\theta)/n$. Si suppone che $U(\hat{\theta}) = 0$ e $U^*(\theta^*) = 0$, ovvero sono equazioni di stima non distorte per il parametro. Si procede quindi con uno sviluppo di Taylor dell'equazione $U^*(\theta)$ centrata in θ^* . A tal fine si utilizzerà la notazione indiciale [2.1](#), riferendosi allo score penalizzato come $\ell_r^*(\theta)$. Lo sviluppo è del tutto identico a quello utilizzato nella Sezione [2.4](#), che quindi non sarà ripetuto. Si perviene in questo modo alla formula:

$$\begin{aligned} (\theta^* - \theta)^r &= \ell^r + A^r + (H_s^r + A_s^r)(\theta^* - \theta)^s + \frac{1}{2}(\nu_{st}^r + A_{st}^r)(\theta^* - \theta)^{st} \\ &\quad + \frac{1}{2}H_{st}^r(\theta^* - \theta)^{st} + \frac{1}{6}\nu_{stu}^r(\theta^* - \theta)^{stu} + \mathcal{O}_p(n^{-2}), \end{aligned}$$




Figura 2.3: Rappresentazione dello score corretto proposto da Firth per la rimozione della distorsione del primo ordine.

in cui l'unico termine che non è ancora stato definito risulta essere $A^r = i^{rs} A_s$, che per costruzione è di ordine $\mathcal{O}(n^{-1})$, il che è coerente con l'obiettivo prefissato di eliminazione della distorsione di primo ordine.

L'espressione ottenuta risulta essere della forma [A.2](#); pertanto è possibile applicare il metodo delle *sostituzioni iterative* considerando i termini fino all'ordine $\mathcal{O}_p(n^{-3/2})$. Con i medesimi passaggi del Paragrafo [2.5.1](#) si ottiene:

$$\begin{aligned}
 (\theta^* - \theta)^r &= \ell^r + H_s^r \ell^s + \frac{1}{2} \nu_{st}^r \ell^{st} + A^r \\
 &\quad + H_s^r H_v^s \ell^v + \frac{1}{2} (H_{st}^r + 2\nu_{sv}^r H_t^v + H_u^r \nu_{st}^u) \ell^{st} + \frac{1}{6} (\nu_{stu}^r + 3\nu_{sv}^r \nu_{tu}^v) \ell^{stu} \\
 &\quad + H_s^r A^s + A_s^r \ell^s + \nu_{st}^r A^s \ell^t + \mathcal{O}_p(n^{-2}).
 \end{aligned}$$

Si applica ora il valore atteso per ottenere la distorsione dello stimatore ottenuto come soluzione all'*equazione di score modificata*. Nella seguente formula a_r indica il

valore atteso del vettore A_r

$$\begin{aligned} E\{(\theta^* - \theta)^r\} &= E(\ell^r) + E(H_s^r \ell^s) + \frac{1}{2} \nu_{st}^r E(\ell^{st}) + a^r + \mathcal{O}(n^{-2}) \\ &= \frac{1}{2} i^{rt} (-i^{su} (\nu_{t,s,u} + \nu_{t,su}) + a_t) + \mathcal{O}(n^{-2}), \end{aligned}$$

dove si sono effettuati i medesimi passaggi riportati nel Paragrafo 2.5.2. Si noti inoltre che $a^r = i^{rs} a_s$. Affinché lo stimatore risulti corretto, si impone $E\{(\theta^* - \theta)^r\} = 0$, risolvendo per a_r si ottiene

$$i^{rs} a_s = \frac{1}{2} i^{rs} i^{tu} (\nu_{tu,s} + \nu_{t,u,s}) = -\frac{b^r(\theta)}{n}.$$

La medesima espressione, espressa in termini dei cumulanti della generica osservazione y_i , assume la forma

$$\begin{aligned} a_r &= \frac{1}{2} \kappa^{s,t} (\kappa_{r,s,t} + \kappa_{st,r}) \\ &= -\kappa_{r,s} b^s(\theta) + \mathcal{O}(n^{-1/2}), \end{aligned} \tag{2.8}$$

dove si osserva che la correzione a_r è $\mathcal{O}(1)$, che, coerentemente con lo sviluppo della funzione di score che comporta la divisione per l'informazione attesa, rimuove la distorsione di ordine $\mathcal{O}(n^{-1})$. In ultimo, è importante notare come i candidati naturali del vettore A siano $A_s^{(O)} = -n^{-1} j_{rs}(\theta) b^r(\theta)$ e $A_s^{(E)} = -n^{-1} i_{rs}(\theta) b^r(\theta)$, dove $j_{rs}(\theta)$ è la matrice dell'informazione osservata. Le differenze derivanti dalla scelta di una delle due matrici di correzione sono trattate nell'Articolo [Kosmidis & Firth \(2010\)](#) ma non saranno approfondite in questa sede.

Esempio 2.4 (Distorsione per la famiglia esponenziale binomiale). Si è mostrato come la distorsione delle famiglie esponenziali con legame canonico ($\theta = \eta$) sia completamente determinata da ν_{stu} , il terzo cumulante della statistica sufficiente $K'''(\theta)$, che misura l'asimmetria della distribuzione.

Si consideri il contesto di una regressione binaria, per cui il legame canonico coincide con la funzione di ripartizione della *logistica*: $G^{-1}(\pi) = \log\{\pi/(1-\pi)\} = \eta$, la cui inversa è $G(\eta) = \exp(\eta)/\{1 + \exp(\eta)\} = \pi = K'(\theta)$. La derivata seconda e terza della funzione cumulante sono: $K''(\theta) = \pi(1-\pi)$ e $K'''(\theta) = \pi(1-\pi)(1-2\pi)$. Risulta possibile ottenere la formula della distorsione del primo ordine ([Cox & Snell, 1968](#)) per la stima di massima verosimiglianza del parametro naturale espressa in




Figura 2.4: Distorsione del primo ordine ($b(\theta)/n$), per la logistica in funzione del parametro π con $n = 20$. Si noti come per valori del parametro estremi, l'entità della distorsione è da intendersi rispetto al parametro θ , ovvero sulla scala del predittore lineare, è chiaro che agli estremi il problema sarà la variabilità delle stime più che la stima puntuale di per sé.

funzione della media π :

$$\frac{b^r(\theta)}{n} = -\frac{K'''(\theta)}{2ni(\theta)^2} = -\frac{\pi(1-\pi)(1-2\pi)}{2n[\pi(1-\pi)]^2} = -\frac{1-2\pi}{2n\pi(1-\pi)}. \quad (2.9)$$

Dalla formula appena enunciata risulta immediato notare come, in corrispondenza di $\pi = 1/2$, la distribuzione sia simmetrica ($K''' = 0$) e la stima di massima verosimiglianza risulti pertanto non distorta al primo ordine. L'intuizione sull'effetto della correzione di Firth è quella di portare le stime verso il vettore di equiprobabilità $\pi = 1/2$; tale meccanismo prende il nome di SHRINKAGE e sarà formalizzato nella Sezione 3.3.

2.8 Riduzione della distorsione nelle famiglie esponenziali con legame canonico

Nella Sezione relativa ai *modelli lineari generalizzati* (1.14.1), si è dimostrato come per la scelta del *legame canonico* le quantità $A^{(E)}$ e $A^{(O)}$ coincidono (1.14); vi sono inoltre semplificazioni importanti per quanto riguarda la stima della penalizzazione. Infatti, per le identità di Bartlett (2.2), dall'equazione 2.8 si ha che $2a_r(\theta) = 2\kappa^{r,s}b^s = \kappa^{u,v}\kappa_{r,u,v} = \kappa^{u,v}\kappa_{ruv} = \kappa^{u,v}\partial\kappa_{vu}/\partial\theta^r$, dove si è riconosciuto che $k_{s,tu} = 0$ per le famiglie esponenziali con legame canonico (2.7.2). Da cui, applicando

la *convenzione di Einstein per la somma* (2.1) è possibile riscrivere a_r in notazione matriciale come segue:

$$a(\theta) = \frac{1}{2} \text{tr} \left\{ I^{-1}(\theta) \frac{\partial I(\theta)}{\partial \theta^r} \right\}. \quad (2.10)$$

In Pace & Salvan (1996, Lemma 9.2) è mostrato come la quantità appena descritta rappresenti esattamente la derivata del logaritmo del determinante (o semplicemente *log-determinante*) della matrice dell'informazione attesa, pertanto vale che:

$$a_r = \frac{1}{2} \text{tr} \left\{ I^{-1}(\theta) \frac{\partial}{\partial \theta^r} I(\theta) \right\} = \frac{\partial}{\partial \theta^r} \left\{ \frac{1}{2} \log |I(\theta)| \right\}, \quad (2.11)$$

che rappresenta il vettore di penalizzazione dello *score*, nel contesto dei modelli lineari generalizzati (1.14.1) con legame canonico. Il termine $1/2 \log |I(\theta)|$ rappresenta il logaritmo della *distribuzione a priori di Jeffreys* (Jeffreys, 1961), che non sarà approfondita in questa tesi; come riferimento si cita il testo Robert (2001). Si ottiene in questo modo la formula della *funzione di log verosimiglianza penalizzata*

$$\ell^*(\theta) = \ell(\theta) + \frac{1}{2} \log |I(\theta)|, \quad (2.12)$$

e la funzione dello *score penalizzato*

$$U^*(\theta) = U(\theta) + A(\theta) = U(\theta) - I(\theta) b(\theta)/n, \quad (2.13)$$

dove $A(\theta)$ è il vettore avente come valore atteso $a(\theta)$, definita nell'equazione 2.11.

La distorsione può dunque essere espressa compattamente come:

$$\frac{b(\theta)}{n} = \frac{1}{2} I(\theta)^{-1} \text{tr} \left(I(\theta)^{-1} \frac{\partial I(\theta)}{\partial \theta} \right), \quad (2.14)$$

in cui si noti come, essendo $\text{tr}(I(\theta)^{-1} \partial I(\theta) / \partial \theta)$ un tensore tridimensionale di dimensione $(p \times p \times p)$, la traccia opera sulle p sottomatrici che lo compongono, facendo sì che il risultato di tale operazione sia un vettore $px1$.

Esempio 2.5 (Inferenza con Penalizzazione di Firth per la Regressione Logistica). Si ipotizzi di avere un campione casuale semplice y di numerosità n estratto da una Bernoulli, $y_i \sim \text{ED}(\pi, \pi(1 - \pi))$, con parametro naturale $\theta = \log(\pi/(1 - \pi))$. Si desidera ottenere la stima di massima verosimiglianza penalizzata per il parametro naturale. Considerando che $I(\pi) = n\pi(1 - \pi)$, l'equazione del termine di penalità di Firth diventa $A(\theta) = -I(\theta)b^r(\theta)/n = (1 - 2\pi(\theta))/2$, ricordando che la distribuzione Bernoulli appartiene alla famiglia esponenziale 1.10, l'equazione di *score* può essere




Figura 2.5: Confronto fra lo stimatore di massima verosimiglianza (ML), lo stimatore introdotto in Firth (1993) (KF) e la correzione a posteriori di Cordeiro-McCullagh (CM) per una regressione binaria con legame canonico. Il pannello di sinistra riporta la distorsione al variare della numerosità campionaria: le pendenze delle rette OLS in scala logaritmica, pari rispettivamente a -1.171 (ML), -1.636 (KF) e -2.339 (CM), evidenziando come i due metodi rimuovono empiricamente la distorsione del primo ordine. Il pannello di destra riporta il rapporto tra errori quadratici medi ($\text{MSE} = E\{(\hat{\theta}_i - \theta)^2\}$), per il quale valori maggiori di uno indicano efficienza maggiore dello stimatore di Firth. Si osserva come lo stimatore di Firth accompagna riduzione della distorsione con una riduzione dell'MSE, tanto più marcata quanto minore è la numerosità campionaria. Il guadagno di efficienza di KF rispetto a CM è particolarmente rilevante per n ridotto, mentre per n sufficientemente grande i tre metodi tendono ad equivalersi. Per $m = 1$ è stato escluso il caso $n = 25$ per la presenza di una replica con separazione le cui stime ML, dell'ordine di 10^8 , inficiavano il rapporto; per $m = 1$ e $n = 15$ la stima ML è fallita 13 volte.

scritta compattamente come: $U(\theta) = n_1 - K'(\theta) = n_1 - n \exp(\theta)/(1 + \exp(\theta))$ con $n_1 = \sum_{i=1}^n y_i$ statistica sufficiente per l'inferenza (1.8) e dove si è usata la proprietà di additività dei cumulanti, $K(\theta) = nK_i(\theta)$ (1.12). Si ottiene immediatamente, risolvendo per θ , che la stima di massima verosimiglianza classica sia $\hat{\theta} = \log(n_1/(n - n_1))$. Risulta immediato notare, come conseguenza della Sezione 2.6, che, per le note proprietà dei logaritmi, la stima non esiste se $n_1 = n$ oppure $n_1 = 0$.

La formula dello score penalizzato diventa $U^*(\theta) = U(\theta) + A(\theta) = n_1 - K'(\theta) + (1 - 2K'_i(\theta))/2 = (n_1 + 1/2) - (n + 1) \exp(\theta)/(1 + \exp(\theta))$, che coincide con lo score classico in cui si sia aggiunta una pseudo-osservazione, ripartita in mezzo successo e mezzo insuccesso. Si noti come sia stata ottenuta la nota formula del logit empirico corretto

$$\theta^* = \log \left\{ \frac{(n_1 + 1/2)}{(n - n_1 + 1/2)} \right\}.$$

Tale espressione rappresenta la correzione classica impiegata nella regressione logistica per gestire situazioni con separazione; infatti, essa garantisce l'esistenza anche

in presenza di statistiche sufficienti sul bordo del ricoprimento convesso $\mathcal{C}$. Alla luce del risultato di Firth, la formula può essere interpretata come caso particolare della penalizzazione basata sulla *distribuzione a priori di Jeffreys* in un modello binario dotato di sola intercetta.

Capitolo 3

Penalizzazione di Jeffreys nei Modelli Lineari Generalizzati per dati binari

Nel presente capitolo si intendono analizzare e formalizzare le proprietà dei Modelli Lineari Generalizzati (GLM) per risposte binarie, laddove venga utilizzata la penalizzazione basata sulla *distribuzione a priori di Jeffreys* (2.8), o sue varianti ad essa proporzionali, considerando innanzitutto l'utilizzo del legame canonico (*logit*) e successivamente la generalizzazione ad altri legami. Per fare ciò si seguirà l'approccio esposto in Kosmidis & Firth (2021a) enunciando e dimostrando i risultati presenti nell'Articolo. Infine, verrà illustrata la procedura dei Minimi Quadrati Iterativamente Riponderati declinati alla massimizzazione della verosimiglianza penalizzata (che saranno chiamati IWLS per differenziarli dagli IRLS presentati nella Sezione 1.14.3), con un approfondimento legato alla convergenza di questi metodi.

3.1 Specificazione dei GLM per risposte binarie

Poiché il presente capitolo verterà interamente sui modelli lineari generalizzati per dati binari, risulta opportuno declinare le equazioni generali ottenute nella Sezione 1.14, considerando anche legami non canonici. Si inizi specificando la formula della *funzione di verosimiglianza* per una variabile casuale Y_i distribuita come una binomiale (m_i, π_i) dove m_i è il numero di prove effettuate e y_i rappresenta il totale dei successi. La forma della *log-verosimiglianza* è data da

$$\ell(\theta; y) = \sum_{i=1}^n m_i \left\{ \frac{y_i \theta(\mu_i)}{m_i} - b(\theta(\mu_i)) \right\} + \log \binom{m_i}{y_i}, \quad (3.1)$$

con parametro naturale $\theta = \log \mu / (1 - \mu)$, che definisce la funzione di legame canonico *logit* e $b(\theta(\mu)) = -\log(1 - \mu)$. Per quanto riguarda i problemi di regressione si

è interessati alle stime del vettore dei parametri β , si noti infatti che la dipendenza rispetto a tali parametri è implicita nella scelta della funzione legame $G(\eta(\beta)) = \mu$.

Un'interessante interpretazione della funzione legame nel contesto di regressione binaria, è che la sua inversa, ovvero la funzione con dominio il predittore lineare e codominio lo spazio delle media, risulta ben definita in termini di una *funzione quantile* (ovvero l'inversa della funzione di ripartizione $F^{-1}(\cdot)$ di una generica distribuzione di probabilità). Infatti, la funzione di ripartizione è monotona crescente ed invertibile, con dominio $(0, 1)$, il quale coincide con il supporto della media μ , e codominio $\mathbb{R}$, che corrisponde a quello del predittore lineare η (la binomiale è una famiglia esponenziale regolare come mostrato nell'esempio 2.3).

La regressione logistica ha tale nome proprio perché la funzione legame coincide con la ripartizione della distribuzione logistica; ampliando questo ragionamento a funzioni di probabilità diverse, si definiscono i legami non canonici più noti: il *Probit*, il *loglog* (ed il suo complementare) ed il *Cauchit*, che derivano rispettivamente dalla funzione di ripartizione della *Normale Standard*, della *Gumbel* e della *Cauchy*. Le quantità riportate nella Tabella 3.1 si ottengono attraverso le formule specificate in 1.14.1.

Tabella 3.1: Inversa della funzione legame $G(\eta)$ e peso $\omega(\eta)$. Tabella adattata da Kosmidis & Firth (2021a), si noti che il simbolo π della Cauchit è inteso come il numero trascendente.

Funzione legame	$G(\eta)$	$\omega(\eta)$
<i>Logit</i>	$\frac{\exp(\eta)}{1 + \exp(\eta)}$	$\frac{\exp(\eta)}{\{1 + \exp(\eta)\}^2}$
<i>Probit</i>	$\Phi(\eta)$	$\frac{\{\phi(\eta)\}^2}{\Phi(\eta)\{1 - \Phi(\eta)\}}$
<i>cloglog</i>	$1 - \exp\{-\exp(\eta)\}$	$\frac{\exp(2\eta)}{\exp\{\exp(\eta)\} - 1}$
<i>loglog</i>	$\exp\{-\exp(-\eta)\}$	$\frac{\exp(-2\eta)}{\exp\{\exp(-\eta)\} - 1}$
<i>Cauchit</i>	$\frac{1}{2} + \frac{\arctan(\eta)}{\pi}$	$\frac{1}{(1 + \eta^2)^2 \left[\frac{\pi^2}{4} - \{\arctan(\eta)\}^2 \right]}$

Un risultato fondamentale per l'individuazione delle stime riguarda l'espressione della derivata della log-verosimiglianza penalizzata attraverso la *distribuzione a priori di Jeffreys*. In questo contesto risulta utile specificare l'equazione del vettore




Figura 3.1: Inverse delle funzioni legame non canoniche per la regressione binaria. Si noti come esse evidenzino caratteristiche differenti, i legami loglog e cloglog sono asimmetrici, mentre il legame cauchit ha code molto pesanti, ovvero associa probabilità “contenute” a valori estremi del predittore lineare, garantendo robustezza nei confronti dei valori anomali.

punteggio (1.11) per un GLM binario

$$U_r(\beta) = \sum_{i=1}^n \left\{ \frac{g(\eta_i)(y_i - m_i\pi_i)}{G(\eta_i)(1 - G(\eta_i))} \right\} x_{ir}, \quad r = 1, \dots, p,$$

la quale può essere riscritta utilizzando la notazione nell'Articolo Kosmidis & Firth (2021a),

$$U_r(\beta) = \sum_{i=1}^n \frac{w_i(\beta)}{d_i(\beta)} (y_i - m_i\pi_i) x_{ir}, \quad r = 1, \dots, p. \quad (3.2)$$

Nell'equazione precedente, i pesi $w_i(\beta)$ sono definiti per una generica funzione legame come $w_i(\beta) = m_i g(\eta_i)^2 / \{G(\eta_i)(1 - G(\eta_i))\}$, invece, la funzione $d_i(\beta)$ è definita come $m_i g(\eta_i)$, ovvero la derivata della media rispetto al predittore lineare η .

3.2 Esistenza delle SMV penalizzate

Si è mostrato nel Paragrafo 2.6 quali siano le cause della mancata esistenza delle stime di massima verosimiglianza. Per quanto riguarda i GLM binari, l'esistenza finita degli elementi del vettore dei parametri β è legata alla configurazione delle covariate rispetto alle risposte $(y_i, x_{1i}, \dots, x_{pi})$, con $i = (1, \dots, n)$. L'Articolo Albert & Anderson (1984) mostra come vi siano tre possibili tipi di configurazione dei dati: separazione completa, separazione quasi completa e sovrapposizione. Nel

contesto bernoulliano, si dirà di essere in presenza di separazione completa se esiste un vettore $\gamma \in \mathbb{R}^p$ tale per cui $\gamma^T X_i > 0$ per ogni i t.c. $Y_i = 1$, e $\gamma^T X_i < 0$ per ogni i t.c. $Y_i = 0$. In altre parole, la *separazione completa* si presenta qualora sia possibile definire un *iperpiano* nello spazio delle covariate, descritto da γ , in grado di discriminare senza errori i successi dagli insuccessi. Se almeno una delle due disuguaglianze fosse debole, ci si troverebbe in una situazione di *separazione quasi completa*. L'importante risultato dimostrato nell'Articolo [Albert & Anderson \(1984\)](#) è che il vettore dei parametri β può divergere all'infinito *se e soltanto se* vi sia presenza di separazione completa o quasi completa.

In questo contesto, un risultato complementare è stato enunciato nel già citato Articolo [Silvapulle \(1981\)](#), in cui viene mostrato come sia sufficiente che la funzione legame inversa $G(\eta)$ sia monotona crescente, che $-\log\{G(\eta)\}$ e $-\log\{1 - G(\eta)\}$ siano *convesse* e che vi sia *sovrapposizione* dei dati, affinché le stime di massima verosimiglianza esistano finite in un modello con intercetta. Risulta intuitivo che in presenza di parametri divergenti all'infinito le procedure numeriche classiche, come gli *IRLS* ed i test d'ipotesi, diventino instabili e dunque non affidabili.

La formula della *verosimiglianza penalizzata* (o corretta) assume la seguente forma per la regressione logistica:

$$\ell^*(\beta) = \ell(\beta) + \alpha \log |X^T W(\beta) X|,$$

dove la costante $\alpha \in (0, \infty)$ rappresenta una generalizzazione del termine di penalità basato sulla *distribuzione a priori di Jeffreys*. Si ricordi che l'effetto di riduzione della distorsione del primo ordine per il legame canonico si ottiene se e soltanto se $\alpha = 1/2$ (2.8). In questa espressione, $W(\beta)$ rappresenta la matrice diagonale dei pesi $W(\beta) = \text{diag}(w_1(\beta), \dots, w_n(\beta))$, i cui generici elementi, nel caso specifico della regressione logistica, possono essere espressi come

$$\omega_i(\eta_i) = \frac{\exp(\eta_i)}{\{1 + \exp(\eta_i)\}^2} = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)} \left(1 - \frac{\exp(\eta_i)}{1 + \exp(\eta_i)}\right) = \pi_i(1 - \pi_i),$$

senza considerare il prodotto per la numerosità m_i .

Nel contesto appena descritto, il primo teorema affrontato in questo Capitolo è relativo a come la penalizzazione basata sulla *distribuzione a priori di Jeffreys* garantisca l'esistenza delle stime di massima verosimiglianza per la regressione binaria, sotto semplici ipotesi sulla matrice del disegno X .

Teorema 3.1 (Esistenza delle SMV penalizzate). *Si definisce $W^*(r)$ il valore della matrice dei pesi quando $\beta = \beta^{(r)}$, con $r \in \mathbb{R}$ successione dei parametri tale che $\beta^{(r)} \rightarrow \beta_0$. Inoltre, β_0 è un vettore dei parametri in cui almeno una componente è infinita, ovvero diverge al crescere di r . Allora, sotto l'ipotesi che X sia a rango pieno, vale il seguente risultato asintotico*

$$\lim_{r \rightarrow \infty} |X^T W^*(r) X| = 0.$$

Dimostrazione. Dato che X è a rango pieno per ipotesi, lo è anche la forma quadratica $X^T W(\beta) X$, che risulta inoltre definita positiva per ogni $\beta \in \mathbb{R}^p$. Si assuma $R = \{1, \dots, n\}$ come l'insieme degli indici di riga della matrice del disegno, il quale sarà suddiviso in due sottoinsiemi:

- Punti in cui si verifica separazione: $R_{(1)} = \{i : |\eta_i(\beta^{(r)})| \rightarrow \infty \text{ con } r \rightarrow \infty; i \in R\}$. In questa partizione ricadono i dati il cui rispettivo predittore lineare diverge.
- Punti di frontiera: $R_{(2)} = \{i : \eta_i(\beta^{(r)}) \rightarrow c_i, |c_i| < \infty; i \in R\}$. Qui ricadono le osservazioni il cui valore del predittore si assesta asintoticamente su costanti finite; tali osservazioni sono quelle che giacciono sull'iperpiano di separazione.

Questi due sottoinsiemi formano una partizione di R , infatti, $R = R_{(1)} \cup R_{(2)}$ e $R_{(1)} \cap R_{(2)} = \emptyset$. Si procede nella dimostrazione sotto l'ipotesi che ambedue i sottoinsiemi non siano vuoti, risulta dunque legittimo partizionare a blocchi le matrici coinvolte come segue:

$$X = \begin{pmatrix} X_{(1)} \\ X_{(2)} \end{pmatrix} \quad \text{e} \quad W(\beta) = \begin{pmatrix} W_{(1)}(\beta) & 0 \\ 0 & W_{(2)}(\beta) \end{pmatrix}.$$

Dove il blocco della matrice dei pesi è composto da $W_{(l)}(\beta) = \text{diag}\{m_i \omega(\eta_i(\beta))\}$ per $i \in R_{(l)}$ e la sottomatrice $X_{(l)}$ rappresenta le sole righe legate agli indici $i \in R_{(l)}$ con $l \in \{1, 2\}$. Risulta quindi possibile riscrivere la forma quadratica dell'informazione attesa di Fisher come

$$X^T W(\beta^{(r)}) X = X_{(1)}^T W_{(1)}(\beta^{(r)}) X_{(1)} + X_{(2)}^T W_{(2)}(\beta^{(r)}) X_{(2)}.$$

In questa fase è necessario specificare il legame per analizzare il comportamento asintotico della matrice dei pesi, prendendo in considerazione quello canonico si ha che $\omega(\eta) = \exp(\eta)/(1 + \exp(\eta))^2$.

Si studia ora il comportamento asintotico per la prima parte della forma quadratica, ovvero quella contenente le osservazioni per cui il predittore lineare diverge:

$$\lim_{r \rightarrow \infty} \frac{\exp(\eta_i)}{\{1 + \exp(\eta_i)\}^2} = 0 \quad \text{per ogni } i \in R_{(1)}.$$

Pertanto, il contributo della prima partizione è asintoticamente nullo, ossia $\lim_{r \rightarrow \infty} X_{(1)}^T W_{(1)}(\beta^{(r)}) X_{(1)} = 0$.

Per quanto riguarda la seconda partizione, il predittore lineare si stabilizza, ed infatti vale che $X_{(2)}\beta^{(r)} \rightarrow c$ con $r \rightarrow \infty$. Il parametro $\beta^{(r)}$ può allora essere descritto come combinazione lineare di due termini $\beta^{(r)} = \alpha + br$, in cui b è la direzione di divergenza del parametro. Ma, per l'ipotesi di convergenza fatta sul predittore lineare relativo alle osservazioni della partizione $R_{(2)}$, la direzione b non potrà che appartenere al nucleo della matrice del disegno partizionata $X_{(2)}$, ovvero $X_{(2)}b = 0$. Essendo il nucleo della sottomatrice $X_{(2)}$ non banale, essa deve avere colonne linearmente dipendenti, e di conseguenza la matrice da essa definita non potrà che avere determinante esattamente nullo:

$$|X_{(2)}^T W_{(2)}(\beta^{(r)}) X_{(2)}| = 0 \quad \text{per ogni } r.$$

Riflettendo sulla natura delle osservazioni che appartengono a questo sottoinsieme, ovvero i punti di bordo, si sarebbe già potuto asserire che la matrice contenente tali osservazioni non potesse essere a rango pieno. Si consideri a titolo esplicativo un semplice caso univariato con intercetta, in cui si ipotizza separazione nel punto $x = 4$, la matrice disegno partizionata contenente i punti di frontiera $X_{(2)}$, sarà una collezione di colonne $(1 \ 4)^T$ ripetute tante volte quanti sono i punti di bordo, pertanto il rango di tale matrice non potrà che essere $1 < 2 = \text{rank}(X)$.

Unendo le considerazioni fatte finora, poiché $X_{(2)}^T W_{(2)}(\beta^{(r)}) X_{(2)} = 0$ per ogni r , deve valere la seguente scomposizione $X^T W(\beta^{(r)}) X = X_{(1)}^T W_{(1)}(\beta^{(r)}) X_{(1)}$. Da cui, poiché il predittore lineare relativo alla partizione $R_{(1)}$ diverge, i pesi $W_{(1)}(\beta^{(r)})$ tendono alla matrice nulla al crescere di r , e dunque $\lim_{r \rightarrow \infty} X_{(1)}^T W_{(1)}(\beta^{(r)}) X_{(1)} = 0$. Per la continuità del determinante, si conclude che

$$\lim_{r \rightarrow \infty} |X^T W(\beta^{(r)}) X| = \left| \lim_{r \rightarrow \infty} X_{(1)}^T W_{(1)}(\beta^{(r)}) X_{(1)} \right| = 0.$$

In ultimo, si noti che l'ipotesi di rango pieno della matrice disegno X esclude la possibilità che l'insieme $R_{(1)}$ sia vuoto in presenza di un elemento del vettore dei parametri divergente. L'unico altro caso da considerare è quindi quello in cui l'insie-




Figura 3.2: Log-verosimiglianza penalizzata per il modello logistico a un parametro stimato sul dataset iris, covariata lunghezza del petalo in *cm* (centrata nel punto di separazione, modello senza intercetta). Per $\alpha = 0$ (massima verosimiglianza classica) la funzione cresce sempre e la stima diverge; per $\alpha > 0$ il massimo esiste finito e si contrae verso l'origine al crescere della penalità, coerentemente ai Teoremi 3.1 e 3.2.

me $R_{(2)}$ sia vuoto. Risulta altrettanto immediato notare che la dimostrazione fatta precedentemente non è alterata; semplicemente la matrice del disegno corrisponde alla partizione $R_{(1)}$. □

Corollario 3.1 (esistenza finita delle stime). *Sotto le medesime ipotesi del teorema precedente, il vettore β^* che massimizza la funzione di verosimiglianza penalizzata $\ell^*(\beta^*)$ ha tutte le componenti finite.*

Dimostrazione. Dall'equazione 3.1 si nota che la funzione di log-verosimiglianza di una binomiale è limitata superiormente da 0. Nel teorema precedente si è dimostrato che $\ell^*(\beta^{(r)}) \rightarrow -\infty$ con $r \rightarrow \infty$, quindi, deve valere per $r \gg 0$ che qualsiasi scalare sia una scelta migliore rispetto al parametro divergente, ovvero $\ell^*(b) > \ell^*(\beta^{(r)})$, da cui è implicato che la stima di massima verosimiglianza penalizzata assuma un valore finito. □

Infine, si noti come nella dimostrazione non si è mai fatto ricorso alla costante moltiplicativa del log-determinante della matrice dell'informazione, pertanto, la proprietà di esistenza delle stime vale per ogni $\alpha > 0$.

3.3 Contrazione delle SMV penalizzate

Per contrazione (in gergo statistico SHRINKAGE), si intende il fenomeno per cui le stime dei parametri β di massima verosimiglianza penalizzata per dati binari, assumono valori più vicini allo zero rispetto a quelle basate sulla verosimiglianza classica. Espresso in termini di vettore delle probabilità previste π , la contrazione rappresenta la tendenza delle stime verso l'equiprobabilità $(1/2, \dots, 1/2)^T$ nel caso di legami simmetrici. La penalizzazione si basa sull'informazione, pertanto la contrazione è da intendersi secondo tale *metrica* e non quella della distanza euclidea (empiricamente si osserva come spesso la prima comporti anche la seconda).

In relazione a ciò, l'Articolo [Kosmidis & Firth \(2021a\)](#) fornisce un teorema che stabilisce le proprietà di SHRINKAGE nel contesto della regressione logistica.

Teorema 3.2 (Contrazione delle stime penalizzate). *Si supponga che la matrice del disegno X sia a rango pieno, e che il legame sia quello canonico in un contesto di regressione binaria, valgono allora le seguenti affermazioni:*

- i) La funzione $|X^T W(\beta) X|$ è massimizzata globalmente in $\beta = 0$.*
- ii) Definendo la matrice diagonale dei pesi in funzione delle probabilità $\bar{W}(\pi) = \text{diag}\{\pi_1(1 - \pi_1), \dots, \pi_n(1 - \pi_n)\}$, la funzione $|X^T \bar{W}(\pi) X|$ risulta log-concava.*

Dimostrazione del Teorema 3.2, Punto (i). Senza perdita di generalità, si assuma di osservare n realizzazioni binomiali con numerosità $m_i = 1$ (un problema binario può essere sempre ricondotto ad una somma di m_i v.c. bernoulliane). I pesi in questo caso si semplificano in $w_i(\beta) = \omega(\beta)$. Essendo la matrice X per ipotesi a rango pieno, è possibile effettuare la scomposizione QR per matrici rettangolari. Si indica con Q una matrice di dimensione $n \times p$ con colonne ortonormali (ovvero $Q^T Q = I_p$) e con R una matrice quadrata, di dimensione $p \times p$ invertibile e triangolare superiore ([Quarteroni et al., 2014](#), Pag. 84). Allora, il determinante dell'informazione di Fisher può essere riscritto come

$$|X^T W(\beta) X| = |Q^T W(\beta) Q| \cdot |R|^2.$$

Poiché $|R|^2 > 0$ è uno scalare indipendente da β , l'analisi dei punti stazionari di $|X^T W(\beta) X|$ è equivalente a quella di $|Q^T W(\beta) Q|$.

Si indica con $w_{(1)}(\beta) \leq \dots \leq w_{(n)}(\beta)$ la sequenza ordinata degli elementi diagonali di $W(\beta)$, dal Teorema di Separazione di Poincaré ([Magnus & Neudecker,](#)

1999, Cap. 11; Th. 10), dimostrato nell'Appendice A.1. Si mostra che, essendo $W(\beta)$ definita positiva e Q ortonormale, vale la disuguaglianza:

$$\prod_{g=1}^p w_{(g)}(\beta) \leq |Q^T W(\beta) Q| \leq \prod_{h=1}^p w_{(n-p+g)}(\beta), \quad (3.3)$$

dove si sono indicati con w_g gli autovalori ordinati dell'informazione riscalata. La relazione 3.3 vincola il determinante della matrice ad assumere un valore compreso tra il prodotto dei p autovalori minori di $W(\beta)$ ed i suoi p maggiori. Il valore massimo dei pesi, per il legame canonico, si ottiene in corrispondenza di $\eta_i = 0$ (ovvero $\beta = 0$), dove $\omega_i(0) = 1/4$. Dall'equazione 3.3 emerge come il massimo del determinante si raggiunga in corrispondenza del massimo congiunto dei singoli pesi, che si è detto essere in corrispondenza di $\beta = 0$, pertanto si ottiene:

$$\left(\frac{1}{4}\right)^p \leq |Q^T W(0) Q| \leq \left(\frac{1}{4}\right)^p.$$

Per cui si conclude che $|Q^T W(\beta) Q| \leq (1/4)^p$, dimostrando così che la massimizzazione globale avviene in $\beta = 0$. □

Ai fini di dimostrare la seconda parte del Teorema si introduce il seguente Lemma:

Lemma 3.1. *Siano A e B due matrici diagonali $n \times n$ con elementi strettamente positivi, tali che $a_{ii} \geq b_{ii}$ per ogni $i = 1, \dots, n$. Allora, per qualsiasi matrice X vale $|X^T A X| \geq |X^T B X|$.*

La dimostrazione del lemma è presentata in Appendice A.3.

Dimostrazione del Teorema 3.2, Punto (ii). Si noti in via preliminare che la funzione dei pesi per il legame canonico $\bar{w}(\pi) = \pi(1 - \pi)$ risulta strettamente concava. Di conseguenza, per ogni $\gamma \in (0, 1)$ e per ogni coppia di vettori di probabilità π e ρ , si ha componente per componente

$$\bar{w}(\gamma\pi_i + (1 - \gamma)\rho_i) \geq \gamma \bar{w}(\pi_i) + (1 - \gamma)\bar{w}(\rho_i), \quad i = 1, \dots, n. \quad (3.4)$$

Per il Lemma 3.1 si deduce allora che

$$\left|X^T \bar{W}(\gamma\pi + (1 - \gamma)\rho) X\right| \geq \left|X^T \{\gamma \bar{W}(\pi) + (1 - \gamma)\bar{W}(\rho)\} X\right|. \quad (3.5)$$

Per collegare quest'ultima disuguaglianza alla log-concavità del determinante si ricorre al risultato contenuto in Magnus & Neudecker (1999, Cap. 11, Th. 25): per

qualsiasi coppia di matrici A e B definite positive con $\gamma \in (0, 1)$, vale

$$|\gamma A + (1 - \gamma)B| \geq |A|^\gamma |B|^{(1-\gamma)}. \quad (3.6)$$

La dimostrazione della disuguaglianza è presentata in Appendice A.3.

Sostituendo $A = X^T \bar{W}(\pi)X$ e $B = X^T \bar{W}(\rho)X$ nell'equazione 3.6 alla luce anche della 3.5 (concavità), si ottiene

$$|X^T \bar{W}(\gamma\pi + (1 - \gamma)\rho)X| \geq |X^T \bar{W}(\pi)X|^\gamma |X^T \bar{W}(\rho)X|^{(1-\gamma)}.$$

Infine, applicando il logaritmo naturale a entrambi i membri si ricava la seguente disuguaglianza

$$\log |X^T \bar{W}(\gamma\pi + (1 - \gamma)\rho)X| \geq \gamma \log |X^T \bar{W}(\pi)X| + (1 - \gamma) \log |X^T \bar{W}(\rho)X|,$$

che è la definizione di concavità per la funzione $\log |X^T \bar{W}(\pi)X|$. □

Dai risultati appena mostrati è possibile valutare l'effetto di *contrazione* per diversi valori della costante di penalità α . Si considerino due costanti $\alpha_1 > \alpha_2 \geq 0$ e siano $\tilde{\beta}(\alpha_1)$ e $\tilde{\beta}(\alpha_2)$ le stime di massima verosimiglianza penalizzata; in virtù della log-concavità il vettore delle probabilità stimate $\pi(\alpha_1)$ risulterà più vicino (nella metrica dell'informazione) al vettore di equiprobabilità $(1/2, \dots, 1/2)^T$ rispetto a quanto lo sia $\pi(\alpha_2)$. Formalmente, $\pi(\alpha_1)$ è detto giacere all'interno della regione convessa delimitata dall'insieme di livello del log-determinante della matrice dell'informazione passante per $\pi(\alpha_2)$.

Considerando il caso in cui il valore α sia nullo, si ricade nella stima di massima verosimiglianza priva di correzione. Pertanto, dalle considerazioni fatte in precedenza, risulta dimostrato che la stima penalizzata sia più vicina (nel senso della metrica dell'informazione) al vettore di equiprobabilità rispetto a quella ordinaria. Infine, in statistica si definisce varianza generalizzata il determinante della matrice di covarianza. Essendo l'informazione l'inversa della matrice di covarianza asintotica del vettore dei parametri β , e siccome il determinante $|X^T W(\beta)X|$ assume valori maggiori valutato nelle stime penalizzate, le regioni di confidenza per le stime risultano ridotte rispetto a quelle ottenute tramite massima verosimiglianza.





Figura 3.3: Effetto di contrazione delle stime rispetto alla metrica basata sull'informazione. Il grafico riporta le curve di livello della funzione $\log |X^T \bar{W}(\pi) X|$, dimostrata log-concava in π (Teorema 3.2) e massimizzata in $(1/2, 1/2)$. Le frecce congiungono le stime di massima verosimiglianza a quelle penalizzate ($\alpha = 1/2$, penalità di Jeffreys che annulla la distorsione del primo ordine) per ciascuna combinazione $(y_1, y_2) \in \{0, \dots, 9\}^2$ del modello, le quali puntano tutte verso tale punto. Per la figura si sono campionati 100 dataset $x = (-1, 1)$ e $m = 9$, e vi sono quattro insiemi in cui è presente separazione ovvero $(0, 0)$ $(0, 9)$ $(9, 0)$ $(9, 9)$. Le frecce in questo caso non vanno interpretate per la loro lunghezza ma per la direzione a cui puntano e al fatto che vadano sempre in una zona a più alta informazione.

3.4 Estensione dei risultati ai legami non canonici

La condizione sufficiente affinché il risultato del primo Teorema 3.1 possa essere esteso a legami non canonici riguarda la nullità del limite dei pesi $\omega(|\eta|)$ con $\eta \rightarrow \infty$. Si rimanda all'appendice A.3.1 dove si è dimostrato come la condizione sia rispettata dai legami non canonici: loglog e complementare, Cauchit e Probit.

Per quanto riguarda l'estensione ai legami non canonici del secondo Teorema 3.2 bisogna considerare separatamente i due punti. In relazione al primo, guardando la dimostrazione (3.3) si nota come essa possa essere estesa agevolmente fintantoché la matrice dei pesi (che è diagonale anche per i legami non canonici), abbia un massimo in corrispondenza di un generico vettore $\hat{\pi} = (z_0, \dots, z_n)^T$. Risulta possibile mostrare come questo sia il caso dei legami considerati, e che inoltre tale vettore corrisponda a $(1/2, \dots, 1/2)^T$ per ogni legame eccetto il cloglog e loglog. Infatti, a causa dell'asimmetria di tali funzioni legame, il vettore di massimizzazione sarà differente. In ultimo, si noti che considerando un modello dotato di intercetta, il

valore del vettore β che individua $\hat{\pi}$ dovrà essere $(\beta_0, 0, \dots, 0)^T$, in cui $G(\beta_0) = z_0$. Basta notare che per le funzioni legame simmetriche considerate il peso è massimizzato in $z_0 = 1/2$, da cui $\beta_0 = G^{-1}(1/2) = 0$. Per i legami asimmetrici come loglog e cloglog, la massimizzazione avviene in corrispondenza di un vettore differente, pertanto il valore dell'intercetta β_0 per massimizzare i pesi non sarà nullo, e la contrazione indotta dalla penalità avverrà in corrispondenza del vettore $\hat{\pi}$ (diverso da $(1/2, \dots, 1/2)^T$).



Legame	bias _{ML}	bias _{KF}	SHRINK.
Cauchit	0.708	-0.204	0.353
cloglog	-0.013	-0.071	5.461
Logit	0.350	0.074	0.677
Probit	0.177	0.082	0.712

Figura 3.4: Distribuzione delle stime per $N = 1000$ regressioni binomiali simulate con $n = 10$ e $\beta = 0.8$ (linea nera tratteggiata). A sinistra: densità stimate per lo stimatore di massima verosimiglianza (ML) e per quello penalizzato di Kosmidis & Firth (2021a) (KF); la linea rossa indica il punto di massima informazione $\beta^* = \arg\max w(\beta)$, pari a 0 per i legami simmetrici e 0.212 per il cloglog (determinato numericamente, tenendo conto delle covariate in assenza di intercetta). A destra: distorsione dei due stimatori e fattore di SHRINKAGE, definito come $E(|\hat{\beta}_{KF} - \beta^*|)/E(|\hat{\beta}_{ML} - \beta^*|)$, per cui valori inferiori a 1 indicano contrazione verso β^* .

La Figura 3.4 mostra empiricamente i due effetti previsti dal Teorema 3.2. Le stime penalizzate risultano più concentrate attorno al vero valore del parametro e, contratte verso il punto di massima informazione β^* , come evidenziato dai fattori di SHRINKAGE. La riduzione della distorsione, benché dimostrata solo per il legame canonico, si osserva empiricamente per tutti i legami considerati, con la sola apparente eccezione del cloglog discusso in Appendice A.3.3.

3.5 Equazione dello score penalizzato

In questa Sezione si vuole mostrare come ottenere le equazioni di *score penalizzato* per un problema binario con generico legame $G(\eta)$ (3.1). In questo modo si ottiene il riferimento teorico necessario ad individuare la funzione obiettivo sulla quale applicare gli algoritmi di ottimizzazione numerica basati sul metodo di Newton-Raphson

(1.16) e sui minimi quadrati iterativamente ponderati (IRLS) (1.19). In sostanza si tratta di modificare adeguatamente le quantità coinvolte, un approccio generale è esposto in Kosmidis & Firth (2010). Per fare ciò, risulta necessario ottenere la derivata del logaritmo della distribuzione a priori di Jeffreys (2.12) generalizzata dalla costante α . Si noti che la penalizzazione rappresenta una quantità da sommare allo score classico (3.2), dunque, per la derivazione basterà derivare i due elementi e poi sommarli.

Si è mostrato nell'equazione 2.11 come la quantità a_r sommata allo score penalizzato coincide con il log-determinante della matrice dell'informazione moltiplicata per la costante $1/2$. Pertanto, ricordando che in forma matriciale l'informazione attesa per la regressione binaria è $I(\beta) = X^T W(\beta) X$, la sua derivata parziale rispetto a β_r , con $r = (1, \dots, p)$, sarà indicata come $\partial I(\beta) / \partial \beta_r = X^T W_{(r)} X$, dove $W_{(r)}$ è una matrice diagonale i cui elementi sono le derivate dei pesi $\partial w_i / \partial \beta_r$, per $i = 1, \dots, n$. Sostituendo questa quantità nell'espressione 2.10 e sfruttando la proprietà di invarianza ciclica della traccia, si ottiene

$$a_r(\beta) = \alpha \operatorname{tr} \left\{ (X^T W(\beta) X)^{-1} X^T W_{(r)} X \right\} = \alpha \operatorname{tr} \left\{ X (X^T W(\beta) X)^{-1} X^T W_{(r)} \right\}.$$

Dall'equazione si riconosce la matrice di proiezione H_w (1.15), infatti la quantità $X I(\beta)^{-1} X^T$ equivale a $H_w W(\beta)^{-1}$. Essendo H_w , W e $W_{(r)}$ matrici quadrate, di cui le ultime due diagonali, la traccia può essere riscritta come la somma del prodotto degli elementi sulla loro diagonale. Per ottenere la diagonale di $W_{(r)}$ si deve calcolare la derivata del peso w_i . In un GLM tale calcolo genera espressioni che dipendono dalla derivata seconda della funzione legame, infatti, sotto ipotesi che $m = 1$, w_i è pari a $\{g(\eta_i)\}^2 / G(\eta_i)(1 - G(\eta_i))$, dove $g(\eta_i) = \partial G(\eta_i) / \partial \eta_i$ è la derivata prima della media rispetto al predittore lineare. Applicando la regola della catena, la derivata del peso rispetto al parametro β_r risulta essere $\partial w_i / \partial \beta_r = \partial w_i / \partial \eta_i \partial \eta_i / \partial \beta_r = \partial w_i / \partial \eta_i x_{ir}$ il che porta alla seguente espressione per la derivata del logaritmo della penalità basata sulla funzione a priori di Jeffreys:

$$a_r(\beta) = \alpha \operatorname{tr} \left(H_w W(\beta)^{-1} W_{(r)} \right) = \alpha \sum_{i=1}^n \frac{w'_i(\eta)}{w_i(\eta)} h_{ii}(\eta) x_{ir}, \quad (3.7)$$

dove h_{ii} rappresenta il *leverage* della i -esima osservazione. Per esplicitare $w'_i(\eta)$ si applica la regola di derivazione del quoziente a w_i , denotando con $g'(\eta_i)$ la derivata

seconda della funzione legame $\partial^2 G(\eta_i)/\partial \eta_i^2$, essa si scrive come:

$$\frac{\partial}{\partial \eta_i} \left\{ \frac{\{g(\eta_i)\}^2}{G(\eta_i)\{1 - G(\eta_i)\}} \right\} = \frac{2g(\eta_i)g'(\eta_i)G(\eta_i)\{1 - G(\eta_i)\} - \{g(\eta_i)\}^2\{1 - 2G(\eta_i)\}g(\eta_i)}{\{G(\eta_i)\{1 - G(\eta_i)\}\}^2}.$$

Raccogliendo il termine originario w_i , l'espressione si semplifica in

$$\frac{\partial w_i}{\partial \eta_i} = w_i(\beta) \left\{ \frac{2g'(\eta_i)}{g(\eta_i)} - \frac{\{1 - 2G(\eta_i)\}g(\eta_i)}{G(\eta_i)\{1 - G(\eta_i)\}} \right\}.$$

Sostituendo questo risultato nell'equazione 3.7, si nota immediatamente che i termini $w_i(\beta)$ e $w_i^{-1}(\beta)$ si elidono in modo speculare, restituendo la forma

$$a_r(\beta) = \alpha \sum_{i=1}^n h_{ii} \left\{ \frac{2g'(\eta_i)}{g(\eta_i)} - \frac{\{1 - 2G(\eta_i)\}g(\eta_i)}{G(\eta_i)\{1 - G(\eta_i)\}} \right\} x_{ir}. \quad (3.8)$$

Si vuole ora esprimere l'equazione come si è fatto per la 3.2; si procede raccogliendo a fattor comune $w_i(\beta)/d_i(\beta)$ ed analizzando la quantità fra parentesi:

$$\frac{d_i(\beta)}{w_i(\beta)} \frac{w'_i(\beta)}{w_i(\beta)} = \frac{\pi_i(1 - \pi_i)}{g(\eta_i)} \left\{ \frac{2g'(\eta_i)}{g(\eta_i)} - \frac{g(\eta_i)(1 - 2\pi_i)}{\pi_i(1 - \pi_i)} \right\} = \frac{2\pi_i(1 - \pi_i)g'(\eta_i)}{g(\eta_i)^2} + 2\pi_i - 1.$$

Per procedere, si moltiplica e divide il primo termine dell'equazione per m_i , ricavando $2m_i g'(\eta_i)/\{m_i g(\eta_i)^2/\pi_i(1 - \pi_i)\}$. Il numeratore di questa espressione sarà chiamato $d'_i = m_i g'(\eta_i)$, mentre il denominatore rappresenta w_i ; il primo termine si riduce pertanto a $2(d'_i(\beta)/w_i(\beta))$. Sostituendo questa equivalenza e raccogliendo lo scalare si ottiene $2\{d'_i(\beta)/w_i(\beta)\} + \pi_i - 1/2$.

Si definisce ora la funzione $q_i(\beta) = \{d'_i(\beta)/w_i(\beta)\} + \pi_i$ introdotta da Kosmidis & Firth (2021a) per cui la quantità fra parentesi dell'equazione 3.8 può essere semplificata. Alla luce di ciò, la penalità indotta dalla *distribuzione a priori di Jeffreys* per dati binari può essere riscritta come

$$a_r(\beta) = \alpha \sum_{i=1}^n h_{ii} \left\{ 2 \left(q_i(\beta) - \frac{1}{2} \right) \right\} x_{ir}.$$

E in conclusione, l'equazione dello score penalizzato generale derivata rispetto all'esimo parametro, assume la forma:

$$U_r^*(\beta) = \sum_{i=1}^n \frac{w_i(\beta)}{d_i(\beta)} \left\{ y_i - m_i \pi_i + 2\alpha h_i \left(q_i(\beta) - \frac{1}{2} \right) \right\} x_{ir} = 0. \quad (3.9)$$

Risulta possibile osservare che l'espressione 3.9 coincide con l'equazione di *score* per le stime di massima verosimiglianza 3.2, in cui venga sostituita la generica variabile

risposta y_i con quella penalizzata $y_i + 2\alpha h_{ii}(q_i - 1/2)$, a cui ci riferiremo con il termine *risposta aggiustata*.

Concretamente, per individuare le stime di massima verosimiglianza penalizzata si procede iterando i seguenti due passi:

- Individuazione delle risposte aggiustate al valore attuale dei parametri;
- calcolo delle stime di massima verosimiglianza per i parametri utilizzando le *risposte aggiustate* ottenute.

Il secondo passo può essere sostituito con un'iterazione che migliori la verosimiglianza del modello anche senza massimizzarla, aprendo la strada agli algoritmi iterativi di tipo IWLS (1.14.3), discussi nella Sezione 3.6, che saranno implementati nel linguaggio di programmazione R. Il termine IWLS è utilizzato per contraddistinguere l'algoritmo iterativo usato per risolvere le equazioni di verosimiglianza penalizzata rispetto al già esaminato algoritmo IRLS.

3.5.1 Legame Canonico e Semplificazioni

Nel caso in cui si adotti il *legame canonico* (di cui si è accennato nell'esempio 2.4) la formula dello *score penalizzato* risulta ben interpretabile. Le semplificazioni originano dall'identità $\theta_i = \eta_i$, la quale impone che: la derivata prima della media rispetto al predittore lineare coincida esattamente con la funzione varianza, ossia $g(\eta_i) = \mu'_i = V(\mu_i)$ e che, derivando ulteriormente rispetto a η_i , $g'(\eta_i) = \mu''_i = V'(\mu_i)V(\mu_i)$.

Sostituendo entrambe le identità all'interno della parentesi graffa dell'equazione (3.8), si ha

$$\frac{2g'(\eta_i)}{g(\eta_i)} - \frac{\{1 - 2G(\eta_i)\}g(\eta_i)}{G(\eta_i)\{1 - G(\eta_i)\}} = \frac{2V'(\mu_i)V(\mu_i)}{V(\mu_i)} - \frac{V'(\mu_i)V(\mu_i)}{V(\mu_i)} = V'(\mu_i),$$

Sostituendo le equazioni del modello logistico, ottiene $\mu_i = \pi_i$ e $V(\pi_i) = \pi_i(1 - \pi_i)$, da cui deriva $V'(\pi_i) = 1 - 2\pi_i$, e che in definitiva la penalità assuma la forma: $a_r(\beta) = \alpha \sum_{i=1}^n 2h_{ii} (1/2 - \pi_i) x_{ir}$.

Sommando questo termine allo score ordinario del modello logistico (3.2), si ottiene l'equazione dello score penalizzato per il legame *logistico*:

$$U_r^*(\beta) = \sum_{i=1}^n \left[(y_i - m_i \pi_i) + 2\alpha h_{ii} \left(\frac{1}{2} - \pi_i \right) \right] x_{ir}. \quad (3.10)$$

In questo caso l'espressione dello score penalizzato coincide con la formula 3.2 a meno della seguente modifica ai successi y_i :

$$\tilde{y}_i = y_i + h_{ii}(1/2 - \pi_i).$$

Implicazioni sull'esistenza delle stime: è noto che il *leverage* h_{ii} è una quantità strettamente positiva sotto blande ipotesi (nella Sezione 3.6.1 si dimostrerà tale affermazione) e che somma a p , dunque, nel caso in cui si ipotizzi che tutte le osservazioni siano fallimenti ($y_i = 0$), la correzione garantisce $\tilde{y}_i > 0$, infatti π_i sarà una quantità tendente a zero, e dunque il segno della correzione sarà $h_{ii}(1/2 - \pi_i) > 0$, riportando la statistica sufficiente y_i a far parte dell'interno del *ricoprimento convesso* int $\mathcal{C}$. Ma allora, per quanto visto nel Teorema 2.1, esiste una soluzione all'equazione di verosimiglianza, e di conseguenza i parametri β ottenuti mediante stima di massima verosimiglianza penalizzata saranno finiti. Simmetricamente, nel caso opposto in cui si osservassero tutti successi ($y_i = m_i$) la penalità assumerebbe un segno negativo, in quanto π_i sarà una quantità vicina ad uno, ed anche in questo caso la statistica sufficiente tornerà a far parte di int $\mathcal{C}$ rendendo valide le considerazioni fatte per il caso precedente.

Lo score penalizzato è una combinazione di due termini: la massima verosimiglianza classica e la penalità basata sulla derivata del log-determinante della matrice dell'informazione (ovvero la sensibilità di tale grandezza al variare dei parametri β), e, pertanto, risulta in un compromesso fra i due. Si noti che l'effetto della penalità sullo score, essendo basata sul leverage (3.10), corrisponde all'allocazione di un totale di p *pseudo osservazioni* ai totali e $p/2$ successi. In quest'ottica l'Articolo [Rigon & Aliverti \(2023\)](#) fornisce la riscrittura dello score rendendo esplicito il vincolo di somma:

$$U^*(\beta) = \sum_{i=1}^n (y_i - m_i \pi_i) x_{ir} - 2\alpha p \sum_{i=1}^n \left(\frac{h_i}{p} \right) (\pi_i - 1/2) x_{ir}.$$

L'obiettivo della massimizzazione sarà dunque quello di allocare tali *pseudo dati* in modo da massimizzare la log-verosimiglianza penalizzata.

Si è data un'interpretazione del leverage nei GLM in coda alla Sezione 1.14.1. Come mostrato dall'equazione 1.15, il leverage di un'osservazione è tanto maggiore quanto l'informazione ad essa associata è grande. Per i legami simmetrici i pesi sono massimizzati in corrispondenza di $\pi = 1/2$, anche se il valore sul leverage è mediato anche dall'impatto delle covariate, quindi non sempre i due massimi coincidono. Allo stesso tempo però, le osservazioni aventi probabilità associata pari




Figura 3.5: Effetto di contrazione delle probabilità stimate per una regressione binaria con legame logistico. Il dataset considerato è mtcars, presente nell’ambiente R, la variabile risposta è il tipo di cambio mentre la covariata è il peso dell’autovettura, in totale sono 32 auto. Le probabilità che subiscono il maggiore scostamento sono quelle comprese fra gli estremi e il centro, dove il potenziale di miglioramento dell’informazione è maggiore.

ad $1/2$, rappresentano punti in cui la penalità è minima, e quindi la derivata della funzione di varianza $(1 - 2\pi)$ risulta nulla. In sostanza, questi punti non sono in grado di migliorare il log-determinante della matrice dell’informazione, o meglio, lo peggiorerebbero se venissero spostati in qualsiasi direzione. Per quanto riguarda le osservazioni con una probabilità associata molto grande, oppure piccola, esse sono poco influenti rispetto all’informazione attesa del modello (Figura 1.8), e quindi il loro leverage sarà asintoticamente nullo. Tale caratteristica è però compensata dalla derivata della varianza del modello, $1/2 - \pi_i$, che si massimizza invece nei punti estremi, tale compromesso è visibile tramite la Figura 3.5.

L’apparente smorzamento dell’effetto sulle code non è in contraddizione con la log-concavità della penalità: a causa della non linearità della funzione logistica, variazioni marginali di π_i in prossimità degli estremi (0 o 1) richiedono un aggiustamento del vettore dei parametri molto più severo rispetto alla zona centrale.

3.6 Algoritmi numerici per la massima verosimiglianza penalizzata

Si desidera, in ultima istanza, ampliare i metodi numerici introdotti nel Paragrafo 1.14.2 alla massimizzazione della verosimiglianza penalizzata mediante *distribuzione a priori di Jeffreys*. Come anticipato, tale penalità annulla la distorsione del primo ordine nei modelli lineari generalizzati con legame canonico, mentre garantisce l'esistenza e la finitezza delle stime per qualsiasi legame che rispetti le condizioni 3.1. L'algoritmo numerico proposto, chiamato di *quasi Newton-Raphson* o *quasi-Newtoniano*, assume tale aggettivo poiché approssima la derivata seconda della log-verosimiglianza penalizzata con l'informazione attesa di Fisher (che coincide con la derivata seconda dello score classico 1.17). Infine, si osserva che il problema di massimizzazione può essere interpretato come un'estensione dell'algoritmo IRLS (1.14.3) in cui vengano utilizzati i *dati modificati* (a cui ci si riferirà con il termine IWLS), la cui intuizione risale all'Articolo Firth (1993), e che è stata poi formalizzata negli Articoli: Kosmidis (2009), Kosmidis & Firth (2009), Kosmidis & Firth (2010) e Kosmidis et al. (2020) e nel materiale supplementare Kosmidis & Firth (2021b), in cui viene dato lo pseudo codice per l'implementazione del metodo. Per quanto riguarda le fondamenta teoriche dei metodi di ottimizzazione di tipo *quasi-Newtoniano*, si è seguita la linea proposta nel testo Dennis & Schnabel (1996).

Per le stime di massima verosimiglianza penalizzata si parta osservando che, nell'assetto appena descritto sotto il legame canonico, le equazioni 1.17 e 1.16 coincidono grazie all'identità 1.14; in generale verrà utilizzata l'informazione attesa per tutti i legami accontentandosi di un'approssimazione asintotica. Pertanto si va ora a definire la formula iterativa dell'algoritmo *quasi Fisher Scoring*:

$$\beta^{*(t+1)} = \beta^{(t)} + \{I(\beta^{(t)})\}^{-1} U^*(\beta^{(t)}). \quad (3.11)$$

L'approssimazione della matrice Hessiana del modello penalizzato con l'informazione attesa dello score classico avviene a causa delle difficoltà computazionali e algebriche nell'individuare tale quantità. Questa semplificazione comporta una velocità di convergenza teorica minore rispetto a quella quadratica dell'algoritmo di Newton-Raphson, di tipo lineare. Tale caratteristica è stata stimata tramite l'esperimento numerico mostrato nella figura 3.6.

La formula 3.11 può essere riformulata osservando che lo score penalizzato si può riscrivere come $U^*(\beta) = U(\beta) + \alpha \partial / \partial \beta \log |X^T W(\beta) X|$ e di conseguenza l'equazione




Figura 3.6: Distribuzione dell'ordine di convergenza empirico per i diversi legami, stimato tramite regressione lineare di $\log(e_{t+1})$ su $\log(e_t)$ (con $e = \|\beta^{(t)} - \hat{\beta}\|$ errore alla t -esima iterazione) su 300 dataset simulati ognuno con 50 osservazioni. La linea è tratteggiata in corrispondenza di 1, ovvero individua la convergenza lineare teorica. La mediana dell'ordine di convergenza per i diversi legami ottenuti è pari a: 0.974 (cauchit), 1.004 (probit), 1.021 (cloglog) e 1.022 (logit), evidenziando convergenza lineare. La corrispondente costante di riduzione C (sempre stimata tramite OLS) assume mediana pari a 0.171, 0.061, 0.151 e 0.068, questi valori vanno letti come $(e_{t+1}) = C(e_t)$, ovvero il coefficiente di dimezzamento dell'errore ad ogni iterazione.

di aggiornamento diventa

$$\beta^{*(t+1)} = \hat{\beta}^{(t+1)} + \{I(\beta^{(t)})\}^{-1} \alpha \frac{\partial}{\partial \beta} \log |X^T W(\beta^{(t)}) X|,$$

dove il termine $\hat{\beta}^{(t+1)}$ rappresenta lo stimatore ottenuto con un passo di IRLS standard (1.14.3). Per $\alpha = 1/2$, con la scelta del legame canonico il termine di destra coincide con la formula della distorsione del primo ordine (2.14):

$$b(\beta)/n = -\frac{1}{2} \{I(\beta)\}^{-1} \frac{\partial}{\partial \beta} \log |X^T W(\beta) X| = \frac{1}{2} I(\theta)^{-1} \text{tr} \left(I(\theta)^{-1} \frac{\partial I(\theta)}{\partial \theta} \right),$$

così che la formula di aggiornamento possa essere riscritta equivalentemente come

$$\beta^{*(t+1)} = \hat{\beta}^{(t+1)} - b(\beta^{(t)})/n. \quad (3.12)$$

La funzione $b(\cdot)$ segue dall'equazione 2.6, dove si è ommesso l'apice r in quanto si sta utilizzando la notazione matriciale. Come conseguenza, la stima del vettore dei

parametri ottenuta è tale per cui lo *score penalizzato* si annulli e allo stesso tempo, per il legame canonico, che non contenga la distorsione del primo ordine (3.12).

Il passo iterativo (3.11) può essere ricondotto ad un problema di minimi quadrati ponderati. Moltiplicando entrambi i membri per $I(\beta^{(t)}) = X^T W^{(t)} X$ (che è non singolare sotto le condizioni della Sottosezione 3.6.1), si ottiene

$$X^T W^{(t)} X \beta^{(t+1)} = X^T W^{(t)} X \beta^{(t)} + U^*(\beta^{(t)}).$$

Sostituendo la forma esplicita dello score penalizzato (3.9), il termine destro diventa

$$X^T W^{(t)} X \beta^{(t)} + X^T W^{(t)} (\tilde{z}^{(t)} - X \beta^{(t)}) = X^T W^{(t)} \tilde{z}^{(t)},$$

dove la *pseudo-risposta modificata* è

$$\tilde{z}_i^{(t)} = \eta_i^{(t)} + \frac{y_i - m_i \pi_i^{(t)} + 2\alpha h_i^{(t)} (q_i^{(t)} - 1/2)}{d_i^{(t)}}, \quad (3.13)$$

ed il predittore lineare $\eta_i = x_i^T \beta^{(t)}$. Si ottiene così la formula degli IWLS:

$$\beta^{*(t+1)} = (X^T W^{(t)} X)^{-1} X^T W^{(t)} \tilde{z}^{(t)}. \quad (3.14)$$

Si osservi come i due algoritmi di punto fisso definiti sono algebricamente identici, anche se espressi in forme differenti. Pertanto, è sufficiente mostrare che il punto fisso dell'equazione 3.12 risolva lo *score penalizzato* affinché il risultato possa estendersi per gli IWLS.

Punto fisso dell'algoritmo IWLS quasi-Newtoniano. Essendo la formula di aggiornamento (3.11), nel punto fisso $\beta^{(t+1)} = \beta^{(t)} = \beta^*$ si ha

$$\beta^* = \beta^* + \{I(\beta^*)\}^{-1} U^*(\beta^*).$$

Sottraendo β^* da entrambi i membri e pre-moltiplicando per $I(\beta)$ (non singolare per le ipotesi precedenti) si ottiene immediatamente

$$0 = U^*(\beta^*),$$

ovvero il punto fisso annulla lo score penalizzato. La convergenza è invece garantita dal Teorema 3.4, mentre l'algoritmo è ben definito sotto le condizioni esposte nella Sottosezione 3.6.1. □

Nell'appendice A.3.2 si mostra invece come sia possibile definire un algoritmo iterativo basato esclusivamente sui *dati aggiustati*, già intuito da Firth nel suo Articolo Firth (1993), che abbia il medesimo punto fisso dell'algoritmo quasi-Newtoniano, seppur seguendo un percorso di convergenza differente.

3.6.1 Condizioni di stabilità numerica degli algoritmi

Affinché i metodi iterativi convergano, è necessario che tutte le quantità coinvolte nell'equazione dello *score penalizzato* (3.9) siano ben definite ad ogni iterazione dell'algoritmo. Analizzandone le componenti, si osserva come la condizione fondamentale riguardi il dominio dei quasi successi $\{y_i + 2\alpha h_{ii}(q_i - 1/2)\}$, infatti, al di fuori dell'intervallo $(0, m)$ non è né garantita l'esistenza delle stime né la proprietà di concavità del logaritmo della penalità di Jeffreys. Per risolvere il problema del dominio nel contesto dei legami non canonici, si aggiunge alle risposte aggiustate ed ai totali una quantità che dipende da una funzione c . In concreto, si definiscono i dati aggiustati $\tilde{y} = y + 2\alpha h(q - 1/2 + \pi c)$ e $\tilde{m} = m + 2\alpha hc$; si osservi che i termini dipendenti da c si elidono esattamente all'interno dell'equazione 3.9 e quindi non ne alterano la soluzione finale.

Teorema 3.3. *Sia la funzione $c(q, \pi)$ definita come:*

$$c(q, \pi) = \begin{cases} 1 + \frac{(q - 1/2)(\pi - 1)}{\pi(1 - \pi)} & \text{se } q \leq \frac{1}{2}, \\ 1 + \frac{q - 1/2}{1 - \pi} & \text{se } q > \frac{1}{2}, \end{cases}$$

allora le risposte aggiustate $\tilde{y}$ soddisfano la condizione $0 \leq \tilde{y} \leq \tilde{m}$ per ogni iterazione.

Dimostrazione. Con la definizione della funzione $c(\cdot)$, i dati aggiustati assumono la forma:

$$\begin{aligned} \tilde{y} &= y + 2\alpha h\pi \left\{ 1 + \left(q - \frac{1}{2} \right) \frac{1 - \mathbf{1}\left(q \leq \frac{1}{2}\right)}{\pi(1 - \pi)} \right\}, \\ \tilde{m} &= m + 2\alpha h \left\{ 1 + \left(q - \frac{1}{2} \right) \frac{\pi - \mathbf{1}\left(q \leq \frac{1}{2}\right)}{\pi(1 - \pi)} \right\}. \end{aligned} \tag{3.15}$$

Da cui risulta immediato notare che la funzione $c(\cdot)$ annulla il termine responsabile del cambio di segno della penalità (che renderebbe $\tilde{m} < \tilde{y}$). Infine, la relazione $\tilde{y} \leq \tilde{m}$ è garantita dal fatto che il termine di penalità, positivo per costruzione associato alle *risposte aggiustate*, sia moltiplicato per la media π , che assume valori compresi fra zero ed uno, garantendo la minorazione. □

Si noti che il Teorema appena fornito non è di per sé sufficiente a garantire l'esistenza delle stime ad ogni iterazione dell'algoritmo: se il valore della i -esima risposta aggiustata fosse sulla frontiera ed il *leverage* h_{ii} ad essa associato fosse nullo, le stime non esisterebbero per quanto mostrato nella Sezione 2.6. Risulta pertanto necessario aggiungere due ulteriori condizioni affinché la disuguaglianza diventi “stretta”, ossia valga $0 < \tilde{y} < \tilde{m}$. Si richiede che:

- La matrice del disegno X sia a rango pieno e includa un vettore colonna unitario (ovvero il modello deve essere dotato di intercetta).
- La funzione legame $G(\eta)$ sia assolutamente continua e che la sua derivata sia una distribuzione di probabilità unimodale.

Se queste condizioni sono verificate ed il vettore di inizializzazione $\beta^{(0)}$ è composto da quantità finite, risulta garantita la disuguaglianza, e quindi ad ogni passo iterativo le quantità sono ben definite. Sotto le medesime condizioni e grazie all'ipotesi che $g(\eta)$ sia una distribuzione di probabilità unimodale, i pesi $w_i(\beta) = g(\eta)^2 / (G(\eta)(1 - G(\eta)))$ risultano essere strettamente maggiori di zero; come conseguenza la matrice dell'informazione attesa $I(\beta) = X^T W(\beta) X$ è definita positiva. Da questa osservazione discende direttamente che anche i leverage h_i assumeranno valori strettamente maggiori di zero. Il risultato è implicato dall'appena dimostrata positività dei pesi e dall'ipotesi di presenza dell'intercetta nel modello, come si osserva nell'equazione ricavata da Magnus & Neudecker (1999, Cap. 11; Th. 4):

$$h_i(\beta) = w_i(\beta) x_i^T (X^T W(\beta) X)^{-1} x_i \geq w_i(\beta) x_i^T x_i \lambda_1 > 0, \quad (3.16)$$

dove λ_1 è l'autovalore minimo dell'inversa dell'informazione. La presenza dell'intercetta nel modello garantisce che nessuna osservazione abbia come covariate x_i il vettore identicamente nullo, e, come conseguenza dell'ipotesi su $g(\eta)$, è garantita la positività di $X^T W(\beta) X$. In questo modo la disuguaglianza stretta sui dati aggiustati è stata dimostrata, e gli algoritmi iterativi risultano ben definiti ad ogni iterazione.

Per l'enunciato e la dimostrazione del teorema da cui discende la disuguaglianza 3.16 si veda l'Appendice A.3.

3.7 Metodi di ricerca in linea

Gli algoritmi iterativi introdotti nella Sezione 3.6 sono a tutti gli effetti metodi *quasi-Newtoniani*, i quali costituiscono una forma particolare dei più generali *metodi*

di ricerca in linea per l'ottimizzazione delle funzioni. In questa sezione si studieranno i fondamenti teorici alla base di tali metodi seguendo quanto presentato nel testo [Nocedal & Wright \(2006, Cap. 3\)](#).

L'idea alla base è scegliere, a partire dall'iterata corrente $\beta^{(t)}$, una *direzione* $p^{(t)}$ lungo la quale spostarsi e la *lunghezza del passo* $\alpha_t > 0$ da effettuare in tale direzione, ottenendo l'equazione di aggiornamento delle stime:

$$\beta^{(t+1)} = \beta^{(t)} + \delta_t p^{(t)}. \quad (3.17)$$

Nel caso dei metodi di Newton-Raphson legati alla massimizzazione della log-verosimiglianza, si pone $\alpha_t = 1$ e $p^{(t)} = I(\beta^{(t)})^{-1}U^*(\beta^{(t)})$, dove $U^*(\beta)$ indica in generale lo score della funzione obiettivo, incluso lo score penalizzato (3.9), mentre $I(\beta)$ è la matrice dell'informazione attesa di Fisher; quando quest'ultima non coincide con la matrice Hessiana della funzione obiettivo, il metodo si qualifica come *quasi-Newtoniano*.

La necessità di generalizzare questi metodi, rendendo α_t un parametro anziché una costante unitaria, emerge in diverse situazioni, come un'inizializzazione errata, dati con valori estremi oppure che presentano separazione. Un'altra situazione problematica riguarda la scelta di legami con log-verosimiglianza non strettamente concava sul proprio dominio, come per la *Cauchit*. Inoltre, derivando da uno sviluppo di Taylor arrestato al secondo ordine (1.14.2), i metodi di Newton-Raphson sono adeguati a funzioni con una forma approssimativamente quadratica, come si è evidenziato nella Figura 1.9. Tale ipotesi non è sempre rispettata nelle prime iterazioni del metodo: qualora il punto di partenza $\beta^{(0)}$ fosse lontano dalla soluzione, i predittori lineari $\eta_i = x_i^T \beta^{(0)}$ che ne derivano possono diventare grandi in valore assoluto, tali da spingere le probabilità π_i verso zero o uno; i pesi $w_i(\beta^{(0)}) = m_i g(\eta_i)^2 / \{G(\eta_i)(1 - G(\eta_i))\}$ diventano allora piccoli, e con essi l'intera matrice $I(\beta^{(0)}) = X^T W(\beta^{(0)}) X$. Un'informazione quasi nulla segnala che il modello è quasi piatto in $\beta^{(0)}$, rendendo $I(\beta^{(0)})^{-1}$ molto grande: lo score, moltiplicato per questa quantità, proietta l'iterata successiva in una regione potenzialmente molto lontana dal massimo dove la convergenza in generale non è garantita. Per le condizioni di convergenza del metodo di Newton-Raphson classico con passo unitario si veda [Quarteroni et al. \(2014\)](#). Per questa ragione l'inizializzazione riveste un ruolo cruciale assicurando un'informazione iniziale $I(\beta^{(0)})$ ben condizionata ed il primo passo dell'algoritmo risulta numericamente stabile. Nei casi più ostinati però, tale

ipotesi non è sufficiente a garantire la convergenza, pertanto bisogna individuare un metodo complementare che garantisca quest'ultima.

Tornando alla formula 3.17, la lunghezza del passo ideale sarebbe quella che massimizza la funzione locale $\ell^*(\beta^{(t)} + \alpha p^{(t)})$, ma la soluzione esatta è in genere troppo onerosa, rendendola nei fatti controproducente; è preferibile accontentarsi di un passo che garantisca un incremento *adeguato* della funzione ad un costo contenuto. Il successo dell'algoritmo dipende quindi da una scelta accorta di entrambe le quantità, $p^{(t)}$ e α_t . Affinché un passo $p^{(t)}$ produca un aumento della verosimiglianza, si richiede che esso sia una *direzione di salita*, ovvero che $p^{(t)T} U^*(\beta^{(t)}) > 0$. Infatti, dallo sviluppo di Taylor arrestato al primo ordine si ottiene $\ell^*(\beta_k + \alpha p_k) \approx \ell^*(\beta^{(t)}) + \alpha p_k^T U^*(\beta^{(t)})$. Per i metodi quasi-Newtoniano le direzioni hanno la forma generale

$$p^{(t)} = B_t^{-1} U^*(\beta^{(t)}), \quad (3.18)$$

con B_t matrice simmetrica e non singolare, che si è detta essere nel caso di interesse $I(\beta)$. Quando B_t è definita positiva, la (3.18) è automaticamente di salita, infatti $p^{(t)T} U^*(\beta^{(t)}) = U^*(\beta^{(t)})^T B_t^{-1} U^*(\beta^{(t)}) > 0$ essendo una forma quadratica. Poiché $I(\beta)$ è definita positiva sotto le condizioni della Sottosezione 3.6.1, la direzione IWLS è di salita per ogni iterazione.

3.8 Le condizioni di Wolfe

Stabilita la direzione, occorre fissare la lunghezza del passo. Come in ogni scelta si pone un *trade-off*: si vorrebbe un δ_t che incrementi sensibilmente ℓ^* , ma allo stesso tempo individuabile rapidamente. La prima condizione che si impone richiede dunque un incremento *sufficiente*, proporzionale sia al passo che al gradiente della funzione, questa condizione è detta di *Armijo* (Armijo, 1966), e si scrive

$$\ell^*(\beta^{(t)} + \delta_t p^{(t)}) \geq \ell^*(\beta^{(t)}) + c_1 \delta_t U^*(\beta^{(t)})^T p^{(t)},$$

dove la costante $c_1 \in (0, 1)$ è scelta molto piccola, dell'ordine di $c_1 \approx 10^{-4}$. In questo caso, essendo la derivata direzionale $U^* p^{(t)}$ positiva, il membro di destra definisce una funzione lineare di δ_t monotona crescente. Quello che la condizione impone è che più i passi sono lunghi, più debbano corrispondere aumenti significativi della funzione da massimizzare, dove per significativi si intende rispetto alla costante scelta, alla direzione e al gradiente.

La condizione di Armijo da sola non basta, perché è soddisfatta anche da passi eccessivamente corti. Per escluderli si introduce una seconda condizione, chiamata di *curvatura*:

$$U^*(\beta^{(t)} + \delta_t p^{(t)})^T p^{(t)} \leq c_2 U^*(\beta^{(t)})^T p^{(t)}, \quad c_2 \in (c_1, 1).$$

Il significato della disuguaglianza sulla scelta del passo riguarda l'interpretazione della derivata di una funzione: se è marcatamente positiva si intuisce che la verosimiglianza possa crescere ulteriormente lungo tale direzione, e che quindi convenga allungare il passo; se invece la derivata è ormai piccola, ha senso arrestare la ricerca e cambiare direzione.

L'insieme delle due disuguaglianze prende il nome di *condizioni di Wolfe* (Wolfe, 1971):

$$\ell^*(\beta^{(t)} + \delta_t p^{(t)}) \geq \ell^*(\beta^{(t)}) + c_1 \delta_t U^*(\beta^{(t)})^T p^{(t)}, \quad (3.19a)$$

$$U^*(\beta^{(t)} + \delta_t p^{(t)})^T p^{(t)} \leq c_2 U^*(\beta^{(t)})^T p^{(t)}, \quad (3.19b)$$

con $0 < c_1 < c_2 < 1$. Le due condizioni sono mostrate graficamente nella Figura 3.7.




Figura 3.7: Condizioni di Wolfe per la massimizzazione di ℓ^* . La retta tratteggiata $l(\delta)$ definisce la soglia della condizione di Armijo, ovvero il membro destro dell'equazione 3.19a. la linea tratto punto invece rappresenta la condizione di curvatura (3.19b), che esclude i passi eccessivamente brevi, per i quali la pendenza del gradiente è ancora molto elevata.

Il prossimo risultato assicura che la ricerca in linea sia un problema ben posto, ossia che esistono sempre passi compatibili con le disuguaglianze 3.19.

Lemma 3.2 (Esistenza dei passi di Wolfe). *Sia $\ell^* : \mathbb{R}^p \rightarrow \mathbb{R}$ continua e differenziabile con derivate continue, sia $p^{(t)}$ una direzione di salita in $\beta^{(t)}$ e si supponga*

ℓ^* limitata superiormente lungo il raggio $\{\beta^{(t)} + \delta p^{(t)} \text{ t.c. } \delta > 0\}$. Allora, per $0 < c_1 < c_2 < 1$, esistono intervalli di passi δ_t che soddisfano le condizioni di Wolfe (3.19).

Si noti come la log-verosimiglianza sia limitata superiormente da zero, ed il logaritmo della distribuzione a priori di Jeffreys sia limitato per quanto visto nel Teorema 3.2; pertanto, la log-verosimiglianza penalizzata rispetta la condizione di limitatezza. Per la dimostrazione si veda l'appendice A.3.2.

3.9 L'algoritmo di backtracking e il teorema di convergenza

Generalmente, nelle implementazioni pratiche non si verificano entrambe le condizioni esposte in 3.19, bensì la sola condizione di Armijo (3.19a), controllando la lunghezza del passo attraverso una strategia di *backtracking* (o *halving* se $\rho = 1/2$). L'algoritmo inizia fissando $\bar{\delta} > 0$ e $\rho, c_1 \in (0, 1)$, si pone $\delta = \bar{\delta}$ e si verifica la condizione 3.19a, se quest'ultima non è verificata si pone $\delta = \rho \delta$ e si itera fino a che non si individui un passo δ_t che rispetta la condizione. Il passo iniziale è $\bar{\delta} = 1$, ovvero il valore naturale per i metodi quasi-newtoniani e dunque per gli IWLS, mentre generalmente, il fattore di contrazione si mantiene in un intervallo $\rho \in (0.4, 0.8)$, in modo da non accorciare il passo troppo bruscamente. Il valore di δ_t individuato non risulta mai troppo corto, in quanto il valore immediatamente precedente δ_t/ρ era stato rifiutato proprio perché *troppo lungo*, e il passo finale ne dista al più di un fattore ρ . In altre parole, il backtracking garantisce che i passi non siano eccessivamente corti, motivo per cui la condizione di curvatura (3.19b) può essere omessa. Questo meccanismo è stato aggiunto nell'implementazione in R per indurre la convergenza anche ai casi più complicati discussi precedentemente (per il codice completo si consulti la cartella github al link in coda a questo Capitolo).

Resta da chiarire perché la combinazione di una direzione di salita con un passo che soddisfa le condizioni di Wolfe conduca effettivamente ad un punto stazionario. In questo senso ci si avvale di un risultato di convergenza che lega la qualità delle direzioni di ricerca al raggiungimento di un punto stazionario della funzione. Si introduce a tal fine l'angolo θ_t formato dalla direzione $p^{(t)}$ con il gradiente $U^*(\beta^{(t)})$, definito come

$$\cos \theta_t = \frac{U^*(\beta^{(t)})^T p^{(t)}}{\|U^*(\beta^{(t)})\| \|p^{(t)}\|}. \quad (3.20)$$

Teorema 3.4 (Teorema di Zoutendijk per la convergenza). *Si consideri un'iterazione del tipo 3.17, dove $p^{(t)}$ è una direzione di salita e δ_t soddisfa le condizioni di*

Wolfe (3.19). Si supponga che ℓ^* sia limitata superiormente in $\mathbb{R}^p$, e che sia anche continua e differenziabile in un insieme aperto N contenente l'insieme di livello $\mathcal{L} \stackrel{\text{def}}{=} \{\beta : \ell^*(\beta) \geq \ell^*(\beta^{(0)})\}$, con $\beta^{(0)}$ punto di partenza. Si assuma infine che il gradiente U^* sia Lipschitziano su N , ossia che esista una costante $L > 0$ tale che $\|U^*(\beta) - U^*(\tilde{\beta})\| \leq L\|\beta - \tilde{\beta}\|$ per ogni $\beta, \tilde{\beta} \in N$. Allora

$$\sum_{t=0}^n \cos^2 \theta_t \|U^*(\beta^{(t)})\|^2 < \infty. \quad (3.21)$$

La dimostrazione viene riportata nell'Appendice A.3.2.

La condizione del Teorema (3.21) implica che il limite del termine generale debba tendere a zero: $\cos^2 \theta_t \|U^*(\beta^{(t)})\|^2 \rightarrow 0$. Se la scelta della direzione non è ortogonale al gradiente della funzione, ovvero esiste $\delta > 0$ tale che $\cos \theta_t \geq \delta > 0$ per ogni t , allora deve necessariamente essere che

$$\lim_{t \rightarrow \infty} \|U^*(\beta^{(t)})\| = 0,$$

cioè la successione 3.17 è attratta ad un punto stazionario di ℓ^* . Questo è il più forte risultato di convergenza ottenibile per i metodi generali di *ricerca in linea*. Per le situazioni in cui l'Hessiana della *log-verosimiglianza* sia definita negativa, cosa che accade per tutte le famiglie esponenziali con legame canonico (come mostrato nella Sottosezione 1.13.2), il gradiente si annulla solo nel punto di massimo, ed il teorema garantisce una convergenza totale e definitiva per i metodi iterativi di *Newton-Raphson* implementati (si veda l'equazione 1.18). Si noti che questo vale in molti casi anche per la *log-verosimiglianza penalizzata*, si è infatti mostrato che il logaritmo della distribuzione a priori di *Jeffreys* sia concavo, ed essendo la somma di due funzioni concave anch'essa concava, è possibile affermare che la *log-verosimiglianza penalizzata* possieda matrice Hessiana definita negativa. Pertanto, il teorema 3.4 garantisce la convergenza degli algoritmi *quasi-Newtoniani* (equazione 3.14) al massimo assoluto per tutte le funzioni legame concave (ovvero tutte quelle considerate ad eccezione per la Cauchit).

Per accertarsi dei risultati appena enunciati, rimane solo da verificare che il vettore della direzione ed il gradiente della funzione non siano ortogonali. Per i metodi *quasi-newtoniani*, e dunque anche per gli IWLS, tale condizione risulta incredibilmente semplice da verificare: è necessario che il *numero di condizionamento* dell'approssimazione della matrice *hessiana* sia finito e limitato in t . Il numero di condizionamento è definito come $\kappa(B_t) = \|B\| \|B^{-1}\|$, dove per le matrici con

$\|B_t\|$ si intende la norma spettrale (ovvero la norma matriciale indotta dalla norma euclidea sui vettori (Quarteroni et al., 2014, Cap. 1)), che vale $\lambda_{\max}(|B|)$ (l'autovalore di modulo massimo) per matrici simmetriche e definite positive. Quindi, in questi casi la formula del numero di condizionamento può essere semplificata: $\kappa(B_t) = \lambda_{\max}(B_t)/\lambda_{\min}(B_t)$. Tale numero è un coefficiente moltiplicativo che compare nella quasi totalità delle formule riguardanti la stabilità degli algoritmi numerici applicati a matrici, per un approfondimento sul tema si rimanda a Quarteroni et al. (2014) oppure Russo (2026).

Si consideri la direzione (3.18) dei metodi *quasi-Newtoniano*, con B_t simmetrica e definita positiva. Sostituendola nella definizione (3.20) si ottiene

$$\cos \theta_t = \frac{U^*(\beta^{(t)})^T B_t^{-1} U^*(\beta^{(t)})}{\|U^*(\beta^{(t)})\| \|B_t^{-1} U^*(\beta^{(t)})\|}.$$

Si procede con una minorazione di tale quantità; innanzitutto si nota che il denominatore per le proprietà delle norme può essere maggiorato: $\|B_t^{-1} U^*(\beta^{(t)})\| \leq \|B_t^{-1}\| \|U^*(\beta^{(t)})\|$. Il numeratore invece, essendo B_t^{-1} simmetrica e definita positiva, può essere riscritto attraverso il quoziente di Rayleigh Magnus & Neudecker (1999, Cap. 11; Th. 4) (dimostrato in Appendice A.3): $U^*(\beta^{(t)})^T B_t^{-1} U^*(\beta^{(t)}) \geq \lambda_{\min}(B_t^{-1}) \|U^*(\beta^{(t)})\|^2 = \|U^*(\beta^{(t)})\|^2 / \|B_t\|$ (per entrambe le maggiorazioni), quindi mettendo insieme le due osservazioni si ottiene

$$\cos \theta_t \geq \frac{\|U^*(\beta^{(t)})\|^2 / \|B_t\|}{\|U^*(\beta^{(t)})\|^2 \|B_t^{-1}\|} = \frac{1}{\|B_t\| \|B_t^{-1}\|} = \frac{1}{\kappa(B_t)}. \quad (3.22)$$

La (3.22) stabilisce che la condizione sufficiente affinché l'angolo tra la direzione p_k ed il gradiente $U^*(\beta)$ sia diverso da 90° è che il numero di condizionamento della matrice di iterazione B_t sia finito.

Si è già affermato più volte che nel caso degli IWLS si ha $B_t = I(\beta^{(t)}) = X^T W(\beta^{(t)}) X$, la quale, sotto le condizioni di stabilità della Sottosezione 3.6.1, è definita positiva e i suoi autovalori estremi $\lambda_{\min}(I(\beta))$ e $\lambda_{\max}(I(\beta))$ sono limitati e diversi da zero, il che implica un numero di condizionamento finito,

$$\kappa(I(\beta^{(t)})) = \frac{\lambda_{\max}(I(\beta^{(t)}))}{\lambda_{\min}(I(\beta^{(t)}))} \leq M < \infty.$$

Esiste quindi $\delta = 1/M > 0$ tale che $\cos \theta_t \geq \delta$ per ogni t , e per la condizione di Zoutendijk (3.21) si conclude che $\|U^*(\beta^{(t)})\| \rightarrow 0$, ossia l'iterazione IWLS è globalmente convergente verso un punto stazionario della log-verosimiglianza penalizzata.

3.10 Il ruolo dell'halving per la regressione binaria

Per i legami *logit*, *probit*, *log-log* e *complementary log-log*, le funzioni $-\log\{G(\eta)\}$ e $-\log\{1-G(\eta)\}$ sono convesse, condizione che, come discusso nella Sezione 2.6, rende la log-verosimiglianza concava; il suo unico punto stazionario è allora il massimo globale e il passo unitario di quasi Fisher Scoring tende a incrementare ℓ^* . Il legame *Cauchit* costituisce un'eccezione: la sua funzione di legame non è globalmente concava, e di conseguenza non lo è nemmeno la *log-verosimiglianza penalizzata*. In questo caso l'informazione attesa $I(\beta)$ può rappresentare male la curvatura locale di ℓ^* nelle aree lontane dalla soluzione, e il passo classico di IWLS rischia di “scavalcare” il massimo, restituendo un'iterata in cui la verosimiglianza penalizzata è *inferiore* a quella di partenza. In assenza di meccanismi preventivi, l'ipotesi di incremento monotono richiesta dal Teorema 3.4 verrebbe violata e la successione potrebbe non convergere.

Il meccanismo di halving di *Armijo* risolve esattamente questa difficoltà imponendo la condizione di incremento sufficiente (3.19a). Agisce in questo modo sulla lunghezza del passo finché la condizione non sia soddisfatta, garantendo che ogni iterazione produca un aumento di ℓ^* proporzionale a $\cos^2 \theta_t \|U^*(\beta^{(t)})\|^2$, garantendo la validità della condizione di Zoutendijk 3.4. La direzione resta invece di salita per costruzione finché $I(\beta^{(t)})$ è definita positiva. In questo modo l'halving converte il passo di quasi Fisher Scoring per il Cauchit, in un'iterazione globalmente convergente, al prezzo di alcune valutazioni aggiuntive della verosimiglianza per ciascun passo.

Vale la pena osservare che il meccanismo di halving sia utile in pratica anche per i legami globalmente concavi, come il *log-log* e il *complementary log-log*, sebbene per una ragione diversa da quella discussa per il Cauchit: in presenza di predittori lineari estremi, i pesi $w_i(\beta)$ possono incontrare problemi numerici di *underflow*, causando aggiornamenti instabili a causa di un'informazione quasi singolare. Anche in questi casi, dunque, il controllo dell'incremento di $\ell^*(\beta)$ imposto dall'halving limita la lunghezza del passo e stabilizza le iterazioni, evitando aggiornamenti eccessivi nelle regioni in cui l'informazione attesa è *mal condizionata* (ovvero ha un numero di condizionamento grande).

3.11 Implementazione pratica

In questa Sezione si desidera riportare lo pseudo-codice utilizzato per l'implementazione del metodo di Firth per dati binari. Tale pseudo codice risulta, coerentemente

```

Input:  $X, y, m$ , legame  $G, \alpha = 1/2$ , tol, maxit,  $c_1, \rho$ 
Output:  $\beta^*$ 

Inizializzazione:  $c \leftarrow \frac{1}{2} p/n; \quad \pi^{(0)} \leftarrow \frac{y + c}{m + 2c}$ 
 $\beta^{(0)} \leftarrow$  WLS classici su  $\eta^{(0)} = G^{-1}(\pi^{(0)})$ ;
for  $t = 1, \dots, \text{maxit}$  do
     $\eta \leftarrow X\beta^{(t-1)}$ ;
     $\pi \leftarrow G(\eta)$ ;
     $d \leftarrow g(\eta)$ ;
     $w \leftarrow d^2/\{\pi(1 - \pi)\}$ ;  $W \leftarrow \text{diag}(mw)$ ;
    Fattorizzazione QR di  $W^{1/2}X \Rightarrow$  leverage  $h_{ii}$ ;
     $q \leftarrow g'(\eta)/w + \pi$ ;
    // pseudo-risposta modificata
     $z^* \leftarrow \eta + \frac{y/m - \pi + 2\alpha h(q - \frac{1}{2})/m}{d}$ ;
     $\Delta \leftarrow (X^T W X)^{-1} X^T W z^* - \beta^{(t-1)}$ ; // passo IWLS standard risolto
    tramite QR
    // backtracking: condizione di Armijo
     $\delta \leftarrow 1$ ;
    while  $\ell^*(\beta^{(t-1)} + \delta\Delta) \leq \ell^*(\beta^{(t-1)}) + c_1 \delta U^{*\top} \Delta$  do
         $half = \text{max\_half} + 1$ ;
         $\delta \leftarrow \rho \delta$ ; // halving se  $\rho = 1/2$ 
        if  $half \geq \text{max\_half}$  then
            return non convergenza
        end
    end
     $\beta^{(t)} \leftarrow \beta^{(t-1)} + \delta\Delta$ ;
    if  $\|\beta^{(t)} - \beta^{(t-1)}\| < \text{tol}$  then
        return  $(\beta^{(t)})$ 
    end
end

```

con quanto affermato nella Sezione 3.5, del tutto simile all'algoritmo IWLS per l'individuazione delle stime di massima verosimiglianza pesata. La differenza principale riguarda la struttura delle *pseudo-risposte modificate* che inglobano la penalizzazione di Firth.

Il codice della funzione, sviluppata in ambiente R, e dei diversi grafici utilizzati nel corso dell'elaborato, sono disponibili nella seguente repository GitHub: [Codice Tesi](#).

Appendice A

Dimostrazioni dei Teoremi

In questa appendice vengono fornite le dimostrazioni dei teoremi e dei lemmi presentati nei capitoli precedenti, oltre ai complementi tecnici richiamati nel testo.

A.1 Dimostrazioni del Capitolo 1

Disuguaglianza di Wald. Si consideri la differenza fra i due valori attesi, calcolati rispetto alla vera distribuzione indicata da θ_0 ,

$$E_{\theta_0}\{\ell(\theta; Y)\} - E_{\theta_0}\{\ell(\theta_0; Y)\} = E_{\theta_0}\left\{\log \frac{p(Y; \theta)}{p(Y; \theta_0)}\right\}.$$

Essendo la funzione logaritmo strettamente concava, per la *disuguaglianza di Jensen* vale

$$E_{\theta_0}\left\{\log \frac{p(Y; \theta)}{p(Y; \theta_0)}\right\} \leq \log E_{\theta_0}\left\{\frac{p(Y; \theta)}{p(Y; \theta_0)}\right\} = \log \int_{\mathcal{Y}} \frac{p(y; \theta)}{p(y; \theta_0)} p(y; \theta_0) dy = 0,$$

dove per la semplificazione dell'integrando si sono utilizzate le condizioni regolari di stima (1.9), per cui il supporto $\mathcal{Y}$ non dipende dal parametro, e il *secondo assioma di Kolmogorov* che garantisce il valore unitario dell'ultimo integrale. Per linearità del valore atteso si ottiene:

$$E_{\theta_0}\{\ell(\theta; Y)\} \leq E_{\theta_0}\{\ell(\theta_0; Y)\}, \quad \text{per ogni } \theta \in \Theta,$$

dove l'uguaglianza, essendo il logaritmo *strettamente* concavo, si ottiene se e soltanto se $p(y; \theta) = p(y; \theta_0)$; per l'ipotesi di identificabilità (1.2) ciò accade solo per $\theta = \theta_0$, il che conclude la dimostrazione. $\square$

Disuguaglianza di Cramér-Rao. Si definisca $a(\theta) = E\{T(Y)\}$ il valore atteso dello stimatore. Ricordando che $E_\theta\{U(\theta)\} = 0$ (1.3), si calcoli la covarianza fra lo stimatore e la funzione di score:

$$\text{Cov}_\theta\{T(Y), U(\theta)\} = E_\theta\{T(Y) U(\theta)\} = \int_{\mathcal{Y}} T(y) \frac{\partial}{\partial \theta} \log p(y; \theta) p(y; \theta) dy = \int_{\mathcal{Y}} T(y) \frac{\partial}{\partial \theta} p(y; \theta) dy,$$

dove nell'ultimo passaggio si è applicata la regola di derivazione del logaritmo. Grazie alla condizione di scambiabilità fra derivazione e integrazione (4), l'ultima quantità coincide con la derivata del valore atteso dello stimatore,

$$\text{Cov}_\theta\{T(Y), U(\theta)\} = \frac{\partial}{\partial \theta} \int_{\mathcal{Y}} T(y) p(y; \theta) dy = a'(\theta).$$

Risulta ora possibile applicare la *disuguaglianza di Cauchy-Schwarz* alla coppia $(T(Y), U(\theta))$, per cui si ottiene

$$\{a'(\theta)\}^2 = [\text{Cov}_\theta\{T(Y), U(\theta)\}]^2 \leq \text{Var}_\theta\{T(Y)\} \text{Var}_\theta\{U(\theta)\} = \text{Var}_\theta\{T(Y)\} I(\theta),$$

dove si è sfruttata l'identità dell'informazione di Fisher, per cui la varianza dello score coincide con l'informazione attesa (1.5). Dividendo entrambi i membri per $I(\theta)$, strettamente positiva per ipotesi, si perviene alla tesi

$$\text{Var}_\theta\{T(Y)\} \geq \frac{\{a'(\theta)\}^2}{I(\theta)}.$$

Si osservi infine che, nel caso di uno stimatore non distorto ($a(\theta) = \theta$, dunque $a'(\theta) = 1$), il limite inferiore si riduce all'inverso dell'informazione attesa, $\text{Var}_\theta\{T(Y)\} \geq I(\theta)^{-1}$. Questo è il caso dello stimatore di massima verosimiglianza (asintoticamente non distorto 1.7), per cui la varianza asintotica coincide con l'informazione attesa. $\square$

A.2 Dimostrazioni del Capitolo 2

A.2.1 Relazioni exlog fra momenti e cumulanti

La relazione che intercorre fra i momenti dall'origine di ordine r e i rispettivi cumulanti può essere espressa in forma compatta tramite le relazioni EXLOG, che si ottengono dagli sviluppi di Taylor per il logaritmo e l'esponenziale. Si riporta

esclusivamente l'equazione che lega i momenti ai cumulanti:

$$\kappa^{I_r} = \sum_{h=1}^r \sum_{I_r/h} \kappa_c^{I_{r_1}} \dots \kappa_c^{I_{r_h}} \quad (\text{A.1})$$

dove la notazione I_r/h indica la somma su tutte le possibili partizioni dell'insieme di indici $I_r = \{i_1, \dots, i_n\}$ in h sottoinsiemi non vuoti (il cui numero è dato dai *numeri di Stirling di seconda specie*, si veda Charalambides (2005, Cap. 2)). Questi coefficienti sono fondamentali per generalizzare la derivata delle funzioni composte multivariate attraverso la formula di Faà di Bruno:

$$f(g(\theta))_{R_m} = \sum_{h=1}^m f^{(h)} \sum_{R_m/h} g_{R_{m_1}} \dots g_{R_{m_h}}.$$

Tale formula può essere impiegata per esprimere compattamente le *identità di Bartlett* (si veda Sezione 2.2).

Attraverso le relazioni espresse nella formula (A.1) è possibile ricavare l'ordine asintotico del momento r -esimo di S_n : poiché ogni cumulante della somma è $\mathcal{O}(n)$, il termine dominante è quello corrispondente alla partizione in r blocchi singoli, restituendo un ordine asintotico complessivo pari a $\kappa^{I_r} = \mathcal{O}(n^r)$, purché il momento primo sia non nullo. Considerando invece una variabile casuale somma centrata, quale $S_n - E(S_n)$, i momenti presentano un ordine asintotico ridotto, pari a $\mathcal{O}(n^k)$ con $k = r/2$ se r è pari e $k = (r-1)/2$ se r è dispari. Tale riduzione deriva dal fatto che, per una variabile centrata, il cumulante di primo ordine è identicamente nullo; di conseguenza, nello sviluppo combinatorio si possono prendere in considerazione esclusivamente le partizioni in cui ogni sottoinsieme ha cardinalità almeno pari a due. Ne segue immediatamente che l'ordine asintotico della quantità $E(\ell_{r_1} \dots \ell_{r_h})$, che è il momento misto h -esimo di una variabile casuale somma a media nulla, è $\mathcal{O}(n^k)$ con k definito come sopra.

Esempio A.1 (Momento secondo e relazioni EXLOG). Si intende calcolare il momento secondo ($r = 2$) di una generica variabile casuale in funzione dei suoi cumulanti, basandosi sull'insieme di indici $I_2 = \{r, s\}$. Applicando l'equazione (A.1), si somma sul numero di blocchi h (da 1 a 2):

- per $h = 2$, l'unico modo di partizionare i due elementi in due blocchi è dividerli in *singoletti* $\{r\}$ e $\{s\}$; il prodotto dei rispettivi cumulanti restituisce il termine $\kappa^r \kappa^s$;

- per $h = 1$ esiste una sola partizione, ossia l'insieme stesso $\{r, s\}$, che restituisce il cumulante congiunto κ^{rs} .

Sommando i contributi si ottiene la nota relazione

$$\mu^{rs} = \kappa^r \kappa^s + \kappa^{rs}.$$

Se si considera lo stesso momento per la variabile centrata, sapendo che le medie si annullano ($\kappa^r = \kappa^s = 0$), il primo addendo scompare lasciando unicamente $\mu^{rs} = \kappa^{rs}$. Questo è coerente con la regola sull'ordine di convergenza esposta sopra: per una variabile a media nulla, l'ordine asintotico del momento secondo è pari a $\mathcal{O}(n)$ (l'unica partizione con blocchi di cardinalità ≥ 2 è $\{r, s\}$, che dà $\kappa^{rs} = \mathcal{O}(n)$).

A.2.2 Ordini asintotici delle quantità di verosimiglianza

La derivazione degli sviluppi asintotici presentati nella Sezione 2.5.1 e nella Sezione 2.5.2 richiede il controllo dell'ordine di convergenza delle varie quantità di verosimiglianza e dei loro momenti misti. La Tabella A.1 raccoglie tali ordini, ottenuti applicando la legge dei grandi numeri e il teorema del limite centrale ai contributi unitari (per le derivate della log-verosimiglianza e i loro residui centrati H) e la linearità del valore atteso (per le quantità deterministiche i e ν). Le quantità stocastiche di ordine $\mathcal{O}_p(n^{1/2})$ derivano dal fatto che ℓ_r è somma di n variabili aleatorie centrate e indipendenti, mentre le quantità di ordine $\mathcal{O}(n)$ o $\mathcal{O}_p(n)$ derivano dalla presenza di n termini deterministici con valore non nullo. Per una trattazione dettagliata si rimanda a Pace & Salvan (1996, Cap. 9).

A.2.3 Inversione di serie di potenze per sostituzioni iterate

Il *metodo delle sostituzioni iterative* permette di isolare il termine di interesse da espansioni in cui esso compare ricorsivamente. La tecnica è illustrata nel caso univariato; l'applicazione al caso multivariato, impiegata nella derivazione dello sviluppo asintotico dell'errore di stima, è riportata nella Sezione 2.5.1. Sia $y = f(x)$, con $x \in \mathbb{R}$, una funzione regolare che ammette sviluppo in serie di potenze $y = a_0 + a_1x + a_2x^2 + a_3x^3$; si assuma senza perdita di generalità che $a_0 = 0$ e $a_1 = 1$, ottenendo

$$y = x + a_2x^2 + a_3x^3. \quad (\text{A.2})$$

Si richiede che $x = \mathcal{O}_p(n^{-\alpha})$ con $\alpha > 0$ e che i coefficienti siano costanti note, ovvero $a_i = \mathcal{O}(1)$ per $i = 2, 3, \dots$; risulta quindi che $x = y + \mathcal{O}_p(n^{-2\alpha})$. Un ulteriore

Tabella A.1: Ordini asintotici di quantità di verosimiglianza

<i>Quantità</i>	<i>Ordine Asintotico</i>
ℓ	$O_p(n)$
ℓ_r	$O_p(n^{1/2})$
ℓ_{R_n}	$O_p(n)$
i^{rs}	$O(n^{-1})$
$i_{rs} = -\nu_{rs}$	$O(n)$
ν_{R_n}	$O(n)$
$\nu_{rs,t}$	$O(n)$
H_{R_n}	$O_p(n^{1/2})$
$E(\ell_r \ell_s H_{tu})$	$O(n)$
$E(\ell_r \ell_s \ell_t H_{uv})$	$O(n^2)$
$i^{rs} \ell_r \ell_s$	$O_p(1)$

requisito per l'invertibilità nell'intorno $x = 0$ è che la derivata sia diversa da zero: poiché $f'(0) = 1$, la funzione $y = f(x)$ risulta invertibile con inversa $x = g(y)$.

Il procedimento si articola come segue: si esprime la (A.2) nella forma $x = y - a_2 x^2 - a_3 x^3$, si individua un ordine $\mathcal{O}_p(n^{-h\alpha})$ a cui approssimare la serie e si mantengono esclusivamente i termini con ordine di convergenza inferiore a quello specificato. Arrestandosi all'ordine $\mathcal{O}_p(n^{-4\alpha})$ si ottiene

$$\begin{aligned} x &= y - a_2(y - a_2 x^2)^2 - a_3 y^3 + \mathcal{O}_p(n^{-4\alpha}) \\ &= y - a_2 y^2 + 2a_2^2 y^3 - a_3 y^3 + \mathcal{O}_p(n^{-4\alpha}). \end{aligned}$$

Un approccio alternativo è basato sul *Teorema di Dini* della funzione implicita, per il quale si rimanda a [Pace & Salvan \(1996, Cap. 9\)](#).

A.3 Dimostrazioni del Capitolo 3

Dimostrazione del Lemma 3.1. Per ipotesi $A \geq B$ (con A e B diagonali) per ogni elemento, dunque esiste una matrice diagonale semidefinita positiva C tale che $A = B + C$; allora le matrici $X^T A X$, $X^T B X$ e $X^T C X$ sono anch'esse semidefinite positive per definizione. Applicando il teorema 9 [Magnus & Neudecker \(1999, Cap. 11\)](#), si ha $\lambda_k(B + C) \geq \lambda_k(B)$, quindi utilizzando il *Quoziente di Rayleigh*, per

qualsiasi matrice tale che $P^T P = I_{k-1}$, si ottiene

$$\begin{aligned}\lambda_k(A) &= \max_{P^T P = I_{k-1}} \min_{P^T x = 0} \frac{x^T (B + C)x}{x^T x} \\ &\geq \max_{P^T P = I_{k-1}} \min_{P^T x = 0} \left(\frac{x^T Bx}{x^T x} + \frac{x^T Cx}{x^T x} \right) \geq \lambda_k(B).\end{aligned}$$

□

Teorema A.1 (Teorema di Separazione di Poincaré). *Sia A una matrice simmetrica di dimensione $n \times n$ con autovalori ordinati $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$. Sia G una matrice semi-ortogonale di dimensione $n \times p$ (con $n \geq p$), tale che $G^T G = I_p$. Siano inoltre $\mu_1 \leq \mu_2 \leq \dots \leq \mu_p$ gli autovalori della matrice ridotta $G^T A G$ di dimensione $p \times p$. Allora vale la seguente disuguaglianza:*

$$\lambda_i \leq \mu_i \leq \lambda_{n-p+i} \quad \text{per } i = 1, 2, \dots, p.$$

Nel caso particolare unidimensionale in cui $p = 1$, la disuguaglianza si riduce alla nota relazione del Quoziente di Rayleigh, $\lambda_1 \leq (x^T A x)/(x^T x) \leq \lambda_n$.

Dimostrazione del Teorema A.1. Si definisca una matrice R di dimensione $n \times (i-1)$ le cui colonne coincidano con gli autovettori associati ai primi $i-1$ autovalori ordinati di $G^T A G$, allora si può definire λ_i usando Magnus & Neudecker (1999, Th. 7, Cap. 11) come:

$$\lambda_i = \min_{R^T x = 0} \frac{x^T A x}{x^T x},$$

dove la minimizzazione avviene su tutti i vettori $x \in \mathbb{R}^n$ non nulli ortogonali a R . Si consideri ora il vettore $x = Gy$ con $y \in \mathbb{R}^p$ e G matrice semi-ortogonale, tale per cui $G^T A G$ abbia autovalori $(s_1, \dots, s_k)$. Si impone un'ulteriore condizione sul vettore x , ovvero che $x = Gy$, da cui deriva immediatamente $R^T G y = 0$. Lo spazio generato dai vettori Gy rappresenta una restrizione (un sottospazio) del dominio originale, il che porta ad ottenere un minimo che è sicuramente maggiore o uguale a quello globale. Discende quindi la seguente disuguaglianza

$$\lambda_i = \min_{R^T x = 0} \frac{x^T A x}{x^T x} \leq \min_{R^T G y = 0} \frac{y^T (G^T A G) y}{y^T y} \leq \mu_i,$$

ovvero, il minimo ricercato su un sottospazio più piccolo deve essere maggiore o uguale a quello globale. Il sottospazio, in questo caso, è rappresentato da tutti i vettori $x \in \mathbb{R}^n$ ortogonali a R riscrivibili come Gy .

Lo stesso ragionamento può essere fatto con gli autovalori più grandi definendo la matrice T di dimensione $n \times (n - p + i - 1)$ contenente gli autovettori associati agli autovalori più grandi di A , per cui

$$\lambda_j = \max_{T^T x = 0} \frac{x^T A x}{x^T x} \geq \min_{T^T G y = 0} \frac{y^T (G^T A G) y}{y^T y} \geq \mu_{p-n+j}.$$

In conclusione, ponendo $j = n - p + i$ nell'ultima equazione si ottiene $\mu_i \leq \lambda_{n-p+i}$. $\square$

Corollario A.1. *Dall'ultima equazione della dimostrazione precedente si nota che, essendo il determinante di una matrice il prodotto dei suoi autovalori, la disuguaglianza può essere estesa al determinante delle matrici.*

Dimostrazione della disuguaglianza 3.6 (Magnus & Neudecker, 1999, Cap. 11, Th. 25).

Si richiama in via preliminare una disuguaglianza scalare: per ogni $\gamma \in (0, 1)$, la funzione $f(x) = x^\gamma$ è concava su $(0, \infty)$, pertanto il suo grafico giace al di sotto della retta tangente nel punto $x = 1$, ovvero

$$x^\gamma \leq \gamma x + (1 - \gamma), \quad \text{per ogni } x > 0. \quad (\text{A.3})$$

Siano ora A e B due matrici $p \times p$ simmetriche e definite positive e sia $\gamma \in (0, 1)$. Essendo B definita positiva, esiste la sua radice quadrata $B^{1/2}$ (con relativa inversa $B^{-1/2}$), il che permette di definire la matrice

$$C = B^{-1/2} A B^{-1/2},$$

anch'essa simmetrica e definita positiva: la simmetria è immediata, mentre la positività segue dal fatto che, per ogni $v \neq 0$, si ha $v^T C v = (B^{-1/2} v)^T A (B^{-1/2} v) > 0$, poiché A è definita positiva e $B^{-1/2} v \neq 0$.

Siano $\lambda_1, \dots, \lambda_p > 0$ gli autovalori di C . Applicando la disuguaglianza scalare (A.3) a ciascun autovalore e prendendo il prodotto su tutti gli indici, ricordando che il determinante di una matrice simmetrica è il prodotto dei suoi autovalori, si ottiene

$$|C|^\gamma = \prod_{t=1}^p \lambda_t^\gamma \leq \prod_{t=1}^p \{\gamma \lambda_t + (1 - \gamma)\}.$$

Si osservi ora che gli autovalori della matrice $\gamma C + (1 - \gamma)I_p$ sono esattamente $\gamma \lambda_t + (1 - \gamma)$, con $t = 1, \dots, p$; infatti la trasformazione lascia invariati gli autovettori di C e ne trasforma linearmente gli autovalori. Il membro di destra coincide dunque

con un determinante, e la disuguaglianza si riscrive come

$$|C|^\gamma \leq |\gamma C + (1 - \gamma)I_p|. \quad (\text{A.4})$$

Non resta che riesprimere la A.4 in termini delle matrici originarie. Sostituendo la definizione di C e sfruttando la regola di Binet sull'algebra del determinante, per il membro di sinistra si ha

$$|C|^\gamma = |B^{-1/2}AB^{-1/2}|^\gamma = \left(\frac{|A|}{|B|}\right)^\gamma,$$

mentre per quello di destra, raccogliendo $B^{-1/2}$ da entrambi i lati,

$$|\gamma C + (1 - \gamma)I_p| = |B^{-1/2}\{\gamma A + (1 - \gamma)B\}B^{-1/2}| = \frac{|\gamma A + (1 - \gamma)B|}{|B|}.$$

Sostituendo entrambe le espressioni nella A.4 e moltiplicando ambo i membri per $|B| > 0$, si ottiene

$$|A|^\gamma |B|^{1-\gamma} \leq |\gamma A + (1 - \gamma)B|,$$

che è la tesi. $\square$

Teorema A.2 (Teorema 7, Magnus & Neudecker). *Data una matrice simmetrica A con autovalori $\lambda_1 \leq \dots \leq \lambda_n$ e una matrice B di dimensione $n \times (k - 1)$, vale la seguente disuguaglianza*

$$\min_{B^T x=0} \frac{x^T A x}{x^T x} \leq \lambda_k.$$

Dimostrazione del Teorema A.2. Siano $s_1, \dots, s_k$ gli autovettori ortonormali associati ai primi k autovalori di A e si definisca la matrice $R = (s_1, \dots, s_k)$ che diagonalizza la matrice $R^T A R = \text{diag}(\lambda_1, \dots, \lambda_k)$. Il prodotto $B^T R$ ha dimensione $(k - 1) \times k$ quindi il rango è al più $k - 1$, per cui esiste un vettore non nullo $p \in \mathbb{R}^k$ tale che $B^T R p = 0$; scegliendo il vettore $x = R p$ si ottiene

$$\min_{B^T x=0} \frac{x^T A x}{x^T x} \leq \frac{p^T (R^T A R) p}{p^T p} \leq \lambda_k,$$

dove l'uguaglianza si verifica se il vettore p è il vettore della base canonica e_k . In tal caso, infatti, risulta $x = R p = s_k$, ovvero il vettore x coincide esattamente con l'autovettore corrispondente a λ_k . $\square$

A.3.1 Limite determinante matrice dei pesi

Si intende dimostrare che, per tutti i legami non canonici considerati (Probit, loglog, Complementary loglog e Cauchit), il limite della funzione peso al divergere del predittore lineare per $\eta \rightarrow +\infty$ è nullo.

Partendo dal legame Probit, l'equazione dei pesi è $\phi(\eta)^2 / \{\Phi(\eta)\{1 - \Phi(\eta)\}\}$, dove $\Phi(\cdot)$ è la funzione di ripartizione di una normale standard e $\phi(\cdot)$ la sua derivata (densità). Poiché $\lim_{\eta \rightarrow +\infty} \Phi(\eta) = 1$, il limite si riduce alla forma indeterminata $0/0$: $\lim_{\eta \rightarrow +\infty} \phi(\eta)^2 / \{1 - \Phi(\eta)\}$. Applicando il Teorema de L'Hôpital e ricordando le derivate $\phi'(\eta) = -\eta\phi(\eta)$ e $\Phi'(\eta) = \phi(\eta)$, il limite del rapporto delle derivate diviene $\lim_{\eta \rightarrow +\infty} [-2\eta\phi(\eta)^2] / [-\phi(\eta)]$. Semplificando, si ottiene $\lim_{\eta \rightarrow +\infty} 2\eta\phi(\eta)$. Poiché $\phi(\eta)$ contiene il termine esponenziale $e^{-\eta^2/2}$, per la gerarchia degli infiniti si dimostra immediatamente che il decadimento esponenziale domina la crescita lineare, portando il limite a 0.

Per quanto riguarda il legame loglog, la funzione peso assume la forma $\exp(-2\eta) / [\exp\{\exp(-\eta)\} - 1]$, il cui limite genera nuovamente la forma $0/0$. Effettuando la sostituzione $y = \exp(-\eta)$, poiché per $\eta \rightarrow +\infty$ si ha $y \rightarrow 0^+$, l'espressione si riconduce a $\lim_{y \rightarrow 0^+} y^2 / (e^y - 1)$. Applicando L'Hôpital e derivando rispetto a y , si ottiene $\lim_{y \rightarrow 0^+} 2y / e^y$. Sostituendo direttamente, il rapporto si riduce a $0/1$, confermando la convergenza asintotica a 0. Il procedimento per il Complementary loglog è del tutto analogo: tramite la sostituzione $y = \exp(\eta)$, il limite si risolve nel medesimo modo annullandosi.

Infine, per il legame Cauchit, il termine di peso è $1 / [(1 + \eta^2)^2 \{\pi^2/4 - \arctan(\eta)^2\}]$, il quale presenta a denominatore una forma indeterminata $\infty \cdot 0$. Riscrivendolo come rapporto $\lim_{\eta \rightarrow +\infty} (1 + \eta^2)^{-2} / \{\pi^2/4 - \arctan(\eta)^2\}$, si riottiene la forma $0/0$. Applicando L'Hôpital, il quoziente delle derivate diviene $\{-4\eta(1 + \eta^2)^{-3}\} / \{-2\arctan(\eta)(1 + \eta^2)^{-1}\}$. Semplificando i termini, il limite si riduce a $\lim_{\eta \rightarrow +\infty} 2\eta / \{(1 + \eta^2)^2 \arctan(\eta)\}$. Poiché per $\eta \rightarrow +\infty$ si ha $\arctan(\eta) \rightarrow \pi/2$ e la crescita del polinomio a denominatore domina strettamente quella del numeratore, anche in questo caso l'espressione converge a 0.

Teorema A.3 (Teorema 4, Magnus & Neudecker). *Sia A una matrice simmetrica di dimensione $n \times n$ con autovalori ordinati $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$. Allora vale la seguente disuguaglianza*

$$\lambda_1 \leq \frac{x^T A x}{x^T x} \leq \lambda_n.$$

Dimostrazione del Teorema A.3. Sia S la matrice che diagonalizza A , ovvero la matrice costituita dagli autovettori ortonormali $S^T A S = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$. Vale

quindi la seguente relazione

$$\lambda_1 y^T y \leq y^T \Lambda y \leq \lambda_n y^T y.$$

Si ponga ora $y = S^T x$, da cui segue

$$\lambda_1 x^T x \leq x^T A x \leq \lambda_n x^T x.$$

□

Nel caso considerato la matrice $I(\beta)$ dell'informazione attesa corrisponde ad A , mentre i vettori x_i rappresentano le osservazioni della matrice del disegno X . Da tale disuguaglianza discende l'equazione 3.16, che vincola il *leverage* ad essere strettamente positivo, garantendo la finitezza delle stime ad ogni iterazione.

A.3.2 Equivalenza del punto fisso con la formulazione a pseudo-dati

Una formulazione alternativa degli IWLS, originariamente proposta in Firth (1993) e poi ripresa in Kosmidis & Firth (2021b), vede la sostituzione nel passo di aggiornamento dei pesi originali $W^{(t)}$ con i pesi *corretti*, $\tilde{W}^{(t)} = \text{diag}(\tilde{m}_i^{(t)} w_i^{(t)})$, definiti nell'equazione (3.15), e la definizione di $\tilde{d} = \tilde{m}g(\eta)$. Il passo di aggiornamento diventa quindi

$$\beta^{(t+1)} = (X^T \tilde{W}^{(t)} X)^{-1} X^T \tilde{W}^{(t)} \tilde{z}^{(t)}, \quad (\text{A.5})$$

con *pseudo-risposte* $\tilde{z}^{(t)} = \eta^{(t)} + (\tilde{y}^{(t)} - \tilde{m}^{(t)} \pi^{(t)}) / \tilde{d}^{(t)}$.

Questa variante non coincide algebricamente con l'algoritmo di *quasi Fisher-scoring* presentato nella Sezione 3.6, ma si dimostra che il punto fisso resta invariato ed è sempre un algoritmo quasi-Newtoniano per cui valgono le condizioni di convergenza del teorema 3.4.

Punto fisso dell'algoritmo IWLS basato sugli pseudo-dati. Al punto fisso $\beta^{(t+1)} = \beta^{(t)} = \beta^*$, pre-moltiplicando entrambi i membri per la matrice $X^T \tilde{W} X$ (non singolare sotto le condizioni della Sottosezione 3.6.1) e sottraendo $X^T \tilde{W} X \beta^*$, si ottiene

$$0 = X^T \tilde{W} (\tilde{z} - X \beta^*) = X^T \tilde{W} \tilde{D}^{-1} (\tilde{y} - \tilde{m} \pi),$$

dove $\tilde{D} = \text{diag}(\tilde{d}_1, \dots, \tilde{d}_n)$ e tutte le quantità si intendono valutate in β^* .

Si osservi ora che il rapporto fra pesi e derivate non dipende dai totali: componente per componente si ha infatti

$$\frac{\tilde{w}_i}{\tilde{d}_i} = \frac{\tilde{m}_i g(\eta_i)^2 / \{G(\eta_i)(1 - G(\eta_i))\}}{\tilde{m}_i g(\eta_i)} = \frac{g(\eta_i)}{G(\eta_i)(1 - G(\eta_i))} = \frac{w_i}{d_i},$$

poiché il fattore $\tilde{m}_i$ si semplifica; la matrice $\tilde{W}\tilde{D}^{-1}$ coincide con quella classica WD^{-1} (1.12). Dato che i termini dipendenti dalla funzione c si elidono esattamente, come anticipato nella Sottosezione 3.6.1, la condizione di stazionarietà assume la forma

$$0 = \sum_{i=1}^n \frac{w_i}{d_i} \left\{ y_i - m_i \pi_i + 2ah_i \left(q_i - \frac{1}{2} \right) \right\} x_{ir}, \quad r = 1, \dots, p.$$

Si osserva come essa coincida con l'equazione dello *score penalizzato* (3.9): il punto fisso β^* annulla correttamente $U^*(\beta^*)$. $\square$

Esistenza dei passi di Wolfe. Si ponga $\phi(\delta) = \ell^*(\beta^{(t)} + \delta p^{(t)})$, limitata superiormente per $\delta > 0$. Poiché $c_1 \in (0, 1)$ e la pendenza $c_1 U^*(\beta^{(t)})^T p^{(t)}$ è positiva, la retta $\ell(\delta) = \ell^*(\beta^{(t)}) + \delta c_1 U^*(\beta^{(t)})^T p^{(t)}$ deve intersecare il grafico di ϕ almeno una volta; dunque esiste un δ che rispetti la condizione di Armijo (3.19a). Sia δ' il suo più piccolo valore maggiore di zero per cui

$$\ell^*(\beta^{(t)} + \delta' p^{(t)}) = \ell^*(\beta^{(t)}) + \delta' c_1 U^*(\beta^{(t)})^T p^{(t)},$$

e dunque, la condizione (3.19a) vale per ogni passo minore di δ' . Applicando il Teorema del valor medio esiste $\delta'' \in (0, \delta')$ tale che

$$\ell^*(\beta^{(t)} + \delta' p^{(t)}) - \ell^*(\beta^{(t)}) = \delta' U^*(\beta^{(t)} + \delta'' p^{(t)})^T p^{(t)}.$$

In definitiva, combinando le due relazioni, e ricordando che $c_1 < c_2$ con $U^*(\beta^{(t)})^T p^{(t)} > 0$, si ottiene

$$U^*(\beta^{(t)} + \delta'' p^{(t)})^T p^{(t)} = c_1 U^*(\beta^{(t)})^T p^{(t)} < c_2 U^*(\beta^{(t)})^T p^{(t)},$$

cosciché δ'' rispetta entrambe le condizioni 3.19 con disuguaglianze strette. Infine, per la regolarità di ℓ^* (continua e differenziabile con derivate continue), esiste un intorno non vuoto di δ'' in cui le condizioni continuano a valere. $\square$

Teorema di Zoutendijk per la convergenza. Dalla condizione di curvatura (3.19b) e dall'equazione del metodo (3.17) si ricava

$$\left\{U^*(\beta^{(t+1)}) - U^*(\beta^{(t)})\right\}^T p^{(t)} \leq (c_2 - 1) U^*(\beta^{(t)})^T p^{(t)},$$

mentre la condizione di Lipschitz implica

$$\left\{U^*(\beta^{(t+1)}) - U^*(\beta^{(t)})\right\}^T p^{(t)} \geq -\delta_t L \|p^{(t)}\|^2.$$

Combinando le due relazioni, e ricordando che $U^*(\beta^{(t)})^T p^{(t)} > 0$ con $c_2 < 1$, si ottiene una limitazione inferiore per il passo,

$$\delta_t \geq \frac{1 - c_2}{L} \frac{U^*(\beta^{(t)})^T p^{(t)}}{\|p^{(t)}\|^2}.$$

Sostituendo questa disuguaglianza nella condizione di Armijo (3.19a) si ha

$$\ell^*(\beta^{(t+1)}) \geq \ell^*(\beta^{(t)}) + c_1 \frac{1 - c_2}{L} \frac{\left(U^*(\beta^{(t)})^T p^{(t)}\right)^2}{\|p^{(t)}\|^2},$$

che, riconosciuta la definizione (3.20), si riscrive come

$$\ell^*(\beta^{(t+1)}) \geq \ell^*(\beta^{(t)}) + c \cos^2 \theta_t \|U^*(\beta^{(t)})\|^2, \quad c = \frac{c_1(1 - c_2)}{L}.$$

Applicando in modo ricorsivo la disuguaglianza su tutti gli indici fino a t , si ottiene

$$\ell^*(\beta^{(t+1)}) \geq \ell^*(\beta^{(0)}) + c \sum_{j=0}^t \cos^2 \theta_j \|U^*(\beta^{(j)})\|^2.$$

Poiché ℓ^* è limitata superiormente, la differenza $\ell^*(\beta^{(t+1)}) - \ell^*(\beta^{(0)})$ resta inferiore a una costante positiva per ogni t ; passando al limite si conclude che la serie converge (3.21). $\square$

A.3.3 Commento esperimento contrazione stime 3.4

Due aspetti dei risultati relativi al legame cloglog meritano un commento specifico. In primo luogo, l'elevata frequenza di fallimenti della stima di massima verosimiglianza (260 repliche su 1000 per $n = 10$) è una conseguenza diretta dell'esperimento, infatti, a parità di coefficiente, fissato pari a $\beta = 0.8$, e estraendo i dati da una normale standard, l'asimmetria della funzione cloglog concentra le probabilità vere

verso l'unità; già in $\eta = 0$ si ha $\pi = 1 - e^{-1} \approx 0.632$. Per questa ragione i campioni generati presentano con maggiore frequenza sequenze di soli successi, il che genera condizioni di separazione o quasi-separazione trattate nella Sezione 2.6 molto più spesso di quanto avvenga per i legami simmetrici. L'esperimento con i diversi legami a parità di β non va letto come confronto. Lo stesso valore del coefficiente corrisponde, su scale di legame diverse, a relazioni differenti nella scala delle probabilità.

Il secondo aspetto, strettamente legato al primo, è la distorsione apparentemente ridotta dello stimatore di massima verosimiglianza per il legame cloglog (-0.013 , a fronte di 0.350 per il logit). Tale valore non va interpretato come una minore distorsione generale del legame, infatti le statistiche sono calcolate sulle sole repliche in cui la stima esiste finita. Per quanto detto al punto precedente però, le repliche escluse non sono di natura casuale, ma coincidono con i campioni più sbilanciati, quelli per cui la stima avrebbe assunto i valori più estremi e probabilmente con un errore di stima maggiore. Questo argomento rafforza la conclusione centrale del capitolo: le stime ottenute tramite correzione di Firth risultano avere una distorsione confrontabile per il legame cloglog e migliore per gli altri legami, nonostante comprenda anche i dataset più sbilanciati (solo 14 repliche sono fallite per ragioni numeriche).

Bibliografia

- AGRESTI, A. (2013). *Categorical Data Analysis*. Hoboken, New Jersey: John Wiley & Sons, 3rd ed.
- AGRESTI, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley Series in Probability and Statistics. Hoboken, New Jersey: John Wiley & Sons.
- ALBERT, A. & ANDERSON, J. A. (1984). On the existence of maximum likelihood estimates in logistic regression models. *Biometrika* **71**, 1–10.
- AMBROSIO, L., DA PRATO, G. & MENNUCCI, A. (2011). *Introduction to Measure Theory and Integration*, vol. 12 of *Lecture Notes (Scuola Normale Superiore)*. Pisa: Edizioni della Normale.
- ARMIJO, L. (1966). Minimization of functions having Lipschitz continuous first partial derivatives. *Pacific Journal of Mathematics* **16**, 1–3.
- AZZALINI, A. (2008). *Inferenza Statistica*. Springer Verlag.
- BLISS, C. I. (1935). The calculation of the dosage-mortality curve. *Annals of Applied Biology* **22**, 134–167.
- CASELLA, G. & BERGER, R. L. (2002). *Statistical Inference*, vol. 2. Belmont, CA: Duxbury Pacific Grove, CA, 2nd ed.
- CHARALAMBIDES, C. A. (2005). *Combinatorial Methods in Discrete Distributions*. Wiley Series in Probability and Statistics. John Wiley & Sons.
- CORDEIRO, G. M. & MCCULLAGH, P. (1991). Bias correction in generalized linear models. *Journal of the Royal Statistical Society: Series B (Methodological)* **53**, 629–643.
- COX, D. R. & SNELL, E. J. (1968). A general definition of residuals. *Journal of the Royal Statistical Society. Series B (Methodological)* **30**, 248–275.

- DENNIS, JR., J. E. & SCHNABEL, R. B. (1996). *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, vol. 16 of *Classics in Applied Mathematics*. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics.
- EFRON, B. (1982). *The jackknife, the bootstrap and other resampling plans*. SIAM.
- FIRTH, D. (1993). Bias reduction of maximum likelihood estimates. *Biometrika*, 27–38.
- FISHER, R. A. (1922). On the mathematical foundations of theoretical statistics. *Philosophical transactions of the Royal Society of London. Series A, containing papers of a mathematical or physical character* **222**, 309–368.
- FISHER, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of eugenics* **7**, 179–188.
- JEFFREYS, H. (1961). *Theory of Probability*. Oxford University Press, Oxford, 3rd ed.
- JØRGENSEN, B. (1997). *The Theory of Dispersion Models*. Chapman & Hall/CRC Monographs on Statistics & Applied Probability. CRC Press.
- KOSMIDIS, I. (2009). On iterative adjustment of responses for the reduction of bias in binary regression models. CRiSM Working Paper Series 09-36, University of Warwick, Department of Statistics.
- KOSMIDIS, I. & FIRTH, D. (2009). Bias reduction in exponential family nonlinear models. *Biometrika* **96**, 793–804.
- KOSMIDIS, I. & FIRTH, D. (2010). A generic algorithm for reducing bias in parametric estimation .
- KOSMIDIS, I. & FIRTH, D. (2021a). Jeffreys-prior penalty, finiteness and shrinkage in binomial-response generalized linear models. *Biometrika* **108**, 71–82.
- KOSMIDIS, I. & FIRTH, D. (2021b). Supplementary material to “Jeffreys-prior penalty, finiteness and shrinkage in binomial-response generalized linear models”. Biometrika Online Supplementary Material. Available at Biometrika website.
- KOSMIDIS, I., KENNE PAGUI, E. C. & SARTORI, N. (2020). Mean and median bias reduction in generalized linear models. *Statistics and Computing* **30**, 43–59.

- MAGNUS, J. R. & NEUDECKER, H. (1999). *Matrix Differential Calculus with Applications in Statistics and Econometrics*. Chichester: John Wiley & Sons, revised ed.
- MCCULLAGH, P. (1987). *Tensor Methods in Statistics*. London: Chapman and Hall/CRC.
- MCCULLAGH, P. & NELDER, J. A. (1989). *Generalized linear models*. Chapman e Hall.
- MORRIS, C. N. (1982). Natural exponential families with quadratic variance functions. *The Annals of Statistics* , 65–80.
- NOCEDAL, J. & WRIGHT, S. J. (2006). *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. New York: Springer, 2nd ed.
- PACE, L. & SALVAN, A. (1996). *Teoria della Statistica: Metodi, modelli, approssimazioni asintotiche*. Cedam.
- PACE, L. & SALVAN, A. (2001). *Introduzione alla statistica II*. Cedam.
- PAGANI, C. D. & SALSA, S. (2015). *Analisi Matematica 1*. Bologna: Zanichelli, 2nd ed.
- PEARSON, K. (1894). Iii. contributions to the mathematical theory of evolution. *Proceedings of the Royal Society of London* **54**, 329–333.
- QUARTERONI, A., SACCO, R. & SALERI, F. (2014). *Matematica Numerica*. Milano: Springer Milan, 4th ed.
- QUENOUILLE, M. H. (1956). Notes on bias in estimation. *Biometrika* **43**, 353–360.
- RIGON, T. (2021). Statistical inference.
- RIGON, T. (2025). Generalized linear models.
- RIGON, T. & ALIVERTI, E. (2023). Conjugate priors and bias reduction for logistic regression models. *Statistics & Probability Letters* **202**, 109901.
- ROBERT, C. P. (2001). *The Bayesian Choice: From Decision-Theoretic Foundations to Computational Implementation*. Springer Texts in Statistics. Springer New York, 2nd ed.

- RUSO, A. (2026). Note del corso di calcolo numerico. Dispense universitarie non pubblicate, aggiornate annualmente.
- SILVAPULLE, M. J. (1981). On the existence of maximum likelihood estimators for the binomial response models. *Journal of the Royal Statistical Society. Series B (Methodological)*, 310–313.
- STOCK, J. H. & WATSON, M. W. (2005). *Introduzione all'econometria*. Milano: Pearson-Prentice Hall, 1st ed.
- TUKEY, J. W. (1958). Bias and confidence in not quite large samples. *The Annals of Mathematical Statistics* **29**, 614–614.
- WOLFE, P. (1971). Convergence conditions for ascent methods II: Some corrections. *SIAM Review* **13**, 185–188.